



学校代码: 10272

学 号: 2019311070

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS
博 士 学 位 论 文
DOCTORAL DISSERTATION

因果推断视角下自然语言处理任务中的虚
假相关性研究

论文作者 韩明月

院（系所）	信息管理与工程学院
专 业	金融信息工程
指导教师	王英林 教授
完成日期	2023 年 5 月

因果推断视角下自然语言处理任务中的虚假相关性

摘要

现有机器学习的核心思想是寻找输入特征与输出结果的相关性，以建立两者间的映射关系。机器学习以训练样本数据与实际应用场景数据独立同分布为基本假设，从训练过程中寻找输入数据中对预测目标有帮助的线索（输入数据的特征），以实现模型在测试集上的效果提升。然而，在真实场景下这种独立同分布的假设并不成立，因此，模型往往会在分布外数据集上产生诸多预测错误。借鉴因果推断工具来分析模型分布外泛化能力差的现象，可以为设计自然语言处理任务的稳健性学习方法提供新的视角。由于混杂因子的存在（比如：数据选择偏好），训练数据集中的某些特征与预测目标的相关性往往是被错估的，当数据选择偏好改变时，这类特征与目标之间的相关性也会发生变化，呈现出不稳定性，因此被称为虚假相关性特征。基于虚假相关性特征的机器学习模型稳健性能差、可信性不足，难以被金融、医疗等高风险领域的关键应用场景所接受。此外，当模型所学到的虚假相关性特征（线索）与人类身份属性有关时，模型则有可能会传播乃至放大现实生活中的“偏见”，存在一定的负面社会性影响。

本文在综合分析已有文献的基础上，借鉴因果推断理论，从因果图角度来刻画数据生成过程，分别从发现和缓解自然语言处理任务中的虚假相关性两个方面展开研究工作。主要研究内容和创新性工作如下：

（1）常识因果推理任务中的虚假线索探索与分析。为揭示深度学习方法拟合数据中的虚假相关性这一现象，本文选取常识因果推理任务（COPA 任务）作为研究对象，观察基于预训练语言模型微调的常识因果推理系统的脆弱性程度。不同于以往使用可统计线索对常识因果推理模型脆弱性的研究方法，本文探索并发现了在该任务上存在的一个抽象虚假相关性线索：语义相似性。该线索在文本中并未显式呈现，因此不易被发现。通过设置两种干扰实验（前提干扰和问题类型掩盖）测试了基于知识库和基于预训练微调的常识因果推理模型的表现，验证了预训练语言模型对语义相似性的过度依赖假设，并对先前工作中的去偏模型进行测试，实验结果表明针对特定线索制定的缓解方案在新的对抗测试集中所展现出的脆弱程度可能会更严重。

(2) 针对常识因果推理模型中存在的语义相似性虚假线索, 提出了基于反事实约束的去偏方法。现有对常识因果推理模型的去偏方法是针对词分布线索设计的, 这种方法可能导致模型加强对其它浅层线索的依赖。此外, 目前对常识因果推理模型脆弱性的评估仅针对词线索而设计, 对模型推理能力的脆弱性评估不够全面。为此, 本文提出了基于反事实约束的改进方案, 在原有训练损失的基础上增加了一个反事实惩罚项, 该方案降低了模型对语义相似的依赖程度, 并且改进的模型在保持原有预测水平的基础上, 在针对词分布线索的对抗测试集上表现也更加稳健; 此外, 本文设计并构建了一个既可以评估模型对词分布依赖程度, 又可以评估模型是否依赖语义相似线索的挑战测试集 BCOPA-CE, 为衡量模型在该任务上的稳健性能提供了有效标准。

(3) 针对歧视言论检测模型中存在的与身份属性相关的虚假线索, 提出了基于身份核心型样本过滤策略的公平性方案。针对歧视言论检测任务中的非预期偏见问题, 主流去偏方法的目标是使得模型学习到的表示向量与身份信息尽可能无关。然而, 与群体刻板印象相关的歧视言论样本, 其核心情感由身份属性词表现出来, 上下文本身无明显情感贡献。对这种类型样本去偏会使模型对歧视言论的捕捉能力变弱, 在此类样本的对抗样本上呈现出过高的误判率。为此, 本文提出身份核心型样本过滤机制, 借鉴因果推断领域中的条件因果效应概念来刻画样本中的身份信息是否属于核心情感贡献词, 在不同的去偏方法上实施该过滤策略, 实验结果表明改进后的模型在保证 IID 预测能力和去偏能力的同时, 提高了模型在身份核心型样本下的识别准确率。

(4) 针对未知虚假线索情况下分布外泛化能力较差的难题, 提出了一种基于因果干预的模型稳健性增强方案。在许多任务场景下, 虚假线索往往是未知的, 此时设计能捕捉到因果特征的模型尤为重要。现有研究通过反事实增强和域泛化的方式来实现模型对因果特征的学习, 但仍面临反事实生成质量不高、多领域的数据要求难以满足等挑战。本文针对未知虚假线索情况下的情感分类任务, 提出了一种模型稳健性增强方法。该方法在没有域标签情况下, 将文本主题作为混杂因子, 从微观的域(不同主题)出发, 建立因果图假设, 基于后门调整技术对干预概率进行建模, 捕获输入文本的潜在语义特征到目标变量之间的因果相关性, 缓解模型对未知虚假线索的依赖。将所提方法分别在因果词扰动攻击型对抗样本(电影评论文本)和同义词扰动攻击型对抗样本(金融新闻文本)两个公开数据集上进行了实验, 结果表明该方法能够提升情感分类模型的稳健性能, 尤其

是长文本分类任务。

综上所述，本文以因果推断为视角，对基于深度学习方法所建立的自然语言处理模型所面临的虚假相关问题进行了较为深入的创新性研究和探索，尝试从已知虚假线索和未知虚假线索的角度对虚假相关性提供去偏方法，为提高自然语言处理模型的分布外泛化性能提供了有效途径。

关键词： 自然语言处理，虚假相关，因果推断，分布外泛化，算法公平，稳健性

Spurious Correlation in Natural Language Processing Tasks from the Perspective of Causal Inference

Abstract

The core of the existing machine learning models is correlation-based learning, which is effective under the assumption of independent and identical distribution (IID). The algorithms recklessly absorbing all the correlations found in training data, which can improve the performance on the IID test set, is statistically correct. However, the assumption of IID is usually violated in real life. Utilizing the causal inference tools to analyze the poor generalization ability of the models in the out-of-distribution (OOD) setting can provide a new perspective for designing robust methods for natural language processing tasks. Due to the existence of the confounder, some features utilized by the models are likely to have an unreasonable correlation with the target, so they present an unstable prediction if the dataset shifts, which is also known as spurious correlation. The correlation between the clues that are helpful for the prediction in the IID setting and the target may change greatly under the new distribution. Therefore, the model often shows a significant drop on the performance on the OOD test set, which hinders the application and promotion of the model in real life, especially in high-risk domains, such as in the fields of finance and medicine. In addition, when the clues exploited by the model are related to the demographic identity attributes, the model may spread or even amplify the "bias" in real life, which has negative social impacts.

This paper explains the data generation process and elaborates on the possible changes in the correlation between the features and the target in data from the perspective of the causal graphs. The research on spurious correlation in natural language processing tasks from the two steps of investigation and mitigation. The main contents of this paper are as follows:

(1) The exploration and analysis of the spurious cues in the commonsense causal reasoning tasks.

To reveal the phenomenon in which deep learning methods might capture the spurious correlation in the training data, this paper selects the commonsense causal

reasoning task (COPA task) as the research object to observe the vulnerability of the pre-trained language models (PLMs). Different from the previous work that used statistical clues to investigate the vulnerability of a commonsense causal reasoning model, this paper explores an abstract spurious clue in this task, semantic similarity. This clue is not explicitly presented in the text, which is not easy to identify. By conducting two different perturbation experiments—premise perturbation and question type masking, this paper evaluates the vulnerability of both the knowledge-based models and fine-tuned pre-trained language models. The experimental result verifies the assumption of over-dependence of the PLMs on semantic similarity. This paper also evaluates the de-biased model proposed in previous work, which focuses on token distribution. The experimental result shows that the mitigation solution developed for some specific clue might be more vulnerable in the new adversarial test set which is designed against another clue.

(2) The counterfactual constraint method for reducing the semantic similarity bias in the commonsense reasoning models

The current de-biased methods for the commonsense causal reasoning task are designed to address unbalanced token distribution, which may inadvertently increase the model's dependence on another spurious clue. Moreover, the current vulnerability evaluation of commonsense causal reasoning models focuses on the token distribution only, which is not comprehensive enough. Therefore, this paper proposes an improved method based on the counterfactual constraint. This method introduces a penalty to reduce the dependence of the model on semantic similarity. The proposed model defends the model from the semantic similarity attacking and is also more robust on the COPA-test-hard set, which has unbiased token distribution. Additionally, this paper introduces a challenging test set called BCOPA-CE, which can evaluate the ability of a system to distinguish the cause and effect and to choose cause or effect under unbiased token distribution.

(3) The identity-cored samples filtering strategy for the fairness problem in the discrimination text classification

For the fairness problem in the discrimination text detection, the goal of the existing debiasing methods is to make the representations of the input sentences as independent

of the sensitive identity information as possible. However, this rule is not in line with the real-world setting. There are some samples whose sentimental information comes from the stereotypes associated with specific identity groups which are expressed by the identity words, while the contexts have no obvious sentimental contributions. Applying debiasing techniques to such examples could weaken the ability of the model to detect discriminatory statements, and will lead to a high FPR on the adversarial samples of this type of samples. Motivated by this concern, this paper proposes an identity-cored samples filtering mechanism. It leverages the concept of conditional causal effect from the field of causal inference to determine whether the identity information in a sample expresses the sentiment. We implement the filtering mechanism on the different debiasing methods. The experimental results show that the model can improve the accuracy on the identity-cored samples while preserving the IID prediction ability and debiasing ability.

(4) Robust sentiment classification without specific spurious clues based on causal intervention mechanism

When dealing with unknown spurious clues, designing a model that can capture causal features becomes crucial. Existing methods promote the models to capture causal features through counterfactual samples augmentation and domain generalization. However, those methods still face the challenges due to the low quality of counterfactual generation and the difficulty in meeting data requirements of multiple domains. To improve the robustness of the models with unknown spurious clues, this paper proposes an improved method. In the absence of domain labels, taking the topic of the text as a confounder and establishing a causal graph, this method fits the causal correlation between the representations and the target through the backdoor adjustment, and so as to alleviate the dependence of the model on unknown spurious clues. The proposed method is evaluated on the out-of-distribution adversarial set (movie review text) and the challenging test set with synonym perturbation (financial news text) proposed in the previous work. The experimental results show that the proposed method can improve the robustness of the text classification task in these two attacks, especially in the case of the long text.

In summary, this paper presents in-depth and innovative research on the spurious

correlation utilized by deep learning models in natural language processing tasks from the perspective of the causal inference. It explores de-biased methods from both the settings of known spurious clues and unknown spurious clues, providing some effective ways to improve the OOD generalization of the deep learning models in natural language processing tasks.

Key words: Natural Language Processing, Spurious Correlation, Causal Inference, Out-of-Distribution Generalization, Algorithm Fairness, Robustness

目 录

第一章 绪论.....	1
第一节 研究背景.....	1
一、 自然语言处理任务中的虚假相关性.....	2
二、 因果相关特征与虚假相关特征.....	3
三、 依赖虚假相关线索引发的公平性问题	6
四、 依赖虚假相关线索引发的稳健性问题	8
第二节 研究问题及内容.....	10
一、 常识因果推理任务中的虚假线索探索与分析	11
二、 已知虚假线索情况下的自然语言处理模型去偏方法	11
三、 未知虚假线索情况下自然语言处理模型的稳健性增强方法	14
四、 术语含义解释.....	15
第三节 研究意义.....	17
一、 学术价值.....	17
二、 应用价值.....	18
第四节 创新点及整体框架.....	19
第五节 本章小结.....	21
第二章 文献综述	22
第一节 虚假相关性识别技术研究综述	22
一、 基于数据发现的方法.....	22
二、 基于模型的探索方法.....	24
第二节 虚假线索依赖缓解技术研究综述	26
一、 已知虚假线索下的缓解技术研究.....	26
二、 未知虚假线索下的因果学习技术.....	29
第三节 本章小结.....	33
第三章 常识因果推理任务中的语义相似偏差现象分析	34
第一节 引言.....	34
第二节 相关工作.....	35
一、 常识因果推理方法.....	35
二、 自然语言推理任务中的虚假相关性.....	36
第三节 语义相似偏差假设.....	36
一、 COPA 任务介绍及基本模型框架	36
二、 COPA 任务中的偏差现象	38
第四节 干扰实验及结果分析	40

一、 实验一:前提为干扰选项.....	40
二、 实验二:掩盖问题类型.....	41
三、 对比模型介绍.....	42
四、 实验部分.....	46
五、 结果与分析.....	47
第五节 本章小结.....	49
第四章 基于反事实约束去偏的常识因果推理模型	50
第一节 引言.....	50
第二节 改进模型.....	51
一、 COPA 任务	51
二、 词偏差与语义偏差.....	52
三、 反事实约束损失.....	52
第三节 BCOPA-CE 数据集	53
一、 数据集介绍.....	53
二、 标注指导.....	54
三、 质量评估.....	54
第四节 实验及结果分析.....	55
一、 数据集介绍.....	55
二、 对比模型.....	56
三、 实验设置.....	56
四、 结果与分析.....	56
第五节 本章小结.....	59
第五章 基于样本过滤机制去偏的歧视言论检测模型	60
第一节 引言.....	60
第二节 条件因果效应计算.....	62
一、 潜在因果框架.....	62
二、 基于 T-Learner 的 CATE 计算方法.....	63
第三节 改进去偏方法.....	64
一、 问题形式化.....	64
二、 去偏步骤.....	66
第四节 实验部分.....	68
一、 数据集使用.....	68
二、 对比模型介绍.....	69
三、 实验设置.....	71
四、 实验结果及分析.....	71
第五节 本章小结.....	75
第六章 基于因果干预的稳健情感分类模型	77
第一节 引言.....	77

第二节 相关工作.....	78
一、反事实样本增强.....	78
二、因果特征学习.....	79
第三节 基于后门调整的情感分析模型	80
一、主题混杂假设.....	80
二、两种不同的相关性.....	81
三、Do 算子分布变换的理解.....	83
四、主题去混杂学习.....	84
第四节 实验部分.....	86
一、数据集介绍.....	86
二、对比模型介绍.....	88
三、实验设置.....	91
四、实验结果及分析.....	91
第五节 本章小结.....	96
第七章 结论与展望	97
第一节 全文总结.....	97
一、常识因果推理任务中的虚假线索探索与分析	97
二、已知虚假线索情况下的自然语言处理模型去偏方法	98
三、未知虚假线索情况下自然语言处理模型的稳健性增强方法	99
第二节 研究展望.....	100
一、偏差之间的关联问题.....	100
二、自动识别偏差线索	100
三、自动学习混杂表示.....	101
四、低资源反事实标注样本的有效利用方法	101
参考文献.....	102

表格目录

表 1-1 不同变量在不同任务中的可能含义	5
表 1-2 研究问题界定	17
表 3-1 一个 BERT 预测失败的验证集样本	39
表 3-2 不同预训练语言模型对比	46
表 3-3 不同推理模型在干扰实验下的表现	48
表 4-1 BCOPA-CE 样本示例	53
表 4-2 生成数据集质量的人类评估结果	55
表 4-3 不同模型在挑战测试集上的实验结果	57
表 4-4 错误样本分析	57
表 5-1 本章对于样本类型的定义	61
表 5-2 两种类型的样本示例及其变量表示	65
表 5-3 因果推断问题中的术语与文本分类任务的映射关系	65
表 5-4 潜在结果的取值	67
表 5-5 数据集介绍	68
表 5-6 无偏测试集的生成模板介绍	69
表 5-7 AMI 数据集的去偏表现	72
表 5-8 ST 数据集的去偏表现	72
表 5-9 去偏模型在反事实样本测试集上的表现	74
表 6-1 逻辑回归模型中对情感影响系数较大的单词	81
表 6-2 假设例子中的相关分布	82
表 6-3 前文假设例子在后门调整后的数据分布	84
表 6-4 数据集介绍	87
表 6-5 电影评论 IMDB 数据集上各模型的表现	92
表 6-6 FPB 数据集上各模型的表现	94
表 6-7 主题预测情感的表现	95

图目录

图 1-1 呈现虚假相关现象的子 (Messerli, 2012)	4
图 1-2 巧克力销量与诺奖人数的因果图	4
图 1-3 适用于常见任务的因果图	5
图 1-4 算法公平性问题因果图	7
图 1-5 模型稳健性问题的因果图解释	9
图 1-6 论文整体逻辑框架	20
图 3-1 预训练语言模型在 COPA 任务上的基本框架	37
图 3-2 语义相似线索与预测目标呈现虚假关联的因果图 (以原因问题为例)	39
图 3-3 基于知识库进行尝试因果推理的流程	42
图 3-4 Transformer 模块的网络架构	45
图 4-1 词重要程度的可视化	58
图 5-1 T-Learner 介绍	63
图 5-2 EAR 模型框架示意图	70
图 5-3 不同身份词所在样本在三个模型中的 AUC 值	73
图 6-1 情感分析任务因果图假设	77
图 6-2 后门调整后的因果图表示	83
图 6-3 基于因果干预的情感分类模型	85
图 6-4 GRU 门控机制示意图	89
图 6-5 GRU-attention 模型示意图	89
图 6-6 分布外测试集对因果路径的阻断	93
图 6-7 注意力均值可视化	95

第一章 绪论

第一节 研究背景

近年来，由数据驱动的深度学习算法，在自然语言推理、计算机视觉、生物信息等诸多领域取得了卓越进展，在相关任务上的表现甚至可以超越人类水平，相关技术也应用在实际产品上，比如：在社交媒体领域，Twitter 利用机器学习技术识别和打击存在恶意言论的用户，帮助遏制网络暴力；在医学领域，利用图像分类、图像分割等医学影像技术为医生提供辅助的判断依据；在金融经济领域，使用新闻文本分析来近似市场情绪的变化。随着算法技术和人类生活日渐相关，深度学习系统在实际应用中的可靠性也逐渐受到学术界和工业界的关注。

现有模型的核心是关联性学习，通过改进算法，可以在已有数据集上得到有效提升，然而，这些算法以独立同分布为假设基础，而该假设在应用场景中往往不成立。比如：数据集分布随着时间发生了变化，或者缺乏标注数据集的领域与之前有标注数据集的领域分布不同。

当模型以提升预测水平为目标，尽管在独立同分布的测试集上表现优异，却易捕捉数据表面的虚假关联（预测捷径），比如，在某些自然语言处理任务背景下，由于选择偏差的存在，句子长度、敏感属性、特定单词，或语法结构等线索与标签可能存在较强的相关性。过度依赖虚假相关性线索的模型会产生两个后果：（1）在涉及到人口属性等敏感信息的任务上产生负面社会影响，虚假线索的出现会导致模型对特定群体产生非预期的偏见（T. Wang 等人，2022a），即公平性问题；（2）在分布外的测试集上表现不好，模型预测会被微小的扰动所干扰，即稳健性问题。

随着自然语言处理（Natural Language Processing, NLP）模型在现实场景中的应用深度与广度不断增加，我们对模型的预测水平也有着更高的要求。首先，当 NLP 技术的应用场景与“人口群体”相关时，除了对模型预测准确率的要求之外，我们期待模型尽可能地做出公平的预测。比如，自然语言处理技术被广泛应用于简历自动筛选以及社交媒体歧视言论检测等任务中。在简历自动筛选任务中，不少公司为了提高招聘效率，利用算法对简历进行初步筛选。由于过往招聘过程中存在歧视现象或其它原因，导致训练数据集对于敏感属性信息（性别、

种族等)存在选择偏差,那么基于该数据集训练后的模型很可能以敏感属性信息为预测依据。在真实应用场景下,如果模型根据其敏感属性信息来判断求职者是否通过筛选,将会导致“不公平”的选拔过程。类似地,在社交媒体言论检测应用场景中,社交平台利用算法过滤恶意言论或限制发布者的活动,从而维护社交媒体平台的秩序和公共空间的健康发展。若该算法的识别依赖于对敏感属性信息的捕捉,那么恶意言论在某些群体中更容易被忽视或误判,这会对社交媒体平台的公信力产生负面影响。其次,当 NLP 技术的应用场景受限于低资源或试错成本高昂等条件时,除了对模型预测准确率的要求之外,我们期待模型尽可能地做出稳定的预测。比如,公司通过情感分析了解用户对产品的真实评价,用来训练模型的标注数据集与用来测试模型的数据集可能来自不同的地区,存在分布差异,因此,在原有地区数据集上训练的模型在新地区数据上的测试效果不佳。研究 NLP 中的稳健性问题可以提高市场研究的准确性和可靠性,为决策者提供更全面的决策参考。

一、自然语言处理任务中的虚假相关性

随着预训练语言模型的提出,从大规模语料中学习上下文语义表示,以特征抽取或微调的方式辅助下游任务的训练,已成为解决自然语言处理任务的通用范式。深度学习算法在诸多自然语言处理任务中取得了令人满意的预测效果,在一些任务上甚至超越了人类的表现。比如,在常识因果推理任务(Choice of Plausible Alternatives, COPA)中,预训练语言模型 DeBERTa (He 等人, 2020)达到了 98.4% 的准确率,表现惊人,但这并不意味着模型具有了常识因果推理能力。任务复杂性及其对世界知识的要求暗示着预训练语言模型所展现出的因果推理能力可能是被高估的。因此,最近有很多研究者关注自然语言处理任务中的虚假相关性问题。Kavumba 等(2019)曾指出,训练集中的某些单词在不同类别标签之间的分布是不同的,模型可能捕捉到这一虚假线索,实验结果发现,向模型只输入两个答案选项,不输入前提时,模型依然能以超出随机水平的概率做出正确预测。类似地,在自然语言推断(Natural Language Inference, NLI)任务中,也有较多以部分输入(Partly Input)为攻击方式的工作,其中,特定词(比如:否定词 not)、选项句与前提句的词重叠程度、句子长度(Gururangan 等人, 2018),和非平衡的词分布(Kavumba 等人, 2019)都曾被识别为任务的虚假相关性线索。然而现有对自然语言推理模型脆弱性的研究集中在可统计的线索上,

与语义相关的抽象线索在类似任务上尚未被探索。

二、因果相关特征与虚假相关特征

哲学、宗教、法律，以及医学等领域都与因果关系密不可分。这里我们不从认知论的角度讨论因果性，而是借鉴因果推断领域中的概念，采用干预主义的观点定义因果，即任何一个系统在自然状态下，外在的介入是因，产生的变化是果。类似地，在自然语言处理任务中，也曾有工作阐述对因果关系的理解（Kaushik 等人，2019），“是什么让这句电影评论的情感成为积极情感？是什么让这张图片上被认知为海豚？”，在其它变量保持不变的情况下，如果对某特征施加一个变化，可以改变文本的情感或者图片的对象识别结果，那么该特征就是属于对预测结果有因果性影响的特征，这里称为因果相关特征。因果特征（Paul, 2017; T. Wang 等人，2022a; Z. Wang & Culotta, 2020），又称核心特征或真正特征¹（Z. Wang & Culotta, 2020）。与因果相关特征相对应的是虚假相关特征，又称浅层线索（Superficial Cues）、虚假模式（Spurious Patterns）、虚假关联（Spurious Correlation），和捷径（Shortcut）²（T. Wang 等人，2022b），它们代表着那些在训练集中对结果变量有预测能力，但这种预测能力会随着数据分布的变化而失效的特征，比如情感分类任务中与情感无关的上下文语义，或者图像识别任务中图片的背景信息。

（一）特征呈现虚假相关的原因

虚假特征的现象主要是因为混杂变量的存在，混杂因子既对特征有影响，又对结果变量有影响，从而导致特征与标签之间呈现出虚假相关性。下面以一个经典的案例来解释这种相关性，统计学家们发现一个城市的巧克力销量与这个城市的诺贝尔获奖人数呈现强相关性，如图 1-1 所示。如果决策者想提高一个国家的诺贝尔获奖人数，期待通过制定政策提高巧克力销量来实现这一目标显然是很荒谬的。虚假相关的特征不能为我们提供决策依据。

如图 1-2 中的因果图所示，之所以巧克力销量与诺奖人数呈现出强相关性，是经济水平作为混杂变量的影响。经济水平高的地区，往往商业发展较好，人民消费水平高，巧克力销量也越高；与此同时，经济水平高也意味着这个地区拥有

¹ 下文不做区分。

² 下文不做区分。

着良好的教育环境，因此这个国家的诺贝尔获奖人数比较多。




图 1-1 呈现虚假相关现象的子（Messerli, 2012）




图 1-2 巧克力销量与诺奖人数的因果图

（二） 识别因果特征的优势

传统的统计方法识别输入特征与结果变量的相关性，但对于改变输入特征，会带来什么样的结果变化，无法给出判断。从这个角度来讲，将因果特征识别与传统的统计方法结合，可以揭示所在任务中从输入变量到结果变量的运行机制（生成过程）。具体来说，学习因果特征的重要性体现在因果关系的两个特质：不变性、以及可理解性。

1. 因果特征的不变性

在同一域内的数据中，联合分布 $P(X,Y)$ 保持不变，拟合相关性的模型，会在未知数据的预测上达到较好的效果，当我们对模型的要求仅仅是域内预测能力强时，可以使用所有相关性的特征（虚假相关和因果相关）进行预测，但如果我们需要将模型应用在不同的场景下，则需要重视虚假相关问题。这是由于在不同的域/场景下，因果特征与结果变量之间的相关性是不变的，而虚假相关特征与结果变量之间的相关程度则呈现出不稳定性。

因果特征的不变性是指因果特征与目标变量之间的影响函数 $Y = f_Y(X^c)$ 是不变的。下面从数据生成过程的角度来分析这一性质。使用一个适用于多种任务的因果图来说明，如图 1-3 所示，因果图包含 4 个变量：




图 1-3 适用于常见任务的因果图

- Z ：域变量，代表一种由标注者或数据来源带来的选择偏差/一种领域的选择等

- Y ：目标变量

- X^c ：目标变量的因果特征

- X^s ：目标变量的虚假特征

在不同任务下各变量所代表的可能含义如表 1-1 所示。

表 1-1 不同变量在不同任务中的可能含义

变量	仇恨言论检测任务	电影评论情感分析任务	手写体识别任务
Z	对群体的仇恨情绪	主题	数据收集偏差
X^s	被保护属性	“horror” 单词是否存在	黑白/彩色
X^c	对群体的攻击词汇	情感词	数字的轮廓
Y	是否为歧视言论	积极/消极	哪个数字

• 虚假特征与目标变量存在不合理相关性

当域变量发生改变，随之引起因果特征变化，进而引起目标变量变化，而域变量改变也会引起虚假特征变化，因此，虚假特征会与目标变量呈现出相关性。比如，当情感分类数据集从金融领域切换到电影领域，情感词的分布产生变化，因此情感标签的分布也随之改变；而对应地，领域专属名词的分布也会随着领域切换而改变，从而导致领域专属名词与情感标签呈现出不合理的相关性。

• 因果特征的不变 VS 虚假特征的变

当域变量取不同的值，虽然会引起因果特征的变化，但是因果特征与目标变量之间的影响函数不会改变；而对于虚假特征来说，域的变化则会引起虚假特征与目标变量之间的函数变化。以极端情况举例，在新领域下，原领域的专属名词不再出现，即 Z 与 X^s 不再具有相关性，那么随之 X^s 与 Y 的相关性也将不存在。

2. 因果相关特征的可理解性

因果特征与目标变量的相关性与人类思维判断一致，比较容易被理解³，这是由因果本身特点所决定的。比如，我们更容易理解情感分类模型为什么将“perfect”一词当作重要的情感线索，但我们很难对一个将“Spielberg”（斯皮尔伯格，美国著名导演）作为情感判断依据的模型产生信赖感。如前文提到的巧克力销量与诺贝尔获奖人数具有相关性的例子，相关性模型所提供的决策依据，很可能是荒谬的。尤其是在高风险领域（比如：自动驾驶，医疗诊断），模型的应用将受到严重阻碍。此外，得知特征与结果变量的相关性结论，对于改变输入特征会在未来带来什么样的结果变化，仍然无法给出判断。从这个角度来讲，因果特征可以揭示所在任务中从输入变量到结果变量的运行机制，注重模型对因果特征的识别，可以提高模型的可信性。

三、 依赖虚假相关线索引发的公平性问题

当模型预测所依赖的线索涉及到敏感属性时，将会带来算法“偏见”。以招聘偏见为例，一款被高盛、希尔顿，以及联合利华等多家名企采用的 AI 面试工具——HireVue，被认为加强了求职偏见，机器通过学习现有员工的招聘模式来寻找新员工。这意味着如果一个部门所有员工全是白人（即使是巧合），AI 也会不自觉地偏向寻找白人。如果好员工恰恰都是女性，那么男性面试者也会被降低

³ 这里的“可理解”倾向于似然性（Plausibility）的含义，即对于人类有多大的说服力。

权重（DeepTech 深科技, 2019）。图 1-4 使用一个简单的因果图来解释算法偏见现象。

随着机器学习方法在众多领域中的应用，算法公平性引起了学者们的关注，即模型是否会对特定群体产生“偏见”。算法公平性问题主要分为两类：（1）预测值的歧视，即是否针对不同的群体给出不同的预测值；（2）预测质量的歧视，即是否针对不同群体展现出不同的预测准确率。本文接下来关于公平性的讨论主要集中在第一类问题上。




图 1-4 算法公平性问题因果图

（一）公平性的定义

最初，学界对算法公平性的定义是统计一致性（Calders 等人，2009）（Statistical Parity），也称群体一致性（Demographic Parity）、或群体公平（Group Fairness），该目标要求预测值与身份信息相独立，有较多的工作以此为基础设计去偏模型（Beutel 等人，2017；Pan 等人，2022；Xia 等人，2020）。后来，Hardt 等（2016）指出，这种公平性标准存在不足之处，它忽视了被保护属性与目标变量之间的事实关联，的确存在被保护属性对目标有影响的任务，比如心脏衰竭疾病，男性群体会比女性群体发病率更高，在这种情况下，忽视预测与敏感属性群体的关联并不是我们想要的。作者提出机会平等指标（Equality of Odds 和 Equality of Opportunities），要求在真实目标变量给定的情况下，预测的目标变量与被保护属性是独立的：

Equality of Odds:

$$Pr(\hat{Y} | Y, Z) = Pr(\hat{Y} | Y)$$

Equality of Opportunities:

$$Pr(\hat{Y} | Y=1, Z) = Pr(\hat{Y} | Y=1)$$

第二个定义不如第一个定义那么严格，这是因为在二元情况下， $Y=1$ 通常代表着一种有利的预测，比如：批准贷款申请/接受入学申请/面试通过，是我们比较关注公平性的结果。这两个度量指标考虑了不同群体当中，目标变量的分布是有差异的。此外，除了群体公平概念外，个体公平性相关指标：反事实公平（Kusner 等人，2017）概念被提出：

$$P(\hat{Y}_{A \leftarrow a}(U) = y | X = x, A = a) = P(\hat{Y}_{A \leftarrow a'}(U) = y | X = x, A = a)$$

反事实公平是指同一个体或者群体的预测结果在现实世界和反事实世界应该相似。在自然语言处理领域，类似的反事实公平概念也在先前工作（Garg 等人，2019）中提到。

（二）自然语言处理任务中的公平性

在自然语言处理领域，有些任务与人口属性信息（种族、性别）相关性较强，比如：情感分析领域下的歧视言论检测任务和厌女言论识别任务。在应用场景下，社交平台通过算法过滤仇恨言论。通常情况下，训练集中表示身份属性的词与仇恨情感共现概率较大，这是因为表达仇恨的言论往往是针对某个种族/性别/宗教（或其他人口身份）群体的，因此，这些身份属性词无可避免地会出现在这些言论中。在训练过程中，数据驱动模型倾向于学习到以人口属性信息为预测线索，从而使得模型在面对类似“You are a woman.”这样的中性表达时，做出毒性的判断，模型被迫产生“偏见”，先前工作（Dixon 等人，2018）将之称为“unintended bias”（非预期偏见）。

四、依赖虚假相关线索引发的稳健性问题

独立同分布假设在现实生活中通常是被违背的。比如，数据集分布随着时间发生了变化；在文本领域，有新词产生或文本含义发生变化；缺乏标注数据集的领域与之前有标注数据集的领域分布不同。因此，模型在分布外测试集上的表现一直是学者们所关注的问题，即稳健性⁴问题（Robustness），又称鲁棒性问题，是指模型在与训练数据集不同分布下保持预测水平的能力。按照前人综述（X. Wang 等人，2022）中的分类，自然语言处理领域稳健性问题主要分为对抗攻击

⁴ Robustness 的中译表达，与鲁棒性同义，下文不做区分。

下的稳健性问题和分布偏移下的稳健性问题。

（一）对抗攻击下的稳健性问题

与传统的稳健性定义有所不同，对自然语言处理任务而言，对抗攻击下稳健性能差意味着，给定输入 x ，在输入 x 上加入微小扰动后变成 x' ，人类能够对 x' 预测正确，模型很大概率会预测错误。先前工作中所使用过的扰动方式主要包括两种类型：

1. 扰动后的文本标签不应发生变化

在 NLP 中，常用的扰动方式包括同义词词语替换、复述、词序发生变化，和添加无关上下文等方式。对于扰动后的文本，人类仍然能够阅读并理解进而做出不变的判断，但模型的预测可能会改变。如果模型要在类似的微小扰动下仍能准确预测原标签，则说明该模型的稳健性能较好。

2. 扰动后的文本标签应该发生变化

另外一种方式，对输入文本施加微小扰动，但可以极大改变标签维度的语义，从而改变对应的标签，这种扰动方式通过人工标注反事实样本来进行，设置“最小编辑、反转标签、语言流畅”三大指导原则来对原始的测试样本进行修改。这种情况要求模型要在微小扰动下理解文本的语义变化。




图 1-5 模型稳健性问题的因果图解释

下面从因果图(图 1-5)的概念来理解，模型在这两种攻击下的脆弱性原因。这两种方式均是以人工干预的方式生成不同分布的对抗测试集。第一种方式主要是阻碍了图 1-5 中的路径①的传播，想象一种极端的情况，在自然语言推断任务中，学者们曾提出选项句的句子长度可能是预测标签的虚假线索，那么对抗

扰动测试的方式可以是在原始输入的后面，接上这句话的复述句（使用复述模型）。在这种扰动下，原有数据集对句子长度的选择偏好消失，从 Z 到 X^s 的生成函数不再存在。自然地， X^s 与 Y 之间的相关性也不再存在，因此，捕捉到 X^s 与 Y 之间相关性的模型会在这样的对抗数据集上表现下降。

第二种干预方式是阻碍图 1-5 中的路径②的传播，在最小编辑的情况下反转标签，标注者极有可能修改的是因果特征，因此， $f_{X^c}(Z)$ 生成函数发生改变，随之带来从 Z 到 Y 的生成函数 $f_Y(f_{X^c}(Z))$ 也发生改变，即使从 Z 到 X^s 的生成函数 $f_{X^s}(Z)$ 保持不变， X^s 与 Y 之间的相关性也会发生变化，因此，捕捉到 X^s 与 Y 之间相关性的模型会在这样的数据集上表现下降。

这两种定义互补，需要同时考虑两种情况来提升模型稳健性。本文主要涉及的研究正是这两种对抗攻击下的稳健性问题。

（二）分布偏移下的稳健性问题

分布偏移下的稳健性问题与域泛化问题相似，二者均要求测试时的域外数据在训练时是不可知的。在 NLP 中，对分布变化的稳健性意味着模型性能不应因语法错误、方言、说话者、语言不同或同任务但不同领域而降低，从因果图的角度来看，这种情况仍然可以归类为对图 1-5 中路径①的拦截，与第一种扰动攻击不同的地方在于，分布偏移下阻断之后的分布是未知的。

第二节 研究问题及内容

本文探讨自然语言处理任务中的虚假相关性问题，分别从发现和缓解两个步骤来展开研究工作。首先，自然语言处理任务中的虚假相关现象是隐含在数据集里的，探究模型对数据集中虚假线索的捕捉能力，是理解模型脆弱性来源的基础，也可为设计更合理的评测数据集提供参考。其次，缓解模型对浅层线索的依赖，促进模型对因果特征的捕捉，又可以细分为两种类型的问题（Yang 等人，2021），一是针对已知的虚假关联，如何设计算法对虚假关联进行约束，比如常识因果推理模型对语义相似偏差的过度依赖问题（虚假线索为语义相似程度），以及歧视言论检识别模型依赖被保护属性所带来的“偏见”问题（虚假线索为敏感属性信息），这两种类型任务的应用场景分别体现了对 NLP 算法公平性与稳健性的关注；二是针对未知的虚假线索，如何根据任务特点设计算法提升模型抵抗攻击的能力。

一、常识因果推理任务中的虚假线索探索与分析

随着预训练语言模型的提出,从大规模语料中学习上下文语义表示,以特征提取或微调的方式辅助下游任务的训练,已成为解决自然语言处理任务的通用范式。深度学习算法在诸多自然语言处理任务中取得了令人满意的预测效果,在一些任务上甚至超越了人类的表现。在常识因果推理任务(Choice of Plausible Alternatives, COPA)上,预训练语言模型 DeBERTa(He 等人, 2020)达到了 98.4% 的准确率,表现优异,但这是否就意味着模型具有了常识因果推理的能力呢?任务复杂性及其对世界知识的要求暗示着预训练语言模型所展现出的推理能力可能是被高估的。在自然语言推断或常识因果推理任务中,特定词、语法词重叠程度、句子长度(Gururangan 等人, 2018),和非平衡的词分布(Kavumba 等人, 2019)等都曾被识别为任务中的虚假线索。

现有对常识因果推理模型脆弱性的研究集中在可统计的线索上,比如:词分布,而与语义相关的抽象线索在常识因果推理任务上尚未被探索。此外,先前工作表明通过数据增强实现数据集的词分布均衡,可以帮助模型缓解对词分布的虚假依赖,然而,以数据增强为代表的缓解方案是否会引入新的虚假相关也是需要关注的问题。

不同于以往对可统计虚假线索的研究,本文提出在常识因果推理任务上存在一个抽象虚假相关性线索:语义相似性。该线索在文本中并未显式呈现,因此不易被发现。通过设置两种不同干扰实验(前提干扰和问题类型掩盖)测试了基于知识库和基于预训练微调的常识因果推理模型的表现,验证了预训练语言模型对语义相似性的过度依赖假设,并对先前工作中的去偏模型进行测试,实验结果表明针对特定线索制定的缓解方案在新的对抗测试集中所展现出的脆弱程度可能会更严重。

二、已知虚假线索情况下的自然语言处理模型去偏方法

首先,本文从较为直接的情况开始研究缓解虚假相关性的方法,即在研究缓解方案之前,已经通过数据的统计分析,或者对抗样本测试获知模型的虚假线索。在这种情况下,设计改进方案的动机通常较为直接。前人工作主要集中在两个方面,第一种思路在训练阶段进行,针对已知的虚假线索设计惩罚损失或对抗学习目标,使模型在学习如何预测原始目标的同时,降低对虚假线索信息的捕捉;第二种思路在训练前阶段进行,主要是通过样本加权、样本补充、样本过滤等调整

方式，使得训练集样本对该虚假线索的依赖不再存在（即阻断图 1-5 中的路径①）。

现有的改进方案在缓解虚假关联方面有一定的成效，但可能会带来两个后果。一方面，针对一种线索的去偏方案，可能会带来对另外一种浅层线索的依赖；另一方面，在执行去偏方法的过程中，忽视该线索与目标变量存在的真实因果效应，盲目去偏可能会降低模型的识别能力。

本文针对上述两个难点，以稳健性和公平性为目标，以常识因果推理任务和歧视言论检测任务为应用场景，研究自然语言处理模型中虚假相关问题的缓解方案。

（一）常识因果推理模型中基于反事实约束的去偏方法

针对常识因果推理的稳健性方法，主要是通过人工数据增强的方式来实现的（Kavumba 等人，2019），现有改进方案在缓解虚假关联方面有一定的成效，但针对一种线索的去偏方案，可能会带来对另外一种浅层线索的依赖；此外，目前对常识因果推理模型脆弱性的评估，往往是针对一项线索，对模型推理能力的脆弱性评估不够全面。因此，有两个问题是我们迫切关注的：如何更加全面地评估模型对虚假线索的依赖程度？以及如何改善模型对虚假相关性的捕捉能力？

基于以上分析，本文针对常识因果推理任务中的语义相似偏差现象，提出基于反事实约束（如果这个样本改变问题类型的话，预测结果应当如何）的改进方案，并介绍了一个既可以评估模型对词分布依赖程度，又可以评估模型依赖语义相似线索程度的挑战测试集 BCOPA-CE。具体来说：

（1）提出缓解模型脆弱性的去偏方案，具体表现为在原有训练损失的基础上增加反事实约束惩罚项。实验结果表明所提方法在保持原有预测水平的情况下，可有效降低模型对语义相似的依赖程度，该方法也在前人所提出的挑战测试集 COPA-test-hard 上表现更加稳健，该数据集可以评估模型在平衡词分布下的表现；

（2）介绍了新的挑战测试集 BCOPA-CE，该数据集既可以评估模型在无偏词分布下的表现，还可以评估一个模型区分原因和结果的能力。基于反事实约束的常识因果推理模型在此数据集上表现更加稳健。

（二）面向歧视言论检测公平性的身份核心型样本过滤算法

为了对 NLP 中的公平性问题进行探讨，这里以歧视言论检测任务为例进行研究。歧视言论检测模型对敏感属性信息的过度依赖可能会使其产生“偏见”。针对歧视言论检测中的非预期偏见问题，较为主流的去偏方法可以分为两个支线。第一支线是从数据的角度，增强、过滤、加权样本，使得训练集在我们所关注的敏感属性上分布平衡。具体地说，Zhao 等人（2018）通过将表示性别身份的单词替换为相反性别的对应单词，生成新的样本，并保持原有的标签，从而增强原始训练集，这种通过反转性别进行数据增强的方案缓解了指代消解任务中的性别偏见。类似的工作（Dixon 等人，2018；Nozza 等人，2019）将该方法应用在情感分析任务中，对于每个身份项，从公开的网络文本里抽取同等数量的 non-toxic 文本，以平衡该身份项在训练集中的标签分布；此外，Ball-Burack 等人（2021）利用 AFLite 和 DataMaps 算法对展露出虚假相关性的训练样本进行过滤来实现数据的调整。从数据角度平衡分布的第三种方式是通过对样本加权来实现的。Zhang 等人（2020）针对毒性检测任务中的模型偏见问题，将歧视分布（现实中的数据集分布）看作是从非歧视分布（理想世界的数据集分布）中采样得来的，通过样本加权恢复原始的非歧视分布，从而帮助模型缓解偏见。去偏方法的第二支线是通过对训练目标施加约束来改进模型，从而降低训练过程中对人口属性线索的依赖。最常见的方法是对抗学习（Elazar & Goldberg, 2018；Faal 等人，2021；Xia 等人，2020），促使模型学习到的文本表示既可以预测情感标签，同时又可以与身份语义无关。此外，也有较多工作在训练目标之外，增加额外的惩罚损失来缓解模型对身份信息的依赖，这些惩罚项包括：预测输出与保护属性的相关性（Beutel 等人，2019）、预测概率与反事实样本的预测概率差异（Garg 等人，2019），和不同群体的漏识率（FNR）/误识率（FPR）的差异（Gencoglu, 2021）等。除了对训练目标的约束，Attanasio 等人（2022）提出对注意力的熵进行约束，阻碍模型对特殊身份项的过拟合。总的来说，目前主流去偏方法都是以促进模型学习到的表示向量与身份信息尽可能无关为目标。

然而，这并不完全符合实际情况。Garg 等人（2019）曾提出非对称反事实问题，即样本的情感贡献词大多来源于对群体的刻板印象，由身份属性词表现出来，而上下文本本身无明显的情感贡献，本文称之为“身份核心型样本”。传统的去偏思路通过解除模型预测与身份信息的相关性，来实现群体一致性的公平目标。然而，由于身份核心型样本大多是以身份信息作为核心情感贡献词，模型的预测需

要特别考虑身份信息的存在，因此，这会使得去偏模型对于歧视言论的捕捉能力变弱，在此类样本的对抗样本上出现过高的误判率。

为了使得去偏方法可以过滤掉身份核心型样本，本文借鉴因果推断领域中的条件因果效应概念来刻画样本中的身份信息是否属于核心情感贡献词，在不同的去偏方法上实施过滤，使得模型在保证去偏能力的同时，仍然具有歧视识别能力。本文针对模型将敏感身份信息作为预测捷径所引发的公平性问题，尝试提出解决方案。所做的工作主要有以下方面的创新：（1）分析了经典去偏方法忽略身份核心型样本所带来的问题，采用条件因果效应计算方式识别这类特殊样本；（2）将身份核心型样本过滤策略与三种经典的去偏方案结合，实验结果显示所提方法可以在保证模型去偏能力的同时，提高模型对身份核心型样本的识别能力。

三、未知虚假线索情况下自然语言处理模型的稳健性增强方法

针对已知虚假线索提出的去偏方案直接且易理解，可以很明显地看到模型降低脆弱性的效果，但仍具有不少局限性。具体来说，公平性问题背景下的虚假线索，即敏感属性，的确是我们较为关注的，因为这涉及到在现实生活中应用模型时会引发的社会性影响。但在不涉及被保护属性的自然语言处理任务下，我们需要顾及的虚假线索范围是很大的，不同线索之间可能互相影响。因此，针对特定线索进行去偏，对促使模型学习因果特征的帮助也是有限的。

当虚假线索未明确时，为缓解虚假相关性对模型的影响，不少研究工作将目标转向为如何学习影响模型预测的因果特征。这方面的工作主要分为两个支线：

（1）人工标注因果特征，包括反事实数据增强和特征约束两种方法，前者通过人工、规则、自动等方式生成训练样本的反事实样本，将原始样本和反事实样本组合进行训练，从而促使模型学习到影响情感的因果特征（Kaushik 等人，2019；Z. Wang & Culotta, 2021；Yang 等人，2021）。后者是在分类的目标损失之外，对数据集的虚假特征和因果特征分别进行约束（Z. Wang 等人，2021）。（2）利用因果特征具有域间不变性，而虚假特征对于域改变比较敏感的特点设置学习目标。

然而，第一种改进方案对反事实生成质量要求较高，尤其是在长文本的情况下，效果有限，特征约束方法需要事先已知任务的虚假特征和因果特征，这需要一定的标注成本。第二种方式要求有不同领域的数据，这往往很难满足。

本文针对未知虚假线索导致的模型稳健性问题，提出改进方法。所做的工作

主要有以下方面的创新：（1）本文对于未明确的虚假线索，提出主题混杂假设，然后基于后门调整学习的方式，缓解模型对未知虚假线索的依赖性；（2）所提方法分别在前人提出的分布偏移型对抗样本（电影评论文本）和扰动攻击型对抗样本（金融新闻文本）做出测试，实验结果表明所提方式能够提升文本分类模型的稳健能力，尤其是长文本情况下的分类模型。

四、术语含义解释

（一）偏差（Bias）

偏差，也称“偏置”。从数据的角度来说，某特征（直接特征或者由输入转换后的特征）在目标类别中分布不平衡，以至于在数据集上训练的模型会对该特征产生不合理的依赖，这种现象被称作“偏差”，对该特征产生过度依赖性的模型被称为“有偏模型”。

这种偏差现象的存在往往是数据选择偏好引起的，比如电话图像识别任务，收集到的数据往往是人在打电话的场景，所以人的出现在“属于电话的图像”与“不属于电话的图像”两个类别中是不平衡的，因此模型很可能会将“人”作为一个判断线索。这种数据选择偏好通常源于获取不同分布数据集的难度不同。类似地，还有词分布偏差、语义相似偏差等。

下文中提到的用词，如虚假特征、偏差线索、虚假线索、浅层线索以及表面线索都代表类似的含义，即该特征（线索）与目标变量之间的分布呈现不合理的相关性且很有可能被模型捕捉到。下文中提到的“选择偏差”是指由于某种对数据的选择方式导致的偏差现象，具体来说，假设训练集中的数据是从一个想象的总体数据分布中采样而来，而当前使用的训练集所对应的采样过程可能具有倾向性，这种采样倾向性导致了“偏差”现象的产生。

在涉及到公平性的问题中，“biased”一词经常被延伸为“有偏见的”，比如“性别偏见”或“种族偏见”，是用来描述一个广泛的系统现象，即模型可能出于不同的原因，以不同的方式，对不同的团体，存在有害的预测（Blodgett 等人，2020）。模型是中性的，这种带有一定主观色彩的描述一般是从社会影响的角度来讲的。

（二）去偏（Debias）

去偏是针对“偏差”（虚假相关性线索）而言的，是指缓解“有偏模型”对虚

假相关线索过度学习的过程。

（三）相关性（Correlation）

相关指两个变量之间的关联程度，一个变量的变动与另一个变量的变动是否呈现出某种规律。

（四）因果相关性（Causal Correlation）与虚假相关性（Spurious Correlation）

因果相关性，是指在其它变量不变的情况下，两个变量所呈现出的相关性。虚假相关则是指观测数据中所呈现出的两个变量的相关性，它不同于两个变量之间的因果相关性。在有混杂存在的情况下，两个变量之间的相关性是被高估或者低估的，这部分相关性会随着数据分布偏移而变化，呈现出不稳定性。

值得注意的是，虚假相关并不代表着两个变量之间不存在任何因果影响，而是说这两个变量在观测数据中最终呈现出的相关性与其直接的因果相关程度不同。

（五）混杂因子（Confounder）

混杂因子，又称混淆变量、混杂变量，是因果推断领域中的概念，在定义混杂之前，需要先明确问题背景。当探究 T 变量是否对 Y 变量有因果影响时，混杂因子是指那些既对 T 产生影响，又对 Y 产生影响的变量。

（六）去混杂（Deconfound）

去混杂是指设计方法使得 T 和 Y 之间不再受混杂影响的过程，比如去除混杂因子和 T 之间的相关性，T 与 Y 之间的相关性即等于二者的因果相关性。

（七）稳健性（Robustness）

稳健性，又称鲁棒性或健壮性，广义的概念是指模型在分布外设置下保持预测水平的能力。狭义的稳健机器学习目标是寻找最优的抵御对抗攻击的模型，默认微小变化不应输出造成影响。

（八）稳健性与因果相关性的联系

以因果相关性为目标导向的学习，所蕴含的对模型的要求相比于传统的稳健性机器学习更加严格，前者要求模型预测仅对因果相关性特征的变化敏感，当其它特征变动时不应改变预测，而后者要求模型对微小的无关扰动具有抵抗能力。

对因果相关性学习的研究是对广义稳健学习的一种补充。

（九）缓解虚假相关性的问题界定

本文研究内容的第二部分是缓解模型对虚假相关性线索的学习。相近的研究方向包括迁移学习、领域适应，以及领域泛化。为更清晰地解释研究问题，此处对本文的研究问题与类似的研究工作做出界定。

表 1-2 研究问题界定

类似的研究工作	域的标签	测试集
迁移学习	有	部分已知
领域适应	有	部分已知
领域泛化	有	未知
本文的问题界定	无	未知

如表 1-2 所示，跟本文的研究问题较为相似的是域泛化，不同点在于本文的问题设置不局限于多个领域的的数据。

第三节 研究意义

一、学术价值

（一）探索自然语言处理任务中的虚假相关性有助于了解模型的脆弱性来源

探索自然语言处理任务中的虚假相关性有助于了解模型的脆弱性来源，对模型脆弱性有更深刻的认识。虚假关联较多的数据集，往往对于模型来说有点“大材小用”，模型未必不具有深度学习语义的能力，只是走了“捷径”，探索自然语言理解任务中的虚假相关性为高效利用模型的特征抽取能力提供方向。

（二）探索虚假相关性为构建基线标准的新数据集提供参考准则

探索一个自然语言处理任务下的虚假相关性，能够帮助我们对该任务现有数据集的缺陷和模型能力的了解更加精细化，为该基线任务构建新数据集提供参考准则，避免被评估的模型走向捷径，从而构建更加有挑战的数据集，有助于更准确地评估模型在该任务上对自然语言的理解能力。比如，在最新的可解释常识

因果推理任务 e-CARE (Du 等人, 2022) 数据集的构建过程中, 为避免引入虚假线索, 作者使用一种对抗过滤算法来替换那些可以很容易地利用表面线索区分正确答案与否的假设句。

(三) 研究模型虚假相关性的缓解方案, 为提升模型稳健性能提供方法补充

研究模型虚假相关性的缓解方案, 为提升模型分布外泛化提供理论补充。对于已知虚假线索的情况, 现有的改进方案在缓解虚假关联方面有一定的成效, 但忽略了线索之间的依赖, 或者忽略了该线索与目标变量存在的真实因果效应, 本文尝试对上述问题提出解决思路。在未知虚假线索的背景下, 现有研究或是需要标注成本, 或是需要有不同领域的数据集。本文尝试在域标签未知的情景下, 设计因果学习方案, 为提升模型稳健性能提供方法补充。

(四) 扩充因果推断领域的应用场景, 丰富深度学习领域的问题视角

从研究内容涉及的领域角度来说, 因果驱动的自然语言处理模型研究, 涉及到因果推断与深度学习两个领域。其中, 因果推断是计量经济学学科中的研究分支, 在流行病学以及政策效应等领域应用较广, 深度学习模型在人工智能的各个领域都有应用, 但由于其表现的稳定性有限, 也阻碍了模型的应用推广能力, 尤其是高风险领域。从因果推断领域来说, 与深度学习模型的结合, 结合文本数据高维的特点, 扩充了传统因果推断算法的应用场景; 从自然语言处理领域来说, 融合因果思维的模型, 辅助深度学习模型加强对因果特征的捕捉, 可以提高模型的稳定性, 为先前的分布外泛化相关工作提供新的思考视角。

二、应用价值

(一) 有利于降低低资源领域下的人工标注成本

学习特征与结果变量的因果相关性是非常重要的, 这是因为因果特征具有域外泛化能力。在一些没有标注数据集或者仅有少量标注数据集的领域, 虚假相关线索对目标的预测能力会失效。因此, 往往需要对这些领域进行大量的数据集标注, 才可以实现该领域的自动化。对虚假关联依赖程度较低的模型, 容易移植到同一任务的不同领域中, 从而降低低资源领域的数据构建成本。

(二) 有利于提高模型在高风险领域的应用推广能力

医学诊断、自动驾驶, 和金融等领域, 算法的预测失误所带来的成本较高,

对模型的稳定性要求较高，因此，虚假相关问题需要特别重视。此外，这些领域易产生新的数据集，导致算法在预测和决策时遇到分布外的数据易受攻击，存在较大风险，这阻碍了机器学习算法的应用推广，影响社会对机器学习系统的可靠性判断。因此，在这些风险厌恶程度高的应用领域，对智能系统捕捉因果特征的能力有着极为迫切的需求。

（三） 缓解虚假相关依赖可缓解智能应用时的社会性偏见

当模型预测所依赖的线索涉及到敏感属性时，将会带来算法“偏见”。比如简历筛选、嫌疑人人脸识别，和社交平台仇恨言论过滤等应用场景，都需要对涉及到身份属性的信息加以保护。机器学习模型在解决相关任务时，会拟合身份属性与标签之间的相关性，存在一定的虚假关联。因此，在面对对抗样本时，以被保护属性为线索的模型，会做出“有偏见”的预测，从而带来一定的社会影响。因此，缓解这部分虚假相关性，可改善社会对模型的“公平性”印象。

第四节 创新点及整体框架

（一） 主要创新点

本文的主要创新点如下：

第三章以常识因果推理任务 COPA 为例，观察预训练语言模型在该任务上的脆弱性表现。具体创新点如下：（1）提出预训练语言模型所依赖的一个新的不易被发现的虚假线索：语义相似性；（2）通过设置两种干扰实验：前提干扰和问题类型干扰，测试模型的表现，验证模型对语义相似的过度依赖假设；

第四章以第三章的结论为前提假设，针对常识因果推理任务，提出方案缓解预训练语言模型对语义相似的依赖程度，所做的工作主要有以下方面的创新：（1）提出缓解模型脆弱性的尝试性方案，在原有训练损失的基础上增加反事实约束项，改进模型在保持原有预测水平的基础上，能够降低模型对语义相似的依赖程度，此外，在前人工作提出的挑战测试集 COPA-test-hard 上表现也更加稳健，该数据集可以评估模型在平衡词分布下的表现；（2）介绍了新的挑战测试集 BCOPA-CE，该数据集既可以评估模型对词分布的依赖程度，还可以评估一个模型区分原因和结果的能力，基于反事实约束的改进模型在此数据集上表现更加稳健。

第五章针对模型将敏感身份信息作为预测捷径所引发的公平性问题，尝试

提出解决方案。所做的工作主要有以下方面的创新：（1）分析了经典去偏方法忽略身份核心型样本所带来的问题，采用条件因果效应计算方式识别这类特殊样本；（2）通过将身份核心型样本过滤策略与三种经典去偏方案结合，表明所提方法可以在保证模型去偏能力的同时，提高模型对身份核心型样本的识别能力。

第六章针对未知虚假线索导致的稳健性问题，提出缓解方法，所做的工作主要有以下方面的创新：（1）对于未明确的虚假线索，提出主题混杂假设，然后基于后门调整的方式，对干预概率进行建模，缓解模型对未知虚假线索的依赖；（2）所提方法分别在前人提出的因果词扰动对抗样本（电影评论文本）和同义词扰动对抗样本（金融新闻文本）上做出测试，实验结果表明所提方式能够提升情感分类模型的稳健性，尤其是长文本分类任务。

（二）整体框架

本文针对自然语言处理任务中的虚假相关性问题，从发现（第三章）和缓解（第四、五、六章）两个步骤展开研究工作，论文整体框架如下文中的图 1-6 所示。




图 1-6 论文整体逻辑框架

其中，整篇论文的重点为缓解模型对虚假线索的依赖，下面针对这部分内容梳理研究逻辑。从研究问题的角度，可以分为：（1）已知虚假线索下的缓解方案：这部分内容包括常识因果推理任务针对语义相似线索的去偏方法研究（第四章），以及歧视言论检测任务针对敏感属性线索的去偏方法研究（第五章）。（2）未知虚假线索下的缓解方案：情感分析任务在对抗攻击下的稳健性方法研究（第六章）。

从研究应用的角度，可以分为：（1）公平性问题：歧视言论检测任务针对敏感属性线索的去偏方法研究（第五章）。（2）稳健性问题：这部分内容包括常识因果推理任务针对语义相似线索的去偏方法研究（第四章），以及情感分析任务在对抗攻击下的稳健性方法研究（第六章）。

第五节 本章小结

本章首先介绍了本文的研究背景和意义，其次对本文主要研究内容与基本思路进行了详细阐述，并对本文的主要创新点进行了总结，最后介绍了本文的整体逻辑框架。

第二章 文献综述

有监督学习算法往往会利用训练数据中所有相关线索进行预测，虽然模型会在同分布的测试集上表现较好，但往往错过重点（Ahuja 等人，2020），当测试集的分布与训练集不一致时，模型表现下降较多；此外，在一些涉及到社会影响的相关自然语言处理任务中，如：侮辱言论检测任务，若模型的预测依赖线索包括人口属性信息，会导致模型存在“偏见”；特别地，在某些风险厌恶程度低的应用领域，模型的预测稳定性通常较为重要，利用虚假相关线索的模型会降低模型可信度（Z. Wang & Culotta, 2020）。因此，本文研究自然语言处理相关任务中的虚假相关现象，并尝试从已知线索和未知线索的角度对模型的虚假相关问题提供缓解方案。为了给后文研究提供相关文献基础以及理论支撑，本章将从自然语言处理任务中的虚假相关性识别以及在不同虚假线索背景下如何提升模型对因果特征的捕捉能力两个方面，分类梳理国内外在该领域的研究现状以及发展趋势。

第一节 虚假相关性识别技术研究综述

自然语言处理模型中的脆弱性识别技术主要分为两个方面：一是针对数据，通过对训练数据集中的虚假线索进行统计来识别（Gururangan 等人，2018），或者通过部分输入而模型仍然保持高性能表现这一反直觉现象（Poliak 等人，2018）来验证模型的脆弱性；二是针对模型，通过构造与训练数据分布不同的对抗数据集来攻击原始模型（Dasgupta 等人，2018），或者通过模型改进的方法表现反过来验证模型的脆弱性。

一、基于数据发现的方法

（一）启发式规则统计

启发规则统计是指基于先验知识对训练数据集中可能存在的虚假线索进行统计，比如：特定的词、句子长度、语法结构，以及位置信息对标签的倾向分布，从而来探究模型是否展示出脆弱性。

Rudinger 等人（2017）通过点互信息（PMI）的词共现统计，来定性分析斯

坦福大学自然语言推理 (SNLI) 数据集中的性别、种族、年龄等线索在目标变量下分布的不同 (Rudinger 等人, 2017); 类似地, Gururanga 等人 (2018) 也曾使用 PMI 指标探索自然语言推理数据集中由标注者技巧所带来的虚假相关现象。Niven 和 Kao (2019) 针对论证推理理解任务进行探讨, 在此任务中, BERT 模型的预测水平仅次于人类表现, 作者通过实验表明上述结果是利用了数据集中的虚假统计线索而达到的。比如 “not” 这个单词更倾向于出现某个类别的样本中。涉及到多个选项的 NLP 任务, 与词分布不平衡相关的统计指标也在这篇工作中被提出 (Niven & Kao, 2019), 包括适用性指标 α_k , 代表单词 k 仅出现在一个选项中的样本数目; 生产性指标 π_k , 代表满足适用性的这些样本中, 单词 k 所在的选项是正确答案的样本比例, 以及覆盖率指标 ξ_k 代表满足适用性样本占有所有样本的比例。如果一个任务的标签有 m 个类别, 那么 $\pi_k > 1/m$, 意味着单词 k 的出现将成为一个对于机器学习模型而言有用的线索。

$$\alpha_k = \sum_{i=1}^n 1 [\exists j, k \in \mathbb{T}_j^{(i)} \wedge k \notin \mathbb{T}_{-j}^{(i)}]$$

$$\pi_k = \frac{\sum_{i=1}^n 1 [\exists j, k \in \mathbb{T}_j^{(i)} \wedge k \notin \mathbb{T}_{-j}^{(i)} \wedge y_i = j]}{\alpha_k}$$

$$\xi_k = \frac{\alpha_k}{n}$$

类似地, 在常识因果推理 COPA 任务中, 将词分布视为虚假线索的工作也曾被提出 (Kavumba 等人, 2019), 该工作通过统计指标分析单词分布的不均衡情况, 实验结果表明 BERT 等预训练语言模型在该任务上的高超表现是由于其在一定程度上利用了词分布线索。

(二) 部分输入法

在涉及到句子对的任务中, 通过部分输入观察模型表现同样可以检测模型的鲁棒能力。如: 在文本蕴含任务中, 若模型接收的输入不包括前提, 但其仍然能取到较好的预测效果, 则说明模型原有的高性能表现是被高估的。因为这不符合人类的推理直觉, 在未知前提的情况下, 人类是无法给出判断的。Gururanga 等人 (2018) 提出, 在自然语言推断 (Natural Language Inference) 任务中, 为了可以高效地生成候选项, 众包标注者往往会利用一些标注技巧, 从而导致某个类别下的候选项存在一定的浅层模式, 比如: 生成中性候选句时往往是在前提句后面

加目的从句,生成矛盾语义的候选句时通常是在句中加否定词,或者在看到任何“行为”时都用“sleeping”的语义来产生矛盾,而生成蕴含语义的候选句时,更倾向于将前提文本中的词用其上位词来替换。先前工作通过测试一个训练好的 NLI 模型在未知输入情况下的预测来评估模型对这些虚假线索的依赖,并且根据模型是否能保持正确的预测,将测试样本分成 easy 和 hard 两种类型。如果模型在不依赖前提的情况下仍然可以从某个样本的选项中识别出答案,说明这个样本中存在虚假线索且被模型捕捉,因此,将之称为“easy”样本,反之则为“hard”样本。对于常识因果推理任务,Kavumba 等人(2019)也曾使用类似的方式将测试集分为“easy”样本和“hard”样本。这些工作表明部分输入(选项句)中包含浅层线索,故模型可以在不学习实际任务的情况下通过捷径给出正确预测。

二、基于模型的探索方法

基于模型的研究工作主要分为两大类:第一类方法通过评估模型在分布外测试集上的表现来探索模型的脆弱性;第二类方法通过改进模型能提升对抗测试集上的表现来反之验证原始模型对虚假线索的依赖。

(一) 基于分布外测试集评估的方式

分布外测试集主要分为两种类型:(1)针对特定线索人工合成“欺骗”模型的对抗样本;(2)在输入文本上加入微小的扰动(人类依然能预测正确)生成对抗样本,比如反事实样本。

McCoy 等人(2019)针对文本蕴含任务,以人工生成的方式,构建了一个与虚假线索相反分布的对抗测试集 HANS (Heuristic Analysis for NLI Systems),观察包括 BERT 在内的几个模型在该压力测试集上的表现是否严重下降(McCoy 等人,2019)。Dasgupta 等人(2018)利用启发式规则人工构造平衡测试集,该测试集要求模型在理解词义的情况下才能预测结果,实验结果发现多数模型在该测试集上的推理表现会下降到随机水平(Dasgupta 等人,2018)。在公平性问题中,学者们经常使用模板人工构建身份平衡测试集 (Identity Phrase Templates Test Sets, IPTTS),具体来说,基于事先定义的模板,填充不同的群体名词,从而构成平衡的测试集(Dixon 等人,2018; Park 等人,2018)。为检查基准数据集是否存在不恰当的系统偏差,Kiritchenko 和 Mohammad(2018)第一次提出 EEC

数据集，该数据集基于模板构建，由 8640 个英语句子组成，可以有效评估模型是否对某些种族或性别存在偏见。作者使用该数据集检查了 219 个情感分析系统，实验结果发现，部分系统针对一个种族或性别，总是提供较高情绪强度的预测。针对中文文本，张顺香等人（2022）提出一种字符级对抗样本生成方法（PGAS），通过对多音字进行替换可以在较小扰动下生成高质量的对抗样本。类似地，王晓娟（2022）通过训练替代模型计算单词重要性分数，并结合语义相似度分层采样后得到的目标模型决策概率差值，对原始输入中的单词进行排序，从而指导对抗样本的生成。从对抗样本的粒度来看，以上使用对抗样本攻击来验证模型脆弱性的研究工作，包括字符级对抗样本、词组级对抗样本，以及语句级对抗样本（仝鑫等人，2021）。

第二种分布外测试集的方式是反事实文本测试集，Kaushik 等人（2019）针对情感分类以及自然语言推断两个任务，以常用的数据集 IMDB，SNLI 为事实样本数据集，通过众包的方式人工生成对抗的反事实样本，保证生成的反事实样本与原始样本标签相反，且语义近似。实验结果表明模型在这样的对抗样本中表现下降。类似地，在公平性问题中，Samory 等人（2021）介绍了一个和性别歧视言论检测任务有关的反事实样本测试集，为评价性别歧视检测模型的稳健性能提供标准。

（二）基于模型改进的反馈方式

通过改进模型提升对抗测试集上的表现可以反之验证原始模型对虚假线索的依赖。最常见的方法是训练前阶段的数据增强，这种方式针对某一种虚假线索，通过人工或自动的方式生成与原始分布不同的样本，通过与原始训练集合并起来训练模型，降低模型对虚假线索的依赖。Wang 和 Bansal（2018）针对阅读理解任务，对原始 ADDSENT 算法进行改进（Y. Wang & Bansal, 2018），以便生成足够的训练数据，以提高模型在先前工作中所提出的对抗性评估集（Jia & Liang, 2017）上的鲁棒性，从而验证改进前的模型对虚假线索有所依赖。类似地，在公平性问题中，也有很多的工作针对敏感属性这一虚假线索进行分布外的数据增强（Dixon 等人，2018；Nozza 等人，2019；Park 等人，2018）。此外，Kaushik 等人（2019）通过人工生成训练集的反事实样本，增强训练模型，在反事实测试集上表现良好，从而验证原始模型的脆弱性。考虑到人工成本高昂，后续的工作通过规则指导（Z. Wang & Culotta, 2021；Yang 等人，2021）、提示学习（Wu 等

人, 2021) 的方式自动生成反事实进行样本增强。针对训练过程阶段模型改进的方法包括联合训练鲁棒模型和有偏模型 (Clark 等人, 2019)、重新加权损失函数以纳入虚假线索信息 (Schuster 等人, 2019; G. Zhang 等人, 2019)、参数正则化 (Sagawa 等人, 2019) 和外部资源的使用 (Zhou 等人, 2020)。

第二节 虚假线索依赖缓解技术研究综述

为避免模型对虚假线索过度利用, 先前研究分别从不同的角度提出解决方案。当虚假线索通过先验或者统计的方式已知时, 所构思的解决方案通常较为直接, 比如从数据的角度增强对抗样本或者从模型的角度约束虚假线索的重要性, 而当虚假线索未知时, 提升模型的稳健性能则需要以学习因果特征为目标构建解决方案。因此, 本节分别梳理已知线索和未知线索两种情况下的虚假相关性缓解方法研究。

一、已知虚假线索下的缓解技术研究

已知虚假线索是指通过先验知识、启发式规则统计, 或者对抗样本攻击等方法已验证模型对特定虚假线索存在依赖的情况, 这个线索可以是敏感属性信息, 也可以是一般的虚假线索。不同线索会有不同的应用难点, 因此缓解技术又可细分为两种研究问题: 如何提升模型的公平性, 以及如何保证模型在基于某线索的对抗测试集上预测稳定。这两个研究问题均要求模型在保证预测能力的同时, 可以降低对虚假相关性特征的依赖。按此区分的原因是二者的去偏目标有所不同, 在公平性问题中, 我们更在意模型的误判率 (FPR), 因为 FPR 代表着对特定群体造成伤害的程度。

(一) 公平性问题

1. 公平性问题中的挑战测试集

Identity Phrase Templates Test Sets (IPTTS) 是指人工构建的测试集, 通常是基于事先定义的模板, 填充不同的群体名词, 从而构成平衡的测试集 (Dixon 等人, 2018; Park 等人, 2018)。为检查基准数据集是否存在不恰当的系统偏差, 学者提出 EEC 数据集 (Kiritchenko & Mohammad, 2018), 该数据集基于人工定义的模板构建而成, 共包括 8640 个英语句子, 可以有效评估情绪识别等任务中的种族和性别偏见。类似于 Dixon 的工作 (2019), 与厌女言论识别任务有关的

无偏测试集也曾被提出（Nozza 等人，2019）。

2. 公平性问题中的评估指标

公平性问题的评估指标根据其是否依赖阈值分为两类。不依赖阈值的指标包括基于 AUC 的指标（Dixon 等人，2018）和基于预测分数的指标（Bhaskaran & Bhallamudi, 2019）。和 AUC 相关的指标包括：SubgroupAUC（包含该群体的测试集样本上的 AUC 值）、BPSN（该群体为负标签，其余群体为正标签的测试集上的 AUC 值），和 BNSP（该群体为正标签，其余群体为负标签的测试集上的 AUC 值），这些指标衡量了模型在某个群体中的表现，其中 BPSN 更看重模型对这个群体的误判率，而 BNSP 更看重模型对这个群体的召回率。基于预测分数差异来评估模型的“偏见”，更多是通过对不同的群体在对称文本上的预测值进行显著性检验来验证的，如果模型对不同的群体预测差异较大，那么模型则表现得不公平。依赖阈值的指标主要是针对误判率和真正率，特别地，误判率是代表模型对某个群体“歧视”程度的普遍性指标。

3. 公平性问题中的去偏方法

较为主流的去偏方法可以分为两个支线。第一支线从数据的角度，增强、过滤，以及加权样本，使得训练集在所关注的敏感属性上分布平衡。第二支线通过对训练目标施加约束，从而降低训练过程中对人口属性的依赖。

从数据角度平衡分布的第一种方式是数据增强，具体来说，Dixon 等人（2018）针对 51 个群体的仇恨言论检测任务，从公开的网络文本中为每个群体增加同等数量的 non-toxic 文本（默认是非毒性），缓解模型对敏感身份属性的依赖。类似地，Nozza 等人（2019）针对厌女言论识别任务，从网络文本中抽取非毒性文本，与前者不同的地方在于，作者对句子长度等信息做了约束，在一定程度上，保证了数据增强的同时不引入额外的噪声。Zhao 等（2018）将表示性别身份的单词替换为相反性别的对应单词，保持原有的标签，生成新的样本，从而增强原始训练集，缓解指代消解任务中的性别偏见。该方法后来也被应用在性别歧视言论检测任务的去偏方法中（Park 等人，2018）。此外，数据过滤的方式也被用来平衡分布，Ball-Burack 等人（2021）利用 AFLite 和 DataMaps 算法对展露出虚假相关性的训练样本进行过滤，从而实现数据的调整。从数据角度平衡分布的第三种方式是通过样本加权来实现的。Zhang 等人（2020）针对毒性检测任务中的模型偏见问题，将歧视分布（现实中的数据集分布）看作是从非歧视分布（理想世界

的数据集分布)中采样得来,通过样本加权恢复原始的非歧视分布,从而帮助模型缓解偏见。Mozafari 等人(2020)介绍了一种基于预训练语言模型 BERT 的仇恨言论检测方法,通过对输入样本进行加权,减少了敏感属性对标签的影响,该工作采用交叉领域测试来评估缓解效果,在两个公开数据集上的实验结果表明这种缓解方案是有效的。

从模型角度来说,最常见的方法是对抗学习(Elazar & Goldberg, 2018; Faal 等人, 2021; Xia 等人, 2020),促使模型学习到的文本表示既可以预测情感标签,又与身份语义尽可能无关。此外,也有较多工作在训练目标之外,增加额外的惩罚损失来缓解模型对身份信息的依赖,这些惩罚项包括:预测输出与保护属性的相关性(Beutel 等人, 2019)、预测概率与反事实样本的预测概率差异(Garg 等人, 2019),和不同群体漏识率(FNR)/误识率(FPR)间的差异(Gencoglu, 2021)。除了约束训练目标,Attanasio 等人(2022)提出对注意力的熵进行约束,防止模型对特殊身份项过拟合。

(二) 稳健性问题

提升自然语言处理任务中的稳健性方法可以分成两类:数据驱动的方法和与模型或训练有关的方法。

1. 数据驱动的方法

与公平性问题类似,通过数据增强、过滤、加权的方式可以缓解模型对已知虚假线索的依赖程度。数据增强近年来在很多领域都展现出优势,比如:低资源语言学习、小样本学习,以及提升 NLP 鲁棒性等研究方向,在一定程度上有效提升模型泛化能力,但这样的策略仍然面临着很难被解释的问题。具体来说,增强方式主要包括基于人工规则构建(Dasgupta 等人, 2018; Minervini & Riedel, 2018)和复述构建(Kang 等人, 2018)。在样本过滤方面,Liu 等(2020)设计数据过滤算法,剔除掉简单的样本。类似地,AFLite 算法(Bras 等人, 2020)也被提出,对展露出虚假相关线索的样本进行剔除处理。在样本加权方面,现有研究往往通过先学习有偏模型,然后以标签的预测概率作为有偏程度,对样本进行加权(Karimi Mahabadi 等人, 2020; Utama 等人, 2020; G. Zhang 等人, 2020)。

2. 与模型或训练有关的方法

近来研究表明预训练可以作为提高 NLP 模型 OOD 稳健性的有效途径,这种

方式利用其自监督的目标，使用大量不同的训练数据，鼓励模型从少数派样本（指与数据集整体分布较为不同的样本，或更难学习的样本）学习中对抗虚假的相关性。Yaghoobzadeh 等人（2021）首先提出使用样本遗忘策略来寻找少数派样本，遗忘样本是指在训练过程中学习但被遗忘或从未学习过的样本，这种策略优势是不需要事先知道数据集中存在的虚假相关性，该工作通过两次微调模型来增强模型的鲁棒性，第一次是针对完整的训练数据，第二次是仅针对少数派样本，在 MNLI、QQP 和 FEVER 数据集上的实验结果证明，所提方案使模型在分布外泛化能力上获得了实质性的改进。

二、未知虚假线索下的因果学习技术

未知虚假线索下，现有研究工作从因果特征的特点入手，比如，因果特征的域间不变性，以及因果特征对整个文本起决定性作用的特点。具体来说包括：（1）基于因果相关性特征识别的方法；（2）基于域不变性的学习；（3）基于因果干预技术的学习。

（一）基于因果相关性特征识别的方法

基于因果相关性特征识别的方法，通过人工、规则、自动化的方式构建因果信号，这种信号既包括直接的因果相关性特征，也包括间接的反事实样本（因果信号蕴含在成对的事实样本与反事实样本中），然后设置损失目标约束或使用反事实样本增强训练来提升模型对因果相关性特征的捕捉能力。

1. 因果相关性特征识别与约束

Wang 等人（2021）事先标注好一个单词是否属于某数据集的因果特征词，通过对虚假特征的重要性进行约束来促进模型对因果特征的捕捉能力。Paul（2017）通过倾向分数匹配算法（Propensity Score Matching）构造去除混杂影响的训练数据集，在新数据集下进行特征学习，实验结果发现根据该方案选出的重要词汇更符合人类的因果认知。然而，匹配的方式在高维环境下表现欠佳（比如：文本），Shan 等人（2020）在 Paul 工作的基础上增加 LDA 主题模型模块，实现降维，然后为处置组的样本和控制组的样本进行主题相似匹配，通过配对卡方检验识别因果特征，实验结果表明，这种方法获得的因果特征可提升机器学习方法在下游任务中的表现。Z. Wang 和 Culotta（2021）则借助因果推断领域中的匹配算法识别因果相关性特征，具体来说，首先，将相关性较强的单词作为因果特

征的候选集，为候选集中的每个单词所在样本集中的每一个样本，匹配一个标签相反但上下文语义最相似的样本，设定语义相似阈值，为候选词所在的样本集合中的每一个样本匹配好对应的样本后，计算每对样本之间的语义相似度，最高相似度超过阈值的特征词为因果特征词。Z. Wang 和 Culotta (2020) 通过上述匹配方法计算得到上下文相似度以及其统计特征（比如：方差），利用这些特征，训练一个区分虚假相关词和真实相关词的分类器，将训练好的模型应用在其它词上面，最终得到每个单词是否属于虚假相关词的分类结果。

2. 基于反事实数据增强的学习方式

从反事实数据增强的角度加强模型对因果相关性特征依赖的研究工作最初是通过“人在回路”(Human in the Loop, HITL)方式进行的(Kaushik 等人, 2019)。针对情感分类以及自然语言推断两个任务，以常用的数据集 IMDB, SNLI 为事实样本数据集，通过众包的方式人工生成对抗的反事实样本集。实验结果表明，反事实样本增强训练后的模型对反事实对抗攻击的防御能力更强。然而，这种方式仍然需要较高的标注成本。为避免这一问题，基于启发式规则的反事实生成方式被提出 (Z. Wang & Culotta, 2021)，这篇工作通过语义匹配的方式识别出对情感标签有真正影响的特征词，作者认为这些单词是对于数据集的情感标签有核心预测作用的因果特征词，借助 wordnet 获得这些单词的反义词之后，将一个样本中的因果特征词替换为其反义词，标签为原始样本的相反标签，从而获得反事实样本，实验结果证明通过将该方法生成的反事实样本与原始样本组合训练，尽管没有众包技术得到的反事实增强方案效果好，但与不做反事实增强的基准模型相比，仍然有较好的分布外泛化能力。类似地，Yang 等人 (2021) 也通过先识别因果项，再基于特定规则编辑因果项的方式来生成反事实样本，不同的是，这篇工作使用 Moverscore 评估不同反事实与原始样本之间的编辑距离，以提高反事实文本的生成质量，但上述这些方法只对句子的部分单词做出编辑和修改，在语言流畅性方面仍有欠缺。

随着预训练语言模型的技术发展，利用生成式语言模型实现反事实自动增强的方法逐渐被探索，有代表性的工作包括：Ployjuice (Wu 等人, 2021), GTC (Madaan 等人, 2021)。具体来说，Ployjuice 利用提示学习技术，设计 8 种不同的扰动类型，包括：否定、插入、删除等操作，以 GPT-2 为基本模型，在 6 个成对句子数据集上微调模型，实现反事实的生成，此外，增加语言流畅的过滤模

块,放弃那些与原始文本对数概率差异较大的反事实样本,保证了生成的语言表达有意义。另一种基于语言模型的反事实生成方案是 GTC(Madaan 等人,2021),该方法类似于控制文本生成技术,包括两个目标:(1)通过扰动矩阵 $\tilde{H}_t$ 重建输入文本,最小化重建损失意味着生成的文本与原始输入文本需要是相似的;(2)通过扰动矩阵 $\hat{H}_t$ 实现控制目标(标签反转),要求生成文本与原始文本的模型预测结果相反,由于第二个目标涉及到不可微分的损失,作者借鉴强化学习中常用的奖励函数来执行优化过程。

除了提高反事实样本生成质量之外,另外一种思路是如何最大效率利用低资源的人工标注反事实样本。从反事实表示学习而非反事实样本生成的角度,De Raedt 等人(2022)从少量标注的<原始样本,反事实样本>中学习从原始样本表示到反事实样本表示的映射函数,利用该方案在只添加 1%人工反事实样本的情况下,模型取得了显著的精度提升,与添加 100%的分布内训练样本相比,精度提升了 3%。

(二) 基于域不变性的学习

从样本角度调整数据分布,可以促使模型将注意力放在因果相关性特征上,另外一种思路则从域泛化的角度展开,对于同一任务多个领域的观测数据集(比如情感分类任务中,有饭店评论、笔记本电脑评论,以及金融新闻等不同领域的情感分类数据集),因果相关性特征具有在不同领域下对预测变量影响稳定的特点,而虚假相关性特征对于域改变则比较敏感。基于这一思路,Shen 等人提出了基于变量聚类的差分变量去相关(Differentiated Variable Decorrelation, DVD)算法,该方法将来自多个环境的未标记数据纳入变量去相关框架中,变量根据其相关性的稳定性进行聚类,使用变量去相关模块学习一组样本权重,以去除变量与不同类别之间的相关性,在合成数据集和真实数据集进行实验,实验结果证明了 DVD 算法可以改善模型的参数估计,且提高模型在分布外的预测稳定性。传统的经验风险最小化思路,促使模型捕捉一切相关特征,Ahuja 等人(2020)提出不变风险最小化的目标,尝试让机器学习方法从多个环境或领域的数据集中学习到那些与标签有稳定预测关系的特征。对于文本问题,Chang 等人(2020)提出不变合理化方案,也属于类似的思路,在此工作中,作者将学习到的特征集合称为“理由”(Rationale),核心思路是从原始特征集学习到一组特征可以使得经验风险最小化的同时,使得域无偏预测器与域敏感预测器的预测值越近越好。

此外，上文提及的反事实样本增强方案（Yang 等人，2021）中所涉及到的因果/虚假特征识别了，也利用了类似的思路，随着领域变化，对标签的影响系数有显著变化的特征更倾向于是虚假相关特征。T. Wang 等人（2022a）在识别电影评论情感分类任务中的虚假特征时，先使用该领域的情感分类数据集预测一个分类模型，而后利用该模型在书籍情感分类领域做预测，通过预测能力是否发生改变来区分虚假相关性特征和因果相关性特征。

（三）基于因果干预的学习

上述工作是以不同领域为前提的，在单一领域中，学习因果特征往往从任务特点本身出发，建立数据生成过程的因果图假设，利用因果推断领域中的去混杂技术，改变数据集的分布，使得模型学习的相关性更接近于因果相关性。以图像表示学习工作中的 VC-R-CNN 模型为例（T. Wang 等人，2020），作者认为视觉常识可以被视作为一种因果联系，常见的表示学习会捕捉到同一张图片中的两个对象之间的相关性，而忽略了场景的混杂影响会导致两个对象之间的相关性是被夸张或缩小的。作者将场景信息作为混杂变量，利用“do 算子”理论，将数据集中的分布转换为无混杂情况下的分布，从而学习两个对象之间的因果联系。实验结果证明，加入因果干预的预测是更加稳健的预测。类似的思路也应用在自然语言处理领域中的词向量表示学习任务上。S. Zhang 等人（2021）提出在掩码式语言模型中，上下文和被预测的单词之间可能是被其他单词所共同影响的，在解码模型阶段中加入去混杂模块，实验结果表明，所提方案在信息抽取、视觉问答等任务上表现是更加稳健的。Niu 等人（2020）利用因果分析消除 VQA（Visual Question Answering（VQA））任务中的语言偏差。

类似的方向还包括稳定学习（Kuang 等人，2020；Shen 等人，2018；Yuan 等人，2021；X. Zhang 等人，2021）。这类方法的核心是学习一组样本权重，去除变量之间的相关性，使得模型拟合的相关性更接近于因果相关性。这种方法与上文的干预方式殊途同归，均是以去混杂为手段（建模干预概率或样本加权），重新调整数据集的分布。具体来说，Shen 等人（2018）提出 CRLR 算法，通过联合优化全局混淆平衡和加权逻辑回归两个目标，实现因果特征的学习，在人工数据集和真实数据集上的实验结果显示该方法超过当前最优模型，并且这种方法具有可解释的优势。Kuang 等人（2020）将上述工作推广到了连续变量情况下，实现变量两两之间线性无关。然而，之前的去相关方法只能去除线性相关，为了

去除非线性相关，Zhang 等人（2021）使用随机傅立叶特征将原始特征映射到高维空间，再消除新特征间的线性相关，从而消除原始特征之间的非线性相关。

第三节 本章小结

本章从自然语言处理技术的脆弱性识别以及在不同的虚假线索背景下如何提升模型对因果特征的捕捉能力两方面，分类总结国内外在该领域的研究现状以及发展趋势。在发现方面，现有对NLP模型虚假相关性的研究集中在可统计的线索上，比如：词分布，而与语义相关的抽象线索尚未被探索；在缓解方面，已知虚假线索下，现有改进方案在缓解虚假关联方面有一定的成效，但可能会带来两个后果。一方面，针对一种线索的去偏方案，可能会带来对另外一种浅层线索的依赖；另一方面，在执行去偏算法的过程中，忽视该线索与目标变量存在的真实因果影响，盲目地去偏可能会降低模型的识别能力。当虚假线索未知时，为缓解虚假相关性对模型的影响，不少研究工作以学习因果特征为目标构建解决方案。然而，常见的反事实样本增强方案对样本生成质量要求较高，尤其是在长文本的情况下，效果有限。利用因果特征具有域间不变性特点进行学习的方式则要求训练集包括不同领域的数据，这往往较难满足。针对现有研究所面临的上述问题，本文后续章节将从发现和缓解两个步骤对自然语言处理任务中的虚假相关性展开研究，在发现层面，以常识因果推理任务为例，探索和分析语义相似偏差对模型脆弱性的影响；在缓解层面，分别针对已知虚假线索和未知虚假线索两种问题背景，以自然语言处理模型的公平性与稳健性为目标导向，对缓解虚假相关性的方法进行研究。

第三章 常识因果推理任务中的语义相似偏差现象分析

第一节 引言

随着预训练语言模型的出现,从大规模语料中学习上下文语义表示,以特征提取或微调的方式辅助下游任务训练,已成为解决自然语言处理任务的通用范式。深度学习算法在诸多自然语言处理任务中取得了令人满意的预测效果,在一些任务上甚至超越了人类的表现。在常识因果推理任务(Choice of Plausible Alternatives, COPA)上,预训练语言模型 DeBERTa(He 等人, 2020)达到了 98.4% 的准确率,表现惊人,但这是否就意味着模型具有了常识因果推理的能力呢?任务复杂性及其对世界知识的要求暗示着预训练语言模型所展现出的因果推理能力可能是被高估的。

深度学习算法以尽可能准确预测标签为目标,在训练过程中,会尽力学习训练数据中所有的相关性线索,最终执行预测时或许准确率很高,但在分布外对抗测试集上表现下降,从而引发模型的可靠性以及公平性等问题。因此,最近有很多研究工作关注自然语言处理常见任务数据集中的虚假相关性现象。比如,在自然语言推断任务中,词重叠程度、句子长度(Gururangan 等人, 2018),和非平衡的词分布(Kavumba 等人, 2019)等都被识别为任务的虚假线索。

COPA 是一项自然语言处理任务,给定一个前提事件, COPA 系统需要根据问题类型,选择前提事件的原因或者结果。下面是 COPA 任务中的一个例子:

Premise: The item was packaged in bubble wrap.

asks-for: "cause"

Alternative1: It was fragile. ✓

Alternative2: It was small. ✗

针对此因果问答任务,使用 BERT 模型(Devlin 等人, 2019)在 COPA 训练集上微调,可以获得 69.5% 的准确率,但与此同时,初探试验发现,一个基于 BERT 的语义相似度模型(Mulyar, 2020),在不利用 COPA 训练集的情况下,通过比较两个候选事件与前提事件的语义相似程度预测正确答案,也可以获得高达 66.8% 的准确率。这暗示着 BERT 在 COPA 训练集上学习时,也可能会选择语义相似线索作为其判断依据。而同一事件的原因和结果通常共享相似的上下文,

那么预训练语言模型可以区分 COPA 任务要问的问题 (“ask-for”) 是 “cause” 还是 “effect” 吗?

基于以上分析, 本章以常识因果推理任务 COPA 为例, 探索预训练语言模型在该任务上的脆弱性表现。具体创新点如下: (1) 提出预训练语言模型预测 COPA 任务所依赖的一个新的不易被发现的虚假线索: 语义相似性; (2) 通过设置两种干扰实验: 前提干扰和问题类型干扰, 测试模型表现, 验证模型对语义相似的过度依赖假设。

第二节 相关工作

一、常识因果推理方法

在 COPA 任务上, 传统的解决方案是通过无监督的统计方法来完成的。从大规模语料库中统计单词对的因果指标, 然后在 COPA 测试集计算两个选项的得分, 取较高者为正确答案。所用到的指标包括: 点互信息、基于因果句计算的因果共现分数 (Gordon 等人, 2011; Luo 等人, 2016; Roemmele 等人, 2011; Sasaki 等人, 2017) 等。具体来说, 在统计阶段, 从大规模语料中计算两个单词的共现程度, 最初的工作使用非对称的点互信息 (PMI, Pointwise Mutual Information) 来近似两个单词的因果强度 (Gordon 等人, 2011; Roemmele 等人, 2011), 收集了所有单词两两之间的因果强度之后, 形成词与词之间的因果分数库, 在评估阶段, 将测试样本中前提句的内容词 (去除停用词), 与选项句中的内容词两两配对, 从之前收集的因果分数库中调取每个词对对应的分数, 进行汇总得到前提句与这个选项句的因果分数, 两个选项中与前提句因果分数最高的即为该系统预测的答案。此外, 前人还曾通过特征构建的方式, 使用有监督算法, 将常识因果推理任务 COPA 作为分类问题或序列生成任务来学习。Roemmele 和 Gordon (2018) 从 ROC 语料 (作者假设带有时序信息的故事文本可以近似因果句子对) 中抽取因果句子对, 使用编码-解码的框架来训练因果生成任务, 最后在两个选项上计算生成概率, 选择生成概率最高的选项作为正确答案。

预训练语言模型利用其提取上下文语义的优势, 在解决 COPA 任务方面也取得了很大进展。Li 等人 (2019) 利用排序损失, 使用 COPA 数据集在 BERT 上微调, 达到了 75.4% 的准确率, 成为首次超过基于知识库系统表现的模型。RoBERTa 和 ALBERT 也曾在该任务上获得了优异的准确率表现, 分别是 86.4%

(Sakaguchi 等人, 2020) 和 92.1% (Kavumba 等人, 2019)。最新研究表明, 基于解耦注意力的 DeBERTa 模型 (He 等人, 2020) 在该任务上已经实现了高达 98.4% 的准确率。

二、自然语言推理任务中的虚假相关性

虚假线索统计是指基于先验知识对训练数据集中的浅层线索进行统计, 比如: 特定的词、句长, 或语法结构 (Gururangan 等人, 2018), 通过统计这些线索对标签的倾向分布来探究该任务存在的偏差现象, Rudinger 等人 (2017) 通过点互信息来定性分析 SNLI 数据集中的性别、种族、年龄偏差现象; Dasgupta 等人 (2018) 发现 SNLI 数据集中词重叠/反义词/否定词对标签均有影响。通过部分输入, 观察模型的表现变化, 同样可以检测模型的鲁棒能力。如: 在文本蕴含任务中, 若模型接收的输入不包括前提, 仍然能取到较好的预测效果 (Gururangan 等人, 2018; Poliak 等人, 2018; Tsuchiya, 2018), 则说明模型原有的高性能表现是被过高估计的, 因为这不符合人类的推理直觉。

在常识因果推理任务上, 前人工作表明了特定单词在正确答案与错误答案之间的非平衡分布给模型提供了判断线索 (Kavumba 等人, 2019), 并且提出 BERT 的优异表现可以被解释为模型对这种线索的过度捕捉, 作者提出数据增强方法阻止模型从词分布中学习预测。具体来说, 为原始 COPA 训练集中的每一个样本, 人工生成一个新的前提事件, 使得这个新前提事件的问题答案是原始样本中的错误答案, 以此得到一个 mirrored-COPA 数据集, 二者共称为 BCOPA 数据集, 将两个数据集结合后, 每个单词在正确答案和错误答案之间的分布是均匀的。实验结果发现数据增强方法可以改进模型在 COPA-test-hard 数据集上的表现。

第三节 语义相似偏差假设

一、COPA 任务介绍及基本模型框架

Roemmele (2011) 提出常识因果推理任务 COPA, 它是一项自然语言处理任务, 给定一个前提事件, COPA 系统需要根据问题类型, 选择前提事件的原因或者结果。该任务也作为 SuperGlue (A. Wang 等人, 2019) 基准测试集之一, 来评估模型的语言理解能力。

常用的预训练语言模型在处理 COPA 任务时, 会将问题类型信息蕴含在输

入顺序中。根据问题类型，每个样本都会构造出两个原因-结果句。具体来说，如果问题类型是“*cause*”，即要在两个候选事件中选出前提事件的原因，此时的输入对是：{[CLS] 候选事件 1 [SEP] 前提事件}和{[CLS]候选事件 2 [SEP] 前提事件}；如果问题类型是“*effect*”，即要在两个候选事件中选出前提事件的结果，此时的输入对是：{[CLS] 前提事件 [SEP] 候选事件 1}和{[CLS] 前提事件 [SEP] 候选事件 2}。原因在前，结果在后，中间用 [SEP] 分隔开。根据问题类型的不同，前提会被放在不同的位置进行输入。

文中实验所用到的基本模型框架如图 3- 1 所示，首先，将两个原因-结果句子输入预训练语言模型，参数为 θ ，取出第一个位置[CLS]的隐藏层向量，其中， i 表示第 i 个原因-结果句子：

$$h_i^0 = \theta(c_i, e_i) \quad (3.1)$$

输入全连接层，参数为 ω ，获得输出：

$$z_i = \omega^T h_i^0 + b \quad (3.2)$$

在训练阶段，将 $[z_0; z_1]$ 经过 softmax 操作后的概率分布与标签计算交叉熵损失，优化模型参数。在测试阶段，最终的预测结果通过比较 z_0, z_1 的大小而得出，即 $i^* = \operatorname{argmax}_{i \in \{0,1\}} z_i$ 。如果评估的是三项选择的测试集，预测结果为：

$$i^* = \operatorname{argmax}_{i \in \{0,1,2\}} z_i \quad (3.3)$$

值得注意的是，模型参数 θ, ω, b 是被两个原因-结果句所共享的。




图 3- 1 预训练语言模型在 COPA 任务上的基本框架

二、COPA 任务中的偏差现象

（一）非平衡的词分布偏差

前人工作探究了特定单词在正确答案与错误答案之间的非平衡分布给模型提供了判断线索（Kavumba 等人，2019），并且提出 BERT 的优异表现可以被解释为模型对这种线索的过度捕捉。相应地，Kavumba（2019）提出以数据增强的方式，阻止模型从词分布中学习预测。具体来说，为原始 COPA 训练集中的每一个样本，人工生成一个新的前提事件，以使得这个新前提事件的问题答案是原始样本中的错误答案，以此得到一个 mirrored-COPA 数据集，二者共称为 BCOPA 数据集。将两个数据集结合起来，每个单词在正确答案和错误答案之间的分布是均匀的。

此外，该工作将 COPA 的原始测试集分为 COPA-test-easy 和 COPA-test-hard，easy 是指模型在看不到前提下也能做出正确选择的样本（即模型的预测依赖选项中的浅层线索），反之则为 hard 样本。实验结果证明数据增强后的训练可以有效缓解模型对词分布偏差的依赖，提高模型在 hard 数据集上的表现。

（二）语义相似偏差

使用 BERT 模型（Devlin 等人，2019）在 COPA 训练集上微调，可以获得 69.5% 的准确率，但与此同时，初探试验发现，一个基于 BERT 的语义相似度模型（Mulyar, 2020），在不利用 COPA 任务训练集的情况下，通过比较两个候选事件与前提事件的语义相似程度预测正确答案，也可以获得高达 66.8% 的准确率。这暗示着 BERT 在 COPA 训练集上学习时，也可能会选择语义相似线索来作为其判断依据。而随之带来的思考是，既然同一事件的原因和结果通常共享相似的上下文，那么当预训练语言模型对一个事件的原因或结果做出正确预测时，它真的可以区分 COPA 任务要问的问题（“ask-for”）是 “cause” 还是 “effect” 吗？还是说它的预测结果仅仅是通过语义相似的比较，因为通常错误选项和前提的语义相似性，比正确选项与前提的语义相似性要小得多。

表 3-1 中的例子似乎能在一定程度上验证猜想，这个样本来自 COPA 的验证集，在这个特殊的样本中，“*The woman banished the children from her property.*”

（这个女人把小孩子们赶出了她家）的 “cause” 更有可能是选项 2 的事件，而错误答案（选项 1）也并不是完全语义无关的事件，而是前提事件的合理 “effect”，这样的样本似乎对 BERT 模型来说较为困难。

表 3-1 一个 BERT 预测失败的验证集样本

A Sample from development dataset
Premise: The woman banished the children from her property. ask-for: "cause" Alt1: The children hit a ball into her yard. × (effect) Alt2: The children trampled through her garden. ✓ (cause)

以上观察分析暗示着，模型令人满意的表现可能是来自于对语义线索的过度捕捉，而非是真正精细的理解原因和结果，第四节将通过设置干扰实验来验证本章的猜想。

（三）因果⁵图视角的虚假相关分析

COPA 数据集来源于网络中的故事文本，从因果图的角度来说，选项句与前提句的语义相似度之所以可能成为模型预测目标的线索，是因为数据选择偏差的存在。




图 3-2 语义相似线索与预测目标呈现虚假关联的因果图（以原因问题为例）

具体来说，如图 3-2 所示，以原因问题为例，当给定数据标注者前提事件时，他需要为前提句生成原因事件句（即正确答案句），以及非原因句（即错误选项

⁵ 注：这里的因果图是指因果推断领域下的因果图，而非常识因果推理任务下的因果事件

句), 此刻存在一种较为容易的数据选择方式, 即从前提事件所在的故事情境的文本中选择原因事件的候选, 那么原因事件很有可能是和前提事件具有相似的语义(拥有类似的上下文); 对于非原因事件(错误选项), 数据收集者更倾向于选择与前提语义无关的句子。然而, 不考虑实操难度的情况下, 数据也可以有很多种选择方式, 即选择那些与前提事件语义相差很大的原因事件。原因事件与前提事件的语义相似不是人类将其判断为原因事件的必要依据。正是这样的一种选择偏好, 数据集在选择原因事件时, 更容易倾向于那些与前提事件语义较为相似的原因事件, 因此数据集中语义相似度与预测目标之间存在过多的相关性。

第四节 干扰实验及结果分析

与词分布或句子长度等直接显示在数据集中的浅层线索不同, 间接的语义线索无法进行统计分析。我们通过特殊的干扰实验来探究预训练语言模型是否过度依赖语义相似性。首先, 我们来观察如果预训练语言模型看到一个干扰选项时的表现情况。此外, 受表 3-1 的启发, 我们对模型在预测过程中是否意识到问题类型进行探究。

一、实验一: 前提为干扰选项

第一个干扰实验通过添加第三个选项来给模型设置干扰, 第三个选项的设计原则包括两个: (1) 与前提句语义相似; (2) 不是正确答案, 即不会对人类的判断形成干扰。

“前提”是一个很好的候选, 因为它在语义上与自身高度相关, 而由于因果关系的非自反性特征, 它不能成为自身的原因或结果, 即满足第二个原则, 不会对人类的判断形成干扰。我们可以预期到这样的结果: 如果模型过分依赖语义相似, 那么当模型遇到第三个选项(前提), 它会倾向于选择第三个选项, 即模型成功被干扰。同时, 我们需要确保预测性能的下降不是因为问题难度增加。因为它从二元选择问题变成了三元选择问题。因此, 我们为前提干扰实验设置了对照组, 在对照实验中, 我们随机添加一个干扰选项。最终, 将前提干扰实验的结果与对照实验的结果进行比较, 两者若有较大的不同, 则验证前文所述的语义偏差假设。从因果图的角度来说, 设置前提干扰实验的动机是阻断路径 $Z \rightarrow X_S$ 的传播, 即对语义相似不再有选择偏好, 因此, $X_S \rightarrow Y$ 的之间的相关性在新的测试集上发生改变。过分依赖语义相似线索的模型会在前提干扰的测试集上表现下

降。

• **COPA-random**: 我们通过从 COPA-test 集中随机抽取一个错误选项作为每个样本的第三个选项，从而来控制干扰实验中的问题难度。在报告实验结果的表 3-3 中，这一测试集的结果被称为“Rand”。

• **COPA-premise**: 我们把前提本身作为第三个干扰选项。在报告实验结果的表 3-3 中，这一测试集的结果被称为“Prem”。

二者的表现差距越小，说明模型对语义相似的依赖越小，模型越稳健。

二、实验二：掩盖问题类型

如上所述，如果模型过度依赖语义相似性成立的话，随之带来的思考是，既然同一事件的原因和结果通常共享相似的上下文，那么当预训练语言模型对一个事件的原因或结果做出正确预测时，它真的可以区分 COPA 任务要问的问题（“ask-for”）是“cause”还是“effect”吗？还是说它的预测结果仅仅是通过语义相似的比较？因为通常错误选项和前提的语义相似性，比正确选项与前提的语义相似性要小得多。

关于模型是否会忽略问题信息（原因或结果）的猜想。这里通过掩盖问题类型的方式来验证。常用的预训练语言模型在处理 COPA 任务时，会将问题类型的信息蕴含在输入顺序中。根据问题类型，每个样本都会构造出两个原因-结果句。下面以 BERT 为例，对该任务的输入构建方式进行说明。

• 如果问题类型是“cause”，即要在两个候选事件中选出前提事件的原因，此时的输入对是：{[CLS] 候选事件 1 [SEP] 前提事件}和{[CLS]候选事件 2 [SEP] 前提事件}

• 如果问题类型是“effect”，即要在两个候选事件中选出前提事件的结果，此时的输入对是：{[CLS] 前提事件 [SEP] 候选事件 1}和{[CLS] 前提事件 [SEP] 候选事件 2}。原因在前，结果在后，中间用 [SEP] 分隔开。

根据问题类型的不同，前提会被放在不同的位置进行输入。在掩盖实验的具体操作上，对于每个测试样本，我们将前提随机放入不同的位置，即随机给样本安排一个问题类型。

由于只有两种问题类型，因此，在统计学意义上，将会有一半的样本保持原来的问题类型，而其他样本会得到相反的问题类型，这些问题类型并没有真正的正确答案。我们观察模型在没有看到问题类型的情况下是否仍然保持良好的性

能。

如果模型仍然保持良好的性能，则说明模型预测并未深入编码问题类型信息。在报告实验结果的表 3-3 中，我们将这个实验设置称为“Mask”。模型在 COPA-test 上的表现称为“Test”，二者的差距越大，模型的稳健性越强。

三、对比模型介绍

本文所使用的对比模型包括基于知识库的推理系统以及基于预训练语言模型的推理系统，从而对比不同推理方式在干扰实验下的表现。下面对实验中所使用到的模型做详细介绍。

（一）基于知识库的常识因果推理任务

基于知识库对 COPA 测试集中的问题进行预测是比较传统的推断方式，这种方式是通过计算前提和选项的因果强度来进行的，流程如图 3-3 所示。具体来说，在统计阶段，从大规模的语料中计算两个单词的共现程度，最初的工作使用非对称的点互信息（PMI, Pointwise Mutual Information）来近似两个单词之间的因果强度（Gordon 等人，2011；Roemmele 等人，2011），收集了所有单词两两之间的因果分数之后，形成词与词之间的因果分数库，在评估阶段，将测试样本前提句的内容词（去除停用词），与选项句的内容词两两配对，从之前收集的因果分数库中调取每个词对对应的相关分数，进行汇总得到前提句与这个选项句




图 3-3 基于知识库进行尝试因果推理的流程

的因果分数，两个选项中与前提句因果分数最高的即为该系统预测的答案。

然而，这种指标计算的方式只体现出词与词之间的关联性，考虑到因果事件中的词关联并不仅仅是共现关系，Luo 等人（2016）事先通过人工定义的因果模板对语料进行筛选，然后统计两个单词出现的因果共现的频次（ w_i 出现在原因句， w_j 出现在结果句的次数），利用因果共现的频次，为两个单词分别定义一个新的因果强度指标，该指标集成了人类因果性内涵中所包括的充分因果和必要因果概念，后续评估阶段的方式与先前工作相同。此外，Sasaki 等人（2017）在此工作的基础上，将知识库中的项从单词粒度扩展到多词表达的短语粒度，达到了基于知识库计算常识因果推理任务的最优表现。这种方法也是本文后续实验中的对比方法之一。

（二）基于预训练语言模型的常识因果推理任务

随着预训练语言模型（Pretrained Language Models, PLMs）的出现，从大规模语料中学习上下文的语义表示，以特征或微调的方式辅助下游任务训练，已成为解决自然语言处理任务的通用范式。对于常识因果推理任务也不例外，DeBERTa（He 等人，2020）在 COPA 任务上的准确率表现高达 98.4%。因此，本文也想探讨这些模型在遇到干扰选项时表现如何。下文实验中所涉及到的预训练语言模型包括 BERT、RoBERTa、ALBERTa，和 DeBERTa，下面对这些模型以及各自的特点做简要的介绍。这些不同的语言模型均使用预训练模式，根据其训练目标的不同设计，属于在 BERT 基础上的不同变体（从模型命名可以体现）。首先，介绍基于上下文的预训练语言模型的起源；其次，介绍在诸多预训练语言模型中起关键作用的 Transformer 特征抽取模块；最后，总结实验中所用到的四个预训练语言模型的不同之处。

1. 基于上下文的词向量

最初的词向量是基于词袋模型来表示的，比如 onehot 编码和 TF-IDF 编码，但这种词向量表示维度较高，且忽视了词与词之间的关系和语序信息。接着，神经网络语言模型（Arisoy 等人，2012）被提出，该方法设计网络结构，根据一个单词的上文，来预测这个单词。网络训练结束后，可以将第一层网络的权重矩阵作为单词的词向量表示。整个过程的目标局限于语言模型的预测，而词向量矩阵只是训练过程中的副产品。当训练的主目标转变成“获得词向量表示”时，网络

的输入信息可以不再受限于上文，而是可同时使用上文和下文双向的语义信息，Word2Vector (Mikolov 等人, 2013) 就是这样的做法。

然而，以上这些方法都存在一个问题，即同一个单词在不同上下文中的向量表示相同，这样就无法处理一词多义的问题。基于上下文的词向量学习，最初来自于 ELMO 模型 (Peters 等人, 2018)，该模型通过 Bi-LSTM 特征抽取模块，可以捕捉双向的上下文信息，最终将原始 embedding 层的词向量与两层 LSTM 隐藏层向量拼接起来作为单词的词向量表示，从而使得同一个单词在不同的上下文中可表示为不同的向量。然而，LSTM 的特征抽取能力，在长文本上是有限的，且不能以并行的方式执行，随着 Transformer 模型的提出，自注意力模块所带来的并行能力证明了其在特征抽取方面的优势，因此 GPT、BERT 均选择该模型作为其特征抽取模块。

2. Trasformer 特征抽取模块⁶

Transformer (Vaswani 等人, 2017) 最初是在机器翻译中提出的模型，包括完整的编码-解码模块，解码模块是为了序列生成，使用的注意力模式与编码模块略微不同，其它网络设置相同，在自编码式预训练语言模型中使用的仅是其中的编码模块，因此，这里从特征抽取器的角度来讲，Transformer 是指编码模块。

Transformer 网络架构图 (Alammar, 2019) 如图 3-4 所示，一个 transformer 模块包括：融合了位置信息的词向量模块、多头自注意力模块、求和与归一化模块、前馈神经网络，以及求和与归一化模块。

由于 Transformer 本身并不带有时序信息的捕捉，因此，编码层既对词信息进行编码，又对位置信息进行编码。多头自注意力机制是核心模块，下面对此模块做出简要介绍。假设当前 Transformer 模块的输入是 $X \in \mathbb{R}^{l \times d_{model}}$ ，多头自注意力模块的输出过程为：

- 通过线性转换获得第 i 个头所有位置的查询向量 $Q_i = XW_i^Q$ 、键向量 $K_i = XW_i^K$ ，以及值向量 $V_i = XW_i^V$ ；
- 计算注意力，以及对值向量加权汇总。

$$Z_i = \text{Attention}(Q_i, K_i, V_i) = \text{softmax}\left(\frac{Q_i K_i^T}{\sqrt{d_k}}\right) V_i$$

- 多头结果汇总，再线性转换，得到多头自注意力模块最终的向量输出。

⁶ 此部分介绍的参考资料来源：<https://zhuanlan.zhihu.com/p/54743941>，以及 <https://jalammar.github.io/illustrated-transformer/>

$$Z = \text{MultiHead}(X) = \text{Concat}(Z_1, \dots, Z_h)W^O$$

多头自注意力机制不仅可以实现快速并行，通过自注意，使得每个单词都可以注意到其它单词的信息，从而解决长距离依赖的问题，其中多头的形式，扩展了模型专注于不同位置的能力。




图 3-4 Transformer 模块的网络架构

3. BERT、RoBERTa、ALBERT、DeBERTa 区别

各大语言模型均利用了 Transformer 的特征抽取能力，通过设置不同的语言学目标，以自监督的方式从大规模语料中学习语义表示。预训练学习到的参数可以编码文本中的语义信息，从而在下游任务的数据中微调使用。下面对实验中使用的四个模型做出对比，对比情况见表 3-2。

不同的预训练目标也对模型的稳健性有一定的影响，比如更多数据，更大批次训练的 RoBERTa 稳健性能也更强。在后文的掩盖问题类型设置下，ALBERT 模型是所有预训练语言模型中脆弱性最低的，这是其句子语序预测（Sentence

Order Prediction, SOP) 预训练目标所带来的优势。该模型对句子语序的编码比较敏感, 而问题类型又是以语序方式体现在输入中, 因此 ALBERT 模型表现相对比较稳健。

表 3-2 不同预训练语言模型对比

模型	使用的版本	预训练主要特点	参数
BERT	bert-large-uncased	静态掩码; 下句预测 (NSP)	24 层 transformer 模块, 1024 向量维度, 16 注意力头数; 336M 参数量
RoBERTa	roberta-large	动态掩码; 数据更多、算力更多、更大 batch	24 层 transformer 模块, 1024 向量维度, 16 注意力头数; 355M 参数量
ALBERT	albert-xxlarge-v1	句子顺序预测 SOP; 部分参数共享	12 层 transformer 模块, 128 embedding 维度, 4096 向量维度, 64 注意力头数; 223M 参数量
DeBERTa	deberta-large	自注意解耦机制; 增强 MLM	24 层 transformer 模块, 1024 向量维度, 16 注意力头数; 350M 参数量

(三) 基于数据增强的常识因果推理模型

Kavumba (2019) 提出以数据增强的方式, 阻止模型从词分布中学习预测。具体来说, 为原始 COPA 训练集中的每一个样本, 人工生成一个新的前提事件, 以使得这个新前提事件的问题答案是原始样本中的错误答案, 以此得到一个 mirrored-COPA 数据集, 与原始测试集合并共称为 BCOPA 数据集, 在 BCOPA 中, 每个单词在正确答案和错误答案之间的分布是均匀的。

此外, 该工作将 COPA 的原始测试集分为 COPA-test-easy 和 COPA-test-hard 两个版本, easy 是指模型在看不到前提下也能做出正确选择的那些样本, 反之是 hard 样本。作者验证使用 BCOPA 数据集进行增强训练可以有效缓解模型对词分布偏差的依赖, 提高模型在 hard 数据集上的表现。为探究一种虚假线索的缓解方案是否影响模型对另外一种虚假线索的依赖, 本章也对数据增强模型进行了干扰实验。

四、实验部分

（一）基本模型

我们使用传统模型和领先的 COPA 模型进行上述实验。下面对各个模型的符号表示做出简要介绍。

- CS: Sasaki 等人 (2017) 从具有因果模板的语料库中提取因果知识, 进而估计 COPA 测试集中的因果得分来执行推理;
- PLMs: 使用预训练语言模型 BERT-large, RoBERTa-large, ALBERT-xxlarge-v1, 和 DeBERTa-large 作为基线模型, 在 COPA 训练集上微调, 使用 huggingface 执行;
- PLMs-aug: 使用上述预训练语言模型, 在 BCOPA 数据集上进行微调。

（二）实验设置

对于每个数据集, 将训练集以 8:2 的比例随机分割为训练集和开发集, 将 20 轮实验的均值表现记录为最终的报告结果, 每轮实验使用不同的随机种子初始化, 运行 20 个 epoch, 使用早停策略来终止模型的训练, patience 为 3, 使用 AdamW 优化器, 预先设置学习率为 $1e-5$, 采用预热策略, 每批训练的样本数量为 64。CS 模型采用原文提供的代码来进行, 其它实验代码使用 huggingface 提供的接口来实现。

五、结果与分析

（一）前提干扰实验结果分析

如表 3-3 所示, 在原始测试集上, DeBERT 是表现最好的模型, 达到了 91.6% 的准确率。ALBERT 和 RoBERTa 表现次之, 但也有着优异的表现。BERT 是所有预训练语言模型中表现最差的模型, 但也能达到 70% 左右的准确率。这也说明随着预训练语言模型的发展, 其在自然语言理解任务上的表现也越来越好的。

当增加随机项 (“Rand”) 时, 基于知识库的 CS 系统几乎不受到任何干扰, 而 BERT 则表现出脆弱性, 准确率下降 10%, 在不带有语义相似干扰的随机项面前, BERT 都改变了预测结果, 说明 BERT 模型还依赖了其它线索, 可能是词分布线索 (Kavumba 等人, 2019), 也可能是其它未被发现的线索。其它三个预训练语言模型指标只表现出轻微的波动。

与增加随机项干扰相比, 当增加前提选项干扰 (“Prem”) 时, 基于知识库的 CS 系统仍然是最稳健的, 表现稳定。这比较符合我们的认知, 储存在文本中的

人类经验因果知识是稳定的。而当预训练模型被前提选项干扰时，它们表现出不同程度的脆弱性。其中，BERT 的防御能力是最弱的，几乎完全被干扰项欺骗。RoBERTa、ALBERT 和 DeBERTa 也分别比“Rand”设置的表现下降了 16.6%、14.7%、12.9%。

综上分析，表 3-3 中的干扰实验结果支持了我们的假设，即预训练语言模型，尤其是 BERT 将语义相似作为虚假线索来执行预测。

表 3-3 不同推理模型在干扰实验下的表现

Model	Exp1: Perturbation			Exp2: Masking	
	Rand ↑	Prem ↑	Δ ↓	Test ↑	Mask ↓
CS	70.1	70.5	-0.4	70.8	61.1
b-l	59.3	11.6	47.6	69.5	69.0
b-l-aug	63.3	13.0	50.3	70.0	69.6
rb-l	83.3	66.7	16.6	86.3	82.8
rb-l-aug	85.6	65.7	19.9	87.3	83.5
alb	86.7	71.9	14.7	88.0	80.2
alb-aug	86.4	61.2	25.2	87.9	84.1
db-l	90.8	77.9	12.9	91.6	87.8
db-l-aug	91.1	78.9	12.2	91.8	88.8

（二）掩盖问题类型实验结果分析

与前提干扰实验的结果相似，BERT 在掩盖问题类型实验中也是最脆弱的模型，在看不到问题类型的情况下仍然保持着原有的准确率。而对于掩盖问题类型这种干扰方式，一个完美鲁棒模型的理论准确率应是概率水平的一半（即 50%）加上原始准确率的一半。CS 方法的准确率达到 61.1%，并且注重问题类型，表现较为稳健。相反，预训练语言模型似乎没有深刻理解问题类型，与原始测试集下的表现相似。不过，预训练语言模型并没有完全忽略问题类型，因为它们没有保持与原始测试集相同的性能。值得注意的是，在掩盖问题类型设置下，ALBERT

模型是所有预训练语言模型中脆弱性最小的，笔者猜测，这是因为 ALBERT 的预训练目标除了掩码预测，还包括句子语序预测（Sentence Order Prediction, SOP），对句子语序的编码比较敏感，而问题类型又是以语序方式体现在输入中，因此，ALBERT 模型表现相对比较稳健。

（三）数据增强方案干扰实验结果分析

数据增强方法来自于 Kavumba 等人（2019）提出的词分布去偏方案。在前提干扰实验中，除了 DeBERTa 之外，数据增强版本的预训练模型展现出的脆弱度甚至比原始模型更严重。而在掩盖问题类型的实验中，结果表明所有数据增强版的模型都更加看不到问题类型。笔者猜测，这可能是因为 BCOPA 中的每个句子对都出现了两次，模型更有可能捕获语义相似性。

第五节 本章小结

本章以常识因果推理任务 COPA 为例，观察预训练语言模型在该任务上的脆弱性表现。首先，本章提出预训练语言模型预测 COPA 任务所依赖的一个新的不易被发现的虚假线索：语义相似性；其次，通过设置两种不同的干扰实验：前提干扰和问题类型干扰，测试模型的表现，验证模型对语义相似的过度依赖假设。实验结果发现，预训练语言模型在 COPA 这个任务上，容易受到语义相似的干扰，模型在进行预测的过程中，尽管给出正确的预测，但是模型并未真正区分当前是在询问“原因”还是“结果”。此外，实验结果发现，针对词分布线索去偏的数据增强方案在语义相似的对抗攻击下，显示出更严重的脆弱性。因此，接下来的章节将探索如何设计更完善的去偏方案，避免模型脱离一种预测捷径后却又走向其它捷径。

第四章 基于反事实约束去偏的常识因果推理模型

第一节 引言

推理任务的复杂性及其对世界知识的要求暗示着预训练语言模型所展现出的语言推理能力可能是被高估的。自然语言处理任务中的虚假相关性逐渐受到研究者的重视。对于 COPA 这项常识因果推理任务，非平衡的词分布、语义相似性都曾被当做模型预测的浅层线索，依赖虚假线索往往虚夸了模型所表现出的语义推理能力。

近来对抗虚假相关性的研究主要集中在两个方面，第一种思路在训练阶段进行，针对已知的虚假线索设计惩罚损失或对抗学习目标（Cheng 等人，2021；Elazar & Goldberg, 2018；Garg 等人，2019；F. Liu & Avci, 2019），使模型在学习如何预测原始目标的同时，降低对虚假线索信息的捕捉；第二种思路在训练前阶段进行，主要是通过样本加权、样本补充、样本过滤等调整方式（Ball-Burack 等人，2021；Reichert 等人，2020；G. Zhang 等人，2020；Zmigrod 等人，2019），使得训练集样本对该虚假线索的依赖不再存在。现有改进方案在缓解虚假关联方面有一定的成效，但针对一种线索的去偏方案，可能会带来对另外一种浅层线索的依赖，且目前对常识因果推理模型稳健性的评估，往往是针对一项线索，对模型推理能力的脆弱性评估不够全面。因此，有两个问题是我们迫切关注的：如何更加全面的评估模型对虚假线索的依赖程度？以及如何降低模型对虚假相关性的捕捉能力？

基于以上分析，本章以常识因果推理任务 COPA 为例，缓解预训练语言模型在该任务上的脆弱性表现，所做的工作主要有以下方面的创新：

（1）提出缓解常识因果推理模型脆弱性的解决方案，具体来说，在原有训练损失的基础上增加反事实约束，该方案降低了模型对语义相似的依赖程度，在保持原有预测水平的基础上，在针对词分布线索的对抗测试集上表现也更加稳健；

（2）介绍了新的挑战测试集 BCOPA-CE，该数据集既可以评估模型对词分布线索的依赖程度，还可以评估一个模型区分原因和结果的能力，改进的模型在此数据集上表现更加稳健。

第二节 改进模型

一、COPA 任务

首先，回顾一个 COPA 任务的样例：

Premise: The item was packaged in bubble wrap.

asks-for: "cause"

Alternative1: It was fragile. ✓

Alternative2: It was small. ×

Roemmele (2011) 提出常识因果推理任务 COPA，它是一项自然语言处理任务，给定一个前提事件，COPA 系统需要根据问题类型，选择前提事件的原因或者结果。该任务也作为 SuperGlue (A. Wang 等人, 2019) 基准测试集之一，评估模型的语言理解能力。

常用的预训练语言模型在处理 COPA 任务时，会将问题类型信息蕴含在输入顺序中。根据问题类型，每个样本都会构造出两个原因-结果句。下面以 BERT 为例，对该任务的输入的构建方式进行说明。

- 如果问题类型是 “cause”，即要在两个候选事件中选出前提事件的原因，此时的输入对是：{[CLS] 候选事件 1 [SEP] 前提事件} 和 {[CLS] 候选事件 2 [SEP] 前提事件}

- 如果问题类型是 “effect”，即要在两个候选事件中选出前提事件的结果，此时的输入对是：{[CLS] 前提事件 [SEP] 候选事件 1} 和 {[CLS] 前提事件 [SEP] 候选事件 2}。原因在前，结果在后，中间用 [SEP] 分隔开。根据问题类型的不同，前提会被放在不同的位置进行输入。

文中实验所用到的基本模型框架如图 3-1 所示，首先，将两个原因-结果句子输入预训练语言模型，参数为 θ ，取出第一个位置 [CLS] 的隐藏层向量，其中， i 表示第 i 个原因-结果句子：

$$h_i^0 = \theta(c_i, e_i) \quad (4.1)$$

输入全连接层，参数为 ω ，获得输出：

$$z_i = \omega^T h_i^0 + b \quad (4.2)$$

在训练阶段，将 $[z_0; z_1]$ 经过 softmax 操作后的概率分布与标签计算交叉熵损失，优化模型参数。在测试阶段，最终的预测结果通过比较 z_0, z_1 的大小而得出，即 $i^* = \operatorname{argmax}_{i \in \{0,1\}} z_i$ 。如果评估的是三项选择的测试集，预测结果为： $i^* =$

$\operatorname{argmax}_{i \in \{0,1,2\}} z_i$ 。值得注意的是，模型参数 θ, ω, b 是被两个原因-结果句所共享的。和第三章类似，预训练模型在 COPA 任务上的整体框架如图 3-1 所示。

二、词偏差与语义偏差

前人的工作探究了特定单词在正确答案与错误答案之间的非平衡分布给模型提供了判断线索 (Kavumba 等人, 2019)，并声称 BERT 的优异表现可以解释为模型对这种线索的过度捕捉。此外，笔者也曾在先前工作中验证了 COPA 模型对语义相似的依赖，以至于会被第三个语义相似的选项干扰预测，且表现出无法区分问题类型（见第三章）。

三、反事实约束损失

针对常识因果推理任务中的语义相似偏差现象，提出基于反事实约束的改进方案。我们将“问题类型” (“ask-for”) 看作因果推断领域中的处置变量，假设 COPA 训练集中的样本为原事实样本，那么反事实样本则是与原事实样本具有相同的前提和选项，但问题类型相反的样本。我们期望模型对原事实样本做出正确的预测，但对反事实样本做出中立的判断，这是因为对于反事实样本，两个选项都不是正确答案。如此一来，满足这种要求的模型就可以在做出正确的选择的同时关注问题类型信息。

对于 COPA 训练集中样本，其损失函数包括两部分：交叉熵损失和反事实约束损失。第一部分促使模型尽可能准确预测，额外的反事实约束损失要求模型在相同的前提和选项下看到相反的问题类型时应该保持中立，因为任何选项都不是正确答案。

一般的 PLMs 把第一个输入的句子作为原因，第二个句子作为结果。从数学上讲，反事实约束损失要求改变问题类型后，两个选项的 logits 应该尽可能地接近，即使其中一个选项在语义上与前提相似（原始问题的正确答案）。

$$L = (1 - \lambda) * L_{CE} + \lambda * L_{Reg} \quad (4.3)$$

$$L_{Reg} = \|z_0^r - z_1^r\|_2^2 \quad (4.4)$$

z_i^r 是 $[e_i; c_i]$ 计算出的 logits, λ 为平衡原始损失和反事实约束损失的超参数，在所有实验中，设置 $\lambda = 0.01$ 。

（一）对词分布偏差的处理

所提方案倾向于达到的效果是：如果颠倒输入顺序时，则阻止模型捕获任何

线索，尽管此时数据集的词分布仍然是有偏的。因此在一定程度上改进方法可以降低模型对词分布的依赖程度。

(二) 对语义相似偏差的处理

改进方案对语义相似偏差的处理体现在问题类型上，此方法通过反事实思维暗示模型对相反问题类型的样本做出中立的预测，具体来说，假如当前是在问前提句的另外一种问题类型，那么这两个选项均不是正确答案。这是因为，对于原样本正确选项而言，一个事件的原因不可能是这个事件的结果，同样地，一个事件的结果不可能是这个事件的原因，因此原样本正确选项不可能是相反问题类型下的正确选项；对于原样本的错误选项而言，其恰巧是原始样本另外一种问题类型的正确答案（见表 3-1）概率较小。因此，两个选项均不是反事实样本下的正确答案，这种反事实约束在直觉上是成立的。

第三节 BCOPA-CE 数据集

为了同时对模型依赖词分布的程度以及依赖语义相似的程度进行评估，本章提出一个新的数据集 BCOPA-CE。

一、数据集介绍

如表 4-1 所示，我们引入一个平衡的 COPA 测试集 BCOPA-CE，将每个前提的原因事件和结果事件作为两个候选。

表 4-1 BCOPA-CE 样本示例

A Sample in COPA-test set	New Samples in BCOPA-CE test set	
Premise: The accident was my fault. ask-for: “effect” Alt1: I felt guilty. ✓ Alt2: I pressed charges. ×	Premise: The accident was my fault. ask-for: “effect” Alt1: I felt guilty. ✓ Alt2: I was absent-minded. ×	Premise: The accident was my fault. ask-for: “cause” Alt1: I felt guilty. × Alt2: I was absent-minded. ✓

具体来说，对于 500 个 COPA 测试样本中的每个前提事件，我们手动生成一个事件，该事件是原始样本相反问题类型的合理答案。以表 4-1 中的样本为例，对于前提：“The accident was my fault.”，原始样本要求 COPA 系统回答它的

“effect”，因此，我们生成一个可能的“cause”：“*I was absent-minded.*”。然后，对每个三元组<前提，前提的原因，前提的结果>，给出两个不同的问题（原因或结果）来构建 1000 个样本，即 BCOPA-CE。一方面，在 BCOPA-CE 中，两选项均和前提事件语义相似，但只有一个为正确答案；另一方面，选项中的每个单词，每在正确答案中出现一次，就会相应地在错误答案中出现一次。因此该数据集既可以评估模型对词分布的依赖程度，又可以评估模型对语义相似的依赖程度以及区分问题类型的能力。

二、 标注指导

我们请五位熟练掌握 NLP 背景知识以及英语的同学根据标注指导生成新的候选选项。类似于 Kavumba 等人（2019）的工作，标注原则中对句子长度、重叠规则和表达通俗性均提出相应要求。生成标注比识别标注困难很多，这里在生成表达句时，借鉴了先前工作（Li 等人，2020）所提供的因果生成模型的输出⁷，以供标注人员修改和编辑。这里的因果生成模型主要通过两个步骤来实现，首先，利用人工定义的暗含因果含义的语法模板，从大规模语料中抽取因果句，并进行切分。其次，使用类似于机器翻译任务中常用的 seq2seq 模型进行因果生成，比如生成结果模型，将原因句作为“源语言”，结果句作为“目标语言”，训练“翻译”模型，特别地，为了使生成的表达更加多元化，该工作利用候选词指导生成过程。

三、 质量评估

BCOPA-CE 数据集中共有 1000 个样本，包括 500 个样本，其答案与原始 COPA 测试集相同（表 4-1 BCOPA-CE 样本示例中第二列中的左侧样本，称为 COPA-CE-ori），另外 500 个样本的答案是我们生成的选项（表 4-1 中第二列的右侧样本，称 COPA-CE-opp）。为了确保生成数据集的质量，我们使用两个问题进行质量评估：

问题 1：对于人类来说，BCOPA-CE 数据集是否与 COPA 测试集的难度相当？

问题 2：我们收集的新选项对于相反的问题类型而言，是否算是比较合理的答案？

⁷ <http://221.207.166.58:8004/>

表 4-2 生成数据集质量的人类评估结果

	COPA-test	COPA-CE-ori	COPA-CE-opp
Accuracy	0.980	0.990	1.000
Fleiss' Kappa	0.919	0.893	0.890

为了回答第一个问题，我们在 COPA-CE-ori 数据集和 COPA-CE-opp 数据集上评估人类选择的准确性，对比 BCOPA-CE 与原始测试集的难度；为了回答第二个问题，我们评估 COPA-CE-opp 数据集上的人类表现。COPA-CE-opp 数据集更改了问题类型，并以生成的事件作为黄金答案，因此可以评估生成选项句的合理性。具体地，我们让 9 个人做选择，每组 3 人，每一组对同一个数据集做判断，通过多数投票决定最终选择。标注者之间的一致性由 Fleiss' Kappa 计算。如表 4-2 所示，BCOPA-CE 数据集具有与 COPA 测试相近的难度。COPA-CE-opp 的表现表明，我们生成的新候选是合理的。

第四节 实验及结果分析

一、数据集介绍

（一）COPA-test

该数据集为 COPA 任务原始测试集，共计 500 个样本，用来评估模型在分布内测试集下的预测能力。

（二）COPA-test-hard

Kavumba 等人（2019）向训练好的 COPA 模型输入测试集的选项句，而不输入前提句，发现模型仍然会有高于 50% 的准确率表现，这是不符合人类直觉的，说明模型捕捉到了预测的虚假线索。不输入前提仍然会被不同的 COPA 模型预测准确的样本被称为“easy”样本，反之属于“hard”样本。这里使用作者在这篇工作中提供的 hard 样本集来评估模型对词分布攻击的防御能力，缩写为：COPA-test-hard。

（三）BCOPA-CE 测试集

本章所介绍的数据集，包括 500 对样本（1000 条）。每对样本的选项相同，正确答案不同。该样本既可以评估模型对词分布攻击的防御能力，也可以衡量模型区分问题类型的能力。

二、对比模型

我们使用传统模型和领先的 COPA 模型进行上述实验。本章使用的模型与第三章的模型一致，关于以下模型的具体介绍见第三章第四小节。

- PLMs: 使用预训练语言模型 BERT-large, RoBERTa-large, ALBERT-xxlarge-v1, 和 DeBERTa-large 作为基线模型，在 COPA 训练集上微调，使用 huggingface 执行；

- PLMs-aug: 使用上述预训练语言模型，在 BCOPA 数据集上（见第三章第三节对数据集的解释）进行微调。

三、实验设置

对于每个数据集，将训练集以 8:2 的比例随机分割为训练集和开发集，将 20 轮实验的均值表现记录为最终结果，每轮实验使用不同的随机种子初始化，运行 20 个 epoch，使用早停策略来终止模型的训练，patience 为 3，使用 AdamW 优化器，预先设置学习率为 1e-5，采用预热策略，每批训练的样本数量为 64。实验代码使用 huggingface 提供的接口来实现。

四、结果与分析

表 4-3 展示了本章所提出的改进模型在 COPA 测试集、BCOPA-CE 测试集和 COPA-test-hard 测试集上的性能。

（一）语义相似的对抗效果

针对原始的 COPA 测试集，改进方案均比原来的 PLMs 表现得更好，即使是 BERT 模型（第三章中的实验结果分析验证了该模型对语义线索的依赖是最强的）。

针对语义相似的对抗效果见模型在表 4-3 中 BCOPA-CE 一栏的表现。从表中可知，具有反事实损失约束的模型在 BCOPA-CE 集上有更好的性能，有效缓解了模型对语义相似线索的依赖。值得注意的是，先前的针对词分布去偏的数据

增强模型比原始模型表现更差,这与我们的猜测一致,即它们放大了语义偏差。与第三章的干扰实验结果类似,在四个预训练语言模型中,ALBERT 的表现是最好的,其在 BCOPA-CE 数据集上的表现与原始测试集上的表现仅有 2.7% 的差距,这说明 ALBERT 的句子语序预测预训练目标,有助于模型区分 COPA 任务下的问题类型。

表 4-3 不同模型在挑战测试集上的实验结果

Model	Test ↑	BCOPA- CE ↑	Δ ↓	Test-hard ↑
b-l	69.5	51.5	18.0	61.6
b-l-reg	71.1	64.1	7.0	63.6
b-l-aug	70.0	51.1	18.9	69.7
rb-l	86.3	73.0	13.3	83.1
rb-l-reg	87.7	83.9	3.8	84.5
rb-l-aug	87.3	69.2	18.2	87.0
alb	88.0	80.5	7.6	86.9
alb-reg	89.4	86.7	2.7	88.6
alb-aug	87.9	71.4	16.5	88.0
db-l	91.6	72.3	19.3	88.6
db-l-reg	92.2	86.3	5.9	89.7
db-l-aug	91.8	69.8	21.9	90.5

表 4-4 错误样本分析

Original sample	<i>Premise:</i> The man's voice projected clearly throughout the auditorium. <i>Ask-for:</i> cause <i>Alt1:</i> He greeted the audience. × <i>Alt2:</i> He spoke into the microphone. ✓
New sample	<i>Premise:</i> The man's voice projected clearly throughout the auditorium. <i>Ask-for:</i> cause <i>Alt1:</i> Everyone heard him. × <i>Alt2:</i> He spoke into the microphone. ✓

（二）词分布的对抗效果

具有反事实约束损失的模型在 COPA-test-hard 上也比原始 PLMs 表现得更好，这个数据集可评估模型在词分布对抗攻击下的防御能力。这是因为反事实损失也考虑了词分布的去偏，当它颠倒输入顺序时，我们倾向于阻止模型捕获任何线索，其中也包括词分布线索。反事实约束方法在 ALBERT 和 DeBERTa 上的表现比较优异，几乎和人工标注的数据增强方案的表现相媲美。

（三）错误分析

我们对模型 DeBERTa 进行误差分析，这里使用的是最接近 20 轮实验平均值的模型。在表 4-4 中的 BCOPA-CE 样本上（第二行），DeBERTa 预测错误，但反事实约束的 DeBERTa 模型却成功预测。有趣的是，这两个模型都在 COPA 测试集中的原始样本（第一行）上做出了正确的预测，这表明我们生成的新候选扰乱了原始 DeBERTa 模型的选择。

（四）词重要度可视化

我们通过擦除法来计算正确答案中所有的单词重要性（Li et al., 2017）。首先依次将单词替换为 [MASK]，其次计算替换后的文本预测对数概率与替换前的相对差异，以此来作为单词的重要性分数。在这个原始样本中，我们观察到两个模型预测正确，但对单词的关注不同。




图 4-1 词重要程度的可视化

如图 4-1 所示，DeBERTa 通过关注“*He*”和“*spoke*”选择了 Alt2，但 DeBERTa-reg 最关注的是“*microphone*”，这更符合人类的因果直觉。当人类做出这样的推断时，“*麦克风*”与“*清晰地投射到整个礼堂*”之间的因果关系应该比共指关系更重要。

第五节 本章小结

针对常识因果推理模型依赖语义线索无法区分问题类型这一挑战，本章提出将反事实约束损失加入到训练目标中来改进模型。实验结果表明，该方法在对抗测试中是有效的，提高了模型在 COPA-test-hard 数据集以及 BCOPA-CE 数据集上的鲁棒性。此外，以往的词分布去偏模型对语义偏差的依赖程度比原始模型更加严重，这提醒我们去偏可能会带来新的偏差。为避免去偏方案最终只是饮鸩止渴，研究偏差之间的关联，设计更加通用的去偏方式是更加值得思考的。除了稳健性问题外，第五章将对公平性问题下的去偏算法进行探讨。自然语言处理技术公平性的问题背景下，虚假线索是明确的，即人类身份属性信息，针对该线索的去偏算法是否存在类似的偏差关联问题，以至于呈现出“矫枉过正”的模型预测，将在第五章进行详细探讨。

第五章 基于样本过滤机制去偏的歧视言论检测模型

第一节 引言

随着机器学习方法在众多领域中的应用，模型公平性引起了学者们的关注，即模型是否会对特定群体产生偏见。在自然语言处理领域，有些任务与人口属性信息（种族、性别）相关性较强，比如：情感分析领域下的歧视言论检测任务，厌女识别任务。在这些任务中，人口属性信息与毒性标签的共现程度较高，导致模型在学习预测模式的过程中，将人口属性信息作为预测标签的线索，从而使得模型在面对“You are a woman.”这样的中性表达时，做出毒性的判断，模型被迫产生“偏见”，先前工作中（Dixon 等人，2018）将之称为“unintended bias”（非预期偏见）。

较为主流的去偏⁸方法可以分为两个支线。第一支线是从数据的角度，增强、过滤、加权样本，使得训练集在我们所关注的敏感属性上分布是平衡的。具体来说，Zhao 等人（2018）通过将表示性别身份的单词替换为相反性别的对应单词，生成新的句子，并保持原有的标签，利用这种性别反转数据增强的方式缓解指代消解任务中的性别偏见。类似的工作也应用在情感分析任务中，对于每个身份项，从公开的网络文本里抽取同等数量的非毒性文本，以平衡该身份项在训练集中的标签分布（Dixon 等人，2018；Nozza 等人，2019）；此外，Ball-Burack 等人（2021）通过利用 AFLite 和 DataMaps 算法对展露出虚假相关性的训练样本进行过滤来实现数据的调整。从数据角度平衡分布的第三种方式是通过对样本加权来实现的。Zhang 等人（2020）针对毒性检测任务中的模型偏见问题，将歧视分布（现实中的数据集分布）看作是从非歧视分布（理想世界的数据集分布）中采样得来的，通过样本加权恢复原始的非歧视分布，从而帮助模型缓解偏见。去偏方法的第二支线是通过对训练目标施加约束来降低训练过程中对人口属性线索的依赖。最常见的方法是对抗学习（Elazar & Goldberg, 2018; Faal 等人, 2021; Xia 等人, 2020），该类方法促使模型学习到的文本表示既可以预测情感标签，同时又可以与身份语义无关。此外，也有较多工作在训练目标之外，增加额外的惩罚损失来缓解模型对身份信息的依赖，这些惩罚项包括：预测输出与保护属性

⁸ 此处的去偏意指缓解情感分析模型对人口属性信息的过度依赖。

的相关性（Beutel 等人，2019）、预测概率与反事实样本的预测概率差异（Garg 等人，2019），和不同群体间漏识率（FNR）/误识率（FPR）的差异（Gencoglu, 2021）。除了训练目标的约束，Attanasio 等人（2022）提出对注意力的熵进行约束，阻碍模型对特殊身份项的过拟合。

总的来说，目前主流去偏方法的目标，都是使得模型学习到的表示向量尽可能地与身份信息无关。

然而，这并不完全符合实际情况。Garg 等人（2019）提出非对称反事实问题。这里的反事实样本是指与原始样本拥有相同上下文，但包含敏感信息情况不同的样本，非对称反事实是指样本的情感贡献词大多来源于对群体的刻板印象，由身份属性词表现出来，而上下文本身无明显的情感贡献，反事实样本与原始样本蕴含的情感标签很可能是不同的。本文将这类样本称为“身份核心型样本”。如表 5-1 所示。

表 5-1 本章对于样本类型的定义

核心贡献词来源	样本分类	样本示例
身份属性词	身份核心型样本	<i>I can't stand watching college football with a female announcer. --- sexism</i>
非身份属性词的上下文	上下文核心型样本	<i>She is so bit**. --- sexism</i>

传统的去偏思路假设所有样本的反事实都是对称的，通过解除模型预测与身份信息的相关性，来实现群体一致性的公平目标。然而，由于身份核心型样本大多是以身份信息作为核心情感贡献词，模型预测需要特别考虑身份信息的存在，因此，这会使得去偏模型对于歧视言论的捕捉能力变弱，在此类样本的对抗样本上呈现过高的误判率。

为了使得去偏方法可以过滤掉身份核心型样本，本文参考因果推断领域中的概念，来鉴别样本中的身份信息是否属于核心情感贡献词，在不同的去偏方法上实施过滤，使得模型在保证去偏能力的同时，仍然具有歧视言论识别能力。针对模型将敏感身份信息作为预测捷径所引发的公平性问题，尝试提出解决方案。所做的工作主要有以下方面的创新：（1）分析了经典去偏方法所忽略的身份核心型样本所带来的问题，采用条件因果效应计算方式识别这类特殊样本；（2）将身份核心型样本过滤机制与三种经典的去偏方法结合以改进模型，实验结果显示

所提方法可以在保证模型去偏能力的同时，提高模型对身份核心型样本的识别能力。

第二节 条件因果效应计算

本章基于 Neyman - Rubin 所提出的潜在结果框架 (Rubin, 2005) 展开讨论敏感属性对样本的情感贡献，以此决定是否对该样本进行去偏处理。本节首先对因果推断的理论作出简要说明，其次，对基于 T-learner 架构 (Künzel 等人, 2019) 的条件因果效应方法作出介绍。

一、潜在因果框架

人类通过比较“做 T 这件事”和“不做 T 这件事”的结局，来推断事件 T 对结局是否有因果效应。Rubin 等人将人类脑海中的因果直觉与数学形式相结合，提出潜在因果框架，为流行病学、统计学等社会科学领域中的因果效应计算提供范式，这里的事件 T 可以是某种干预措施、暴露情况或治疗方案。

假设 T 为二元变量，对于一个可观测的个体单元 i ，其观测数据可表示为： $\langle T_i, C_i, Y_i^{obs} \rangle$ ，其中， T_i 为个体 i 的处置变量观测值， C_i 为个体 i 的协变量观测值， Y_i^{obs} 为个体 i 的结果变量观测值。事件 T 对个体 i 的因果效应 (Individual Treatment Effect, ITE) 被定义为：

$$\tau_i = Y_i(1) - Y_i(0) \quad (5.1)$$

其中， $Y_i(1)$ (或 $Y_i(0)$) 为潜在结果变量，具体来说，表示如果个体 i 接受处置情况 $T=1$ (或 $T=0$)，个体 i 最终的潜在结果。显然地，由于我们永远只能观测到个体 i 的一个观测结果，因此潜在结果与观测结果之间的对应关系为：

$$Y_i^{obs} = \begin{cases} Y_i(1), & \text{if } T_i = 1 \\ Y_i(0), & \text{if } T_i = 0 \end{cases} \quad (5.2)$$

由此，我们可以定义平均因果效应 (Average Treatment Effect, ATE)：

$$\tau = E[Y_i(1) - Y_i(0)] = E[\tau_i] \quad (5.3)$$

以及，条件因果效应 (Conditional Average Treatment Effect, CATE)：

$$\tau(c_i) = E[Y_i(1) - Y_i(0) | C_i] = E[\tau_i | C_i] \quad (5.4)$$

个体因果效应 τ_i 是无法观测的， $\hat{\tau}_i$ 表示个体因果效应 τ_i 的估计值。当满足无混杂假设 (给定协变量 C_i ，没有额外影响 Y 的因素影响处置情况) 时，我们可

以通过估计条件因果效应来代替个体因果效应的估计 (Künzel 等人, 2019), 这是因为 CATE 的最佳估计也是 ITE 的最佳估计。个体 i 的 ITE 估计量的均方误差可分解为公式(5.5), 既然我们无法影响等式右边第一项, 那么 ITE 的最佳估计即为最小化等号右边的第二项, 即最小化 CATE 在 c_i 处的均方误差, 因此我们可以通过估计条件因果效应来代替个体因果效应的估计。

$$\begin{aligned} & E[(\tau_i - \hat{\tau}_i)^2 | C_i = c_i] \\ &= E[(\tau_i - \tau(c_i))^2 | C_i = c_i] + E[(\tau(c_i) - \hat{\tau}_i)^2] \end{aligned} \quad (5.5)$$

二、基于 T-Learner 的 CATE 计算方法

T-learner 包括两部分: 控制组的响应函数估计 (潜在结果估计) 和处置组的响应函数估计。T-Learner 的框架图介绍⁹如图 5-1 所示。




图 5-1 T-Learner 介绍

第一步: 估计控制组的响应函数。用来估计函数 $\mu_0(c)$ 的学习器可以是任何一种有监督学习算法, 使用控制组的观测数据 $\{(C_i, Y_i)\}_{T_i=0}$ 来学习;

⁹ 图源自 <https://github.com/matheusfacure/python-causality-handbook>

$$\mu_0(c) = \mathbb{E}[Y(0) | C = c] \quad (5.6)$$

第二步：估计处置组的响应函数，类似地，使用处置组的数据 $\{(C_i, Y_i)\}_{T_i=1}$ 来学习 $\mu_1(c)$ 。

$$\mu_1(c) = \mathbb{E}[Y(1) | C = c] \quad (5.7)$$

在训练阶段，分别使用控制组和处置组的数据训练两种处置情况下的潜在结果预测模型；在测试阶段，将新样本 i 的协变量 c_i 分别输入两个模型，计算差值可得到处置变量 T 在 c_i 处的条件因果效应。

$$\hat{\tau}(c_i) = \mu_1(C = c_i) - \mu_0(C = c_i) \quad (5.8)$$

第三节 改进去偏方法

本节介绍如何利用 T-Learner 改进传统去偏方法，从而缓解性别歧视言论识别模型的“偏见”问题。首先对研究问题做形式化描述，并对论文中提到的术语概念做详细阐述，其次，对整体去偏流程作出介绍，并说明样本过滤机制与不同去偏方法的结合方式。

一、问题形式化

（一）问题描述

已知歧视言论检测任务的数据为 $\{(S_i, Y_i)\}_{i=1, 2 \dots N}$ ，其中， S_i 表示输入的文本数据，由 T_i （敏感属性单词出现或者不出现）和 C_i （不包含敏感属性的上下文单词）组成，当输入文本中含有敏感属性单词，即 $T_i = 1$ 时， C_i 代表将敏感属性单词掩盖住后的文本；反之， C_i 代表原始的输入文本 S_i 。更细节的实例说明见表 5-3。输出 $Y_i \in \{0, 1\}$ 表示歧视的标签结果，1 代表具有歧视性的言论，0 代表非歧视言论。性别歧视言论识别是文本分类任务，任务目标是要求模型对输入文本进行二分类预测（歧视/非歧视）。

$$\hat{y}_i = \hat{f}(S_i) \quad (5.9)$$

$$Loss = \frac{1}{N} \sum L_{CE}(\hat{f}(S_i), y_i^{gold}) \quad (5.10)$$

由于非预期偏见的存在，我们的目标是学习歧视言论预测模型 $\hat{f}(S_i)$ 的同时，缓解模型对敏感属性信息这一捷径的依赖程度，常用的去偏方法通过解除句子编码表示与身份信息的相关性来实现这一目标。

如第一节所述，部分样本的情感核心贡献词来源于敏感属性信息本身，我们

不需要对这类样本（身份核心型样本）进行去偏（如表 5-3 中的样本示例 2），接下来，我们的目标转换为：对于一个上下文 C_i 所含的语义而言，判断敏感属性信息是否将会为其带来核心贡献。下文借鉴 T-Learner 计算条件因果效应的方式来鉴别某样本是否属于身份核心型样本。

表 5-3 两种类型的样本示例及其变量表示

变量	上下文核心型样本示例	身份核心型样本示例
S	really bit** really ? get on the runway and back in the kitchen.	Men who cry have weak character.
T	0	1
C	really bit** really ? get on the runway and back in the kitchen.	[MASK] who cry have weak character.
Y	1	1

表 5-2 因果推断问题中的术语与文本分类任务的映射关系

因果术语	药物因果效应	含有敏感信息的文本示例	不含敏感信息的文本示例
观测的个体单元	张三	输入文本：“I do not like watching football with a female commentator.”	输入文本：“I do not like watching football with a terrible commentator.”
混杂 X	病情严重程度	不包含敏感信息的上下文：“I do not like watching football with a [MASK] commentator.”	不包含敏感信息的上下文：“I do not like watching football with a terrible commentator.”
处置变量 T	是否施加药物	是否含有敏感信息：1	是否含有敏感信息：0
结果变量 Y	痊愈情况	歧视标签：1	歧视标签：0
Y(0)	如果张三不用药，他的潜在痊愈情况	这句话不包括敏感属性信息时的潜在结果 0 (反事实结果)	这句话不包括敏感属性信息时的潜在结果 0 (观测结果)
Y(1)	如果张三用药，他的潜在痊愈情况	这句话包括敏感属性信息时的潜在结果 1 (观测结果)	这句话包括敏感属性信息时的潜在结果 1 (反事实结果)

（二）术语概念

这里借鉴条件因果效应的思路来识别身份核心型样本。该任务目标与因果推断问题的术语映射关系如表 5-2 所示。以一个常见的因果推断问题举例：探究施加药物对患者的痊愈效果，这里的条件因果效应是指，对特定的人群（重症患者/轻症患者）施加药物的治疗结果。在本文研究背景下，研究问题为：对于一个特定的上下文情景（语义空间是连续的，这里仅做抽象的理解），施加性别敏感信息，是否会造成该言论具有性别歧视情感。

对于含有敏感信息的言论（见表 5-2 第三列），如 “I do not like watching football with a female commentator.”，该样本包含敏感信息 “female”，且表达了对女性这一群体的态度（蕴含着女性不懂运动的刻板印象），被专家标注为歧视言论。因此，该样本在 $T=1$ 下的潜在结果等于其观测类别 Y ，即 $Y(1)=1$ ；而该样本在 $T=0$ 下的潜在结果 $Y(0)$ 无法被观测到，我们通过经验分析得知，如果不包括 “female” 敏感信息，在大多数情况下，类似的上下文情境是一种主观性表达，比如这句话的语义可以是 “我不喜欢看有【业余的/过于情绪激动的】评论员的足球比赛”，无明显歧视含义，因此，在这种理解下，此样本的反事实结果标签应该为 “非歧视”，即 $Y(0)=0$ 。相应地，对于不含敏感信息的言论（见表 5-2 第四列），如 “I do not like watching football with a terrible commentator.”，该样本不包含任何敏感信息，且不具有性别歧视情感，被专家标注为非歧视言论。因此，该样本在 $T=0$ 下的潜在结果等于其观测类别 Y ，即 $Y(0)=0$ ；而该样本在 $T=1$ 下的潜在结果 $Y(1)$ 无法被观测到，类似地，通过经验分析得知，如果包括 “female” 敏感信息，在大多数情况下，类似的上下文情境是一种对女性群体的刻板印象，比如这句话的语义很可能是 “我不喜欢看有女性评论员的足球比赛”，有明显歧视含义，因此，在这种理解下，此样本的反事实结果应该为 “歧视”，即 $Y(1)=1$ 。根据上述分析可知，对于一个样本，尽管我们无法同时观测到这句话在两种处置情况下（包含敏感属性与不包含敏感属性）的潜在结果，只能观察到样本的一种观测结果，但我们可以通过某种方式去估计样本的另外一种潜在结果。参考 T-Learner 方法，将原始样本集分割成 $T=1$ 和 $T=0$ 两组样本，分别估计两种情况下的潜在因果模型。

二、去偏步骤

（一）身份核心型样本识别

研究问题转换为如何从观测数据中估计样本的另外一种潜在结果。本文使用 Zhao 等人（2018）所提供的两个主要性别身份单词列表，将之作为样本的 T 变量取值，分别使用 $T=0$ 和 $T=1$ 的样本上下文训练性别歧视文本分类器 $\{(C_i, Y_i)\}_{T_i=0} \rightarrow \hat{f}_0(C_i)$ 和 $\{(C_i, Y_i)\}_{T_i=1} \rightarrow \hat{f}_1(C_i)$ ，来作为各自潜在结果的预测模型。具体原因是：对于 $T=1$ （包含敏感属性信息）的潜在结果，我们期待潜在结果推断是保持“敏感”的，这是因为对涉及到厨房、运动、政治等刻板印象比较严重的领域，施加身份属性很可能是歧视言论，因此，使用所有 $T=1$ 的样本上下文来训练模型，对这类样本上下文过拟合的模型会比较“敏感”，使用该模型对样本上下文的预测来近似样本在 $T=1$ 情况下的潜在结果；相应地，对于 $T=0$ （不包含身份属性信息）的潜在结果，我们期待潜在结果推断是比较“松弛”的，这是因为在多数情况下，不施加身份属性时，一句话的上下文表达通常意味着一种主观喜好，因此，使用所有 $T=0$ 的样本上下文来训练模型，对这类样本上下文过拟合的模型会比较“松弛”，使用该模型对样本上下文的预测来近似样本在 $T=0$ 情况下的潜在结果。

表 5-4 潜在结果的取值

S 样本的 T 变量	$Y(0)$	$Y(1)$
$T=1$	$\hat{f}_0(C_i)$	Y
$T=0$	Y	$\hat{f}_1(C_i)$

如果样本的 $Y(0)$ 与 $Y(1)$ 结果相同，则认为 T 的出现对于歧视情感贡献不大；如果 $Y(0)$ 与 $Y(1)$ 结果不同，则身份信息为标签变量提供了关键性的影响，因此，可将之识别为身份核心型样本。

（二）改进去偏方法

常见的去偏方法分为样本增强类和目标约束类。针对第一类方法，在增强样本时设置过滤条件，当该样本被识别为身份核心型样本时，不对该样本进行增强；对于第二类去偏方法，我们对样本的惩罚损失项进行加权，如果是身份核心型样

本，权重为 0，否则为 1，原始的分类交叉熵损失目标不变。

第四节 实验部分

本节介绍论文的核心实验部分，首先对论文中所涉及到的数据集作出介绍；其次，简要列出实验所用到的去偏模型，并描述实验设置以及训练流程，为结果复现提供参数细节；最后，分析并阐述论文的实验结果。

一、数据集使用

本章将在两个数据集上评估提出方法，包括：AMI、ST。评估的内容包括三个方面：原始测试集上的表现、人工合成的无偏测试集的表现，以及身份核心型样本测试集的表现。数据集的详细信息如表 5-5 所示。

表 5-5 数据集介绍

数据集	训练集	测试集	来源	无偏测试集	来源	反事实测试集	来源
AMI	Y=1 Y=0 1785 2215	Y=1 Y=0 460 540	(Fersini 等人, 2018)	Y=1 Y=0 732 732	(Nozza 等人, 2019)	Y=1 Y=0 1310 1304	(Samory 等人, 2021)
ST	Y=1 Y=0 3418 11676	Y=1 Y=0 840 2934	(Waseem, 2016; Waseem & Hovy, 2016)	Y=1 Y=0 9324 9324	(Park 等人, 2018)	Y=1 Y=0 1310 1304	

(一) AMI (Automatic Misogyny Identification)

自动厌女识别任务曾分别在 EVALITA 2018、EVALITA 2020 评测中作为其中一项任务提出，AMI 2018 涉及到的语言包括英语和意大利语，AMI 2020 仅包括意大利语。这里使用 EVALITA 2018 中的子任务 A-厌女识别。该任务要求系统对在线社交媒体推特中的言论，进行厌女/非厌女的识别。

Nozza 等人 (2019) 提出 AMI 模型对女性身份词有“偏见”，并参考前人工作 (Dixon 等人, 2018)，根据模板和身份词（只涉及一种性别），生成人工的无偏测试集。

（二）ST（Sexist Tweets）

本章使用的 ST（性别歧视测试集），来自于毒性言论检测的两个数据集的汇总（Waseem, 2016; Waseem & Hovy, 2016）。这个数据集包括被专家标注为“sexist”或“normal”的推文。

前人的工作（Park 等人，2018）提到，在此数据集上训练的模型可能会包含非预期的性别偏见，将“You are a good woman.”这样中性样本预测为“sexist”。参考 Park 等人提供的模板（歧视/不歧视的表达模板），基于 Zhao 等人（2018）提供的性别身份词，人工生成无偏测试集评估模型去偏能力，具体如表 5-6 所示。

表 5-6 无偏测试集的生成模板介绍

模板标签	模板	male	female
Y=1	{verb_negative} {adjective_people}, i hate {adjective_people}, Being {adjective_people} is {adjective_negative}. You are a {adjective_negative} {adjective_people}	actor, boy, man,	actress, girl, woman,
Y=0	{verb_positive} {adjective_people}, i am {adjective_people}, Being {adjective_people} is {adjective_positive}., You are a {adjective_positive} {adjective_people}	husband, ...	wife, ...

（三）CTF（CounterFactual Test）

Samory 等人（2021）用众包方式，为性别歧视检测任务提供了反事实测试样本，即对于性别歧视推文，以最小编辑、反转标签、语言连贯为目标，人工修改样本内容。举例说明：一个原始的歧视样本“It is difficult to work for a female boss.”的标签为：歧视，标注者将之改为：“It is difficult to work for a angry boss.”，对应的标签变为：非歧视，修改后的新样本称为反事实样本。本章实验所用到的反事实测试集是将原始样本与反事实样本汇总之后得到的数据集。两个任务下模型对身份核心型对抗样本的误判能力通过该测试集进行评估。

二、对比模型介绍

（一）BERT-FT

使用 BERT 加全连接层的模型架构，在训练集上微调，BERT 模型介绍见第

三章的第四小节，模型简写为“b-ft”。

（二）SWAP

Zhao 等人（2018）将表示性别身份的单词替换为相反性别的对应单词，生成新的样本，并保持原有的标签，从而增强原始训练集缓解指代消解任务中的性别偏见，这种方法也被应用在性别歧视识别任务的去偏中。模型简写为“swap”。样本过滤方法通过对识别出的身份核心型样本不进行数据增强来实现，模型简写为“swap-t0t1”。

（三）CLP

反事实 logits 约束方法（Garg 等人，2019）通过在分类任务的交叉熵损失之外，对输入文本与反事实文本的 logits 差异进行额外惩罚来缓解模型对敏感信息的依赖，模型简写为“clp”。数学表达如公式(5.11)所示。样本过滤方法通过对识别出的身份核心型样本不进行对抗损失惩罚来实现，模型简写为“clp-t0t1”。




图 5-2 EAR 模型框架示意图

$$Loss = \frac{1}{N} \sum \left(L_{CE}(\hat{f}(S_i), y_i^{gold}) + \Delta(\hat{f}(S_i) - \hat{f}(\bar{S}_i)) \right) \quad (5.11)$$

（四） EAR

该方法在原始分类目标的基础上，对注意力的熵进行约束，阻碍模型对特殊身份项过拟合，由 Attanasio 等人（2022）提出。该方法被证明在 AMI 数据集的去偏上表现优异。EAR 的模型框架图如图 5-2 所示。模型简写为“ear”。其中 H_i^l 表示第 i 个单词在第 l 层 Transformer 网络中注意力的熵。样本过滤方法通过对识别出的身份核心型样本不进行注意力熵约束来实现，模型简写为“ear-t0t1”。

$$H_i^l = - \sum_{j=0}^{d_s} a_{i,j}^l \log a_{i,j}^l \quad (5.12)$$

三、 实验设置

对于每个数据集，将训练集以 8:2 的比例随机分割为训练集和开发集，使用 5 轮实验的表现均值记录为最终的报告结果，每轮实验使用不同的随机初始化，运行 20 个 epoch，使用早停策略来终止模型的训练，patience 为 3，使用 AdamW 优化器，预先设置学习率为 $1e-5$ ，采用预热策略，每批训练的样本数量为 64。EAR 模型系列（包括 bert，ear，以及）实验采用原文提供的代码来进行¹⁰，其他实验代码使用 huggingface 提供的接口来实现。

四、 实验结果及分析

（一） 去偏效果分析

不同模型在 AMI 数据集和 ST 数据集上的去偏表现如表 5-7 和表 5-8 所示。从 AMI 数据集上的结果来看，从数据角度的 swap 样本增强方法、从模型目标角度惩罚约束方法，以及从模型注意力的熵约束方法，都在保证模型 IID 预测水平的同时，缓解了原有模型对身份信息的依赖，其中 swap 方法的去偏效果最好，在误判率 FPR 上下降了 22% 左右，但与此同时，该方法所带来的漏识率也是最高的，这比较符合直觉，模型的整体预测趋于保守，倾向于将测试样本的标签预测为 $Y=0$ ，降低误判率的同时，也提高了漏识率。相对来讲，ear 虽然缓解误判率的幅度相比于 swap 较小，但也保持了对歧视言论的召回能力。

¹⁰ <https://github.com/g8a9/ear>

表 5-7 AMI 数据集的去偏表现

方法	Test		Unbiased			
	Accuracy	F_1^{macro}	Accuracy	F_1^{macro}	FPR	FNR
b-ft	0.683	0.682	0.643	0.629	0.511	0.202
swap	0.678	0.678	0.649	0.647	0.287	0.414
swap-t0t1	0.702	0.702	0.680	0.676	0.260	0.381
b-ft	0.683	0.682	0.643	0.629	0.511	0.202
clp	0.666	0.665	0.639	0.626	0.487	0.236
clp-t0t1	0.681	0.680	0.653	0.644	0.476	0.219
b-ft	0.683	0.682	0.643	0.629	0.511	0.202
ear	0.674	0.674	0.671	0.658	0.486	0.172
ear-t0t1	0.677	0.676	0.667	0.652	0.499	0.166

表 5-8 ST 数据集的去偏表现

方法	Test		Unbiased			
	Accuracy	F_1^{macro}	Accuracy	F_1^{macro}	FPR	FNR
b-ft	0.873	0.809	0.529	0.437	0.068	0.874
swap	0.865	0.797	0.541	0.456	0.068	0.850
swap-t0t1	0.871	0.805	0.523	0.424	0.066	0.888
b-ft	0.873	0.809	0.529	0.437	0.068	0.874
clp	0.879	0.811	0.544	0.448	0.044	0.868
clp-t0t1	0.878	0.810	0.537	0.443	0.055	0.870
b-ft	0.873	0.809	0.529	0.437	0.068	0.874
ear	0.874	0.811	0.545	0.458	0.058	0.852
ear-t0t1	0.877	0.815	0.543	0.449	0.045	0.869

基于身份核心型样本过滤策略改进的去偏方法,除了略微影响了 ear 模型的

误判率，在其它模型上，既降低了误判率，又降低了漏识率。在一定程度上可以说明，改进的去偏方法能够保证传统去偏方法的纠偏能力。从 ST 数据集上的效果来看，也可以得出类似的结论，即改进的去偏方法，对于三种去偏方法的去偏能力没有较大的影响。

图 5-3 展现了不同的身份群体的在三个模型下的 AUC 表现，这里展示的是 swap 系列模型以及其在 AMI 数据集上的表现，该任务是厌女言论识别任务，仅涉及到一个身份属性：即女性。我们参考 Attanasio 等人（2022）对该任务的 $AUC_{subgroup}$ 定义，对图 5-3 中 12 个代表女性身份的词划分样本组，分别计算每组的 5 轮实验的 AUC 值，并画出箱型图。除了 “ladies” “she” 这两组样本，改进的去偏方法相对于去偏方法 swap 在 AUC 值上有所下降之外，其他 10 组样本的 AUC 值均有所提升。这进一步说明加入身份核心型样本过滤步骤，不会减弱模型的去偏能力。




图 5-3 不同身份词所在样本在三个模型中的 AUC 值

（二）反事实对抗效果分析

反事实样本是根据歧视言论文本，以反转标签为目的，同时以最小编辑、语言流畅为修改原则，人工编辑原始文本后形成的样本。反事实测试集包括原始样本 1307 条和对应的反事实样本 1307 条。由于修改的位置数量要求最小化，因此，被编辑的位置往往是对标签有因果影响的单词或者短语，而对特定单词有虚假依赖的模型，会在此测试集上展示出脆弱性。

表 5-9 去偏模型在反事实样本测试集上的表现

method	AMI				ST			
	Accuracy	AUC	F_1^{macro}	FPR	Accuracy	AUC	F_1^{macro}	FPR
b-ft	0.722	0.810	0.718	0.157	0.692	0.788	0.679	0.104
swap	0.693	0.772	0.692	0.268	0.624	0.685	0.606	0.163
swap-t0t1	0.719	0.806	0.715	0.188	0.642	0.726	0.618	0.104
b-ft	0.722	0.810	0.718	0.157	0.692	0.788	0.679	0.104
clp	0.688	0.779	0.682	0.177	0.655	0.740	0.639	0.145
clp-t0t1	0.730	0.830	0.724	0.129	0.667	0.770	0.648	0.110
b-ft	0.722	0.810	0.718	0.157	0.692	0.788	0.679	0.104
ear	0.741	0.824	0.741	0.214	0.710	0.790	0.702	0.127
ear_t0t1	0.746	0.827	0.745	0.202	0.709	0.788	0.701	0.127

不同的去偏模型在此数据集上的表现如表 5-9 所示。无论是以 AMI 为训练集，还是以 ST 为训练集，均有相似的结论。首先，不幸的是，三种基础去偏模型相比于原始模型均在该数据集上 FPR 上升幅度较大，预测准确率有所下降(ear 模型除外)，呈现出较高的误判率。这与我们猜测一致，因为反事实测试集对模型更具有挑战性，不仅是以身属性词为预测依据的模型会展现出脆弱性，对任何非因果特征有虚假依赖的模型，都会在该测试集上损失掉“捷径”所带来的预测准确率；其次，去偏方法经过身份核心型样本过滤后，所展现的误判率上升幅度较小，在 ST 数据集上可以维持有偏模型的水平，AMI 数据集上的 clp-t0t1 模型甚至可以在反事实测试集上超过有偏模型的表现水平。常见的去偏方法在该

测试集上误判率相比较于有偏模型要高很多,这说明去偏(对身份信息解除依赖)的同时,模型也被迫地加强了对其它虚假线索的依赖。改进版本的去偏方法,仍然有这样的影响,但相对较弱。这也正是身份核心型样本识别之所以有效的原因。当去偏模型剥离身份属性信息的影响时,模型对上下文单词的注意力会加强,比如:提到女性和政治的文本很大概率上是具有歧视性的,当模型被纠偏,放弃对身份信息的捕捉时,模型对“政治”这一语义的依赖将会加强,当遇到同样含有“政治”语义但与性别无关的主观表达时,会做出误判。

(三) 身份核心型样本识别的有效性

本文主张身份核心型样本不需要去偏,从而利用条件因果效应计算方法识别出身份核心型样本,对去偏方法进行过滤,而经识别的样本是否真的如同我们所期待的那般,属于身份核心型样本呢?遗憾的是,并没有一个数据集拥有这样的黄金标签。这里我们从反事实样本的原始样本中随机抽取 100 条样本(原始样本属于自然文本,对抗样本是众包标注者后期编辑的样本),对其人工判断,结果发现,在这 100 条样本中,有 70 条被样本过滤方法识别为身份核心型样本,而其中 65 条被人工判断为身份核心型样本。这说明我们的识别算法与身份核心型样本的相关性较强,这在一定程度上也解释了为何使用该识别方式改进的去偏算法能够提升去偏模型在反事实样本集上的稳健性。

第五节 本章小结

传统的去偏思路通过解除模型预测与身份信息的相关性,来实现群体一致性的公平目标。然而,由于身份核心型样本大多是以身份信息作为核心情感贡献词,模型的预测需要特别考虑身份信息的存在,因此,这会使得去偏模型对于歧视言论的捕捉能力变弱,在此类样本的对抗样本上展现出过高的误判率。本章基于此动机,提出身份核心型样本过滤机制,借鉴因果推断领域中的概念来刻画样本中身份信息的重要性,在不同的去偏方法上实施样本过滤,使得模型在保证去偏能力的同时,仍然具有较好的歧视识别能力。实验结果表明,传统的去偏方式虽然会解除模型对身份信息这一捷径的依赖,但也会被迫从其他虚假线索寻找预测模式,从抽象的角度理解,我们的算法对去偏进行了细化分类,通过对上下文核心型样本施加去偏,不仅保证原有去偏模型的纠偏能力,同时也缓解了模型对其他虚假线索的依赖,提升去偏模型在反事实测试集上的稳健性。针对明确虚

假线索的去偏算法似乎不可避免地遇到类似“矫枉过正”的问题，有不少研究将重点从对虚假相关特征的被动防御转变为对因果相关特征的主动学习。第六章将针对未明确虚假线索的问题背景，研究如何设计方案学习因果相关特征。

第六章 基于因果干预的稳健情感分类模型

第一节 引言

尽管机器学习模型在不同任务中都取得了卓越表现，但不少研究工作发现，由于统计模型学习特征与标签之间的相关性，模型的稳定性和可靠性受到了虚假线索的威胁，这阻碍了其在金融、医疗等领域的应用推广。文本分类模型也经常依赖虚假相关线索，以电影评论的情感分类任务为例，单词项“Spielberg”（斯皮尔伯格，美国著名导演）与积极的情感标签呈现强相关性，这是因为该导演的大多数电影作品都获得了正面的评论，然而，单词项“Spielberg”本身并不暗含情感（Z. Wang & Culotta, 2020），当数据分布偏移时，比如斯皮尔伯格拍摄了一部评价不好的电影，模型仍然会做出积极的情感预测，因此在分布外数据集上预测水平下降。

文本分类相关的研究工作表明，之所以存在虚假关联，是因为混淆的存在，即存在同时影响输入文本分布和情感标签的变量（Kaushik 等人，2019）。Landeiro 等人（2019）曾提出，IMDB 电影评论数据集中，由于选择偏差的存在，涉及到恐怖片的电影评论倾向于表达消极的情感，而涉及到爱情电影的评论倾向于表达积极地情感。Z. Wang 和 Culotta（2020）也曾将语境当作混杂，将情感分类任务视作一个因果推断问题。类似地，我们考虑一个简化的因果模型（图 6-1），将评论主题作为混杂因子进行稳健性学习。具体来说，一方面，评论的主题影响用户对评论的表达，比如，“恐怖电影”主题下更容易出现“horror”这样的单词；




图 6-1 情感分析任务因果图假设

另一方面，主题可能对情感有倾向，比如，观众对“恐怖电影”的要求更高，很容易表达负面的评价。尽管识别和控制混杂因子在社会科学领域是非常重要的，但在以机器学习方法为核心的文本分类任务上却很少见，这是因为机器学习的首要目标是预测，而非因果推断。

近来，为缓解虚假相关性对模型的影响，不少研究工作将目标转向如何促使模型学习因果相关特征。对于单个领域的数据集，相关工作主要分为两个支线：

（1）反事实数据增强。通过人工、规则、自动等方式生成训练样本的反事实样本，反事实样本与原始样本的区别在于最小限度地修改了表达中的特定单词或短语（因果相关特征词），导致文本的情感改变。原始样本和反事实样本大部分上下文是相同的，二者的组合训练会促使模型学习影响情感预测的因果特征（Kaushik 等人，2019；Z. Wang & Culotta, 2021；Yang 等人，2021）。（2）在分类的目标损失之外，对数据集的虚假特征和因果特征分别进行约束（Z. Wang 等人，2021）。第一种改进方案对反事实的生成质量要求较高，尤其是在长文本的情况下，效果有限；而第二种方式需要事先已知任务的虚假特征和因果特征，这需要一定的标注成本。本章针对未知虚假线索导致的模型稳健性问题，提出改进方法，所做的工作主要有以下方面的创新：

（1）本文对于未明确的虚假线索，提出主题混杂假设，然后基于后门调整学习的方式，缓解模型对未知虚假线索的依赖性；

（2）所提方法分别在前人提出的分布偏移型对抗样本（电影评论文本）和扰动攻击型对抗样本（金融新闻文本）做出测试，实验结果表明所提方式能够提升文本分类模型的稳健能力，尤其是长文本情况下的分类模型。

第二节 相关工作

促使模型学习影响标签的因果特征，提升模型的域外泛化能力，主要分为两个研究支线：反事实样本增强以及因果特征学习。

一、反事实样本增强

提升模型对真正特征捕捉的研究工作最初是通过“人在回路”（Human in the Loop, HITL）方式进行的（Kaushik 等人，2019）。针对情感分类以及自然语言推断两个任务，以常用数据集 IMDB，SNLI 为事实样本数据集，通过众包方式人工生成对抗的反事实样本集，实验结果表明，反事实样本增强后训练出的模型

对于反事实对抗攻击的防御能力更强。然而,这种方式仍然需要较高的标注成本。为避免这一问题,基于启发式规则的反事实生成方式被提出(Z. Wang & Culotta, 2021),这篇工作通过语义匹配的方式识别出对情感标签有真正影响的特征词,作者认为这些单词是对此数据集情感标签有核心预测作用的因果特征词,借助 wordnet 获得这些单词的反义词,将一个样本中的因果特征词替换为其反义词,标签为原始样本的相反标签,从而获得反事实样本,实验结果表明通过将该方法生成的反事实样本与原始样本组合训练,尽管没有众包技术得到的反事实增强方案效果好,但与基准模型相比,仍然可以提高模型的泛化能力。类似地, Yang 等人(2021)也通过先识别因果项,再基于规则编辑因果项的方式生成反事实,不同的是,这篇工作使用 Moverscore 评估不同反事实与原始样本之间的编辑距离,以提高反事实文本的生成质量,但上述这些方法只对句子的部分单词做出编辑和修改,在语言流畅性方面仍有欠缺。

随着预训练语言模型的技术发展,利用生成式语言模型实现反事实的自动增强逐渐被探索,有代表性的工作包括:Ployjuice(Wu 等人, 2021), GTC(Madaan 等人, 2021)。具体来说, Ployjuice 利用提示学习技术,设计 8 种不同的扰动类型,包括:否定、插入、删除等操作,以 GPT-2 为基本模型,在 6 个的成对句子数据集上微调模型,实现反事实的生成,此外,增加流畅度过滤模块,保证生成的语言表达是有意义的。另一种基于语言模型的反事实生成方案是 GTC (Madaan 等人, 2021),该方法类似于控制文本生成技术,包括两个模块,一是通过扰动矩阵 $\tilde{H}_t$ 重建输入文本,最小化重建损失意味着生成的文本与原始输入文本需要是相似的;二是通过扰动矩阵 $\hat{H}_t$ 实现控制目标(标签反转),要求生成文本与原始文本的模型预测结果相反,由于第二个模块涉及到不可微分的损失,作者借鉴强化学习中常用的奖励函数来实现优化过程。

除了提高反事实的生成质量之外,另外一种思路是如何最大效率利用人工标注的反事实样本。从反事实表示学习而非反事实样本生成的角度, De Raedt 等人(2022)从少量反事实样本对中学习从原始样本到反事实样本的向量映射函数,利用该方案在只添加 1 %人工反事实样本的情况下,模型取得了显著的精度提升,与添加 100 %的分布内训练样本相比,精度提升了+3 %。

二、因果特征学习

（一）域泛化的因果特征学习

另外一种思路从域泛化的角度来展开，因果特征具有在不同领域中对目标变量影响不变的特点，而虚假特征对于域的改变则比较敏感。传统的经验风险最小化思路是促使模型捕捉一切相关的特征，Ahuja 等人（2020）提出不变风险最小化的目标，尝试让机器学习方法从多个环境或领域的数据集中学习到那些与标签有稳定预测关系的特征。对于文本问题，Chang 等人（2020）提出不变合理化方案，也属于类似思路，在此工作中，作者将学习到的特征集合称为“理由”（rationale），核心思路是从原始特征集学习到一组特征可以在实现经验风险最小化目标的同时，保证域无偏预测器与域敏感预测器的预测值越近越好。此外，上文提到过的反事实样本增强方案中涉及到因果/虚假特征识别，也利用了类似的思路，随着领域变化，对标签的影响系数有显著变化的特征更倾向于是虚假特征（Yang 等人，2021）。

（二）去混杂的因果特征学习

上述工作是以不同领域为前提的，在单一领域中，学习因果特征往往从任务特点本身出发，以图像表示学习中的 V-R-CNN 模型为例（T. Wang 等人，2020），作者认为视觉常识可以被视作为一种因果，常见的表示学习会捕捉到同一张图片中两个对象之间的相关性，而忽略了由于场景的影响会导致两个对象之间的相关性是被夸张或缩小的。将场景信息作为混杂变量，利用“do 算子”理论，通过后门调整公式建模干预概率。实验结果表明，加入因果干预的预测更加稳健。类似思路也应用在自然语言处理领域中的词向量表示学习任务上。Zhang 等人（2021）提出在掩码式语言模型中，上下文和被预测的单词之间可能是被其他单词所共同影响的，实验结果表明，在解码模型阶段中加入后门调整去混杂模块后，模型在信息抽取、视觉问答等任务上表现是更加稳健的。

第三节 基于后门调整的情感分析模型

一、主题混杂假设

Landeiro 等人（2019）曾提出，在 IMDB 电影评论数据集中，由于选择偏差的存在，涉及到恐怖片的电影评论倾向于表达消极的情感，而涉及到爱情电影的评论倾向于表达积极的情感，因此，我们假设可以将评论主题作为混杂因子。采

用文本的 TF-IDF 表示作为输入特征，使用简单的逻辑回归模型学习情感预测，影响系数较高的单词列表如表 6-1 所示：

表 6-1 逻辑回归模型中对情感影响系数较大的单词

正向影响标签的词汇	负向影响标签的词汇
['great', ' romantic ', 'excellent', 'perfect', 'wonderful', 'best', 'fun', 'love', 'enjoyed', 'especially', 'loved', 'beautiful', 'amazing', 'favorite', 'has', 'enjoy', 'life', 'classic', 'drama', 'moving', 'will', 'together', 'performances', 'funniest', 'greatest']	['worst', 'bad', 'awful', 'waste', ' horror ', 'terrible', 'poor', 'boring', 'worse', 'stupid', 'poorly', 'dull', 'even', 'unfortunately', 'pointless', 'something', 'lacks', 'sucks', 'annoying', 'money', 'wasted', 'predictable', 'badly', 'fails', 'talent']

从表 6-1 中可知，“horror”对消极情感的贡献系数较高，而这一单词本身并无情感含义，因此，在涉及到恐怖电影的积极评论时，模型也许会做出错误的判断。本章将模型学习到“horror”的虚假相关性的原因解释为：主题影响评论文本分布的同时，对标签也有相关性。也就是说，单词“horror”更容易出现在恐怖语义（该电影属于恐怖片）的上下文中，与此同时，观众在恐怖电影下发表的评论，倾向于是消极的情感。因此，单词“horror”出现时，更容易是消极情感。

本章使用 BERTopic 模型（Grootendorst, 2022）获取训练集的主题概率分布以及主题表示向量。BERTopic 主题模型主要分为 3 步：（1）获取上下文语义的句子表示：所利用的句子编码表示可以任一句子向量表示模型，比如 Glove 向量表示、BERT 或 RoBERTa 等预训练语言模型的句子表示都可以作为其向量表示基本模型。（2）对句子表示进行降维：文档的表示向量维度较高，在词嵌入空间非常稀疏，不易实现聚类，因此，该工作使用 UMAP 算法进行降维。（3）对降维后的句子表示进行聚类：使用基于层次和密度的经典聚类算法 HDBSCAN 进行聚类。

二、两种不同的相关性

下面以本章使用的电影评论情感分析任务为例，用一个假设的数据集，来直观地说明在考虑混杂与不考虑混杂的两种情况下，所得到的特征与目标变量之间的相关性是截然不同的。

假设训练集一共 1000 条样本，其中包括 300 条恐怖电影相关的评论（简称

恐怖主题)以及 700 条爱情片相关的评论(简称爱情主题),相关分布见表 6-2。这个例子满足图 6-1 中的因果图假设,这种假设对于观测数据是合理的,因为提到“情节”的主题更容易是恐怖电影(对于这种类型的电影,人们更在意情节),情感消极的样本主题更容易是恐怖电影(人们对恐怖片的要求是很严格的,过于刺激或过于老套的情节设定都很难取悦观众)。

表 6-2 假设例子中的相关分布

1000 条样本	爱情电影 (700 条)	提到“情节” (30 条)	积极 (24 条)
			消极 (6 条)
		未提到情节 (670 条)	积极 (536 条)
			消极 (134 条)
	恐怖电影 (300 条)	提到“情节” (70 条)	积极 (14 条)
			消极 (56 条)
		未提到情节 (230 条)	积极 (46 条)
			消极 (184 条)

不考虑主题的情况下,在未提到情节的 900 条样本中,消极情感占比 35.3%,而提到情节的 100 条样本中,消极情感样本占比 62%。因此,是否提到情节与情感消极与否存在很强的相关性。

当我们按照主题¹¹分层,则会得到不同的结论:

- 爱情主题电影下,在未提到情节的 670 条样本中,消极情感占比 20%,而提到情节的 30 条样本中,消极情感样本占比也为 20%。因此,在爱情主题电影评论中,是否提到情节与情感消极与否不存在相关性。

- 恐怖主题电影下,在未提到情节的 230 条样本中,消极情感占比 80%,而提到情节的 70 条样本中,消极情感样本占比也为 80%。因此,在恐怖主题电影评论中,是否提到情节与情感消极与否也不存在相关性。

因此,按照主题分层讨论时,是否提到情节与情感变量是不存在相关性的,

¹¹ 此处举例,主题代表着电影类型,基于电影评论是对某个电影的评价,本章假设电影类型相关的语义被用户以评价电影内容的形式表达出来。

这更符合人类的认知，即情节一词是中性的，本不应该对情感变量有影响作用。

三、Do 算子分布变换的理解

在社会科学领域，用来控制混杂的方法包括：匹配、分层，以及回归等。Pearl（2009）提出使用协变量调整（又称后门调整）方法来去除混杂变量的影响。Landeiro 和 Culotta（2016）首先利用后门调整方法提升文本分类任务的鲁棒性。与其不同点在于，为了利用预训练语言模型优异的语义表示能力，我们使用主题的连续性表示作为混杂变量。后门调整是通过 do 算子来实现的：

$$P(Y | do(X)) = \sum_Z P(Y | X, Z) \cdot P(Z) \quad (6.1)$$

后门调整思路的核心是，在数据生成过程满足因果图假设的前提下，通过后门调整公式将原数据分布（图 6-2 中的左图）转换为新分布（图 6-2 中的右图），在新分布下，混杂（主题）与处置变量（输入文本）之间的相关性不再存在，此时学习到的相关性是特征与情感之间的因果相关性。




图 6-2 后门调整后的因果图表示

这里从数据加权的角度解释 do 算子（干预操作）能够进行分布变换的原因。如公式(6.2)所示，将后门调整公式的分子和分母同时乘以条件概率 $P(X|Z)$ ，可发现后门调整的操作，等价于将总体数据中每个样本 $(Y = y, X = x, Z = z)$ 的分布概率用因子 $1/P(X = x|Z = z)$ 来放大，也就是说，在本章这个任务背景下，如果对于某样本，主题 z 生成其输入文本 x 的概率越高，那么该样本的权重越低。在该因子的作用下，去除了每个主题与输入文本的相关性，即图 6-2 中右图的分布。因此，使用网络结构对干预概率（而非条件概率）进行建模，再对干预概率与分类目标之间的损失进行优化训练，模型学习到的相关性才是比较接近因

果的相关性，进而可以提升模型的稳健性能。

$$\begin{aligned}
 P(Y | do(X)) &= \sum_Z P(Y | X, Z) \cdot P(Z) \\
 &= \sum_Z \frac{P(Y | X, Z) P(X | Z) P(Z)}{P(X | Z)} \\
 &= \sum_Z \frac{P(Y, X, Z)}{P(X | Z)}
 \end{aligned} \tag{6.2}$$

回到上文的假设例子，如表 6-3 所示，后门调整的作用是将总体数据中每个样本($Y = y, X = x, Z = z$)的分布概率按照因子 $1/P(X = x | Z = z)$ 来进行复制，形成新的数据分布，在这个分布下，1400 条爱情电影评论中，提到“情节”和未提到“情节”的样本各占 700 条；在 600 条恐怖电影评论中，提到“情节”和未提到“情节”的样本各占 300 条。即电影主题与是否包含“情节”这个特征无关，阻断了从主题混杂到输入文本之间的箭头传播。

表 6-3 前文假设例子在后门调整后的数据分布

1000 条样本 → 2000 条样本	爱情电影 (700 条 → 1400 条)	提到“情节” (30 条→30*700/30 条)	积极 (24 条→24*700/30 条)
			消极 (6 条→6*700/30 条)
		未提到情节 (670 条→670*700/670 条)	积极 (536 条→536*700/670 条)
			消极 (134 条→134*700/670 条)
	恐怖电影 (300 条 → 600 条)	提到“情节” (70 条→70*300/70 条)	积极 (14 条→14*300/70 条)
			消极 (56 条→56*300/70 条)
		未提到情节 (230 条→230*300/230 条)	积极 (46 条→46*300/230 条)
			消极 (184 条→184*300/230 条)

四、 主题去混杂学习

已知文本分类任务的数据为 $D: \{(X_i, y_i)\}_{i=1, 2 \dots N}$ ，其中 X_i 表示输入文本， y_i

表示分类标签, $y_i \in \{0, 1, \dots, c\}$ 。首先, 使用特征抽取模块 (RNN-att 或预训练语言模型) 对句子进行编码表示: $H_\theta(X)$, 其中, θ 是文本编码模块的参数。模型的整体框架如图 6-3 所示。




图 6-3 基于因果干预的情感分类模型

(一) 主题表示

使用文本数据训练主题模型 BERTopic 获取各主题的先验概率以及嵌入表示, 这里为保证主题的嵌入表示与文本的编码表示在同一语义空间, BERTopic 句子编码模型与文本分类模型的编码模型保持一致, 具体来说, 当文本分类模型的特征抽取模块是 BERT 预训练模型 (或 RNN, RoBERTa) 时, BERTopic 使用的句子编码模型也是 BERT (或 Glove, RoBERTa):

$$P(Z), H(Z) = \text{BERTopic}(\{X_1, X_2, \dots, X_N\}) \quad (6.3)$$

其中 $P(Z)$ 代表各个主题的先验概率, $H(Z)$ 代表各个主题的向量表示, 维度取决于 BERTopic 模型所使用的编码模型。

（二）干预概率

通过后门调整计算的干预概率为：

$$P(Y | do(X)) = \sum_Z P(Y | X, Z) \cdot P(Z) \quad (6.4)$$

下面来对干预概率进行建模，具体来说，最后一层预测标签的网络是 Softmax 层，因此有：

$$P(Y | X, Z) = \text{Softmax}(f_Y(X, Z)) \quad (6.5)$$

汇总来看，后门调整后的干预概率计算方式为：

$$P(Y | do(X)) := \mathbb{E}_z[\text{Softmax}(f_Y(X, Z))] \quad (6.6)$$

参考（T. Wang 等人，2020）的处理方式，这里应用归一化加权几何平均（Normalized Weighted Geometric Mean, NWGM）（Xu 等人，2015）来近似上述期望的计算，即：

$$\mathbb{E}_z[\text{Softmax}(f_y(X, Z))] \stackrel{NWGM}{\approx} \text{Softmax}(\mathbb{E}_z[f_y(X, Z)]) \quad (6.7)$$

在本章，假定函数 $f_y(X, Z)$ 的形式为：

$$f_y(X, Z) = W_c[H_\theta(X); \alpha_y(Z) \odot H(Z)] + b \quad (6.8)$$

其中， $[\cdot]$ 代表向量的拼接操作， $\odot$ 代表点乘运算符号， $\alpha_y(Z)$ 代表各个主题对于输入特征来说的重要程度，计算方式为：

$$\alpha_y(Z) = \frac{(W_q H_\theta(X))^T (W_z H(Z))}{\sqrt{\sigma}} \quad (6.9)$$

其中， σ 为隐藏层向量表示的维度。最后，可以得到建模后的干预概率：

$$P(Y | do(X)) \approx \text{softmax}\left(W_c\left[H_\theta(X); \sum_z P(Z) \odot \alpha_y(Z) \odot H(Z)\right] + b\right) \quad (6.10)$$

对干预概率与分类目标之间的损失进行优化训练，这里使用交叉熵函数来计算损失，整体的损失表示为：

$$\frac{1}{N} \sum L_{CE}(P(Y_i | do(X_i)), Y_i^{gold}) \quad (6.11)$$

第四节 实验部分

一、数据集介绍

本章将在两个任务上评估所提方法，包括：电影评论情感分析任务 IMDB，

以及金融情感分析任务 FPB (FinancialPhraseBank)。评估的内容包括: IID 设置下的原始测试集表现, 以及 OOD 设置下的对抗样本测试集的表现。关于数据集的来源介绍及样本标签分布如表 6-4 所示。

表 6-4 数据集介绍

数据集	训练集			IID 测试集			OOD 测试集		
	积极	中性	消极	积极	中性	消极	积极	中性	消极
IMDB-L	856	-	851	245	-	243	243	-	245
IMDB-S	4114	-	4059	1144	-	1101	1204	-	1177
FPB	954	2011	423	205	431	90	205	431	90

(一) IMDB

该任务包括 IID 设置下的原始 IMDB 测试集以及 OOD 设置下的反事实 IMDB 测试集。反事实测试集从原始的 IMDB 电影评论数据集 (PANG, 2005) 采样而来, 其中的反事实部分由 (Kaushik 等人, 2019) 收集和发布, 这篇工作按照标签情感分层采样了 2.5K 条电影评论, 并将其切分成 1707 条训练样本、245 条验证样本、488 条测试样本, 然后采用众包的方式修正每条样本, 修正的指导原则包括: 最小编辑、反转情感目标, 以及保证语言流畅性。最终收集到 2.5K 条调整后的反事实样本。特别地, IMDB 数据集中大多数文本长度较长, 为了比较长文本和短文本的不同表现, 前人工作 (Z. Wang & Culotta, 2021) 额外创建了 IMDB 数据集的短文本形式, 以及对应的短文本反事实测试集, 本章也使用了该版本的数据集进行实验, IMDB 原始版本即长文本版本, 简称为 IMDB-L, 短文本版本简称为 IMDB-S。

(二) FPB (Financial PhraseBank)

Financial Phrasebank 数据集 (Malo 等人, 2014), 包括 4840 条来自金融新闻领域中的文本句, 被 16 个具有金融商科背景的标注者标注为积极、中性、消极三个类别。标注依据为文本中的信息是否会给公司的股票价格产生积极影响、消极影响, 或没有影响。这是一个不平衡的数据集, 包括 1363 条积极情感的样

本, 604 条消极情感的样本, 以及 2873 条中性样本。按照标注结果的一致程度, 数据集被分为 50%、66%、75%, 和 100%一致程度的数据集。比如, 50%一致程度意味着超过 50%的标注者对某个样本选择了相同的情感极性。本章使用 50%一致水平下的数据集, 即 4840 条样本。

OOD 设置下的测试集来自对测试集的同义词扰动, 这里使用 nlpaug (Ma, 2019) 提供的同义词替代模块, 进行分布外测试集的生成。同义词的来源包括: wordnet、glove 词向量相似替代、BERT 语言模型对词的替代, 以及 RoBERTa 语言模型对词的替代。

二、对比模型介绍

实验使用三个模型来验证方法的有效性, 包括: GRU、BERT、RoBERTa。分别对每个模型进行后门调整设计, 不同的地方在于, 所使用的主题向量表示根据各模型的词嵌入向量不同进行调整, 比如 RNN 模型使用 Glove 词向量, 主题向量的表示也是通过 Glove 作为句子编码来获得的。实验中所使用的 BERT 和 RoBERTa 的模型介绍可见第三章的第四节。

(一) BiGRU-att

使用 BiGRU 模块对句子进行编码表示, 词向量使用 Glove 的 6B 版本, 此外增加注意力模块对各个位置的隐藏向量表示进行汇总。

$$h_1, h_2 \dots h_l = BiGRU(w_1, w_2 \dots w_l)$$

$$H_\theta(X) = \sum_i \alpha_i h_i \quad (6.12)$$

其中 α_i 是 *Attention* 模块对各个位置施加的注意力, 接下来的因果干预部分与第三节一致, 即将获得的句子编码表示代入公式(6.10)。RNN 系列的模型在实验结果中简称: rnn-att 和 rnn-att-back。此外, 对下文使用的 GRU 模块做出简要介绍。与 LSTM 相比, GRU 只有两个门控机制: 更新门和重置门, 在效果可比的情况下, 参数较少, 训练所耗费的时间成本低。具体来说, 如图 6-4 所示, 首先输入当前时间点的状态值以及上一个时间点的隐藏层变量值, 通过线性转换来计算更新门和重置门的值:

$$z_t = \sigma_g(W_z x_t + U_z h_{t-1} + b_z) \quad (6.13)$$

$$r_t = \sigma_g(W_r x_t + U_r h_{t-1} + b_r) \quad (6.14)$$




图 6-4 GRU 门控机制示意图

接着，重置门决定是否忽略之前的隐藏层状态，来更新当前时间点的隐藏层向量值：

$$\hat{h}_t = \phi_h(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h) \quad (6.15)$$

其次，更新门选择是否使用新的隐藏层向量来更新隐藏层状态。

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \hat{h}_t \quad (6.16)$$

其中 $\odot$ 表示哈达玛乘积。




图 6-5 GRU-attention 模型示意图

当 BiGRU 获得隐藏层向量表示后,如图 6-5 所示,将两层的隐藏层向量进行拼接,再增加注意力模块,加权汇总成最后的句子向量表示。

(二) BERT-FT

使用 BERT 预训练模型对句子进行编码表示,然后在训练集上微调网络参数。模型使用 bert-base-uncased 版本。

$$h_{cls}^{-1}, h_1^{-1}, h_2^{-1} \dots h_l^{-1} = BERT([CLS], w_1, w_2 \dots w_l)$$

$$H_{\theta}(X) = h_{cls}^{-1} \quad (6.17)$$

其中, h_i^{-1} 代表位置 i 最后一层编码模块的向量表示,接下来的因果干预部分与第三节一致,即将获得的句子编码表示代入公式(6.10)。BERT 系列的模型在实验结果中简称: b-ft 和 b-ft-back。

(三) RoBERTa-FT

类似使用 RoBERTa 预训练模型对句子进行编码表示,然后在训练集上微调网络参数。模型使用 roberta-large 版本。

$$h_{<s>}^{-1}, h_1^{-1}, h_2^{-1} \dots h_l^{-1} = RoBERTa(<s>, w_1, w_2 \dots w_l)$$

$$H_{\theta}(X) = h_{<s>}^{-1} \quad (6.18)$$

其中, h_i^{-1} 代表位置 i 最后一层编码模块的向量表示,接下来的因果干预部分与第三节一致,即将获得的句子编码表示代入公式(6.10)。RoBERTa 系列的模型在实验结果中简称: rb-ft 和 rb-ft-back。

(四) 反事实数据增强

针对电影评论数据集,先前工作曾提出反事实自动增强的方式(Z. Wang & Culotta, 2021),具体地,通过语义匹配的方式识别出对情感标签有真正影响的特征词,作者认为这些单词是对此数据集的情感标签有核心预测作用的因果特征词,借助 wordnet 获得这些单词的反义词,然后,将样本中的因果特征词替换为其反义词,标签为原始样本的相反标签,从而获得反事实样本,实验结果表明通过将该方法生成的反事实样本与原始样本组合训练,尽管没有众包技术得到的反事实增强方案效果好,但与基准模型相比,仍可以提高模型的泛化能力。实验结果报告中,通过在原有模型简称的基础上增加后缀 &&causal 来表示该模型,对应的,使用人工标注反事实进行样本增强的模型则用增加后缀 &&human 来表示。

三、实验设置

对于每个数据集，将训练集以 8:2 的比例随机分割为训练集和开发集，使用 5 轮实验的表现均值记录为最终的报告结果，每轮实验使用不同的随机初始化，BERT、RoBERTa 系列实验运行 20 个 epoch，使用早停策略来终止模型的训练，patience 为 3，使用 AdamW 优化器，预先设置学习率为 $1e-5$ ，采用预热策略，每批训练的样本数量为 64。RNN 系列模型设置为 50 个 epoch，patience 为 5，学习率设置为 $1e-4$ 。涉及到预训练语言模型的实验代码使用 huggingface 提供的接口来实现。所有实验的主题数目均设置为 5，BERTopic 句子编码模型与文本分类模型的编码模型保持一致，具体来说，当文本分类模型的特征抽取模块是 BERT 预训练模型(RNN,RoBERTa)时，BERTopic 使用的句子编码模型也是 BERT (Glove,RoBERTa)。

四、实验结果及分析

(一) IID 测试集的表现

不同模型在 IMDB 任务上的实验结果如表 6-5 所示。从表 6-5 中可以看出，对于两个版本的数据集，RoBERTa 预测情感分类的表现是最优异的。对于 IMDB-L 数据集，在准确率指标上，RoBERTa 模型分别超过 BERT 模型 5%，超过 RNN 模型 11%。因果干预学习在三个模型上都能提高原始测试集上的表现，其中后门调整后的 RNN 模型在分布内测试集上提高了 4.7%的准确率，改进幅度最大，这可以解释为主题表示缓解了 RNN 在长文本上的遗忘程度，但这种改进在 IMDB-S 数据集上没有出现。对于 IMDB-S 数据集，只有 RoBERTa 模型保持了对原始测试集的提升，对于其它两个模型，后门调整机制基本保持了模型的原有表现。

与反事实样本增强方案相比，对于 IMDB-L 数据集，后门调整模型均超过了反事实文本自动增强的对应模型，与人工增强方式相比，只在 RNN 模型上表现略微不足，在其余两个模型上均超过了人工反事实增强的准确率。这反映了反事实文本自动增强方法在长文本情况下可能会引入噪声，影响整体表现。

金融情感分析数据集 FPB 的实验结果如表 6-6 所示，与 IMDB 数据集类似，RoBERTa 仍然是表现最优异的模型，这可以解释为 RoBERTa 模型具有较强的特征抽取能力。略为遗憾的是，因果干预模型在原始测试集上表现略有下降，下降幅度最高的是 RoBERTa 模型，相比于原始模型，准确率下降了 1.6%左右，但仍

然在可接受的范围。

表 6-5 电影评论 IMDB 数据集上各模型的表现

实验方法	IMDB-L		IMDB-S	
	test	ctf	test	ctf
b-ft	88.98	86.97	78.41	71.20
b-ft&&causal	88.40	85.61	78.08	73.23
b-ft&&human	86.60	92.95	77.05	83.42
b-ft-back	89.14	87.17	77.68	71.26
rb-ft	93.16	87.13	82.62	71.63
rb-ft&&causal	92.58	80.29	82.88	74.52
rb-ft&&human	92.87	94.43	80.20	85.41
rb-ft-back	93.69	87.38	83.10	69.97
rnn-att	72.09	65.90	73.51	66.91
rnn-att&&causal	56.68	52.70	72.93	70.21
rnn-att&&human	79.67	85.74	72.08	76.99
rnn-att-back	76.80	70.86	73.47	66.97

（二）OOD 稳健性能的表现

1. 反事实对抗测试下的稳健性

对于 IMDB 数据集，分布外测试集是人工标注的反事实样本测试集，这种对抗方式，阻断了因果图中的路径②（图 6-6），因此，对虚假线索有依赖的模型会在这样的测试集上失效。通过观察三个模型在反事实测试集上的表现可以评估模型对虚假线索的依赖程度。在长文本数据集上，在原始测试集上表现最好的 RoBERTa 模型下降较高，达到了 6% 左右，体现了其对预测捷径的依赖。类似地，RNN 模型下降也比较严重，BERT 模型表现更加稳定。对于短文本数据集，三个模型都有着较高度数的下降，这说明在短文本数据集上模型更容易对输入文本的虚假线索进行捕捉。




图 6-6 分布外测试集对因果路径的阻断

在模型稳健性方面，因果干预机制均提升了三个模型在反事实样本测试集上的表现，除了短文本数据集中的 RoBERTa 模型。其中提升效果最好的是长文本下的 RNN 模型，在提高 IID 测试集准确率 4% 的基础上，将反事实测试集上的准确率也提升了 5%。与反事实增强方案相比，人工标注的反事实样本增强是表现效果最优异的，尽管这种方式会带来一定程度的 IID 测试集表现下降。与反事实自动生成的方案相比，长文本上的因果干预机制表现更加有效，而短文本情况下，反事实自动生成方案仍然是在减少人工标注的前提下较好的选择。这可以解释为，在短文本情况下，更容易生成高质量的反事实，比如：“这部电影很精彩。”，只需将“精彩”修改为反义词即可得到正确的反事实，当文本长度增加时，自动生成高质量反事实则会变得更加困难，甚至可能给模型引入新的噪声，如表 6-5 所示，RNN 模型经过反事实自动增强后的训练结果在原始测试集上有大幅度的下降。

2. 同义词扰动对抗测试下的稳健性

对于 FPB 数据集，本章使用同义词替代的扰动方式，阻断因果图中的路径①（图 6-6），从而破坏目标变量与虚假线索之间的依赖。对于该数据集，使用了四种不同的方式作为同义词的来源：wordnet 同义词替代、glove 词向量相似替代、BERT 语言模型对词的替代，以及 RoBERTa 语言模型对词的替代四种方式。

表 6-6 的结果显示三种基本模型均在扰动测试集上表现下降，其中，在 glove 词替代的测试集上下降程度整体最大，wordnet 扰动对三个模型的扰动影响相对较小。具体来说，在 glove 词替代的扰动测试集上，RNN 模型抵抗效果最好，这是因为 RNN 使用的词向量即为 glove 词向量，这种方式获得的同义词对其干扰

不大，对其他两个大规模的预训练语言模型，特别是 BERT，反而引起了较大的干扰。这说明 glove 词向量获得的相似语义词，在上下文语言模型中可能并不流畅。对于整体干扰效果最弱的 wordnet 同义词替代测试集，RNN 模型的对抗能力反而表现出不足，这说明上下文语言模型在大规模语料上习得的语言抽取能力为其泛化能力提供了支持。

表 6-6 FPB 数据集上各模型的表现

方法	test	扰动测试集下准确率的下降程度			
		wordnet_sub	glove_sub	bert_sub	roberta_sub
b-ft	86.09	2.95	11.38	7.82	8.37
b-ft-back	85.79	2.73	11.74	7.80	7.49
rb-ft	88.18	2.89	10.61	9.06	6.45
rb-ft-back	86.53	0.69	7.47	5.48	5.37
rnn-att	78.18	5.37	6.89	6.69	6.01
rnn-att-back	77.05	4.90	6.78	5.70	5.10

在防御效果上，对于 RoBERTa 和 RNN 来说，加入因果干预机制均降低了模型在四种扰动测试集下的准确率表现，对于 BERT 模型，除了在 glove 词替代的方式上所提方案的防御效果不明显外，其它三种干扰方式下的下降幅度均有所改进。如上所述，这说明 glove 词向量获得的相似语义词，在上下文语言模型中可能并不流畅，为改进防御能力增加了难度。整体来说，从相对水平来看（考虑到 RoBERTa 模型在 IID 测试集上的准确率下降了 1.6%），因果干预对 RoBERTa 模型的稳健性能提升仍然是较强的。

（三）主题混杂假设验证

前文主张建立在主题是输入文本与情感标签的混杂因子这一假设下，即主题符合两个条件：（1）影响输入文本的分布，（2）影响情感标签的分布。不同的主题会产生不同的文本表达，因此第一个条件是显然的；下面通过一个简单的预

测模型来验证第二个条件的成立。使用 BERTopic 模型对训练集的主题预测结果作为输入特征，情感标签作为目标变量，利用简单的逻辑回归算法预测情感标签。预测结果如表 6-7 所示，三个数据集的主题对情感标签具有一定的预测能力，其中电影评论数据集的长文本版本预测效果最强。这也解释了为何因果干预机制对 IMDB-L 数据集稳健性能改善效果最好。

表 6-7 主题预测情感的表现

指标	IMDB-L	IMDB-S	FPB
Accuracy	0.673	0.571	0.578

（四）可视化分析

为了更直观地展示因果干预模型能够在一定程度上缓解模型对虚假线索的依赖程度，这里使用热力图展示模型对各单词的注意力分布。具体地，将第一个位置对其他位置的最后一层注意力提取出来，对同一个位置所有头的注意力取平均值，然后通过热力图展示结果。




图 6-7 注意力均值可视化

如图 6-7 所示，在一个和“horror”有关的评论文本中，“*I love horror movies, but this is the worst one I've ever seen.*”，基础模型 rb-ft 除了对“worst”这一明显的因果词进行捕捉外，还将重点放在“horror”、“movies”等中性词上，这与我

们前期对数据集的分析比较一致,“horror”作为一种电影主题的中性描述,更倾向于出现在恐怖电影主题下,与此同时,观众对恐怖电影的情感大多数是消极的,所以模型经常捕捉到数据集中“horror”这样的单词与目标变量的虚假相关性,进而会将“horror”这样的词汇识别为判断线索。因果干预模型的注意力分布则更加符合人类对因果特征的直觉期待。

第五节 本章小结

本章针对未明确的虚假线索,提出主题混杂假设,然后基于后门调整学习的方式,缓解模型对未知虚假线索的依赖性;所提方法分别在前人提出的分布偏移型对抗样本(电影评论文本)和扰动攻击型对抗样本(金融新闻文本)做出测试,实验结果表明所提方式能够提升长文本分类任务的稳健能力。目前的工作通过去混杂提升模型稳健性,而混杂变量是通过先验知识获取,比如:写作风格、评论主题等,在不同的任务之间缺乏一定的通用性,可考虑通过生成网络自动学习混杂表示。混杂因子的特点是:既对输入文本有影响,又对标签变量有影响,可根据混杂因子是 X 和 y 共同原因的特点,设计混杂学习方案,在生成式模型(如变分自编码模型)的基础上,使用隐藏向量重构输入文本的同时,预测分类标签。利用学习到的抽象混杂表示,结合先前的去混杂技术提升模型的稳健性,实现研究方法的通用性。

第七章 结论与展望

本文以常识因果推理任务为例对自然语言处理任务中的虚假相关问题进行探索分析,并针对已知虚假线索和未知虚假线索两种情况,提出了针对虚假线索的缓解方法。本章将对全文内容进行归纳总结,并指出本文研究中还存在的不足之处,提出未来进一步改进方向。

第一节 全文总结

本文从因果推断的视角研究自然语言处理相关任务中的虚假相关现象,从发现和缓解两个步骤展开研究工作。首先,自然语言处理任务中的虚假相关现象是隐含在数据集中的,探究模型对数据集中浅层线索的捕捉能力,是理解模型脆弱性来源的基础,也为设计更合理的评估数据集提供参考。其次,缓解模型对浅层线索的依赖,促进模型对因果特征的捕捉,又可以细分为两种类型的问题,一是针对已知的虚假关联,如何设计算法对虚假关联进行约束,比如常识因果推理任务中模型对语义相似偏差的过度依赖问题(虚假线索为语义相似程度),以及歧视言论检测任务中与受保护属性相关的“偏见”问题(虚假线索为敏感属性信息),这两种类型任务的应用场景分别体现了对 NLP 算法公平性与稳健性的关注;二是针对未知的虚假线索,如何根据任务的特点设计算法提升模型抵抗攻击的能力。

一、常识因果推理任务中的虚假线索探索与分析

随着预训练语言模型的提出,从大规模语料中学习上下文语义表示,以特征或微调的方式辅助下游任务的训练,已成为解决自然语言处理任务的通用范式。深度学习算法在诸多自然语言处理任务中取得了令人满意的预测效果,在一些任务上甚至超越了人类的表现。常识因果推理任务的复杂性以及对世界知识的要求暗示着预训练语言模型所展现出的推理能力可能是被高估的。现有的对常识因果推理模型脆弱性的研究集中在可统计的线索上,比如:词分布,而与语义相关的抽象线索在常识因果推理任务上尚未被探索。先前工作表明在词分布上促进数据集实现均衡,可以帮助模型缓解与词分布的虚假关联,然而,以数据增强为代表的缓解方案是否会引起新的虚假相关也是需要关注的问题。

本文针对常识因果推理任务中存在的抽象虚假线索进行探究,并对之前表现优异的预训练模型以及先前工作中的去偏模型进行测试,评估针对特定虚假线索制定的缓解方案在新的虚假线索攻击下的脆弱程度。具体来说,以常识因果推理任务 COPA 为例,观察预训练语言模型在该任务上的脆弱性表现,提出预训练语言模型预测 COPA 任务所依赖的一个新的不易被发现的虚假线索:语义相似性;通过设置两种不同的干扰实验:前提干扰和问题类型干扰,测试模型的表现,验证预训练语言模型对语义相似的过度依赖假设。

二、已知虚假线索情况下的自然语言处理模型去偏方法

首先,本文从较为直接的情况开始研究缓解虚假相关性的方法,即在研究缓解方案之前,已经通过数据的统计分析,或者对抗样本测试获知模型的虚假线索。这种情况下,设计改进方案的动机通常较为直接。前人工作主要集中在两个方面,第一种思路在训练阶段进行,针对已知的虚假线索设计惩罚损失或对抗学习目标,使模型在学习如何预测原始目标的同时,降低对虚假线索信息的捕捉;第二种思路在训练前阶段进行,主要是通过样本加权、样本补充,以及样本过滤等调整方式,使得训练集样本对该虚假线索的依赖不再存在。

现有的改进方案在缓解虚假关联方面有一定的成效,但可能会带来两个后果。一方面,针对一种线索的去偏方案,可能会带来对另外一种浅层线索的依赖;另一方面,在执行去偏算法的过程中,忽视该线索与目标变量存在的直接因果效应,盲目去偏可能会降低模型的识别能力。

本文针对上述两个难点,研究常识因果推理任务和歧视言论检测任务中缓解虚假相关的具体方案。

(一) 常识因果推理模型中基于反事实约束的去偏方法

现有对常识因果推理模型的去偏方法是针对词分布线索设计的,这种方法可能导致模型加强对其他浅层线索的依赖,且目前对常识因果推理模型脆弱性的评估仅针对词线索,对模型推理能力的脆弱性评估不够全面。为此,本文提出了基于反事实约束的改进方案,在原有训练损失的基础上增加了一个反事实惩罚项,该方案降低了模型对语义相似的依赖程度,且改进的模型在保持原有预测水平的基础上,在针对词分布线索的对抗测试集上表现也更加稳健;此外,本文设计并构建了一个既可以评估模型对词分布依赖程度,又可以评估模型是否依

赖语义相似线索的挑战测试集 BCOPA-CE，为检测模型在该任务上的稳健性提供了有效评价标准。

（二）面向歧视言论检测公平性的身份核心型样本过滤算法

为了对 NLP 中的公平性问题进行探讨，本文以歧视言论检测任务为例进行研究。歧视言论检测模型对敏感属性信息的过度依赖可能会使其产生“偏见”。主流去偏方法的目标，都是使模型学习到的表示向量与身份信息尽可能的无关。然而，这并不完全符合实际情况。存在部分样本的情感贡献来源于对群体的刻板印象，由身份属性词表现出来，而上下文本身无明显情感贡献。由于这类样本大多是以身份信息作为核心情感贡献词，模型的预测需要特别考虑身份信息的存在，因此，针对这种类型样本的去偏会使模型对歧视言论的捕捉能力变弱，在此类样本的对抗样本上出现过高的误判率。本章基于此动机，提出身份核心型样本过滤机制，借鉴因果推断领域中的概念来鉴别样本中的身份信息是否属于核心情感贡献词，在不同的去偏方法上实施过滤，使得模型在保证去偏能力的同时，仍然具有歧视识别能力。实验结果表明，传统的去偏方式虽然会解除模型对身份信息这一捷径的依赖，但模型也会被迫从其它虚假线索寻找预测模式，从抽象的角度理解，我们的算法对去偏进行了细化分类，仅仅对上下文核心型样本施加去偏，不仅保证原有去偏模型的纠偏能力，同时也缓解了对其它虚假线索的依赖，提升去偏模型在反事实样本集上的稳健性。

三、未知虚假线索情况下自然语言处理模型的稳健性增强方法

针对已知虚假线索提出的去偏方法直接且易理解，这种方法可以明显降低模型的脆弱性，但仍具有不少局限性。但许多自然语言处理任务下，虚假线索范围很大且往往是未知的，不同线索之间也可能互相影响。因此，针对特定线索进行去偏，对提升模型对因果特征的捕捉能力作用是有限的。当虚假线索未知时，为缓解虚假相关性对模型的影响，不少研究工作将重点从对虚假相关特征的被动防御转变为对因果相关特征的主动学习上。现有研究通过反事实增强和域泛化方式来实现模型对因果特征的学习，但仍面临反事实生成质量不高、多领域的数据要求难以满足等挑战。

本文针对未知虚假线索导致的模型稳健性问题，提出改进方法，在没有域的标签情况下，从微观的域（比如：不同主题）出发建立因果图假设，提出主题混

杂假设,然后基于后门调整学习的方式,缓解模型对未知虚假线索的依赖性;所提方法分别在前人提出的分布偏移型对抗样本(电影评论文本)和扰动攻击型对抗样本(金融新闻文本)上进行了测试,实验结果表明所提方式能够提升文本分类模型的稳健能力,尤其对于长文本情况下的分类模型有较好效果。

第二节 研究展望

本文研究仍存在着一些不足之处,以下是未来重点研究和改进的方向。

一、 偏差之间的关联问题

一个任务的偏差(虚假线索)不是只有一个,针对特定线索制定的去偏方案很可能对别的偏差问题带来更严重的影响,第一种影响是可能引入新的偏差。比如在常识因果推理任务中,由于常识中的因果事件具有时序性的特点,采用故事文本生成的数据集(具有时序性的特点)进行数据增强,可以提高模型在分布内数据集的表现,但与此同时,也可能会带来新的时序偏差(并不是所有的时序的事件都具有因果性)。第二种影响是针对特定线索的去偏方案对其他偏差线索的依赖更加严重。正如在第三章中的实验结果所呈现的那样,针对常识因果推理任务的词分布偏差设计的数据增强方案,可以提升原模型在对抗测试集(即COPA-test-hard数据集)上的表现,但与此同时,该方案也在针对语义偏差所设计的两个干扰实验中,与原模型相比表现更加脆弱。

为避免去偏差的同时带来新的偏差,研究偏差之间的关联,设计更加通用的去偏方式是值得思考的。

二、 自动识别偏差线索

现有的偏差往往是通过先验知识来获知,然后通过统计分析或者干扰实验进行验证。然而,数据的不均衡往往不止在某种特定特征的分布上可以体现,尽可能的识别数据中存在的偏差,可以促使模型的学习更加稳健。

在有多个领域的数据集中,可以利用偏差域敏感的特质进行识别。具体来说,首先,针对当前领域数据集,学习出有偏模型,该模型学习到的相关性既包括因果相关,又包括虚假相关;其次,将该模型在另外一个领域中的数据集中做测试,将相关性失效的特征识别为虚假特征。

在不涉及多个领域的数据集中,根据有偏模型在训练集上的预测对数概率与

分类目标的差异对训练样本进行分类，来代表该样本在训练集中的“另类程度”，差异越大，代表这类样本与训练集中多数派样本的分布越不同。较为简单的方式是分成两类：预测正确的样本与预测错误的样本，预测错误的样本属于未被模型学习到，或者学习过之后又被遗忘的样本，从两类样本的分布差异中建立偏差识别方式。

三、 自动学习混杂表示

目前的工作通过去混杂提升模型稳健性，其中混杂变量是通过先验知识得知，比如：第六章的评论主题，在不同的任务之间缺乏一定的通用性，可考虑通过神经网络的方式自动学习混杂表示。混杂因子的特点是：既对输入文本有影响，又对标签变量有影响，可根据混杂因子是 X 和 y 共同原因的特点，设计混杂学习方案，在生成式模型（如变分自编码模型）的基础上，使用隐藏向量重构输入文本的同时，预测分类标签。利用学习到的抽象混杂表示，结合先前的去混杂技术，提升模型稳健性，提升研究方法的通用性。

四、 低资源反事实标注样本的有效利用方法

通过反事实样本增强促进模型对因果特征的捕捉，除了提高反事实样本生成质量之外，如何设计算法最大效率地利用低资源的高质量反事实样本（来自人工标注）也是很重要的途径，比如，可以将思路从如何学习生成反事实样本，转换到如何学习反事实表示上来，从少量标注的反事实样本中学习从原始样本到反事实样本的向量映射函数。

参考文献

- [1] 全鑫, 王斌君, 王润正, & 潘孝勤.(2021). 面向自然语言处理的深度学习对抗样本综述. 计算机科学.
- [2] 王晓娟.(2022). 基于词替换的对抗文本生成研究. 现代信息科技, 017, 006.
- [3] 张顺香, 吴厚月, 朱广丽, 许鑫, & 苏明星.(2022). 面向中文文本分类的字符级对抗样本生成方法. 电子与信息学报, 44, 1–10.
- [4] Ahuja, K., Shanmugam, K., Varshney, K., & Dhurandhar, A.(2020). Invariant risk minimization games. *International Conference on Machine Learning*, 145–155.
- [5] Alammar, J.(2019). The Illustrated Transformer. *The Illustrated Transformer*. <https://jalammar.github.io/illustrated-transformer/>
- [6] Arisoy, E., Sainath, T. N., Kingsbury, B., & Ramabhadran, B.(2012). Deep neural network language models. *Proceedings of the NAACL-HLT 2012 Workshop: Will We Ever Really Replace the N-gram Model? On the Future of Language Modeling for HLT*, 20–28.
- [7] Attanasio, G., Nozza, D., Hovy, D., & Baralis, E.(2022). Entropy-based Attention Regularization Frees Unintended Bias Mitigation from Lists. *Findings of the Association for Computational Linguistics: ACL 2022*, 1105–1119.
- [8] Ball-Burack, A., Lee, M. S. A., Cobbe, J., & Singh, J.(2021). Differential Tweetment: Mitigating Racial Dialect Bias in Harmful Tweet Detection. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 116–128.
- [9] Beutel, A., Chen, J., Doshi, T., Qian, H., Woodruff, A., Luu, C., Kreitmann, P., Bischof, J., & Chi, E. H.(2019). Putting Fairness Principles into Practice: Challenges, Metrics, and Improvements. *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, 453–459.
- [10] Beutel, A., Chen, J., Zhao, Z., & Chi, E. H.(2017). Data Decisions and Theoretical Implications when Adversarially Learning Fair Representations. arXiv. <https://doi.org/10.48550/arXiv.1707.00075>
- [11] Bhaskaran, J., & Bhallamudi, I.(2019). Good Secretaries, Bad Truck Drivers?

- Occupational Gender Stereotypes in Sentiment Analysis. *Proceedings of the First Workshop on Gender Bias in Natural Language Processing*, 62–68.
- [12] Blodgett, S. L., Barocas, S., Daumé III, H., & Wallach, H.(2020). Language(Technology)is Power: A Critical Survey of “Bias” in NLP. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 5454–5476.
- [13] Bras, R. L., Swayamdipta, S., Bhagavatula, C., Zellers, R., Peters, M., Sabharwal, A., & Choi, Y.(2020). Adversarial Filters of Dataset Biases. *International Conference on Machine Learning*, 1078–1088.
- [14] Calders, T., Kamiran, F., & Pechenizkiy, M.(2009). Building classifiers with independency constraints. *2009 IEEE international conference on data mining workshops*, 13–18.
- [15] Chang, S., Zhang, Y., Yu, M., & Jaakkola, T. S.(2020). *Invariant Rationalization*. arXiv. <https://doi.org/10.48550/arXiv.2003.09772>
- [16] Cheng, P., Hao, W., Yuan, S., Si, S., & Carin, L.(2021). FairFil: Contrastive Neural Debiasing Method for Pretrained Text Encoders. arXiv. <https://doi.org/10.48550/arXiv.2103.06413>
- [17] Clark, C., Yatskar, M., & Zettlemoyer, L.(2019). Don’t Take the Easy Way Out: Ensemble Based Methods for Avoiding Known Dataset Biases. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 4060–4073.
- [18] Dasgupta, I., Guo, D., Stuhlmüller, A., Gershman, S. J., & Goodman, N. D.(2018). Evaluating Compositionality in Sentence Embeddings. arXiv. <https://doi.org/10.48550/arXiv.1802.04302>
- [19] De Raedt, M., Godin, F., Devellder, C., & Demeester, T.(2022). Robustifying Sentiment Classification by Maximally Exploiting Few Counterfactuals. arXiv. <https://doi.org/10.48550/arXiv.2210.11805>
- [20] DeepTech 深科技.(2019). AI 正学会所有偏见！精华与糟粕通吃，算法偏见更难辨认也更持久. <https://baijiahao.baidu.com/s?id=1651178885132208343&wfr=spider&for=pc>

- [21] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K.(2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1(Long and Short Papers)*, 4171–4186.
- [22] Dixon, L., Li, J., Sorensen, J., Thain, N., & Vasserman, L.(2018). Measuring and Mitigating Unintended Bias in Text Classification. *Proceedings of the 2018 AAAI/ACM Conference on AI, Ethics, and Society*, 67–73.
- [23] Du, L., Ding, X., Xiong, K., Liu, T., & Qin, B.(2022). e-CARE: A New Dataset for Exploring Explainable Causal Reasoning. *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics(Volume 1: Long Papers)*, 432–446.
- [24] Elazar, Y., & Goldberg, Y.(2018). Adversarial Removal of Demographic Attributes from Text Data. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, 11–21.
- [25] Faal, F., Yu, J., & Schmitt, K.(2021). Domain Adaptation Multi-task Deep Neural Network for Mitigating Unintended Bias in Toxic Language Detection: *Proceedings of the 13th International Conference on Agents and Artificial Intelligence*, 932–940.
- [26] Fersini, E., Nozza, D., & Rosso, P.(2018). Overview of the Evalita 2018 Task on Automatic Misogyny Identification(AMI). *EVALITA Evaluation of NLP and Speech Tools for Italian*(P59–66). Accademia University Press.
- [27] Garg, S., Perot, V., Limtiaco, N., Taly, A., Chi, E. H., & Beutel, A.(2019). Counterfactual Fairness in Text Classification through Robustness. *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, 219–226.
- [28] Gencoglu, O.(2021). Cyberbullying Detection With Fairness Constraints. *IEEE Internet Computing*, 25(1), 20–29.
- [29] Gordon, A., Bejan, C., & Sagae, K.(2011). Commonsense causal reasoning using millions of personal stories. *Proceedings of the AAAI Conference on Artificial Intelligence*, 25.
- [30] Grootendorst, M.(2022). *BERTopic: Neural topic modeling with a class-based TF-*

- IDF procedure*. arXiv. <https://doi.org/10.48550/arXiv.2203.05794>
- [31] Gururangan, S., Swayamdipta, S., Levy, O., Schwartz, R., Bowman, S., & Smith, N. A.(2018). Annotation Artifacts in Natural Language Inference Data. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2(Short Papers)*, 107–112.
- [32] Hardt, M., Price, E., & Srebro, N.(2016). Equality of opportunity in supervised learning. *Proceedings of the 30th International Conference on Neural Information Processing Systems*, 3323–3331.
- [33] He, P., Liu, X., Gao, J., & Chen, W.(2020). DeBERTa: Decoding-enhanced BERT with Disentangled Attention. arXiv. <https://doi.org/10.48550/arXiv.2006.03654>
- [34] Jia, R., & Liang, P.(2017). Adversarial Examples for Evaluating Reading Comprehension Systems. *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, 2021–2031.
- [35] Kang, D., Khot, T., Sabharwal, A., & Hovy, E.(2018). AdvEntuRe: Adversarial Training for Textual Entailment with Knowledge-Guided Examples. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics(Volume 1: Long Papers)*, 2418–2428.
- [36] Karimi Mahabadi, R., Belinkov, Y., & Henderson, J.(2020). End-to-End Bias Mitigation by Modelling Biases in Corpora. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 58th Annual Meeting of the Association for Computational Linguistics.
- [37] Kaushik, D., Hovy, E., & Lipton, Z.(2019). *Learning The Difference That Makes A Difference With Counterfactually-Augmented Data*. International Conference on Learning Representations.
- [38] Kavumba, P., Inoue, N., Heinzerling, B., Singh, K., Reisert, P., & Inui, K.(2019). When Choosing Plausible Alternatives, Clever Hans can be Clever. *Proceedings of the First Workshop on Commonsense Inference in Natural Language Processing*, 33–42.
- [39] Kiritchenko, S., & Mohammad, S.(2018). Examining Gender and Race Bias in Two Hundred Sentiment Analysis Systems. *Proceedings of the Seventh Joint*

- Conference on Lexical and Computational Semantics*, 43–53.
- [40] Kuang, K., Xiong, R., Cui, P., Athey, S., & Li, B.(2020). Stable prediction with model misspecification and agnostic distribution shift. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(04), 4485–4492.
- [41] Kusner, M. J., Loftus, J., Russell, C., & Silva, R.(2017). Counterfactual Fairness. *Advances in Neural Information Processing Systems*, 30.
- [42] Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B.(2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10), 4156–4165.
- [43] Landeiro, V., & Culotta, A.(2016). *Reducing confounding bias in observational studies that use text classification*.
- [44] Landeiro, V., Tran, T., & Culotta, A.(2019). Discovering and controlling for latent confounds in text classification using adversarial domain adaptation. *Proceedings of the 2019 SIAM International Conference on Data Mining*, 298–305.
- [45] Li, Z., Chen, T., & Van Durme, B.(2019). Learning to Rank for Plausible Plausibility. arXiv. <https://doi.org/10.48550/arXiv.1906.02079>
- [46] Li, Z., Ding, X., Liu, T., Hu, J. E., & Van Durme, B.(2020). Guided Generation of Cause and Effect. *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*, 3629–3636.
- [47] Liu, F., & Avci, B.(2019). Incorporating Priors with Feature Attribution on Text Classification. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 6274–6283.
- [48] Liu, T., Xin, Z., Chang, B., & Sui, Z.(2020). HypoNLI: Exploring the Artificial Patterns of Hypothesis-only Bias in Natural Language Inference. *Proceedings of the 12th Language Resources and Evaluation Conference*, 6852–6860.
- [49] Luo, Z., Sha, Y., Zhu, K. Q., Hwang, S., & Wang, Z.(2016). Commonsense causal reasoning between short texts. *Proceedings of the Fifteenth International Conference on Principles of Knowledge Representation and Reasoning*, 421–430.
- [50] Ma, E.(2019). *NLP Augmentation*. <https://github.com/makcedward/nlpaug>.
- [51] Madaan, N., Padhi, I., Panwar, N., & Saha, D.(2021). Generate Your Counterfactuals: Towards Controlled Counterfactual Generation for Text.

- Proceedings of the AAAI Conference on Artificial Intelligence*, 35(15), 13516–13524.
- [52] Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P.(2014). Good debt or bad debt: Detecting semantic orientations in economic texts. *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- [53] McCoy, T., Pavlick, E., & Linzen, T.(2019). Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 3428–3448.
- [54] Messerli, F. H.(2012). Chocolate Consumption, Cognitive Function, and Nobel Laureates. *New England Journal of Medicine*, 367(16), 1562–1564.
- [55] Mikolov, T., Chen, K., Corrado, G., & Dean, J.(2013). Efficient estimation of word representations in vector space. arXiv. <https://doi.org/10.48550/arXiv.1301.3781>
- [56] Minervini, P., & Riedel, S.(2018). Adversarially Regularising Neural NLI Models to Integrate Logical Background Knowledge. *Proceedings of the 22nd Conference on Computational Natural Language Learning*, 65–74.
- [57] Mozafari, M., Farahbakhsh, R., & Crespi, N.(2020). Hate speech detection and racial bias mitigation in social media based on BERT model. *PLOS ONE*, 15(8), e0237861.
- [58] Mulyar, A.(2020). *AndriyMulyar/semantic-text-similarity: Zenodo Archiving Release(v1.0.1)*. Zenodo.
- [59] Niu, Y., Tang, K., Zhang, H., Lu, Z., Hua, X.-S., & Wen, J.-R.(2020). Counterfactual VQA: A Cause-Effect Look at Language Bias. arXiv. <https://doi.org/10.48550/arXiv.2006.04315>
- [60] Niven, T., & Kao, H.-Y.(2019). Probing Neural Network Comprehension of Natural Language Arguments. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 4658–4664.
- [61] Nozza, D., Volpetti, C., & Fersini, E.(2019). Unintended Bias in Misogyny Detection. *IEEE/WIC/ACM International Conference on Web Intelligence*, 149–155.
- [62] Pan, L., Yao, L., Zhang, W., & Wang, X.(2022). Mitigating Multi-class

- Unintended Demographic Bias in Text Classification with Adversarial Learning. *International Conference on Web Information Systems Engineering*, 386–394.
- [63] PANG, B.(2005). Seeing stars: Exploiting class relationships for sentiment categorization with respect to rating scales. *Proc. 43rd Annual Meeting of the Association for Computational Linguistics, 2005*, 115–124.
- [64] Park, J. H., Shin, J., & Fung, P.(2018). Reducing Gender Bias in Abusive Language Detection. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, 2799–2804.
- [65] Paul, M. J.(2017). Feature Selection as Causal Inference: Experiments with Text Classification. *Proceedings of the 21st Conference on Computational Natural Language Learning(CoNLL 2017)*, 163–172.
- [66] Pearl, J.(2009). *Causality*. Cambridge university press.
- [67] Peters, M., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K., & Zettlemoyer, L.(2018). *Deep contextualized word representations*.
- [68] Poliak, A., Naradowsky, J., Haldar, A., Rudinger, R., & Van Durme, B.(2018). Hypothesis Only Baselines in Natural Language Inference. *Proceedings of the Seventh Joint Conference on Lexical and Computational Semantics*, 180–191.
- [69]Reichert, E., Qiu, H., & Bayrooti, J.(2020). Reading Between the Demographic Lines: Resolving Sources of Bias in Toxicity Classifiers. arXiv. <https://doi.org/10.48550/arXiv.2006.16402>
- [70] Roemmele, M., Bejan, C. A., & Gordon, A. S.(2011). Choice of Plausible Alternatives: An Evaluation of Commonsense Causal Reasoning. *AAAI Spring Symposium: Logical Formalizations of Commonsense Reasoning*, 90–95.
- [71] Roemmele, M., & Gordon, A.(2018). An Encoder-decoder Approach to Predicting Causal Relations in Stories. *Proceedings of the First Workshop on Storytelling*, 50–59.
- [72] Rubin, D. B.(2005). Causal inference using potential outcomes: Design, modeling, decisions. *Journal of the American Statistical Association*, 100(469), 322–331.
- [73] Rudinger, R., May, C., & Van Durme, B.(2017). Social Bias in Elicited Natural Language Inferences. *Proceedings of the First ACL Workshop on Ethics in*

- Natural Language Processing*, 74–79.
- [74] Sagawa, S., Koh, P. W., Hashimoto, T. B., & Liang, P.(2019). *Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization*. arXiv. <https://doi.org/10.48550/arXiv.1911.08731>
- [75] Sakaguchi, K., Le Bras, R., Bhagavatula, C., & Choi, Y.(2020). Winogrande: An adversarial winograd schema challenge at scale. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34, 8732–8740.
- [76] Samory, M., Sen, I., Kohne, J., Flöck, F., & Wagner, C.(2021). "Call me sexist, but...": Revisiting Sexism Detection Using Psychological Scales and Adversarial Samples. *ICWSM*, 573–584.
- [77] Sasaki, S., Takase, S., Inoue, N., Okazaki, N., & Inui, K.(2017). Handling multiword expressions in causality estimation. *IWCS 2017—12th International Conference on Computational Semantics—Short papers*.
- [78] Schuster, T., Shah, D., Yeo, Y. J. S., Roberto Filizzola Ortiz, D., Santus, E., & Barzilay, R.(2019). Towards Debiasing Fact Verification Models. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing(EMNLP-IJCNLP)*, 3419–3425.
- [79] Shan, G., Foulds, J., & Pan, S.(2020). Causal Feature Selection with Dimension Reduction for Interpretable Text Classification. arXiv. <https://doi.org/10.48550/arXiv.2010.04609>
- [80] Shen, Z., Cui, P., Kuang, K., Li, B., & Chen, P.(2018). Causally Regularized Learning with Agnostic Data Selection Bias. *Proceedings of the 26th ACM international conference on Multimedia*, 411–419.
- [81] Tsuchiya, M.(2018). Performance Impact Caused by Hidden Bias of Training Data for Recognizing Textual Entailment. *Proceedings of the Eleventh International Conference on Language Resources and Evaluation(LREC 2018)*.
- [82] Utama, P. A., Moosavi, N. S., & Gurevych, I.(2020). Towards Debiasing NLU Models from Unknown Biases. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing(EMNLP)*, 7597–7610.
- [83] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N.,

- Kaiser, \Lukasz, & Polosukhin, I.(2017). Attention is all you need. *Advances in neural information processing systems*, 30, 5998–6008.
- [84] Wang, A., Pruksachatkun, Y., Nangia, N., Singh, A., Michael, J., Hill, F., Levy, O., & Bowman, S. R.(2019). Superglue: A stickier benchmark for general-purpose language understanding systems. arXiv. <https://doi.org/10.48550/arXiv.1905.00537>
- [85] Wang, T., Huang, J., Zhang, H., & Sun, Q.(2020). Visual Commonsense R-CNN. arXiv. <https://doi.org/10.48550/arXiv.2002.12204>
- [86] Wang, T., Sridhar, R., Yang, D., & Wang, X.(2022a). *Identifying and Mitigating Spurious Correlations for Improving Robustness in NLP Models*. arXiv. <https://doi.org/10.48550/arXiv.2110.07736>
- [87] Wang, T., Sridhar, R., Yang, D., & Wang, X.(2022b). Identifying and Mitigating Spurious Correlations for Improving Robustness in NLP Models. *Findings of the Association for Computational Linguistics: NAACL 2022*, 1719–1729.
- [88] Wang, X., Wang, H., & Yang, D.(2022). Measure and Improve Robustness in NLP Models: A Survey. *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4569–4586.
- [89] Wang, Y., & Bansal, M.(2018). Robust Machine Comprehension Models via Adversarial Training. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2(Short Papers)*, 575–581.
- [90] Wang, Z., & Culotta, A.(2020). Identifying Spurious Correlations for Robust Text Classification. *Findings of the Association for Computational Linguistics: EMNLP 2020*, 3431–3440.
- [91] Wang, Z., & Culotta, A.(2021). *Robustness to Spurious Correlations in Text Classification via Automatically Generated Counterfactuals*. Proceedings of the AAAI Conference on Artificial Intelligence.
- [92] Wang, Z., Shu, K., & Culotta, A.(2021). Enhancing Model Robustness and Fairness with Causality: A Regularization Approach. *Proceedings of the First Workshop on Causal Inference and NLP*, 33–43.

- [93] Waseem, Z.(2016). Are You a Racist or Am I Seeing Things? Annotator Influence on Hate Speech Detection on Twitter. *Proceedings of the First Workshop on NLP and Computational Social Science*, 138–142.
- [94] Waseem, Z., & Hovy, D.(2016). Hateful Symbols or Hateful People? Predictive Features for Hate Speech Detection on Twitter. *Proceedings of the NAACL Student Research Workshop*, 88–93.
- [95] Wu, T., Ribeiro, M. T., Heer, J., & Weld, D.(2021). Polyjuice: Generating Counterfactuals for Explaining, Evaluating, and Improving Models. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing(Volume 1: Long Papers)*, 6707–6723.
- [96] Xia, M., Field, A., & Tsvetkov, Y.(2020). Demoting Racial Bias in Hate Speech Detection. *Proceedings of the Eighth International Workshop on Natural Language Processing for Social Media*, 7–14.
- [97] Xu, K., Ba, J., Kiros, R., Cho, K., Courville, A., Salakhudinov, R., Zemel, R., & Bengio, Y.(2015). Show, attend and tell: Neural image caption generation with visual attention. *International conference on machine learning*, 2048–2057.
- [98] Yang, L., Li, J., Cunningham, P., Zhang, Y., Smyth, B., & Dong, R.(2021). Exploring the Efficacy of Automatically Generated Counterfactuals for Sentiment Analysis. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing(Volume 1: Long Papers)*, 306–316.
- [99] Yuan, J., Ma, X., Kuang, K., Xiong, R., Gong, M., & Lin, L.(2021). Learning Domain-Invariant Relationship with Instrumental Variable for Domain. arXiv. <https://doi.org/10.48550/arXiv.2110.01438>
- [100] Zhang, G., Bai, B., Zhang, J., Bai, K., Zhu, C., & Zhao, T.(2019). Mitigating Annotation Artifacts in Natural Language Inference Datasets to Improve Cross-dataset Generalization Ability. arXiv. <https://doi.org/10.48550/arXiv.1909.04242>
- [101] Zhang, G., Bai, B., Zhang, J., Bai, K., Zhu, C., & Zhao, T.(2020). Demographics Should Not Be the Reason of Toxicity: Mitigating Discrimination in Text Classifications with Instance Weighting. *Proceedings of the 58th Annual*

- Meeting of the Association for Computational Linguistics*, 4134–4145.
- [102] Zhang, S., Jiang, T., Wang, T., Kuang, K., Zhao, Z., Zhu, J., Yu, J., Yang, H., & Wu, F.(2021). DeVLBert: Out-of-Distribution Visio-Linguistic Pretraining With Causality. 1744–1747.
- [103] Zhang, X., Cui, P., Xu, R., Zhou, L., He, Y., & Shen, Z.(2021). *Deep Stable Learning for Out-of-Distribution Generalization*. 5372–5382.
- [104] Zhao, J., Wang, T., Yatskar, M., Ordonez, V., & Chang, K.-W.(2018). Gender Bias in Coreference Resolution: Evaluation and Debiasing Methods. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2(Short Papers)*, 15–20.
- [105] Zhou, M., Huang, M., & Zhu, X.(2020). Robust Reading Comprehension With Linguistic Constraints via Posterior Regularization. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28, 2500–2510.
- [106] Zmigrod, R., Mielke, S. J., Wallach, H., & Cotterell, R.(2019). Counterfactual Data Augmentation for Mitigating Gender Stereotypes in Languages with Rich Morphology. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 1651–1661.