

大语言模型人类偏好数据的长度与格式关联分析

——基于配对 Logistic 模型的审计应用

程豪 梁斯祯 李嘉帅 姜弼达 翁祖成 姚博晟

中央民族大学理学院, 北京 100081

基金项目: 国家自然科学基金青年科学基金项目 (72001197);

中央民族大学创新训练项目青苗计划 (QMRP2025110352)

摘要: 针对大语言模型评价中回答形式与人类选择相互交织的问题, 构建基于配对比较的偏好数据审计流程。以 LMArena 公开数据的 108,154 个唯一会话首轮评价为基础, 对其中 78,959 对明确胜负记录, 采用配对检验及含模型身份对比项的 Logistic 回归, 联合分析长度对数比与标题、列表、粗体密度差, 并通过英语和单轮子集检查敏感性。结果表明: 不等长配对中较长回答获胜比例为 62.37%; 控制可观测任务信息及模型身份后, 长度指标每标准差的优势比为 1.6196, 粗体密度呈较稳定的正关联, 标题关联较弱且对子集敏感, 列表密度未获得明确关联证据。进一步按长度比构建审计分层, 长度接近与长度比超过 2 的配对中, 较长回答获胜比例分别为 52.46% 和 69.06%。据此提出包含明确胜负与未决评价的分层复核方案, 为偏好数据质量管理提供量化依据。上述结果属于观察性关联, 应用示例不构成标签错误识别或去偏成效验证。

关键词: 大语言模型; 人类偏好; 配对比较; Logistic 回归; 数据审计

Length and Formatting Associations in Human Preference Data for Large Language Models

An Audit Application Using a Paired Logistic Model

Abstract: This study develops a paired-comparison workflow for auditing the association between response form and human choice in large language model evaluation. The analysis uses 108,154 first-evaluation records from unique sessions in a public LMArena dataset, including 78,959 pairs with a decisive outcome. Paired tests and logistic regression with model-identity contrasts jointly examine the log token ratio and differences in heading, list, and bold-formatting densities. English-language and single-turn subsets provide sensitivity checks. Among unequal-length decisive pairs, the longer response wins in 62.37% of cases. After adjustment for observed task information and model identity, the odds ratio per standard deviation of the length measure is 1.6196. Bold density shows a relatively stable positive association, whereas the heading association is weaker and subset-sensitive; list density has no clear statistical support. A descriptive audit illustration groups pairs by their length ratio. The longer-response win proportions are 52.46% for near-equal-length pairs and 69.06% for pairs with a length ratio above two. The resulting strata support a review plan covering both decisive and non-decisive evaluations. These findings are observational associations, and the audit illustration does not establish label errors or validate debiasing effectiveness.

Key words: large language models; human preference; paired comparison; logistic regression; data audit

1 引言

大语言模型评价常采用成对比较：对同一用户问题展示两个候选回答，由用户选择较优者。该方式能够直接记录实际使用中的相对偏好，Chatbot Arena 等平台据此开展众包评价与模型比较 [1]。然而，一个回答被选中并不等于其所有可观察特征都具有同样的质量含义。较长回答可能提供更多必要信息，也可能包含重复解释；标题、列表和粗体可能改善信息组织，也可能仅改变文本外观。对评价数据使用者而言，需要判断选择结果与这些形式特征之间存在多大关联，从而决定哪些配对进入进一步复核。

已有研究从不同角度讨论偏好信号的构成。Li 等 [2] 通过细粒度属性分析比较人类与大语言模型的偏好，表明总体选择背后包含多种评价维度。Dubois 等 [3] 利用回归控制长度因素，改进自动评价指标对长度差异的处理。Zhang 等 [4] 进一步考察列表、粗体等格式模式，说明格式与偏好学习之间的关系值得独立研究。这些工作为偏好数据审计提供了依据，但人类评价与自动评价器输出是不同的研究对象，对自动评价器的校正效果不能直接转化为人类选择中的因果结论。

在真实成对数据中，长度与格式分析还面临两个相互联系的问题。其一，格式计数随文本扩展而变化，仅比较胜者与败者的格式总量，难以判断关联来自格式本身还是文本规模。其二，不同模型的输出习惯、任务分布和被选择概率可能同时不同，忽略模型身份会使形式指标吸收模型间差异。因此，实际分析既要保持成对比较单位的一致性，也要在同一回归中联合纳入长度、格式和可观测背景信息。

本文以 LMArena 公开人类偏好数据为对象，研究三个问题：明确胜负配对的长度与格式差异如何分布；联合调整可观测变量后，哪些关联仍有统计支持；这些结果如何转化为可操作的审计分层。方法上，将长度对数比、格式密度差与模型身份对比项放入同一 Logistic 模型，并结合配对检验和敏感性分析评估结果。应用上，使用真实样本构建长度分层报告，给出固定复核预算下的抽样方案。本文的贡献在于将配对建模与评价数据复核衔接起来，并明确不同格式指标的证据差异。研究目标限定为观察性关联及其审计用途，形式编辑的因果效果需由独立干预设计检验。

2 数据与指标构造

2.1 数据来源与样本边界

研究使用 `lmarena-ai/arena-human-preference-140k` 的本地冻结数据 [5]，共 7 个原始分片、135,634 条记录。数据同时包含会话标识、评价次序、双方对话、胜负标签及长度和格式元数据。本文按会话首轮评价建立比较单位，检查角色交替、两侧用户输入轨迹一致性、文本有效性、标签完整性及计数合法性。通过筛选后，对仍存在多条候选记录的会话整体排除，得到每个唯一会话一条记录的分析集。

按首次失败原因互斥计数，排除非首轮评价 27,319 条、语言异常 30 条、空或无效文本内容 109 条、会话记录歧义 22 条，最终保留 108,154 条。评价结果包括 A 胜 39,042 条、B 胜 39,917 条、平局 16,574 条、双方差 12,621 条。后两类保留用于描述和审计分层，不并入二元胜负模型；因此，回归样本为 78,959 对明确胜负记录。其分析目标是该筛选总体中的相对选择，而不是所有平台交互中的偏好。

首轮评价与单轮对话需要区分：首轮评价记录内部仍可能包含多轮用户与模型交互，长度和格式由该评价记录的汇总字段表示。限制为首轮有助于减少评价历史与当前测量混杂，但不保证全部计量误差被消除。不同会话仍可能来自同一用户或相同提示词，故会话唯一性不能直接作为观测相互独立的证据。

2.2 结果变量与形式指标

对第 i 个明确胜负配对, 令 $Y_i = 1$ 表示 A 侧胜出, $Y_i = 0$ 表示 B 侧胜出。记双方回答 token 总量为 L_{Ai} 、 L_{Bi} , 二者均为正数。长度指标定义为

$$x_{Li} = \log \frac{L_{Ai}}{L_{Bi}}. \quad (2.1)$$

与绝对差相比, 对数比描述相对长度差异, 并在交换双方后改变符号。例如, 200 对 100 tokens 与 2,000 对 1,000 tokens 对应相同的长度比。该度量不把相同的绝对差视为相同的相对扩展, 也不能替代任务所需信息量的测量。

记格式类型 $f \in \{H, B, S\}$ 分别代表标题、粗体和列表, 双方格式计数为 C_{fAi} 、 C_{fBi} 。定义每千 token 密度差

$$x_{fi} = 1000 \left(\frac{C_{fAi}}{L_{Ai}} - \frac{C_{fBi}}{L_{Bi}} \right). \quad (2.2)$$

格式计数沿用上游元数据: 标题为 h1-h6 计数之和, 列表为有序与无序列表计数之和, 粗体为两种标记计数之和。本文未重新实现 Markdown 解析器, 故这些指标表示上游识别规则下的形式数量, 不等于经人工验证的结构质量或视觉效果。密度可以减少文本规模对格式总量的直接影响, 但仍共享长度分母, 不能据此认为长度与格式已完全分离。

描述检验使用胜者减败者的差值; 回归始终保持原始 A/B 方向, 不按照胜负重新排列解释变量。主模型将四个形式指标在相应分析子集中分别标准化, 即 $z_{ki} = (x_{ki} - \bar{x}_k)/s_k$, 其中 s_k 采用分母为该子集样本数的标准差。

表 1: 主要变量及统计含义

变量	定义与来源	解释边界
胜负 Y_i	A 胜为 1, B 胜为 0	排除平局与双方差后的条件总体
长度 x_{Li}	双方 token 总量的对数比	相对文本规模, 不代表信息增益
格式 x_{fi}	标题、粗体、列表每千 token 密度差	依赖上游计数, 共享长度分母
任务及提示词	任务标签、七类提示词属性、输入长度、轮数及语言	不是逐条回答内容质量评分
模型身份	A、B 两侧模型指示变量之差	控制模型间平均差异, 不等于题目级质量控制

2.3 控制变量与敏感性子集

任务信息包括创意写作、指令遵循、数学和代码标签。七类提示词属性对应复杂性、创造性、领域知识、问题求解、现实情境、具体性和技术准确性需求, 其取值来自任务标注, 不能解释为回答已达到相应质量标准。另纳入用户输入 token 数的 $\log(1 + L_U)$ 、对话轮数和语言虚拟变量; 各分析子集中频数低于 100 的语言合并为低频类别。

模型身份采用双方模型指示变量的差表示, 不使用由本批胜负标签估计的模型胜率作为解释变量。为检查语言混合及对对话轮次口径的影响, 另对英语样本 42,001 对和单轮对话样本 67,608 对拟合相同类型模型。二者与全量样本重叠, 属于敏感性检查; 子集间指标标准差不同, 不能直接将 OR 差异解释为同一原始单位的关联变化。

3 配对统计模型与审计方法

3.1 配对差异检验

令 D_i 为某项特征的胜者值减败者值，剔除零差后的配对数为 n_* ，正差数为 n_+ 。以

$$\hat{q} = \frac{n_+}{n_*} \quad (3.1)$$

描述不等值配对中胜者特征更大的比例。在独立配对及正负差等概率的零假设下， $n_+ \sim \text{Binom}(n_*, 1/2)$ ，据此进行双侧符号检验并计算精确二项区间。对格式是否出现的二元指标，只比较双方存在性不一致的配对，形成精确 McNemar 检验。零差数量与总样本量同时报告，避免以不同分母比较特征强弱。

作为补充，以非零差绝对值的平均秩计算配对秩二列相关

$$r_{\text{rb}} = \frac{W_+ - W_-}{W_+ + W_-}, \quad (3.2)$$

其中 W_+ 和 W_- 为正差与负差的秩和。该量用于描述差异方向及相对强度。Wilcoxon 符号秩检验也保留在补充结果中；由于差值分布对称性未得到保证，不将其无条件表述为中位数检验，也不依赖它识别因果关系。

3.2 含模型身份对比项的 Logistic 模型

设 $p_i = \Pr(Y_i = 1 \mid \mathbf{z}_i, \mathbf{X}_i, m_{Ai}, m_{Bi})$ ，构建

$$\log \frac{p_i}{1 - p_i} = \alpha + \beta_L z_{Li} + \beta_H z_{Hi} + \beta_B z_{Bi} + \beta_S z_{Si} + \boldsymbol{\gamma}^\top \mathbf{X}_i + \theta_{m_{Ai}} - \theta_{m_{Bi}}. \quad (3.3)$$

其中 $\mathbf{X}_i$ 为控制变量， θ_m 为模型身份参数，选定一个参考模型并令其参数为零。模型身份项沿用 Bradley-Terry 配对比较的参数差形式 [6]，在此基础上加入记录层特征与控制变量。截距及记录层控制项允许 A 侧获胜概率随观测背景变化，因此本文模型不是只含模型能力参数的纯排名模型。

令 $\mathbf{v}_i$ 为完整设计向量、 $\boldsymbol{\eta}$ 为参数向量，通过最大化 Bernoulli 对数似然估计参数：

$$\ell(\boldsymbol{\eta}) = \sum_{i=1}^n \left[Y_i \mathbf{v}_i^\top \boldsymbol{\eta} - \log\{1 + \exp(\mathbf{v}_i^\top \boldsymbol{\eta})\} \right]. \quad (3.4)$$

实现中先检查设计矩阵满秩，再检验迭代收敛和参数有限性。全量、英语和单轮模型均通过上述检查；对应设计矩阵秩分别为 90、69 和 89。这些检查保证数值结果满足当前估计程序要求，不等于模型设定已经充分捕捉全部选择因素。

采用 HC0 夹心协方差估计标准误。若 $\widehat{W} = \text{diag}\{\widehat{p}_i(1 - \widehat{p}_i)\}$ ，则

$$\widehat{\text{Var}}(\widehat{\boldsymbol{\eta}}) = (V^\top \widehat{W} V)^{-1} \left[\sum_{i=1}^n \mathbf{v}_i \mathbf{v}_i^\top (Y_i - \widehat{p}_i)^2 \right] (V^\top \widehat{W} V)^{-1}. \quad (3.5)$$

这里仍以观测间独立为工作假设。HC0 不处理同一用户跨会话或重复提示词带来的聚类依赖，相应区间应在该限制下解释。

3.3 关联量解释与多重比较

标准化指标 z_k 的条件优势比为 $\text{OR}_k = \exp(\beta_k)$ ，表示在模型中其他变量保持不变时，该指标增加一个标准差对应的获胜优势之比。OR 不等于概率倍数，也不意味着实际添加某种格式后必然

产生同样变化。若需概率尺度的辅助描述，平均局部导数为

$$\overline{\partial p / \partial z_k} = \frac{\hat{\beta}_k}{n} \sum_{i=1}^n \hat{p}_i (1 - \hat{p}_i). \quad (3.6)$$

其含义是拟合概率的平均局部斜率，不是实际增加一个标准差的离散概率变化。

多重比较采用 Holm 方法 [7]。配对分析中，全量、英语、单轮及 16 种任务标签组合的全部符号与 McNemar 检验共同构成一个家族；补充 Wilcoxon 检验未参与该校正。回归中，三个模型的 12 个焦点系数共同构成另一个家族。按升序排列原始 p 值后，调整值为

$$\tilde{p}_{(j)} = \min \left\{ 1, \max_{1 \leq k \leq j} (M - k + 1) p_{(k)} \right\}. \quad (3.7)$$

本文采用双侧 0.05 水平，表图中的 95% 区间为逐项区间，不是同时置信区间。对于浮点下溢产生的零值，以 $p < 0.001$ 呈现，不将其解释为概率严格等于零。任务组合的小样本结果仅保留供追溯，不据此开展细碎的实质推断。

3.4 审计分层规则

模型分析用于识别需要关注的特征，具体抽样则使用可直接计算且不依赖胜负方向的指标。定义无方向长度比

$$R_i = \frac{\max(L_{Ai}, L_{Bi})}{\min(L_{Ai}, L_{Bi})} \geq 1, \quad (3.8)$$

以 $R_i \leq 1.25$ 、 $1.25 < R_i \leq 2$ 和 $R_i > 2$ 构成三层。阈值用于展示接近、中等和较大长度差异，是本次分析阶段确定的解释性规则，不是预注册阈值或已验证的最优风险界限。规则不将原始标签判为正确或错误，也不因结果显著而自动调整样本权重。

审计报告同时输出各层总量、明确胜负数、平局与双方差数量，以及不等长明确胜负配对中的较长回答获胜比例。这样既可观察形式差异，也可检查二元建模排除的评价是否集中在特定层中。第 5 节基于真实记录给出应用示例。

4 实证结果与敏感性分析

4.1 未调整的配对差异

在 78,959 对明确胜负记录中，187 对等长，78,772 对不等长；较长回答获胜 49,130 对，比例为 62.37%，95% 精确二项区间为 [62.03%, 62.71%]。胜者减败者的中位长度差为 125 tokens，配对秩二列相关为 0.3278。前一比例只使用不等长配对，中位数则使用全部明确胜负配对，二者回答的问题不同。

表2表明，计数与密度不能混为同一证据。胜者列表计数较多的比例为 59.13%，但列表密度较高的比例仅为 50.33%，校正后未获显著支持。标题和粗体在密度口径下仍呈正向差异，但秩二列相关较计数口径减小。这说明格式比较对文本规模的处理敏感；它不证明列表仅由长度生成，也不能将显著的格式密度差直接等同于不合理偏好。

4.2 联合回归中的调整关联

表3报告全量样本四个焦点系数。长度对数比每增加一个标准差，其调整后 OR 为 1.6196，95% 区间为 [1.5804, 1.6597]。全量长度指标标准差约为 1.0224，故这个单位不是增加一个 token，也不是长度恰好翻倍。相同模型条件下，长度对数比增加 1.0224，对应原长度比乘以约 2.780；该换算仅说明回归尺度。

表 2: 全量样本的配对差异摘要

特征与口径	非零差配对数	正差比例 (%)	r_{rb}	Holm p
长度计数	78,772	62.37	0.3278	< 0.001
标题计数	47,046	58.79	0.2080	< 0.001
标题密度	49,087	55.30	0.1164	< 0.001
粗体计数	68,357	60.26	0.2608	< 0.001
粗体密度	70,187	55.80	0.1547	< 0.001
列表计数	66,959	59.13	0.2334	< 0.001
列表密度	69,296	50.33	0.0046	1.0000

注：正差为胜者特征大于败者；各行分母仅为相应特征的非零差配对。全部明确胜负配对数为 78,959，零差数可由总数减去第二列得到。

表 3: 全量联合 Logistic 模型的焦点关联

变量	$\hat{\beta}$	OR	95% 逐项区间	Holm p
长度对数比	0.4822	1.6196	[1.5804, 1.6597]	< 0.001
标题密度差	0.0278	1.0282	[1.0092, 1.0476]	0.0212
粗体密度差	0.0541	1.0556	[1.0339, 1.0778]	< 0.001
列表密度差	-0.0129	0.9872	[0.9703, 1.0043]	0.5631

注：样本数为 78,959；四项指标联合入模并分别标准化。模型调整任务、提示词属性、输入长度、轮数、语言及模型身份，标准误为 HC0。

粗体密度的 OR 为 1.0556，标题密度为 1.0282，均在全量模型中呈正关联；列表密度区间跨越 1。即使标题和粗体通过多重比较校正，其在各自标准化尺度上的关联量仍小于长度项，不能只凭大样本下的显著性把格式描述为主导选择的因素。对于全量样本，标题、粗体及列表密度差的标准差分别约为 5.2319、18.3675 和 18.3726 次/千 tokens，这也说明标准化 OR 不能直接转换为“添加一次格式”的收益。

联合纳入可观测变量后长度关联仍然存在，表明它不完全被本模型的控制项吸收。然而，模型身份只控制不同模型的平均差异，不能测量同一模型在具体题目上的回答质量。准确性、覆盖率和冗余程度未被独立标注，因而长度仍可能同时代表信息充分性及其他未观测因素。这里的“调整”是给定模型设定后的条件比较，而非剥离内容质量后的纯长度效应。

4.3 英语与单轮子集

图1展示三个分析样本的估计。英语和单轮子集的长度 OR 分别为 1.5847 和 1.6436，校正后均有统计支持；粗体密度 OR 分别为 1.0815 和 1.0581，同样保持正关联。因此，在本次可检查的语言和轮次口径下，长度与粗体的方向较稳定。

标题密度在英语子集中的 OR 为 1.0124，95% 区间为 [0.9868, 1.0388]；单轮子集 OR 为 1.0213，逐项区间为 [1.0011, 1.0420]，但 Holm 校正后的 $p = 0.1954$ 。因此，标题不宜与粗体合并为“稳定格式效应”。列表密度在两个子集中均缺少明确关联证据。逐项区间排除 1 与校正后不显著并不矛盾，因为二者采用不同的多重比较口径。

这些子集分析没有消除选择偏差或提供独立外部验证。尤其是子集分别标准化，且样本大量重叠，点估计差异只能作为敏感性描述。对于重复提示词、用户相关性、极端长度以及非线性关系，当前模型仍需进一步检验；不能把三次同向估计理解为全部稳健性问题均已解决。




图 1: 全量、英语与单轮样本的调整关联。左右面板横轴范围不同；区间为逐项 95% 区间，各子集分别标准化。

5 偏好数据审计应用

5.1 面向复核的分层报告

设偏好数据进入后续评价或训练流程前，管理者只能复核有限数量的记录。仅按总体比例随机抽样能够描述总体，却可能使特定形式差异层中的记录较少。本文依据式(3.8)形成三个长度层，并同时保留明确胜负和平局、双方差。表4为本次冻结数据的实际统计，图2展示各层的较长回答获胜比例。

表 4: 按无方向长度比构建的审计分层

长度层	保留记录	明确胜负	未决比例 (%)	较长者获胜 (%)
$R \leq 1.25$	23,536	15,964	32.17	52.46
$1.25 < R \leq 2$	37,992	27,017	28.89	59.26
$R > 2$	46,626	35,978	22.84	69.06

注：未决包括平局与双方差，分母为本层全部保留记录；较长者获胜比例的分母为本层不等长且明确胜负配对，依次为 15,777、27,017 和 35,978。

在长度接近层，较长回答获胜比例为 52.46%，区间为 [51.67%, 53.24%]；中等差异层为 59.26%，区间为 [58.67%, 59.84%]；较大差异层为 69.06%，区间为 [68.58%, 69.53%]。这是一组未调整的分层描述，不是控制其他条件后使回答变长的效果。不同层的内容充分性、任务需求或模型组合可以不同，不能因比例上升便把较大差异层判为偏差样本。

长度分层也揭示了二元分析的样本边界。长度接近层中平局及双方差占 32.17%，在较大差异层中占 22.84%；前者比后者高约 9.33 个百分点。若审计只沿用回归中的明确胜负样本，将无法检查这些未决评价是否包含可识别的质量问题。因而实际复核应将未决状态纳入抽样框，不能把排除记录理解为没有分析价值。

作为格式交叉描述，在粗体密度不相等且明确胜负的配对中，粗体密度较高者在三个长度层的获胜比例依次为 49.79%、51.36% 和 61.49%，分母分别为 13,525、23,817 和 32,845。该结果提示总体格式关联可能随长度层的样本构成变化，支持同时检查长度与格式。它没有进一步控制层内残余长度差、任务和模型身份，不应与表3的联合回归量相互替代。




图 2: 各长度层中较长回答获胜的比例与 95% 精确二项区间。区间以配对独立为工作假设, 未进行多重比较校正。

5.2 固定预算下的复核方案

上述分层可以转化为具体的抽样任务。例如, 在 300 条记录的复核预算下, 先向三个长度层各分配 100 条, 并在层内按明确胜负、平局、双方差的构成进行随机抽样; 若某类样本需单独研究, 可事先设定最低抽样数并记录实际纳入概率。等额分配是便于比较各层的方案示例, 本文未实际实施人工复核, 也未验证其优于比例分配或随机抽样。

复核者需同时评价双方内容的正确性、相关性、信息覆盖及组织清晰度, 尽可能隐藏原始胜负标签, 并记录复核选择与理由。不能把复核者不同意原选择直接当成标签错误: 偏好本身可能存在合理差异, 应另设独立可核验的内容标准。由于标题或列表可能承载任务所需结构, 自动删去格式再比较也未必保持语义和任务条件不变。

若用分层样本估计该审计总体的争议比例, 应恢复原抽样权重。记层 h 的总体数量为 N_h 、复核样本量为 b_h 、争议指标为 $a_{hj} \in \{0, 1\}$, 在层内简单随机抽样条件下可使用

$$\hat{A} = \sum_{h=1}^H \frac{N_h}{N} \left(\frac{1}{b_h} \sum_{j=1}^{b_h} a_{hj} \right). \quad (5.1)$$

若进一步按评价状态分层, 则 h 应表示长度层与状态的交叉层; 若采用不等概率抽样, 则需使用相应纳入概率加权。直接平均三个长度层的争议比例, 会把当前样本中人数不同的层赋予相同权重, 改变所估计的总体。

5.3 应用价值与验证范围

本例已经完成从配对数据到分层统计的可复现转换: 使用不依赖 A/B 位置的长度比, 输出各层记录量、未决构成及形式与选择的描述关联, 并提供可实施的复核分配规则。这使“关注长度与格式”成为有明确抽样框和结果口径的操作, 而不仅是原则性建议。

应用上, 长度和粗体可作为持续监测的候选特征; 标题需要结合具体场景复核, 列表密度不宜单独作为剔除条件。关联强弱不能替代标签可靠性判断, 也不能由当前 OR 直接推导去偏权重。尤其不能为了使较长回答获胜比例接近 50% 而删样, 因为真实内容优势也可能产生这一关联。

本文没有开展复核效率、奖励模型训练或榜单校准实验, 因此应用结论限于审计流程与数据示例。要评价分层方案的实际收益, 需要在独立样本和相同复核预算下比较不同抽样方案, 报告争议

发现率、复核一致性及其不确定性，并避免同一用户或重复提示词跨验证组。只有获得此类证据后，才能讨论审计效率是否改善。

6 结论与局限

本文针对大语言模型成对评价数据，联合分析长度对数比及标题、粗体、列表密度差。在明确胜负且不等长的样本中，较长回答获胜比例为 62.37%；调整可观测任务信息及模型身份后，长度与粗体呈较稳定的正关联，标题关联较弱且对子集敏感，列表密度未获得明确关联证据。结果表明，评价数据中的形式关联需要分指标、分口径报告，不能以格式计数差异代替独立格式作用的判断。

基于真实记录构建的长度分层，将统计结果衔接到抽样复核流程：各层较长回答获胜比例及未决评价构成均有差异，支持同时保留明确胜负、平局和双方差开展审计。该应用提供了可计算的分层规则和总体恢复公式，尚不构成审计效率或偏好训练质量改善的证明。

研究局限包括单一平台及冻结样本的外部有效性、缺乏独立回答质量测量、上游长度与格式测量误差、重复用户与提示词的相关性、时间变化及平局排除带来的选择问题。当前线性 logit 设定和密度分母耦合也可能影响解释。后续应优先补充内容复核、聚类依赖与非线性敏感性检验，并在独立数据上评价审计流程。本文结论应理解为有条件的观察性关联，而非长度或排版干预的因果效应。

参考文献

- [1] CHIANG W L, ZHENG L, SHENG Y, et al. Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference[EB/OL]. (2024-03-07)[2026-09-21]. <https://arxiv.org/abs/2403.04132>.
- [2] LI J, ZHOU F, SUN S, et al. Dissecting Human and LLM Preferences[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 1790–1811. <https://doi.org/10.18653/v1/2024.acl-long.99>.
- [3] DUBOIS Y, GALAMBOSI B, LIANG P, et al. Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators[EB/OL]. (2024-04-06)[2026-09-21]. <https://arxiv.org/abs/2404.04475>.
- [4] ZHANG X, XIONG W, CHEN L, et al. From Lists to Emojis: How Format Bias Affects Model Alignment[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025: 26940–26961. <https://doi.org/10.18653/v1/2025.acl-long.1308>.
- [5] LMARENA AI. arena-human-preference-140k[DS/OL]. [2026-09-21]. <https://huggingface.co/datasets/lmarena-ai/arena-human-preference-140k>.
- [6] BRADLEY R A, TERRY M E. Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons[J]. Biometrika, 1952, 39(3/4): 324–345. <https://doi.org/10.1093/biomet/39.3-4.324>.
- [7] HOLM S. A Simple Sequentially Rejective Multiple Test Procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70. <https://www.jstor.org/stable/4615733>.