



中央民族大学本科生创新训练计划申报书
Project Application of Minzu University of China

基于大语言模型输出文本的选择偏好研究

——以 LMArena 对话数据为例

申报类型： 青苗计划

指导教师： 程豪

项目成员： 梁斯祯、李嘉帅、姜弼达、翁祖成、姚博晟

依托单位： 理学院

2025 年 10 月 24 日

项目名称

一、立项依据

1. 现状与背景分析

基于人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）已成为当前实现大语言模型（Large Language Model, LLM）高质量对齐的主流范式^[1]，然而人类对于 LLM 回答的无意识偏好，如长度偏好^[2]与格式偏好^[3]，往往误导奖励模型（Reward Model, RM）形成“形式”与“质量”的伪相关性（spurious correlations）^{[2][4]}，进而削弱 RLHF 的优化效果，导致 LLM “过优化”（over-optimization）或“破解奖励”（reward hacking）^[5]。

上述隐性偏好潜藏着将 LLM 导向“形式优于实质”的风险，现有研究与实践已明确观察到以下现象：一是“长度偏好”陷阱^[6]：RLHF 数据标注者易将“更长回答”等同于“更专业”^[7]，导致 LLM 通过冗余表达获取高分，既降低信息密度，又可能忽视信息准确性。二是“格式偏好”陷阱^[8]：结构化格式虽然能提升阅读体验，但可能掩盖内容空洞或事实错误，使模型过度学习形式而忽视内在逻辑和事实正确性。两类文本特征共同污染 RLHF 所依赖的人类反馈数据^[9]。为弥补模型的泛化能力和真实性能^[10]的损失，现有的研究聚焦于训练更鲁棒的 RM^{[6][7]}，以及优化 RLHF 的对齐机制^{[2][8]}。但过度注重“如何使 LLM 对齐人类反馈”的方法论，易弱化“对齐什么”这一根本性认知问题。

因此，前移研究焦点，系统性地揭示、量化和验证这些偏好的存在、强度及其影响机制，已成为提升 LLM 训练透明度和效果纯净度的关键前提。本研究旨在利用大规模、多模型的实测数据平台，对这一问题进行深入的统计实证分析。

2. 学术与应用价值

- (1) 指导高质量训练数据集的构建与清洗：研究成果将为数据标注提供明确规范。通过识别和量化哪些反馈特征可能引入偏见，可设计更科学的标注指南与数据筛选流程，从源头降低反馈噪声，生产出更“纯净”、更专注于内容质量的人类反馈数据为人类偏好研究提供“多变量机制建模”方法论参考
- (2) 为人类偏好研究提供“多变量机制建模”方法论参考：所设计的结构方程（Structural Equation Modeling, SEM）路径分析（整合自变量、分层中介、控制与调节变量），突破单一变量分析局限，可指导后续研究系统探索“特征 - 中介 - 偏好”的复杂交互关系，推动该领域从零散现象分析走向体系化机制研究，完善人

类偏好实证分析的方法论体系。

3. 已有研究实践基础

(1) 数据基础：项目团队已获取国际公开基准平台 LMArena 发布的大规模人类偏好数据集“arena-human-preference-140k”。该数据集包含超过 13.6 万条经过严格标注的人类评判记录，覆盖 53 种不同架构与规模的 LLM 生成结果，收集了纯文本类别的用户投票数据——每一行代表一次针对用户对话中两个模型（model_a 与 model_b）的偏好结果，同时包含完整的对话历史与元数据，其中的关键字段包括：

- ① id：每张投票/每行的唯一反馈标识
- ② evaluation_session_id：每次评估会话的唯一标识，单会话可含多次独立评估
- ③ evaluation_order：当前投票的评估轮次顺序
- ④ winner：评估结果，可选值为 model_a、model_b、tie 或 both_bad
- ⑤ conversation_a/conversation_b：当前评估轮次的完整对话内容
- ⑥ full_conversation：完整对话记录，包含历史评估轮次的所有上下文提示与回答。注意每轮投票后会重新抽样模型，因此不同上下文的应答模型可能不同
- ⑦ conv_metadata：用于风格控制的聚合 Markdown 标记与 token 计数统计
- ⑧ category_tag：标注标签组，涵盖数学、创意写作、指令遵循等类别
- ⑨ is_code：对话是否涉及代码内容

(2) 指导支撑：指导教师为程豪老师。程豪老师长期从事复杂数据统计计算和应用、结构方程模型理论与应用研究等领域研究工作，在《Mathematics and Computers in Simulation》（TOP, JCR 一区，中科院二区，独作）《Phytomedicine》（TOP, JCR 一区，中科院一区，一作）《Test》《Journal of Management Analytics》等国内外重要学术期刊发表论文百余篇。在本研究中，程豪老师可在混淆变量控制、多元逻辑回归模型设定、结构方程 (Structural Equation Modeling, SEM) 的路径分析与中介效应验证等关键方法论环节提供专业指导，确保研究设计的严谨性与结论的统计可靠性。

4. 团队优势

项目团队基本由理学院统计学专业本科生构成，形成了知识与能力结构互补、科研素养与协作意识并重的研发梯队，且对本课题保有强烈的探索欲望以及学习动力，协作

意识强，可高效推进数据处理、模型构建、结果分析等全流程工作。

二、研究内容、目标、拟解决的关键问题

1. 研究内容

本研究以 LMArena 平台“arena-human-preference-140k”数据集为基础，围绕“人类对 LLM 输出文本的长度与格式偏好”展开系统性统计实证分析，核心内容分为四大模块，构建“现象识别→干扰排除→机制拆解”的完整分析链。

(1) 数据的初步处理与描述性统计：

核心目标：将“长度 / 格式偏好”转化为可量化特征，初步观察偏好趋势。

① 长度与格式特征的量化编码：

将“长度”与“格式”这两个抽象偏好指标转化为可计算的客观特征，确保分析的可操作性

A. **长度特征编码** - 从多维度定义长度，避免单一指标的局限性，减少用户输入文本长度对于 LLM 输出文本分析的干扰：

- a. 基础指标：LLM 回复文本的词元（Token）数
- b. 相对指标：一是长度比率（LLM 输出文本 Token 数 / 用户输入文本 token 数）
二是长度差异（同一对比组中 model_a 与 model_b 的输出文本的 Token 数差值）

B. **格式特征编码** - 基于 Markdown 语法，通过正则表达式识别，对于各特定文本格式进行计数：

- a. 标题（header）数：一级标题（h1）（如“#”）、二级标题（h2）（如“##”）……
- b. 列表（list）数：有序列表（ordered）（如“1.”、“2.”……）、无序列表（unordered）（如“*”“+”“-”）
- c. 粗体（bold）数（如“**”“__”）

② 数据集拆分及描述性统计

按对话的任务类型，将数据集拆分为更易操作的子集，通过基础统计分析观察偏好的初步趋势，进行可视化描述，并为后续检验提供假设方向，具体实施步骤如下：

A. **数据集拆分及基础统计分析** - 依据 category_tag 字段，按任务类型（数学、

创意写作、指令遵循……)划分子集,对量化编码进行初步整理分析

B. 偏好趋势推测 - 结合任务类型的特点,推测各子集中 LLM 文本特征的偏好倾向。如,在“数学”类型中,短回答胜率更高(数学注重精准,冗余无用);在“创意写作”类型中,中长回答胜率更高(写作需细节支撑)。

C. 可视化描述性统计 - 结合上述对于各个任务类型的基础统计分析,基于长度特征编码和格式特征编码,设计多维度可视化图表,确保趋势直观可解读绝对长度,以下图表作为示例:

a. **长度偏好可视化**: 双轴折线图(x轴 - 长度比率;左y轴 - 胜率;右y轴 - 样本占比),可标注最优比率区间

b. **格式偏好可视化**: 小提琴图(x轴 - 列表数量;y轴 - 胜率;小提琴宽度 - 样本量),展示胜率分布与样本密度

c. **任务分层可视化**: 子图矩阵(子图分别对应不同的任务类型),每个子图为“长度分组×格式类型”的胜率热力图

D. 产出具体的假设: 通过上述描述性探索,在总集及各子集形成明确待检验假设,如:

a. **长度假设**: 在创意写作任务中,长度比率 1.5 - 3 的回答胜率显著高于 < 1.5 或 > 3 的回答

b. **格式假设**: 有序列表回答的胜率显著高于无序列表回答,且列表数量 1-2 个组胜率最高

(2) 人类偏好的存在性检验与强度量化

核心目标: 继承(1)中分层检验框架,结合任务目标差异梳理偏好逻辑,根据数据特征(连续、分组/单一、组合)确定检验方式,设计存在性检验方案,并进行效应量计算以确定偏好影响强度:

① 偏好存在性检验:

A. 长度偏好检验:

a. **连续变量**: 对比“偏好/未偏好”回答长度

一是 独立样本 t 检验(正态+方差齐)

二是 Mann-Whitney U 检验(非正态)

b. **分组变量**: 定位偏好显著的长度区间

一是 ANOVA 检验（正态）

二是 Kruskal-Wallis H 检验（非正态）

B. 格式偏好检验：

a. 单一格式：是否含列表/标题/粗体

二分类：四格表卡方检验（期望频数 < 5 用 Fisher 精确检验）

b. 组合格式：格式组合类型（如列表+粗体）

多分类： $R \times C$ 列联表卡方检验，残差分析定位最优组合

② 效应量计算：量化实际影响强度, 按检验类型匹配核心效应量指标，兼顾统计意义与实践价值

检验类型	效应量指标	强度判定标准（取值范围）	实践意义
二分类卡方检验	Cramp's V	弱（0.1）、中（0.3）、强（0.5）；0~1	$V=0.35 \rightarrow$ 格式对偏好中等影响
二分类卡方检验	优势比（OR）	$OR > 1$ 正向影响、 $OR < 1$ 负向影响；0~ ∞	$OR=1.8 \rightarrow$ 有列表回答偏好优势高 1.8 倍
t 检验	Cohen's d	弱（0.2）、中（0.5）、强（0.8）； $-\infty \sim +\infty$	$d=1.2 \rightarrow$ 偏好回答长度高 1.2 个标准差
ANOVA 检验	Eta 平方（ η^2 ）	弱（0.01）、中（0.06）、强（0.14）；0~1	$\eta^2=0.08 \rightarrow$ 长度分组解释 8% 偏好变异

(3) 伪相关性建模与控制混淆变量：

核心目标：聚焦模型能力与问题类型两大关键混淆变量，确保可量化、易落地

① 核心混淆变量定义与操作化

A. 模型能力：统计各模型模型平均胜率，可按胜率分为 3 个级别（高： $\geq 60\%$ 、中：40%-60%、低： $\leq 40\%$ ），计算对比组两模型的“能力等级差”（如高 - 中 = 1），避免将“强模型 $\rightarrow$ 高质量回答 $\rightarrow$ 被偏好”误归因于“强模型输出的长/优格式 $\rightarrow$ 被偏好”

B. 问题类型：依据 category_tag 字段拆分子集，以哑变量纳入模型，排除“任务属性差异”干扰（如数学需简洁、创意需长文本），确保长度/格式偏好是独立效应

② 分层逻辑回归建模设计

以“是否被选为偏好回答（1 = 是，0 = 否）”为因变量，通过分层回归逐步控制混淆，定位核心自变量（长度 / 格式）的净效应：

A. 仅含控制变量：纳入“模型能力等级差”+“问题类型哑变量”，计算模型基础解释力（ R^2 ），验证控制变量本身的影响。

B. 加入核心自变量：在 1) 基础上，加入“长度特征”与“格式特征”，若长度/格式系数仍显著（ $p < 0.05$ ），说明其对偏好的影响独立于模型能力与问题类型

③ 混淆控制效果验证

采用子样本交叉验证精简验证逻辑，确保结论稳健：

A. 按“问题类型”分层：在数学、创意写作等子集中重复回归，验证“数学任务中长度系数负向、创意任务中长度系数正向”的规律一致性

B. 按“模型能力”分层：在“高能力模型对比组”“中低能力模型对比组”中复现分析，若格式特征（如列表数）系数始终正向显著，说明格式偏好与模型能力无关，控制有效

④ 净效应量化

(4) 偏好影响机制与路径探索

核心目标：基于认知心理学逻辑，揭示长度/格式偏好的内在形成逻辑，分离“形式特征”与“内容质量”的影响效应，理解人类偏好的心理机制

① 明确变量定义：

A. Qqq 自变量（X）

- a. 长度特征（X1）：输出文本 Token 数、长度比率、长度差异
- b. 格式特征（X2）：header、list、bold 数量

B. 因变量（Y）：偏好选择，将 winner 字段转换为二分类

C. 中介变量（M）

a. 感知体验层（M1）

- 一是 易读性（M1a）：用弗莱士易读性指数计算
- 二是 情感导向（M1b）：基于文本内容分析情感极性

b. 语义质量层（M2）

- 一是 语义连贯性（M2a）：LLM 输出与用户输入的 BERT 向量相似度
- 二是 信息密度（M2b）：TF-IDF 均值
- 三是 人工标注特征（M2c）：依据 category_tag 字段中 bool 型变量 criteria_v0.1 整理，其中包含复杂性（complexity）、创造性

(creativity)、专业领域知识 (domain_knowledge)、问题解决情况 (problem_solving)、现实应用可行性 (real_world)、内容具体性 (specificity)、技术准确性 (technical_accuracy)

D. 控制变量 (C)

- a. 模型能力等级差 (C1)：按数据集各模型平均胜率分高 ($\geq 60\%$)、中 (40%-60%)、低 ($\leq 40\%$)，计算对比组模型等级差值
- b. 问题类型哑变量 (C2)：基于 category_tag 拆分为各任务类型

② 分层中介效应四步检验：以 “X1/X2 $\rightarrow$ M1/M2 $\rightarrow$ Y” 的分层路径为例，分四步验证中介效应：

A. Qqq 第一步：检验 X 对 Y 的总效应

- a. 目的：确认自变量是否对偏好有显著影响
- b. 操作方式：在控制 C1 和 C2 的前提下，分析 X 与 Y 的关联

B. 第二步：检验 X 对 M 的效应

- a. 目的：确认自变量能显著影响中介变量，中介变量可传递自变量对因变量的作用
- b. 操作方式：控制 C 后，分别分析 X 与 M1、M2 的关联。

C. 第三步：检验 M 对 Y 的效应

- a. 目的：排除自变量的直接干扰，确认中介变量能独立影响偏好，即 “X $\rightarrow$ M $\rightarrow$ Y” 的中间链条通顺。
- b. 操作方式：同时控制 X 和 C，分析 M 与 Y 的关联。

D. 第四步：检验 控制 M 后 X $\rightarrow$ Y 的直接效应变化

- a. 目的：对比控制中介变量前后，自变量对偏好的效应，确定中介效应的显著性（完全/部分中介）。
- b. 操作方式：对比 1），控制 M 后，X 对 Y 的影响是否变化。

③ SEM 路径假设与扩展分析：基于分层中介检验结果，构建多中介、多调节的 SEM 模型，整合所有路径并检验调节效应，揭示更复杂的机制网络。

变量类型	具体变量	路径假设 ($\rightarrow$ 表示 “影响”)
外生变量 (X)	长度特征、格式特征	X $\rightarrow$ 感知体验层中介变量；X $\rightarrow$ 语义质量层中介变量；X $\rightarrow$ 偏好（直接效应）

中介变量 (M)	感知体验层、语义质量层	M→偏好(间接效应);感知体验层 M→语义质量层 M (如易读性提升→语义连贯性感知提升)
内生变量 (Y)	偏好(是否被选为 winner, 二分类)	-
控制变量 (C)	模型能力等级差、问题类型哑变量	C→X; C→M; C→Y (控制混淆)
调节变量 (W)	任务类型(分类变量, 以“数学”为参照组)	W 调节 “X→M”“M→Y” 路径 (如数学任务中 “长度→认知负荷” 效应更强)

2. 研究目标

- (1) 明确证实或证伪在 Arena 数据集中存在系统性的人类长度与格式偏好。
- (2) 精确量化这些偏好在不同模型、不同任务类型下的效应大小，提供如优势比、回归系数等具体的统计证据。
- (3) 揭示并控制关键混淆变量，确保所观测到的偏好效应是纯净的、可归因的。
- (4) 通过 SEM 的路径分析确定偏好的形成机制，分离形式特征与内容质量的影响。

3. 创新点

- (1) 视角创新：将研究焦点从“如何让模型更好地对齐人类偏好”前移至“人类偏好数据本身是否存在系统性偏差”，从数据源头审视对齐过程的有效性，深化了对“对齐什么”这一根本问题的理解。
- (2) 方法创新：将经典的统计因果推断方法（如控制混淆变量的回归分析、中介效应分析）系统性地应用于 LLM 人类偏好研究这一新兴领域，推动该领域从现象描述走向机制检验和因果探索。
- (3) 解释创新：依托 SEM 多路径分析框架，突破现有研究“重现象、轻机制”局限。通过“感知体验层 - 语义质量层”分层中介，量化长度、格式影响偏好的传导逻辑，避免混同不同机制效应。
- (4) 问题导向创新：直面 RLHF 实践中“奖励破解”和“过优化”的痛点，选题具有鲜明的现实针对性。研究成果旨在直接服务于提升训练数据的“信噪比”和评估体系的鲁棒性，具有明确的实践转化价值。

4. 拟解决的关键问题


- (1) 混淆变量的有效控制问题：如何筛选并量化所有可能同时影响回答形式特征与人类偏好的关键混淆变量（如问题内在难度、模型核心能力）？解决方案：充分利用数据集中的元信息（如 category_tag、模型胜率），在指导教师指导下通过文献梳理与预检验确定核心混淆变量，采用分层回归逐步控制。
- (2) 偏好强度的可操作化度量问题：如何将统计上显著的偏好效应转化为对实践具有指导意义的可操作指标？解决方案：基于效应量指标（如 Cramp's V、OR），结合任务类型特征，提出“偏好偏差指数”，用于评估不同数据子集的“纯净度”或校正现有评估指标。
- (3) 复杂影响路径的建模与解释问题：在本科生知识储备与项目周期有限的前提下，如何设计并实现既能揭示复杂机制、又不过于黑箱化的统计模型（如 SEM）？解决方案：采取“从简到繁”策略，先构建基础中介模型验证核心路径，再在指导教师协助下逐步增加模型复杂度，优先保证核心结论的稳健性与可解释性。

三、拟采取的研究方案及可行性分析


1. 技术路线

将按照“研究内容”中四大模块：**数据的初步处理与描述性统计**、展示相关技术路线。

数据的初步处理与探索




人类偏好的存在性检验与强度量化



伪相关性建模与控制混淆变量



偏好影响机制与路径探索



2. 可行性分析

(1) 数据可行性：核心优势所在。Arena 平台数据开放、格式统一，便于复现与扩展。

目前我们已明确获取“Imaginary/axena-human-preference-140k”数据集，该数据规模巨大、标注统一、包含丰富的模型和问题类型，完全满足统计检验的功率要求，为研究的可靠性奠定了坚实基础。

(2) 方法与技术可行性：

① 理论匹配：本项目本质是基于观测数据的因果推断研究，采用的假设检验、

回归分析、中介效应等是统计学领域的标准方法，与团队成员的核心课程知识（《统计学基础》、《概率论》）高度契合。

- ② 工具成熟：采用 Python 数据分析生态工具（Pandas 用于数据处理、Scipy / Statsmodels 用于统计检验、Matplotlib/Seaborn 用于可视化、Scikit-learn 用于模型辅助），文档丰富、社区活跃，能有效支持从数据清洗到复杂建模的全过程。

(3) 指导与资源可行性：

- ① 资源充足：项目对计算资源要求不高，普通笔记本电脑即可完成全部数据分析任务。青苗计划提供的经费足以覆盖资料打印、数据存储等日常开销。
- ② 数据可行：已获取 136k 条标注数据，覆盖 53 个模型，具备统计代表性。

四、预期效果与具体成果

1. 预期效果

- (1) 理论效果：系统性地揭示并量化人类反馈中存在的长度与格式偏好，明确其作为混淆变量对 RLHF 训练数据的污染，为构建更纯净、更可靠的对齐数据提供实证依据。
- (2) 方法效果：形成“数据处理→特征编码→假设检验→混淆控制→机制分析”的可复现统计实证分析范式，为后续 LLM 人类偏好研究提供方法论参考。
- (3) 实践效果：团队成员系统锻炼统计学实证研究能力，掌握数据处理、建模分析、学术写作的核心流程，形成对 LLM 偏好研究领域的深度认知。

2. 具体成果

- (1) 一篇完整的青苗计划结题研究报告
- (2) 一份结构化的统计数据分析报告
- (3) 一套可复现的 Python 数据分析代码
- (4) 一篇格式规范的学术论文初稿
- (5) 项目答辩展示材料

五、具体安排及进度

2025. 11

第一阶段：数据奠基，完成数据清洗与特征工程

目标：获得干净、可用于分析的结构化数据集

负责人：姜弼达、翁祖成、姚博晟

工作安排：翁祖成负责核心特征提取代码编写，发挥其编程严谨性；姜弼达、姚博晟负责数据质量检查与清洗，利用其细致的数据处理能力。全体成员共同熟悉数据。

2025. 12

第二阶段：洞察发现，完成描述性统计与可视化

目标：形成初步分析报告，明确待检验假设

负责人：李嘉帅、梁斯祯

工作安排：李嘉帅主导统计计算与可视化，运用其统计学知识选择恰当的图表；梁斯祯负责撰写初步分析报告，发挥其逻辑梳理与文字表达能力。

2026. 01 – 2026. 02

第三阶段：模型攻坚，完成统计推断与机制建模

目标：完成核心统计推断与机制建模

工作安排：翁祖成、姚博晟负责代码实现与调试；李嘉帅、梁斯祯负责结果解读与初步分析。

2026. 03

第四阶段：成果整合，完成论文初稿与研究主报告

目标：整合结果，撰写报告与论文初稿

负责人：李嘉帅、梁斯祯

工作安排：梁斯祯主笔研究报告，确保逻辑流畅；李嘉帅主笔论文，侧重学术规范与结论提炼。翁祖成、姚博晟提供所有代码、图表及数据结果支持。

2026.04

第五阶段：结题准备，完成所有结题准备工作

目标：完成材料归档与答辩准备

负责人：全体成员

工作安排：姜弼达、姚博晟负责材料格式最终统一与归档；翁祖成负责代码库整理；李嘉帅、梁斯祯负责 PPT 制作与主讲。全体参与预答辩，相互质询，优化展示效果。

六、经费预算执行计划

经费预算总计 500 元，现进行以下安排

支出类目	单价(元)	数量	金额(元)	用途说明
数据存储与处理	100	1 项	100	用于云存储服务或移动硬盘，保障大规模数据集的安全备份与高效处理。
打印与资料复印	0.1	400 页	40	用于打印文献资料、中期检查表及最终结题报告。
办公用品	60	1 批	60	买笔记本、文具、文件夹等，用于日常研讨记录与资料整理。
小范围差旅	300	1 次	300	用于前往海淀校区参加相关学术讲座或与指导教师进行面对面研讨的交通费用。

- [1] 黎宇声. 多目标对齐大语言模型的强化学习策略研究[D]. 成都: 电子科技大学, 2025.
- [2] HU Zhengzhou, SONG Lining, ZHANG Jitney, ET AL. Explaining Length Bias in ELM-Based Preference Evaluations[J/OL]. arrive, 2024. [HTTP://arrive.org/abs/2407.01085](http://arrive.org/abs/2407.01085).
- [3] LIU Zhejiang, XU Magi, PI Quotidian, ET AL. Format as a Prior: Quantifying and Analyzing Bias in Alms for Heterogeneous Data[J/OL]. arrive, 2025. [HTTP://arrive.org/abs/2508.15793](http://arrive.org/abs/2508.15793).
- [4] 张永岗. 基于数据分布的深度学习对抗鲁棒性研究 [D]. 合肥: 中国科学技术大学, 2022.
- [5] LI Jun long, ZHOU Fan, SUN Chaotic, ZHANG Yikes, ZHAO Hai, LIU Pengfei. Dissecting Human and LLM Preferences[J/OL]. 2024. <https://arxiv.org/abs/2402.11296>.
- [6] SHEN Wei, ZHENG Rui, ZHAN Wenyu, et al. Loose lips sink ships: Mitigating Length Bias in Reinforcement Learning from Human Feedback[J/OL]. 2023. <https://arxiv.org/abs/2310.05199>.
- [7] DUBOIS Yann, GALAMBOSI Balazs, LIANG Percy, et al. Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators[J/OL]. 2024. <https://arxiv.org/abs/2404.04475>.
- [8] ZHANG Xuanchang, XIONG Wei, CHEN Lichang, et al. From Lists to Emojis: How Format Bias Affects Model Alignment[J/OL]. 2025. <https://arxiv.org/abs/2508.15793>.
- [9] PARK Junsoo, JWA Seungyeon, REN Meiyang, et al.. OffsetBias: Leveraging Debaised Data for Tuning Evaluators[J/OL]. 2024. <https://arxiv.org/abs/2407.06551>.
- [10] 韩明月. 因果推断视角下自然语言处理任务中的虚假相关性研究[D]. 上海: 上海财经大学, 2023.