

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

硕士学位论文

MASTER THESIS



论文题目 多目标对齐大语言模型的强化学习策略研究

学科专业	<u>信息与通信工程</u>
学 号	<u>202221010925</u>
作者姓名	<u>黎 宇 声</u>
指导教师	<u>段景山 高级实验师</u>
学 院	<u>信息与通信工程学院</u>

分类号 TN828.6 密级 公开
UDC^{注1} 621.39

学 位 论 文

多目标对齐大语言模型的强化学习策略 研究

(题名和副题名)

黎宇声

(作者姓名)

指导教师 段景山 高级实验师
电子科技大学 成 都

(姓名、职称、单位名称)

申请学位级别 硕士 学科专业 信息与通信工程
提交论文日期 2025 年 3 月 30 日 论文答辩日期 2025 年 5 月 26 日
学位授予单位和日期 电子科技大学 2025 年 6 月
答辩委员会主席 付毓生
评阅人 费高雷、于富财

注 1: 注明《国际十进分类法 UDC》的类号。

Research on Reinforcement Learning Strategies for Multi-Objective Alignment of Large Language Models

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline Information and Communication Engineering

Student ID 20221010925

Author Yusheng Li

Supervisor Senior Experimental Engineer Jingshan Duan

School School of Information and Communication
Engineering

摘要

近年来，以 GPT 为代表的大语言模型在自然语言处理领域取得了显著进展。然而，要确保其在应用中可靠又实用，核心在于使其行为能同时满足多个、甚至相互冲突的人类期望（如信息准确性、内容安全性等）。当前，在实现这种多目标对齐的过程中，现有方法在奖励信号的精确表征、多目标的有效权衡以及对齐过程的灵活控制等方面仍面临挑战，这已成为制约模型在关键领域深度应用的核心瓶颈。基于上述背景本文提出一种创新的对齐策略，集中体现为以下三点核心贡献：

（1）本文提出并实现了一种基于多维度绝对评分和混合专家机制的多目标奖励模型。方法通过引入多维度绝对评分机制，克服了传统成对比较方法带来的信息损失；并创新性地集成了混合专家架构，通过门控网络实现了对不同奖励维度重要性的动态、上下文感知评估与聚合，同时有效缓解了冗余性偏见。模型的设计旨在为后续的强化学习优化提供一个高质量、可解释、且更精确的评价基础。

（2）构建并验证了一个迭代式多目标可控对齐框架。该框架有机整合了奖励模型提供的精细化多目标奖励信号、迭代式同策略偏好采样机制以及基于可控偏好优化的算法。该框架通过一个从精确评价到有效优化再到持续改进的完整流程，旨在实现对模型多目标对齐程度和可控性的系统性提升。

（3）通过在十亿参数级别的大语言模型上进行的系统性实验，证实了上述对齐框架构成的协同对齐策略在提升模型多目标对齐综合性能方面的显著优势。实验结果表明：多目标奖励模型在 RewardBench 和 RMB 基准上的得分（分别为 89.2 和 0.650）均优于传统基线。在模型对齐效果层面，经所提对齐框架训练的模型在 AlpacaEval 上的长度控制胜率达到 40.8，在 MT-Bench 上的平均分达到 8.72，全面超越了基线方法。这些量化的性能提升，充分证明了该策略在增强模型多目标对齐能力方面的有效性，及其在赋能关键落地应用场景方面的巨大潜力。

综上所述，本文通过多目标奖励模型和可控对齐框架的协同创新，为解决大语言模型在多样化应用场景下实现高质量多目标对齐所面临的挑战提供了一套高效、灵活、可解释且经过充分验证的解决方案。研究成果不仅丰富了多目标强化学习对齐的理论与实践，也为推动人工智能更安全、更可靠、更智能地服务于社会各领域具有重要的学术价值和实际应用前景。

关键词：自然语言处理，大语言模型，人工智能对齐，强化学习，多目标优化

ABSTRACT

In recent years, Large Language Models (LLMs), exemplified by GPT, have achieved significant advancements in the field of Natural Language Processing. However, ensuring their reliability and practicality in real-world applications hinges on aligning their behavior to simultaneously satisfy multiple, and often conflicting, human expectations (e.g., informational accuracy, content safety). Currently, in the process of achieving such multi-objective alignment, existing methods face significant challenges in the precise representation of reward signals, the effective trade-off among multiple objectives, and the flexible control of the alignment process. These challenges have become a core bottleneck constraining the deep application of LLMs in critical domains. Against this backdrop, this thesis proposes an innovative alignment strategy, centered on the following three core contributions:

(1) This thesis proposes and implements a novel Multi-Objective Reward Model (MORM) based on multi-dimensional absolute scoring and a Mixture-of-Experts (MoE) mechanism. The method overcomes the information loss inherent in traditional pairwise comparison approaches by introducing a multi-dimensional absolute scoring mechanism. It innovatively integrates an MoE architecture to enable dynamic, context-aware assessment and aggregation of the importance of different reward dimensions via a gating network, while also effectively mitigating verbosity bias. Experimental results demonstrate that, compared to baseline methods, this model exhibits significant advantages in accurately evaluating and balancing multi-dimensional preferences, thereby providing a high-quality evaluation foundation for subsequent reinforcement learning.

(2) An iterative, multi-objective, controllable alignment framework (IMOCA) is constructed and validated. This framework organically integrates the fine-grained multi-objective reward signals from our proposed MORM, an iterative on-policy preference sampling mechanism to enhance data quality and model adaptability, and an algorithm based on Controllable Preference Optimization (CPO) to achieve explicit and flexible control over multiple objectives via external preference condition instructions. The framework establishes a complete optimization pipeline, proceeding from precise evaluation to effective optimization and continuous improvement. Experiments show that models trained with this framework significantly outperform baselines on mul-

tiple alignment evaluation benchmarks, effectively enhancing the model's degree of multi-objective alignment and controllability.

(3) Systematic experiments conducted on a billion-parameter-scale Large Language Model (LLM) have confirmed the significant advantages of the synergistic alignment strategy constituted by the aforementioned alignment framework in enhancing the model's comprehensive multi-objective alignment performance. The experimental results demonstrate that: at the reward model level, our Multi-Objective Reward Model achieved scores of 89.2 on RewardBench and 0.650 on the RMB benchmark, both outperforming traditional baselines. At the model alignment efficacy level, the model trained with the proposed alignment framework achieved a length-controlled win-rate of 40.8 on AlpacaEval and an average score of 8.72 on MT-Bench, comprehensively surpassing baseline methods. These quantified performance enhancements fully substantiate the effectiveness of this strategy in improving the model's multi-objective alignment capabilities and reveal its substantial potential for empowering key real-world application scenarios.

In summary, through the synergistic innovation of the multi-objective reward model and the controllable alignment framework, this thesis provides an efficient, flexible, interpretable, and thoroughly validated solution to the problem of multi-objective alignment for LLMs in diverse application scenarios. The research findings not only enrich the theory and practice of multi-objective reinforcement learning alignment but also hold significant academic value and practical prospects for advancing Artificial Intelligence to serve various societal sectors more safely, reliably, and intelligently.

Keywords: Natural Language Processing, Large Language Model, Artificial Intelligence Alignment, Reinforcement Learning, Multi-Objective Optimization

目 录

第一章 研究背景与方法概述	1
1.1 研究工作的背景与意义.....	1
1.2 国内外研究现状与核心挑战	3
1.2.1 大语言模型发展历程.....	3
1.2.2 语言模型对齐技术范式.....	4
1.2.3 多目标对齐方法与进展.....	5
1.2.4 对齐性能评估方法与基准.....	6
1.3 当前对齐研究核心挑战.....	7
1.4 本文研究目标与研究内容	9
1.5 本研究的预期应用价值.....	10
1.6 本研究的结构安排.....	11
第二章 大语言模型对齐相关工作	13
2.1 大语言模型技术概述.....	13
2.1.1 大语言模型的定义与发展.....	13
2.1.2 自注意力机制与 Transformer 架构.....	14
2.2 语言模型对齐相关工作.....	16
2.2.1 现有的单目标对齐方法.....	17
2.2.2 现有多目标对齐方法.....	21
2.3 语言模型奖励建模相关工作	24
2.3.1 语言奖励模型.....	24
2.3.2 现有奖励建模相关工作.....	25
2.4 混合专家模型相关工作.....	27
2.4.1 混合专家机制的基本原理.....	28
2.4.2 混合专家模型的训练与优化.....	29
2.5 本章小节.....	30
第三章 基于混合专家的多目标奖励模型方法	31
3.1 引言.....	31
3.2 MORM 的设计理念与核心挑战.....	32
3.2.1 传统奖励建模的局限性与精细建模的需求	32
3.2.2 引入混合专家模型机制的必要性.....	34
3.3 MORM 架构与核心机制设计.....	36
3.3.1 MORM 整体架构	36
3.3.2 MORM 核心机制	38
3.3.3 MORM 的主要优势和特点	40

3.4 MORM 的实现与训练.....	41
3.4.1 训练数据构建与预处理.....	41
3.4.2 训练框架.....	43
3.4.3 训练流程与损失函数.....	44
3.5 MORM 性能评估.....	46
3.5.1 实验目的.....	46
3.5.2 基准评估数据集与评价指标.....	46
3.5.3 实验结果与分析.....	49
3.6 MORM 的应用价值与对后续对齐的意义.....	52
3.7 本章小结.....	53
第四章 基于多目标奖励建模的可控对齐框架	55
4.1 引言.....	55
4.2 IMOCA 框架的设计理念与核心优势	56
4.2.1 现有方法的局限与多目标可控对齐的必要性	56
4.2.2 IMOCA 的核心特点	57
4.3 IMOCA 框架的理论基础与关键组件	58
4.3.1 迭代式同策略优化的理论依据.....	58
4.3.2 基于 MORM 的多目标奖励信号在强化学习中的应用.....	61
4.3.3 可控偏好优化的核心机制与理论支撑	62
4.4 IMOCA 的整体架构与算法流程	67
4.4.1 IMOCA 整体架构图与工作流程	67
4.4.2 IMOCA 框架的创新性与设计特点	71
4.5 IMOCA 的训练与实现	73
4.5.1 训练数据构建与预处理.....	73
4.5.2 模型架构与训练设置.....	74
4.6 IMOCA 对齐性能评估	75
4.6.1 实验目标.....	76
4.6.2 基准评估数据集与评价指标.....	77
4.6.3 实验结果与分析.....	78
4.7 IMOCA 的实际应用价值与落地潜力	81
4.8 本章小节.....	82
第五章 总结与展望	84
5.1 本文总结.....	84
5.2 未来工作展望.....	85
参考文献.....	87

第一章 研究背景与方法概述

1.1 研究工作的背景与意义

近年来,随着计算能力和数据规模的飞跃发展,大型语言模型(Large Language Models, LLM)(如 OpenAI 的 GPT 系列^[1]、Google 的 BERT^[2]、Meta 的 LLaMA^[3]等)在自然语言生成(Natural Language Generation, NLG)领域取得了显著的进展,并展现出赋能智能客服、个性化教育、医疗健康辅助等众多关键应用领域的巨大潜力。大型语言模型通过大规模的预训练和细粒度的微调,能够在文本生成、翻译、对话系统等多种任务中展现出卓越的性能。这些模型通过从大量语料中学习语言规律、语境信息和世界知识,能够生成接近人类水平的文本输出,甚至在一些复杂的任务中超过传统方法的效果。

然而,将大语言模型的强大潜力转化为在这些实际落地场景中的可靠应用,依然面临诸多挑战。首先,生成的文本质量时常存在不可控性,尤其是在内容涉及到复杂的推理、逻辑性或情感表达时,往往出现语义模糊、逻辑不连贯甚至不真实的信息。例如,在教育辅导中,不准确或带有偏见的内容会误导学生。其次,大型语言模型的黑箱性质使得人类难以理解其决策过程,增加了对生成文本进行监督和校正的复杂性。更重要的是,在实际应用中,如何确保模型的输出符合特定的道德、法律或社会准则,是一个亟待解决的关键问题。这些问题的核心,在于如何提升大语言模型与多维度人类期望的对齐程度。

为了解决上述模型在实际应用中出现的問題,提升 LLM 在实际应用中的可靠性和可信度,研究者提出了模型对齐(Model Alignment)这一概念。模型对齐的核心目标是最大化模型行为与人类期望、价值观及在特定落地场景下的具体需求的契合度,确保其生成的内容在多个维度(如“有用性”、“诚实性”、“无害性”)上表现得一致和可控。一个高度对齐的语言模型,能够在复杂的下游应用中发挥正面作用,提供真正有价值的辅助,并最大限度地降低潜在风险。反之,对齐不足的模型则可能成为信息污染源或决策误导者,严重制约其在关键领域的应用。

随着大语言模型应用范围的不断拓展,从简单的文本生成延伸至人工智能(Artificial Intelligence, AI)教育辅导、自动编程、金融分析、法律咨询、医学文本理解等更多元、更专业的落地场景,模型行为的复杂性和对齐要求也随之提升。在这些高级应用中,单一目标的对齐方法往往难以满足现实需求。一个在通用对话中表现良好的模型,在需要高度专业性和严谨性的医学文本生成场景中,若缺乏对“真实性”和“安全性”的严格对齐,则可能生成不合适的、甚至危险的输出。

这种“任务间不一致性”或“场景适应性不足”的问题，正是当前对齐工作面临的重要挑战。更进一步，模型在真实落地场景中往往需要同时展现多种能力，并平衡这些能力之间的潜在冲突。

在此背景下，多目标对齐（Multi-Objective Alignment）成为提升大语言模型在复杂应用中实用性和可靠性的关键技术路径。在当前的 LLM 对齐实践中，要实现理想的多目标对齐面临诸多挑战，往往导致模型在多个期望之间表现失衡，即出现“多目标对齐失衡”的现象。这种对不齐的核心机制性原因包括：

（1）奖励信号的表征与聚合机制不足，导致奖励机制失衡：现有奖励模型在表征和聚合多维度偏好时，存在固有缺陷。例如，基于成对比较的偏好数据收集方式，在将多维度、细粒度的人类偏好压缩为单一标量或二元标签时，不可避免地会丢失大量关键信息。此外，许多奖励模型缺乏对不同对齐目标之间内在冲突与动态权衡的有效建模机制，难以根据上下文动态调整各目标权重。这种固化或简化的奖励聚合方式，容易导致奖励信号本身存在偏向（例如，过度奖励长度而忽视简洁性，或在追求帮助性时牺牲了严格的真实性），使得模型在优化时侧重某些目标而忽略其他，造成事实上的“奖励机制失衡”，这是导致模型后续优化偏离人类综合期望，产生不可控或不真实输出的直接原因之一。

（2）强化学习优化策略在多目标权衡与控制上的固有挑战：即使能够获得相对理想的多维奖励信号，现有的强化学习优化算法（如 PPO^[4]）在指导 LLM 同时优化多个、甚至相互竞争的目标时，也面临固有挑战。例如，单一目标的优化函数难以直接表达多目标间的复杂权衡关系，导致优化过程可能陷入局部最优，或在不同目标间产生不期望的冲突。更进一步，现有优化策略往往缺乏对对齐过程和最终结果的精细化、可控性。开发者或用户难以根据特定落地场景的需求，灵活地、显式地引导模型在不同对齐目标上的行为倾向。

（3）模型的学习范式与真实应用动态性之间的差距：多数对齐方法依赖于预先收集的静态数据集进行训练。然而，真实世界的交互是动态、开放且情境多变的。基于静态数据训练的模型，其学到的偏好和行为模式可能难以泛化到未见过的新情境中，导致在实际应用中出现问题，即在特定动态交互下表现出人类不期望的现象，即模型不对齐现象。

这些机制上的不足，使得 LLM 在面对涉及复杂推理、逻辑性、情感表达或需严格遵循道德法律准则的任务时，其输出质量的不可控性尤为突出。例如，AI 教育辅导场景中，如果奖励模型过度侧重于“回答详尽”（帮助性的一种体现），而忽略了对“知识点准确性”的严格把控，那么模型可能会为了提供更多内容而引入未经核实的信息，导致辅导效果适得其反，这就是典型的奖励失衡导致的“多目标对不齐”现象。

因此，如何克服上述导致“多目标对不齐”的机制性缺陷，设计出能够精确建模多维偏好、动态权衡目标冲突、并实现灵活可控优化的对齐策略，已成为推动 LLM 从通用技术走向行业深度赋能的关键。本论文的研究正是围绕这一核心目标展开，即通过提出和验证新的强化学习策略，解决奖励机制和优化控制等方面的具体问题，从而显著提升大语言模型的多目标对齐程度，增强其在关键落地场景中的正面影响和实用价值。开展基于多目标奖励的对齐研究，不仅具有重要的学术价值，更对推动大语言模型安全、有效地服务于社会各领域具有深远的实践意义和应用前景。

1.2 国内外研究现状与核心挑战

1.2.1 大语言模型发展历程

大型语言模型的崛起可以追溯到深度学习在自然语言处理（Natural Language Processing, NLP）领域的应用兴起。传统的 NLP 方法依赖于手工设计的特征和规则，效果有限，尤其在处理大规模数据时表现出显著的不足。随着深度学习的发展，尤其是深度神经网络在语音识别、图像处理等领域的突破，NLP 领域开始向深度学习转型。

最初，基于循环神经网络（Recurrent Neural Networks, RNN）^[5] 和长短时记忆（Long Short-term Memory, LSTM）^[6] 网络的语言模型被广泛应用。这些模型通过在序列数据中传播上下文信息，逐步提高了自然语言的生成和理解能力。然而，由于其训练过程中存在梯度消失问题，且在捕捉长程依赖上存在瓶颈，RNN 和 LSTM 难以应对复杂的语义理解任务。2017 年，Google 提出了 Transformer 模型^[7]，这一架构革命性地摆脱了循环结构，使用自注意力机制（Self-Attention）来捕捉序列数据中的长程依赖。Transformer 不仅提高了训练效率，还使得模型能够在大规模数据上实现并行训练，大大加速了深度学习在 NLP 领域的应用。基于 Transformer 架构，后续涌现出了多个基于深度神经网络的预训练模型，标志着大型语言模型的兴起。2018 年，Google 提出了 BERT（Bidirectional Encoder Representations from Transformers）模型^[2]，采用了双向预训练的策略，从而有效地捕捉了文本中的上下文信息。BERT 模型的提出改变了 NLP 任务的解决方式，模型的预训练和微调（Fine-tuning）策略使得语言模型在多个下游任务中取得了极大成功。2019 年，OpenAI 提出了 GPT-2（Generative Pre-trained Transformer 2）^[8]，这一模型显著扩大了模型规模，具有更强的文本生成能力。GPT-2 基于单向自回归模型，通过大规模的数据预训练，使得生成的文本不仅语法正确，且具备较高的连贯性和多样性。随后，GPT-3^[9] 的推出进一步突破了模型规模的界限，参数量达到 1750 亿，能够处理更复杂的任务，展

现出强大的语言生成和推理能力。

随着这些大语言模型的不断发展，其应用范围从文本生成扩展到机器翻译、情感分析、对话系统、代码生成等多个领域，极大推动了 NLP 技术的发展。然而，随着模型规模的增大，其可控性、透明性和可靠性问题也变得愈加复杂，导致了对模型行为对齐的强烈需求。

1.2.2 语言模型对齐技术范式

大语言模型的卓越能力为其在各行各业的广泛应用展现出巨大潜力。然而，正如前文所述，要将这种潜力转化为在实际落地场景（如智能客服、教育辅导、内容创作等）中的可靠表现，解决其输出不可控、不准确、甚至可能有害的问题至关重要。模型对齐正是应对这一挑战的核心技术，它通过一系列方法引导大语言模型的行为，使其更符合人类的期望、价值观和社会规范，从而更好地赋能实际应用。本节将简要介绍当前主流的对齐技术范式及其在服务落地应用中的作用与局限。

监督微调（Supervised Fine-Tuning, SFT）是大语言模型对齐的基础步骤之一，可以为特定应用场景提供行为示范。其核心思想是收集一批高质量的“输入-期望输出”示例数据，然后在预训练的语言模型基础上进行进一步训练。这些示例数据如同“行为教科书”，明确地告诉模型在特定情境下（例如，当用户提出一个医疗咨询问题时，模型应该如何以专业、谨慎的方式回答；或者在代码生成任务中，如何根据需求生成正确且高效的代码），什么样的回答是“好”的，什么样的行为是被期望的。Google 公司研究团队在其早期的工作 Flan[10] 中便利用 SFT 来初步引导模型生成符合用户期望的对话式回答。

通过 SFT，模型能够学习到特定任务的格式、风格以及初步的指令遵循能力。然而有团队工作表示，SFT 高度依赖高质量、大规模的标注数据，而这些数据的获取成本高昂，且难以覆盖所有可能的应用场景和细微的用户偏好^[11]。更重要的是，研究发现 SFT 主要教会模型“模仿”示例，对于未见过或更复杂的指令，以及需要权衡多个潜在目标的场景，其对齐效果与泛化性能往往有限^[12]，难以满足复杂落地应用对模型鲁棒性和适应性的高要求。

为克服 SFT 的局限性，研究者们提出从人类反馈中强化学习（Reinforcement Learning from Human Feedback, RLHF）方法，并成为当前实现高质量对齐的主流范式。Ouyang 等人 [13] 在其对 InstructGPT 的研究中系统性地确立了 RLHF 的三阶段流程：首先进行 SFT，然后利用人类对模型输出的成对比较数据训练一个奖励模型（Reward Model, RM），最后使用该奖励模型作为强化学习（通常采用 PPO 算法^[4]）的奖励信号来优化 LLM 的策略。Bai[14] 等人在其研究中进一步探索了 RLHF 在提升模型“无害性”方面的应用，并提出了著名的“HHH”（Helpful,

Honest, Harmless) 对齐原则。这一“SFT+RM+PPO”的技术路径, 因其在提升模型帮助性、诚实性和安全性方面的显著效果, 被后续众多工作(如 ChatGPT^[1]) 所采纳和发展。

对齐技术的核心在于偏好学习 (Preference Learning), 即如何精确地捕捉和建模人类的偏好。传统的偏好学习主要基于成对比较 (Pairwise Comparison) 数据, 并借鉴 Bradley-Terry 模型^[15] 将偏好转化为可优化的概率形式。这种方式虽然直观, 但存在信息损失等问题。为了获取更精细的反馈信号, 学术界和工业界正积极探索超越二元比较的偏好信息利用方式。Touvron^[16] 等人在其 Llama2 模型的训练中, 提出在奖励建模的损失函数中引入边际 (margin), 用以区分不同偏好对之间的偏好强度 (例如, “远好于”和“略好于”应区别对待), 从而让奖励模型学习到更丰富的偏好信息。为充分利用标注者对多个候选回答进行排序所产生的信息, Zhu 等人^[17] 提出了基于 Plackett-Luce 模型的 K-wise 损失函数。该方法旨在从 k 个排序的候选项中学习偏好, 理论上比成对比较能更高效地利用标注数据。Starling-7B^[18] 等模型在其奖励建模中也采纳了类似思路。探索不同类型的奖励模型: 除了对文本整体质量进行偏好打分, 研究者还针对特定任务设计了不同类型的奖励模型。例如, 在需要严谨推理的任务中, Cobbe 等人^[19] 提出了结果奖励模型 (Outcome Reward Models, ORMs), 直接判断数学题的最终答案是否正确。而 Lightman 等人^[20] 则提出了过程奖励模型 (Process Reward Models, PRMs), 对解题过程中的每一个推理步骤进行监督和评分, 以期提升模型的推理能力和可解释性。

综上所述, 对齐技术范式已从基础的 SFT 发展到更复杂的 RLHF, 而作为 RLHF 核心的偏好学习研究, 也正从简单的成对比较向更精细、更多维、更具任务针对性的方向演进。然而, 如何将这些偏好信息有效地应用于多目标场景下的权衡与控制, 仍是当前研究面临的关键挑战。

1.2.3 多目标对齐方法与进展

传统的单目标对齐方法已难以满足复杂应用场景对模型综合表现的要求, 多目标对齐为此提供了新的解决视角和技术方向。研究重点已逐渐转向更具挑战性的多目标对齐领域, 旨在解决 LLM 在实际应用中必须同时满足多个、甚至可能相互冲突的目标 (如帮助性与无害性) 的难题。当前的研究进展主要体现在对现有对齐框架的扩展、提升对齐过程的可控性以及探索更高效的优化方法等方面。

一个主要的研究方向是将单一偏好优化方法 (DPO)^[21] 扩展到多目标场景。为解决传统强化学习方法 (如 PPO) 在多目标优化中计算开销大且不够稳定的问题, Zhou 等人^[22] 提出了多目标直接偏好优化 (Multi-Objective Direct Preference

Optimization, MODPO)。该方法在 DPO 的基础上, 通过引入线性标量化和权重参数, 将多目标信息融入优化过程, 旨在找到一组在不同偏好权重下的语言模型 Pareto 最优解。MODPO 作为一种无需强化学习 (RL-free) 的多目标对齐方法, 能够更高效地利用现有偏好数据, 在处理有冲突的目标任务时, 其训练的模型通常表现优于仅使用单一目标优化方法训练的模型。此外, 为了应对微调整个大模型带来的高昂计算成本, 研究者也在探索更高效、轻量化的对齐方法。例如, Yang 等人 [23] 提出的 MetaAligner 是一种通用的、“策略模型参数不可知” (policy-agnostic) 的多目标对齐方法。该方法通过动态目标重构和条件弱到强校正策略, 在不访问或调整目标 LLM 参数的情况下实现对齐。MetaAligner 因其训练成本显著降低, 并具备对未见过的目标进行零样本对齐的能力而受到关注, 为在资源受限环境下进行多目标对齐提供了新的思路。

综上所述, 当前的多目标对齐研究正朝着更高效、更轻量化的方向发展。尽管取得了这些进展, 但在如何实现更优的动态目标权衡、保证对齐策略的稳定性和泛化能力、以及构建能全面反映复杂人类偏好的奖励模型等方面, 仍存在诸多挑战, 为本论文的研究提供了广阔的空间。

1.2.4 对齐性能评估方法与基准

要验证 LLM 对齐策略的有效性, 并理解其对下游应用的真实影响, 科学、全面的评估至关重要, 评估基准是连接理论提升与实际应用价值的桥梁。随着对齐研究的深入, 对齐性能的评估方法本身也成为重要的研究方向, 其发展历程反映了学术界和工业界对模型在真实场景中表现的日益增长的期望。

早期的 LLM 评估更多地集中在传统的自然语言处理任务上, 如 GLUE 和 SuperGLUE 等基准^[24, 25]。然而, 这些基准难以衡量 LLM 在开放式生成、遵循复杂指令以及与人类价值观对齐方面的能力。为应对这一挑战, 一系列新的评估方法和基准应运而生。当前, 对齐性能的评估主要可以分为两大类: 基于固定数据集的自动化评估和基于人类偏好的在线对抗性评估。

基于固定数据集的自动化评估是目前最主流的评估方式, 其核心是利用一组预先设定的提示 (Prompts) 来测试模型, 并通常采用更强大的 LLM 作为“裁判” (LLM-as-a-judge) 来进行自动化评分。Zheng 等人 [26] 在其工作中系统地验证了利用 GPT-4 作为评估者的可行性, 并发现其与人类评估具有高度的一致性, 这为后续自动化评估框架的发展奠定了基础。此类评估框架的代表性工作包括: Dubois 等人 [27] 提出的 AlpacaEval, 该基准主要关注模型遵循指令和单轮对话的帮助性。后续更是引入了长度控制胜率, 旨在更公平地评估内容质量而非长度。其评估结果直接关系到模型在个人助理、信息查询服务等场景中的基础能力。Zeng 等人 [28]

提出的一个评估基准，包含了人工设计的对抗性示例，旨在挑战模型在处理陷阱问题或细微差异回答时的分辨能力。**RewardBench**[29] 是由艾伦人工智能研究院等机构开发，是一个专门用于评估奖励模型性能的基准。其测试类别覆盖了对话、安全、推理等多个维度，对于从根源上评价对齐能力至关重要。

基于人类偏好的在线对抗性评估则提供了一个更动态、更贴近真实世界交互的评估视角。这类平台允许用户与多个匿名模型进行对话，并对模型的回答进行投票，从而收集大规模、真实的众包偏好数据。**Chatbot-Arena** 由 Chiang 等人和 LMSYS 团队推出^[30]，是该领域最具影响力的平台。它通过“盲测”和用户投票的方式，计算出各个模型的 Elo 评分，形成一个动态更新的排行榜。这种评估方式不仅能捕捉到用户在真实、开放式对话中的细微偏好，还能通过其对话模式发现模型在与人类自然交互时的优点和缺点。其衍生的 **Chat-Arena-Hard**^[30] 数据集则进一步包含了高难度、开放式以及涉及伦理困境的问题，专门挑战模型在需要进行复杂推理或辅助决策的落地场景中的表现。

综上所述，当前的 LLM 对齐评估正在从静态、单一任务的评估，走向更动态、多维度、更贴近真实人类偏好和复杂应用场景的综合性评估体系。然而，如何设计更全面、更公平、更能反映人类复杂价值观的评估体系，以及如何弥合自动化评估与真实用户体验之间的差距，本身仍是一个持续存在的挑战。本论文后续的实验评估也将综合利用部分上述主流框架，以期更全面地验证所提方法在提升对齐性能方面的效果。

1.3 当前对齐研究核心挑战

当前研究进展与核心挑战是多目标对齐技术在落地应用中的瓶颈。在 1.2 节中，本文介绍了监督微调和 RLHF 是提升大语言模型对齐性能的主流技术路径。RLHF 通过引入人类偏好，特别是利用奖励模型指导强化学习过程，显著提升了模型在“有用性”、“诚实性”和“无害性”等方面的表现。例如，通过精细的偏好数据和 RLHF 训练，模型在遵循复杂指令、生成更安全内容以及在特定对话场景中提供更令人满意的回答方面取得了长足进步。

然而，随着 LLM 在金融分析、医疗咨询、教育辅导、法律服务等对可靠性和多维度综合能力要求极高的专业落地场景中的应用探索不断深入，现有对齐研究，特别是针对“多目标对齐”的策略，仍面临诸多核心挑战，这些挑战直接构成了 LLM 从通用能力向深度赋能特定行业应用转化的瓶颈。

首先是当前单目标奖励建模难以精确捕捉和权衡多维偏好。奖励模型是 RLHF 的基石，其质量直接决定了对齐的天花板。尽管现有奖励模型在单一或少数目标

上表现尚可，但在多目标场景下，其局限性尤为突出：

(1) 信息损失与偏好模糊化：传统的奖励模型多基于成对比较和 Bradley-Terry^[15] 等模型，将复杂的人类偏好简化为二元标签（例如，回答 A 优于回答 B）。这种方式不可避免地丢失了偏好的强度信息（“A 比 B 好多少？”）以及在多个维度上的细粒度评价。这导致奖励信号相对粗糙，难以指导模型进行精细的多目标权衡。例如，在评估一个 AI 教育辅导的回答时，研究者可能需要同时关注其“知识准确性”（核心概念是否正确无误）、“解释清晰度”（是否使用了学生易于理解的语言和比喻）、“启发性”（是否能引导学生独立思考而非直接给出答案）以及“鼓励性”（在学生遇到困难时能否给予积极反馈）等多个方面。

(2) 多目标冲突处理能力不足：现实应用中，不同的对齐目标（如帮助性、真实性、安全性、简洁性、创造性等）之间往往存在内在的张力甚至冲突。例如，在医疗问答中，追求极致的“帮助性”可能会诱导模型提供未经充分验证的信息，从而牺牲“真实性”和“安全性”。现有奖励模型大多缺乏有效的机制来显式建模和动态调整这些冲突目标间的权重，导致模型在优化时容易“顾此失彼”，难以达到理想的平衡点。

(3) 可解释性与可信度不足：许多奖励模型如同“黑箱”，其内部决策逻辑不透明。这使得研究者难以理解奖励信号的来源和具体含义，也难以诊断奖励劫持（Reward Hacking，即模型学会利用奖励模型的漏洞获得高分，而非真正提升期望行为）等问题。在对可靠性和安全性有极高要求的金融风控或法律文书审阅等场景，一个不可解释的奖励机制是难以被信任和应用的。

(4) 冗余性偏见：研究发现，现有奖励模型和基于其训练的 LLM 往往表现出“冗余性偏见”，即倾向于生成更长的回答以获得更高的奖励分数，即便这些回答并不包含更多有用信息。这在追求高效沟通的智能客服、信息摘要等落地场景中，显然是不受欢迎的。

其次是强化学习优化策略缺乏灵活性、可控性与稳定性。即使有了奖励信号，如何设计有效的强化学习策略来指导 LLM 在多目标空间中进行优化，也面临诸多挑战：

(1) 静态数据与分布外泛化问题：传统的 RLHF 训练通常依赖于预先收集的静态偏好数据集。然而，语言交互是动态和开放的，静态数据集难以覆盖所有可能的真实世界输入和偏好组合。这导致模型在训练分布之外的场景（Out-of-Distribution, OOD）中泛化能力不足，在实际多变的业务流程中表现可能急剧下降。

(2) 多目标优化的可控性不足：用户或开发者往往希望能够根据特定落地场景的需求，灵活地控制模型在不同对齐目标上的侧重点。例如，在创意写作辅助中，可能更看重“创造性”和“流畅性”，而在技术文档生成中，则更侧重“准确

性”和“完整性”。现有的 RLHF 框架大多缺乏这种细粒度的、动态的偏好控制能力，难以实现“按需对齐”。

(3) 训练效率与稳定性问题：RLHF 的训练过程，尤其是近端策略优化^[4]等算法，计算开销大，对超参数敏感，且训练过程可能不稳定。在多目标设定下，优化空间的维度更高、目标间的依赖关系更复杂，这进一步加剧了训练的难度和成本，阻碍了更精细对齐策略的快速迭代和部署。

综上所述，尽管 LLM 对齐技术取得了显著进展，但在面向更广泛、更深入、更专业的实际落地应用时，特别是在“多目标对齐”方面，现有研究在奖励建模的精确性与灵活性、强化学习策略的可控性与适应性，以及评估体系的全面性与场景相关性等方面，均存在亟待突破的核心挑战。解决这些挑战，是推动 LLM 从通用智能向赋能千行百业的实用工具转变的关键。本论文的研究工作正是围绕这些核心挑战展开，旨在提出更有效的多目标奖励建模方法和强化学习优化策略，以期提升 LLM 在复杂应用场景中的综合对齐性能。

1.4 本文研究目标与研究内容

面对 1.3 节中阐述的当前大语言模型在多目标对齐方面，特别是在满足复杂落地应用场景需求时所面临的诸多核心挑战——如奖励建模难以精确捕捉和权衡多维偏好、强化学习优化策略缺乏灵活性与可控性等——本论文旨在研究并提出一套创新性的解决方案。

本论文的核心研究目标是，设计并验证一套高效、可解释且可控的多目标对齐强化学习策略，以显著提升大语言模型与人类在多个关键维度（如帮助性、真实性、安全性、简洁性等）上的对齐程度。通过实现更优的多目标对齐，增强 LLM 在关键落地场景中的可靠性、实用性和安全性，从而扩大其应用场景。

为实现上述总目标，本论文的核心工作和主要贡献可概括为以下三个方面：

(1) 提出并实现了一种基于多维绝对评分和混合专家（Mixture-of-Experts, MoE）机制的多目标奖励模型（Multi-Objective Reward Modeling, MORM）。

针对传统奖励模型在处理多目标偏好时存在的信息损失、偏好模糊化及难以权衡冲突等问题，MORM 采用多维度绝对评分机制，更精细地捕捉人类偏好的丰富信息。创新性地集成了混合专家架构，通过门控网络动态调整不同奖励目标（如帮助性、正确性、冗余性等）的权重，从而实现了对奖励信号的自适应和上下文感知聚合。MORM 旨在提供更准确、鲁棒、可解释且能有效缓解冗余性偏见的多目标奖励信号，为后续的强化学习优化提供了高质量的“评价基础”。（详见第三章）

(2) 构建并验证了一个迭代式多目标可控对齐框架（Iterative Multi-Objective

for Controllable Alignment, IMOCA)。

针对现有强化学习对齐策略在多目标控制、数据效率和适应性方面的不足, IMOCA 是一个创新的强化学习优化框架。该框架有效整合了: (a) 由 MORM 提供的精细化多目标奖励信号; (b) 迭代式同策略偏好采样机制, 通过在线生成和筛选与当前策略相关的高质量偏好数据, 持续优化训练数据分布, 提升模型的适应性和泛化能力; (c) 基于可控偏好优化 (Controllable Preference Optimization, CPO) [31] 的算法, 允许通过明确的偏好条件指令, 引导模型在多个对齐目标之间进行显式、灵活的权衡与优化。

IMOCA 旨在实现对 LLM 多目标对齐过程的精细控制和持续改进, 是本研究提升模型在复杂落地场景中综合表现的“优化核心”。(详见第四章)

(3) 对所提方法在十亿级参数量大语言模型上开展了全面的实验验证。

本论文系统梳理了支撑 MORM 奖励模型设计 (如多维评分、MoE 机制) 和 IMOCA 对齐框架 (如强化学习、迭代优化、CPO、多目标平衡) 的相关理论基础, 阐明了本文方法各组成部分的设计原理和理论合理性。

通过在多个开源社区主流的自动化偏好评估基准 (其设计理念已在 1.2.4 节中阐述, 旨在反映模型在模拟真实应用场景中的核心能力) 以及奖励模型评估基准 (如 RewardBench、RMB) [29, 32] 上进行全面的实验评估, 系统验证了 MORM 作为奖励模型的优越性, 以及 IMOCA 框架在提升 LLM 多目标对齐性能方面的有效性和相比基线方法的显著优势。这些实验结果为所提策略在实际应用场景中通过提升对齐度带来正面影响的潜力提供了有力的证据。

1.5 本研究的预期应用价值

本论文提出的 MORM 多目标奖励模型和 IMOCA 迭代式可控对齐框架, 旨在通过提升大型语言模型 (LLM) 的多目标对齐性能, 为 LLM 在更广泛、更深入的实际落地场景中安全、有效地发挥作用提供关键技术支撑。本研究的成果预期将在以下几个方面展现出重要的应用价值:

(1) 提升 LLM 在专业领域服务中的可靠性与专业性。在医疗健康辅助、法律咨询、金融服务等对信息准确性、真实性和安全性有极高要求的专业领域, 传统的 LLM 因难以平衡多个对齐目标而应用受限。本研究的对齐策略能够:

- 增强内容可靠性: 通过 MORM 对“真实性”、“安全性”等维度的精确评估和 IMOCA 的针对性优化, 能够显著降低模型生成错误或有害信息的风险。
- 提升专业适配性: 利用 IMOCA 的可控性, 可以根据特定行业的规范和偏好 (例如, 法律文书要求严谨, 医疗建议要求谨慎), 定制化对齐模型, 使其输

出更符合专业标准。

(2) 赋能更智能、更具个性化的教育与交互体验。在 AI 教育辅导、智能客服、AI 伴侣等需要深度、动态交互的场景中，用户体验至关重要。本研究的成果能够：

- 实现个性化交互：IMOCA 的 CPO 机制允许根据不同用户的特点（如学生的学习阶段、客户的情绪状态）动态调整模型的沟通风格和策略，例如，在 AI 导师应用中实现从“严谨”到“鼓励”的教学风格切换。
- 提升对话质量与用户满意度：通过迭代式在线学习，IMOCA 能够使模型持续适应新的对话模式和用户偏好，同时 MORM 对冗余性等偏见的缓解能促使模型生成更精炼、更高效的回答，从而提升整体的交互体验 and 用户满意度。

(3) 提高内容创作与办公自动化的效率与质量。在营销文案生成、新闻撰写、代码编写、报告总结等内容创作和办公自动化场景中，对输出质量和风格有多样化需求。本研究的策略能够：

- 实现风格与需求的可控生成：开发者可以通过 IMOCA 的偏好条件指令，精确控制生成内容的风格（如正式、风趣）、结构和侧重点，从而满足不同品牌或任务的特定要求。
- 增强复杂任务的完成能力：一个经过良好多目标对齐的模型，在需要同时兼顾创造性、逻辑性、准确性和格式要求的复杂任务中，表现将更加稳定和出色，从而有效提升工作效率。

总结而言，本研究的价值不仅在于提出了一套技术上更先进的对齐方法，更在于这套方法为解决 LLM 从“通用技术平台”向“赋能千行百业的实用化、价值化工具”转变过程中所面临的核心瓶颈提供了可行的解决方案。通过提升模型的多目标对齐能力，本研究有望将 LLM 更安全、更可靠、更高效地部署到对社会和经济具有重要价值的各个领域。

1.6 本研究的结构安排

为系统地阐述本论文在大型语言模型多目标对齐方面的研究工作，全文结构安排如下：

第一章：研究背景与方法概述。本章首先介绍大型语言模型（LLM）在关键落地应用场景中的潜力及其面临的“对齐”挑战，强调“多目标对齐”对于提升模型在真实世界中实用性与可靠性的重要性。接着，本章将科普大语言模型对齐的核心概念与主流方法，分析当前多目标对齐研究的进展与核心瓶颈。最后，明确提出本论文以“提升 LLM 多目标对齐性能以赋能更优落地应用”为总目标，并概

述本研究的核心贡献——即多目标奖励模型（MORM）和迭代式多目标可控对齐框架（IMOCA）的设计思路与整体技术路线。

第二章：相关工作。本章将系统回顾与本研究相关的国内外研究现状，主要涵盖大型语言模型的基础架构、现有的语言模型对齐方法（包括 SFT、RLHF 及其变种）、语言模型奖励建模（特别是多目标奖励建模的探索）、以及多目标优化理论与算法等方面的代表性工作。通过分析现有研究的成就与不足，进一步明确本论文研究的切入点和创新价值。

第三章：基于混合专家的多目标奖励建模方法研究 (MORM)。本章聚焦于多目标对齐策略的“评价基础”——奖励模型的设计与实现。针对传统奖励模型在精确捕捉和权衡多维偏好方面的局限性，本章将详细阐述提出的多目标奖励模型（MORM）。内容将包括 MORM 的设计理念（如采用多维绝对评分）、核心架构（特别是混合专家（MoE）机制在动态加权不同奖励维度上的应用与理论依据）、训练方法与实现细节。最后，本章将通过在权威奖励模型评估基准（如 RewardBench、RMB）上的实验，验证 MORM 作为高质量、可解释且能有效缓解冗余性偏见的多目标奖励信号源的优越性，为其在后续强化学习框架中的应用奠定坚实基础。

第四章：基于 MORM 的迭代式多目标可控对齐框架 (IMOCA)。在成功构建了高性能的 MORM “评价体系”后，本章将重点研究如何利用该评价体系来训练出一个更优的“行动者”（即 LLM 策略模型），使其行为能够持续提升并满足多目标对齐的期望。为此，本章将详细介绍本研究构建的迭代式多目标可控对齐框架（IMOCA）。内容将涵盖 IMOCA 的整体框架设计、核心组件与机制（包括如何应用 MORM 提供的奖励信号、迭代式同策略偏好采样机制的设计与理论依据、以及基于可控偏好优化（CPO）算法实现多目标显式控制的策略与具体实现）。最后，本章将通过在主流自动化偏好评估基准（如 AlpacaEval、MT-Bench、Chat-Arena-Hard）上的全面实验，验证 IMOCA 框架在显著提升 LLM 多目标对齐性能方面的有效性及其相比现有方法的优势。

第五章：总结与展望。本章将对全文的研究工作进行全面总结，再次凝练并强调在 MORM 奖励模型设计和 IMOCA 对齐框架构建方面的核心贡献，及其在提升 LLM 多目标对齐性能上所取得的成果。在此基础上，将分析本研究存在的局限性，并对未来可能的研究方向进行展望，特别关注如何进一步优化多目标对齐策略以更好地服务于关键落地应用场景，推动大语言模型技术更安全、更负责任、更有效地赋能社会发展。

第二章 大语言模型对齐相关工作

2.1 大语言模型技术概述

随着人工智能和深度学习技术的迅速发展，大语言模型（LLM）已经成为自然语言处理（NLP）领域的核心技术之一。大语言模型通过在海量文本数据上进行训练，能够捕捉语言的复杂模式，并在多个任务中展现出卓越的表现。无论是在生成自然语言文本、理解用户意图，还是进行多轮对话交互，大语言模型都展现出了显著的能力，推动了包括对话系统、代码生成、机器翻译和数学推理等多种应用的快速发展。

随着模型规模的不断扩大，缩放定律（Scaling Law）^[33]显示，模型的性能随着其参数量、训练数据和计算资源的增加呈现非线性增长。特别是在大语言模型达到一定规模后，模型的涌现能力（Emergent Abilities）^[34]得以体现，使得模型能够在少样本学习、零样本学习和推理任务中展现前所未有的能力。这些能力的涌现不仅提升了模型的通用性，也使其在处理更复杂的任务时表现更加出色。

尽管大语言模型在多个领域展现出了强大的能力，它们仍然面临着诸多挑战，包括偏见问题、生成有害内容的风险、可解释性和可控性问题。因此，如何使这些模型更加符合人类价值观和需求，如何保证其生成的内容既有用又安全，依然是当前和未来的研究重点。

2.1.1 大语言模型的定义与发展

大语言模型（LLM）指的是那些在大规模语料库上进行预训练，并具有数十亿到数百亿参数的自然语言处理模型。LLM的核心目标是理解和生成语言，它们通过分析大量的文本数据学习到语言的规律、结构和语义，从而能够在不同的自然语言处理任务中展现出强大的性能。与传统的语言模型相比，LLM的突出特点在于其规模巨大、能力强大，能够执行更复杂的任务。20世纪90年代，统计语言模型（Statistical Language Models, SLM）开启了机器理解语言的新篇章。这类模型基于马尔可夫假设^[36]，通过分析词序列中的统计规律来预测下一个可能出现的词。其中，最具代表性的是n元语法模型（n-gram），如bigram和trigram模型。虽然SLM在信息检索^[37]和自然语言处理任务^[38]中取得了显著成果，但面临着维度灾难的挑战-随着上下文长度增加，需要估算的参数呈指数级增长。为解决这一问题，研究人员提出了多种平滑策略，如回退估计^[39]等。

随着深度学习的发展，神经语言模型（Neural Language Models, NLM）^[40]的概




图 2-1 大语言模型发展时间线（图片来源：[35]）

念被提出。这一阶段的重要突破在于引入了词的分布式表示概念，使用神经网络来刻画词序列的概率分布。特别是 word2vec^[41] 的提出，通过简化的浅层神经网络学习词向量表示，为自然语言处理任务提供了强大的特征表示方法。这一创新超越了传统的词序列建模，开创了表示学习的新范式。

预训练语言模型 (Pre-trained Language Models, PLM) 标志着语言模型进入了新纪元。从 ELMo^[42] 的双向 LSTM 架构，到革命性的 BERT^[2] 模型，它们都采用了“预训练 + 微调”的范式。BERT 基于 Transformer 架构^[7]，通过在大规模无标签语料上预训练，能够捕捉深层的语义特征。这一阶段催生了众多创新模型，如 GPT-2^[8] 和 BART^[43] 等，显著提升了各类自然语言处理任务的性能。

最新的发展阶段是大型语言模型的出现。研究表明，随着模型规模的扩大，语言模型展现出了超越简单任务处理的能力。从 GPT-3^[9] 的 175B（十亿）参数到 PaLM^[44] 的 540B 参数，这些模型不仅在规模上实现了突破，更重要的是展现出了涌现能力，即能够理解上下文并完成复杂任务。其中最具代表性的应用是 ChatGPT^[13]，它展示了与人类进行自然对话的惊人能力。

语言模型的发展历程展示了人工智能在语言理解领域的巨大进步。从早期的统计方法到今天的大语言模型，每个阶段都带来了重要的技术突破，推动了机器语言智能的不断提升。未来，随着技术的进一步发展，有理由期待语言模型将在更多领域发挥重要作用。

2.1.2 自注意力机制与 Transformer 架构

自注意力机制是 Transformer 架构^[7]的核心组成部分，它使得模型能够在处理输入数据时，灵活地聚焦于序列中不同位置的信息。与传统的递归神经网络（RNN）和长短期记忆网络（LSTM）不同，自注意力机制不依赖于输入序列的顺序，而是

通过计算输入序列中每个元素与其他元素之间的关系来建立上下文信息。这种机制能够同时关注到输入序列中所有位置的依赖，从而能够更好地捕捉长距离依赖，并且在并行化处理上具有显著优势。

在自注意力机制中，模型对每个词的表示不仅仅依赖于它自身的信息，还会根据其他所有词的表示来调整其自身表示。具体来说，每个词与其他词的关系通过计算“注意力权重”（Attention Weights）来得到，注意力权重决定了模型在生成输出时，应该多大程度上依赖其他词的表示。




图 2-2 Transformer 架构图

自注意力的计算过程如下：

(1) 输入表征：首先，将输入序列中的每个词表示为一个向量，通常通过词嵌

入 (Embedding) 得到。对于输入序列中的每个词，模型会生成三个向量，分别是查询向量 (Query)、键向量 (Key) 和值向量 (Value)。

(2) 计算注意力权重：查询向量与所有键向量进行点积运算，得到一个表示词之间关系的得分。然后，对这些得分进行归一化处理，通常使用 Softmax 函数将其转化为概率分布。这个过程就是计算每个词对其他词的注意力权重。

(3) 加权求和：最终，输出向量通过加权求和得到。加权系数就是前面计算出的注意力权重，权重越大，表示该词在生成当前输出时的影响力越大。

这个过程可以用以下公式表示：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-1)$$

其中 Q 是查询向量 (Query)，表示当前词的表示； K 是键向量 (Key)，表示序列中其他词的表示； V 是值向量 (Value)，表示用于生成最终输出的加权表示； d_k 是键向量的维度，用于缩放计算，避免数值过大。

Transformer 的成功使得许多 NLP 任务得到了革命性的进展，特别是在机器翻译、文本生成和文本理解等任务中，Transformer 架构展现了其强大的能力。此外，随着自注意力机制与 Transformer 的广泛应用，许多变种和改进相继出现。比如，T5 (Text-to-Text Transfer Transformer) [45] 将所有任务都视为文本到文本的转换任务，进一步统一了 NLP 任务的处理方式；XLNet [46] 则通过结合自回归和自编码的方式进一步改进了 Transformer 的表现；而最近的 ViT 模型 (Vision Transformer) [47] 则将 Transformer 架构成功应用于计算机视觉领域。

尽管 Transformer 架构在许多任务中取得了巨大成功，但它也面临着一些挑战。例如，Transformer 在处理非常长的序列时会遇到计算和存储开销较大的问题。为了解决这一问题，研究人员提出了如稀疏注意力 (Sparse Attention) [48] 和线性时间复杂度 (Linear Attention) [49] 的注意力机制等改进方法。此外，如何在保持性能的同时减少模型的计算成本，如何处理多模态数据 (如图像和文本的结合) 等，仍然是 Transformer 架构未来研究的重要方向。

2.2 语言模型对齐相关工作

随着大语言模型 (LLM) 在自然语言处理领域的广泛应用，它们展现出的强大能力使得人工智能系统在生成自然语言、理解复杂任务、进行多轮对话等方面得到了前所未有的进展。然而，尽管大语言模型在多个任务上取得了显著的成功，它们在实际应用中仍然面临着一系列的挑战，尤其是如何确保这些模型生成的内容与人类的价值观和预期一致，这个问题被称为“模型对齐”。模型对齐不仅仅是

确保 AI 模型的能力符合人类需求，更是保证这些能力在执行任务时能够始终如一地符合伦理、准确并且无害。因此，语言模型的行为对齐已经成为当前大语言模型发展的核心问题之一。

2.2.1 现有的单目标对齐方法

为了实现大语言模型与人类意图的对齐，当前的研究主要集中在三种方法上：监督微调（SFT）和人类反馈强化学习（RLHF），直接偏好优化（Direct Alignment Algorithms, DAA）。这三种方法从不同的角度优化模型的行为，使其更符合人类的期望，尤其是在生成文本时遵循用户指令、保持真实、无害和有用的输出。

2.2.1.1 监督微调

监督微调（Supervised Fine-Tuning, SFT）是一种基本的训练方法，主要通过使用带标签的训练数据来优化模型的参数。在这个过程中，模型首先在一个大的语料库上进行预训练，然后通过监督学习对预训练的模型进行微调，确保其能够适应具体的任务需求。监督微调的目标是通过最小化模型生成输出与目标输出之间的误差，来提高模型在特定任务上的表现。

$$L_{\text{SFT}}(\theta) = - \sum_{t=1}^T \log P_{\theta}(y_t | x_1, x_2, \dots, x_{t-1}) \quad (2-2)$$

其中 $P_{\theta}(y_t | x_1, x_2, \dots, x_{t-1})$ 是模型在给定上下文 $X_{(x_1, x_2, \dots, x_t)}$ 的情况下对目标输出 $Y_{(y_1, y_2, \dots, y_t)}$ 的预测概率。通过最小化损失函数，模型能够逐步学习到符合目标任务要求的输出。

2.2.1.2 人类反馈强化学习

人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）^[13] 是一种通过利用人类的反馈信息来优化大语言模型的技术。在 RLHF 中，模型的行为不再直接通过传统的监督学习进行调整，而是通过人类的反馈来指导模型生成更符合人类偏好的输出。RLHF 能够在模型生成的内容质量、符合伦理规范以及准确性上进行细致的优化，尤其适用于一些难以明确定义奖励函数的复杂任务。

RLHF 的核心在于引入人类偏好反馈。这一过程可以分为三个主要步骤：数据收集、奖励模型的训练和强化学习优化。

（1）数据收集：在 RLHF 的初始阶段，首先需要收集人类的反馈。具体方法是，模型会在给定的输入（如用户问题或指令）下生成多个候选输出，接着由人类评估者对这些输出进行评估，给出反馈。评估可以是定性的，也可以是定量的，通常包括对输出文本的排名或质量评分。




图 2-3 基于人类反馈的强化学习的工作流程

例如，假设给定一个用户查询，“什么是机器学习？”，模型可能生成多个不同的回答。人类评估者的任务是根据其质量、准确性、信息性等标准，对这些回答进行排序，并指出哪个回答最符合用户的需求。评估者不仅会关注模型是否正确回答问题，还会考虑输出内容是否恰当、清晰、符合道德规范和社会价值观。

(2) 奖励建模: 接下来, 将人类的反馈转化为奖励信号, 这就是奖励模型 (Reward Model, RM) 的训练过程。奖励模型通过训练学习评估输入-输出对的质量, 并为每个输出分配一个奖励值, 反映该输出是否符合人类的偏好。奖励模型的目标是通过模拟人类评估者的行为, 预测哪些生成的文本在真实应用中会被认为是更好或更优的。

损失函数: 奖励模型的训练通常采用回归损失或排序损失来优化模型的预测能力。假设给定一对输入 x 和两个候选输出, 奖励模型的目标是最大化人类评估者给出的排名偏好, 即输出 y_1 的奖励比输出 y_2 高。损失函数可以表示为:

$$L_{RM}(\theta) = \sum_i \log(1 + \exp(-\Delta R_i)) \quad (2-3)$$

其中 $\Delta R_i = R_{\text{human}}(x, y_1) - R_{\text{human}}(x, y_2)$ 是人类评估者对两个输出的偏好差; $R_{\text{human}}(x, y)$ 表示人类评估者对输出 y 的评分; θ 是奖励模型的参数。

(3) 强化学习策略优化: 在奖励模型训练完成后, 接下来进入模型的优化阶段。这一步使用强化学习的方法来进一步调整模型的生成策略, 使得它在给定输入的情况下, 能够生成更符合人类偏好的输出。在这个过程中, 模型的目标是最大化预期的奖励, 从而生成高质量的输出。

通常, 强化学习的优化使用策略梯度方法, 例如近端策略优化算法 (Proximal Policy Optimization, PPO) [4]。通过 PPO 算法, 模型会根据奖励模型给出的反馈, 调

整其生成策略，以便产生符合人类期望的内容。

在强化学习的过程中，模型通过以下损失函数进行优化：

$$L_{\text{RL}}(\theta) = -\mathbb{E}_{x,y \sim \pi_{\theta}} [R_{\phi}(x, y)] \quad (2-4)$$

其中 π_{θ} 是模型的策略，表示给定输入 x 时生成输出 y 的概率分布； $R_{\phi}(x, y)$ 是奖励模型对输出 y 的评估，反映了输出的质量； θ 是模型的参数， ϕ 是奖励模型的参数。通过 PPO 算法，模型不断调整生成策略，使得生成的文本更符合人类的偏好，并且在不同任务中保持一致的高质量表现。

RLHF 的优势在于，它能够根据人类的实时反馈优化模型行为，使得模型在执行复杂任务时能够表现得更加符合用户的真实需求。通过引入人类的判断，RLHF 可以解决许多传统方法难以应对的问题，如如何生成符合伦理标准的文本、如何准确理解复杂的任务指令等^[13]。然而，RLHF 也面临一些挑战。首先，收集高质量的人类反馈数据是一个昂贵且耗时的过程，尤其是在大规模应用中。其次，奖励模型的质量直接影响到强化学习过程的效果，如果奖励模型的评估标准与真实需求存在偏差，可能导致模型优化方向错误。最后，尽管 RLHF 能显著提高对齐性能，但如何确保长期使用中模型始终遵循正确的反馈机制，避免不必要的过拟合或误导性训练，仍是一个亟待解决的问题。

2.2.1.3 直接偏好学习

直接对齐算法（Direct Alignment Algorithms, DAA）是近年来在大型语言模型（LLMs）与人类偏好对齐领域中兴起的一类方法。与传统的基于人类反馈的强化学习（RLHF）依赖多阶段流程不同，DAA 通过直接优化模型策略，简化了对齐过程，同时保持高效性和效果。本文将以连贯的叙述方式介绍主要的 DAA 方法，聚焦于它们的起源、创新思想和独特贡献，帮助读者理解这些算法如何推动语言模型对齐技术的发展。

DAA 的出现是对 RLHF 复杂性和资源需求的回应。传统的 RLHF 需要经过监督微调（SFT）、奖励建模（RM）和强化学习（RL）三个阶段，而 DAA 则通过直接利用人类偏好数据（通常以成对比较的形式，如优选响应与次优响应的对比）优化模型，省去了显式奖励模型和 RL 步骤。这种设计的简洁性不仅降低了计算负担，还为对齐任务带来了新的可能性。从 2023 年的开创性工作 [50] 到 2024 年的多样化发展，DAA 逐渐形成了一个丰富的方法体系。

DAA 的目标是通过直接基于人类偏好优化模型策略来对齐 LLM，这些偏好通常以成对比较的形式表达（例如，对于给定的输入 x ，一个“优选”响应 y_w 与一个“次优”响应 y_l ）。DAA 无需显式奖励模型或 RL 优化，因此在计算上更高效，

概念上也更简洁。这些算法在损失函数、隐式奖励形式以及是基于成对还是逐点偏好优化方面有所不同。

接下来介绍主流直接对齐算法：

(1) 直接偏好优化：直接偏好优化（Direct Preference Optimization, DPO）由 Rafailov[50] 等人于 2023 年提出，开辟了 DAA 的先河。DPO 的灵感来源于 RLHF 的低效性，它提出了一种新颖的想法：将偏好优化视为分类任务，直接基于成对偏好数据调整模型，使其更倾向于生成人类偏好的响应。DPO 通过当前策略与参考策略的对数似然比隐式推导奖励。其损失函数鼓励模型为优选响应 (y_w) 分配比次优响应 (y_l) 更高的概率。DPO 不对概率进行长度归一化，这可能影响其在变长序列上的表现。

$$r_{\theta}^{\text{odds}}(y, x) = \log \left(\frac{\pi_{\theta}(y | x)}{1 - \pi_{\theta}(y | x)} \right) \quad (2-5)$$

其中 σ 是 sigmoid 函数， β 是控制偏好优化强度的缩放参数。

DPO 通过隐式奖励——基于当前策略与参考策略（如 SFT 模型）的对数似然比——驱动优化过程，其成对优化的方式有效捕捉了偏好的相对性。这种方法不仅简化了对齐流程，还因其高效性和显著的对齐效果，成为后续 DAA 的基准。

(2) 身份偏好优化：在 DPO 的基础上，身份偏好优化（Identity Preference Optimization, IPO）^[51] 试图解决优化过程中的稳定性问题。IPO 的独特之处在于使用平方误差损失，确保优选与次优响应之间的隐式奖励差值接近一个固定目标。IPO 旨在确保优选与次优响应的隐式奖励差值接近目标值 ($\frac{1}{2\beta}$)，促进均衡的偏好幅度。与 DPO 类似，它依赖 r_{θ}^{ref} 并采用成对优化。

$$\mathcal{L}_{\text{IPO}} = \left(r_{\theta}^{\text{ref}}(y_w, x) - r_{\theta}^{\text{ref}}(y_l, x) - \frac{1}{2\beta} \right)^2 \quad (2-6)$$

其中 σ 是 sigmoid 函数， β 是控制偏好优化强度的缩放参数。

IPO 的平方损失相比 DPO 的逻辑损失可提供更稳定的梯度，但对极端偏好信号的敏感性可能较低。这种设计使 IPO 在面对偏好信号较弱或数据噪声时，能够提供更平稳的训练过程。IPO 通过精确控制偏好幅度，为对齐任务带来了更高的鲁棒性，尤其在复杂场景中表现出色。

(3) 简单偏好优化：随着对简化和高效性的追求，简单偏好优化（Simple Preference Optimization, SimPO）^[52] 的核心创新在于摒弃了对参考策略的依赖，直接基于当前策略的概率差值进行优化，并引入一个可调参数来灵活调整偏好强度。SimPO 通过直接比较当前策略的对数概率避免使用显式参考策略，使其无需参考模型。 γ

项调整偏好阈值，增加了优化的灵活性。

$$\mathcal{L}_{\text{SimPO}} = -\log \sigma(\beta \log \pi_{\theta}(y_w | x) - \beta \log \pi_{\theta}(y_l | x) - \gamma) \quad (2-7)$$

其中 γ 是额外的偏移参数

这种无参考模型的设计大幅降低了内存和计算需求，使 SimPO 特别适合资源受限的场景，如快速部署或小型设备上的对齐任务。SimPO 以其简洁性和实用性，为 DAAs 的应用开辟了新方向。

(4) Odds 比率偏好优化：除了这些双阶段方法，单阶段 DAAs 也为对齐任务带来了新视角。Odds 比率偏好优化（Optimal Reward Proxy Optimization, ORPO）^[53] 将 SFT 和成对偏好优化整合为一步。其基于 odds 比率的隐式奖励设计无需参考策略，同时通过可调参数平衡生成能力和对齐目标。它基于 r_{θ}^{odds} ，无需参考策略，使得优化过程更加独立和直接。其成对设计保留了对偏好相对性的关注，同时通过 λ 参数平衡监督和对齐目标。

$$\mathcal{L}_{\text{ORPO}} = -\log \pi_{\theta}(y_w | x) - \lambda \log \sigma(r_{\theta}^{\text{odds}}(y_w, x) - r_{\theta}^{\text{odds}}(y_l, x)) \quad (2-8)$$

其中第一项是 SFT 损失，第二项是成对对齐项，由 λ 加权。

ORPO 通过结合 SFT 和成对偏好优化，实现在单阶段内同时提升模型的生成能力和对齐质量。ORPO 无需参考模型的特性显著降低了内存需求，使其在资源受限环境下具有很强的适用性。此外，单阶段设计缩短了训练时间，提高了效率，而成对优化方式则确保了偏好数据的有效利用。文档实验表明，添加显式 SFT 阶段可进一步提升性能，显示其灵活性。

直接对齐算法为将 LLM 与人类偏好对齐提供了一个多样化的工具集，平衡了简单性、效率和性能。从 DPO 的基础成对方法到 ORPO 的单阶段创新，每种方法都带来独特的优势和权衡。DPO 以其高效性和基准地位奠定了基础，IPO 通过稳定梯度提升鲁棒性，SimPO 以简单性适应资源受限场景。而 ORPO 的单阶段设计则在效率与效果间找到平衡。理解它们的公式——无论是基于参考策略还是 odds 比率，成对还是逐点目标——使研究者能够根据具体需求选择最合适的算法，优化对齐质量和计算资源。随着研究的推进，进一步的改进和混合方法可能会继续模糊这些算法之间的差异，推动 LLM 对齐的进步，为该研究方向提供广阔的空间。

2.2.2 现有多目标对齐方法

在大语言模型 (LLM) 的对齐问题中，多目标优化 (Multi Objective Optimization, MOO) 扮演了至关重要的角色。LLM 的对齐任务通常涉及多个相互竞争的目标，如有帮助性和无害性，这些目标有时会发生冲突。

因此，如何平衡多个目标，并在它们之间找到合适的优化策略，是当前研究的关键问题之一。针对这些问题，近年来涌现了一些新的多目标对齐方法用于处理这一问题。

以下是一些在 LLM 对齐中应用的主要多目标优化方法：

(1) 直接偏好优化的多目标对齐：Zhou 等人 [22] 提出的基于直接偏好优化的多目标对齐（Multi-Objective Direct Preference Optimization, MODPO）则是在直接偏好优化（DPO）基础上扩展到多目标对齐的场景。传统的 DPO 利用 Bradley-Terry 模型来刻画偏好分布，MODPO 则通过引入线性标量化和权重参数，将多目标信息融入优化过程中，从而获得一组在不同偏好权重下的语言模型 Pareto 最优解。

MODPO 的关键思想是多目标扩展与线性标量化，即考虑多目标时，通过预先确定的权重向量 $w = [w_1, \dots, w_N]$ （其中 $\sum_i w_i = 1$ ），目标转化为：

$$\max_{\pi} \mathbb{E} \left[w^T r^*(x, y) - \beta \log \frac{\pi(y | x)}{\pi_{\text{sft}}(y | x)} \right] \quad (2-9)$$

MODPO 对 DPO 损失进行扩展，引入权重和 margin 项，其损失可写为：

$$\begin{aligned} \mathcal{L}_{\text{MODPO}}(\pi_{\theta_w}; \mathbf{r}_{\phi, -k}, \pi_{\text{sft}}, \mathcal{D}_k) = & \\ - \mathbb{E}_{\mathcal{D}_k} \left[\log \sigma \left(\frac{\beta}{w_k} \log \frac{\pi_{\theta_w}(y_w | \mathbf{x})}{\pi_{\text{sft}}(y_w | \mathbf{x})} - \frac{\beta}{w_k} \log \frac{\pi_{\theta_w}(y_l | \mathbf{x})}{\pi_{\text{sft}}(y_l | \mathbf{x})} \right) \right. & \\ \left. - \frac{1}{w_k} \mathbf{w}_{-k}^T (\mathbf{r}_{\phi, -k}(\mathbf{x}, y_w) - \mathbf{r}_{\phi, -k}(\mathbf{x}, y_l)) \right] & \end{aligned} \quad (2-10)$$

其中 w_k 表示第 k 个目标的权重， w_{-k} 为除第 k 个目标之外的权重。

MODPO 作为一种无 RL（RL-free）的多目标对齐方法，能更高效地利用现有偏好数据生成不同偏好权重下的模型集合，既保留了 DPO 的稳定性，又显著降低了计算开销，适用于多目标环境下的高效对齐。使用 MODPO 训练的模型在有冲突的目标任务上，通常表现优于那些仅使用单一目标优化方法训练的模型。

(2) 可控偏好优化：该工作主要由 Guo 等人 [31] 提出，针对传统对齐方法在多目标设置下难以权衡各目标冲突的问题，提出了可控偏好优化（Controllable Preference Optimization, CPO）算法。该方法的核心思想是通过引入显式的偏好条件来引导模型在特定目标上的生成，从而在不同对齐目标之间实现更灵活的权衡。

CPO 方法通常分为两个主要阶段：

1. 可控偏好监督微调（Controllable Preference Supervised Fine-Tuning, CPSFT）：在这一阶段，通过使用明确的偏好标记，来指导模型的输出，使其更好地符合预定义的有帮助性和无害性标准。具体而言，偏好标记能够明确地告诉模型什么样的输出是符合目标的，从而有效地进行任务特定的微调。在原有监督微调（SFT）的

基础上，增强输入信息，目标函数为：

$$L_{\text{CPSFT}}(\theta) = -\mathbb{E}_{(x,y,c_1,\dots,c_m) \sim D} [\log \pi_{\theta}(y \mid c_1, \dots, c_m, x)] \quad (2-11)$$

其中 $c_1, \dots, c_m$ 是偏好条件。

2. 可控直接偏好优化（CDPO）：这一阶段通过直接比较不同响应，并根据人类偏好的多种条件进行优化，从而使得模型输出更好地符合实际的需求和预期。CDPO 通过多次人类偏好的反馈来优化模型，使得模型输出逐渐接近理想的目标。采用可控多目标奖励函数：

$$L_{\text{CDPO}} = -\mathbb{E}_{(x,c,y_w,y_l) \sim D} \left[\log \sigma \left(\hat{R}_{\theta}(c, x, y_w) - \hat{R}_{\theta}(c, x, y_l) \right) \right] \quad (2-12)$$

通过调整偏好条件 c_i 来实现对不同目标的控制。其中隐式奖励函数定义为：

$$\hat{R}_{\theta}(c, x, y) = \beta \log \frac{\pi_{\theta}(y \mid c, x)}{\pi_{\text{ref}}(y \mid c, x)} \quad (2-13)$$

此外，该方法还引入了加权控制策略，对被控制目标采用如下形式：

$$g_i = \begin{cases} -\lambda_i |p_i - c_i|, & \text{若为控制目标} \\ p_i, & \text{否则} \end{cases} \quad (2-14)$$

最终将多目标奖励值定义为：

$$R = \sum_{i=1}^m \omega_i g_i \quad (2-15)$$

其中 $\sum_{i=1}^m \lambda_i = 1$ 且 $\sum_{i=1}^m \omega_i = 1$ 。

CPO 方法的核心优势在于其能够处理复杂的偏好对齐问题，通过明确引入偏好条件，CPO 能够在保证单一目标性能的同时，缓解各目标之间的冲突，实现更细粒度的对齐调控，从而部分缓解“对齐税”问题。模型能够在面对复杂任务时，做出更加符合人类期望的决策。

（3）MetaAligner：一种通用化的多目标对齐方法，MetaAligner 由 Yang 等人 [23] 提出，其主要目标在于解决现有多目标对齐方法依赖于具体策略模型参数的问题，同时具备对未见目标的零样本对齐能力。该方法属于“不依赖策略模型参数”（policy-agnostic）的对齐方法，通过动态目标重构和条件弱到强校正策略，实现了对多目标的灵活对齐。它采用三阶段框架来实现对多目标偏好的动态对齐：

动态目标重构：将传统的对齐数据集转换为动态多目标数据集，其中每个样本不仅包含问题和回答对，还附带各目标的文本描述（如“Helpful”、“Harmless”、“Factual”等），并通过预定义的提示模板重新组织数据。

条件弱到强校正：训练一个 MetaAligner 模型 δ_{θ} ，对于给定问题 q 初始输出 y_0 ，

模型 δ_θ 在提示模板 $T(q, y_0, O, t)$ 的条件下生成更优的对齐回答：

$$\pi^*(y | q) = \delta_\theta(y | T(q, y_0, O, t)) \pi_\phi(y_0 | q) \quad (2-16)$$

其中 O 表示目标描述集合, t 表示“更好”或“相同”等标签。

在固定策略模型参数的条件下, MetaAligner 仅对校正模块进行训练, 其目标函数简化为：

$$\min_{\theta} -\mathbb{E}_{(q, y_0, y, O) \sim D} [\log \delta_\theta(y | T(q, y_0, O, t))] \quad (2-17)$$

此外, 算法还通过三步训练（预热、等偏好对齐和对比偏好对齐）来进一步提升校正效果。

MetaAligner 的优势在于不需要访问或调整目标策略模型参数, 大大降低了训练成本；利用提示模板动态调整目标描述, 实现对未见目标的零样本对齐；通过动态重构数据, 使得模型能够适应多种不同对齐目标的组合。在提高多目标对齐效果的同时, 显著减少了与传统方法相比的训练成本。它不仅提高了对齐效果, 而且优化了模型训练的效率, 是一个在实际应用中具有广泛前景的方法。

大语言模型的多目标对齐任务需要复杂的多目标优化方法来平衡多个目标之间的冲突。通过提出 MODPO、CPO、MetaAligner 等方法, 研究人员已经开发出了一系列优化策略, 使得 LLM 能够更好地符合人类的伦理标准和偏好需求。每种方法都有其独特的优势和适用场景, 未来的研究将在此基础上进一步优化这些方法, 推动大语言模型在多任务和多领域中的广泛应用。

2.3 语言模型奖励建模相关工作

随着大语言模型（LLM）在各种自然语言处理任务中的广泛应用, 如何为这些模型设计有效的奖励机制以确保其输出符合预期, 成为了模型对齐问题的核心。奖励模型（Reward Model, RM）在这一过程中扮演着至关重要的角色。奖励模型的目标是为生成的文本分配一个“奖励值”, 通过这些奖励值指导模型学习和优化其行为, 使其输出更符合人类的期望和伦理标准。在现有大语言模型的强化学习中, 奖励模型的作用是通过评估模型的行为（即输出文本）, 提供反馈信号, 以便模型通过奖励最大化学习如何更好地完成任务。

2.3.1 语言奖励模型

奖励模型是现代 RLHF 方法的核心, 是根据特定任务和目标评估语言模型生成文本质量的关键工具。奖励模型在强化学习研究中被广泛用作环境奖励的代理, 其核心作用是通过学习一个标量奖励函数 r , 为给定输入 X 和模型生成的响应 Y

计算一个偏好评分，从而用于后续的强化学习训练。

这种做法与逆强化学习（Inverse reinforcement learning, IRL）^[54]密切相关，其中问题是根据行为轨迹（Trajectory）近似代理的奖励函数^[55]。奖励模型以其现代形式被提出作为研究价值对齐问题的工具^[56]，目标是将文本生成任务转化为优化问题，在该问题中，模型的每个生成输出会根据人类定义的标准（如质量、准确性、符合性等）获得一个“奖励值”。

最常见的奖励模型预测文本与训练比较中“首选”文本的接近程度。在 RLHF 中，主流工作使用以下几种奖励模型：

- （1）标准奖励模型：预测文本之间偏好的模型。
- （2）结果奖励模型（Outcome Reward Models, ORM）：预测完成结果是否正确。
- （3）过程奖励模型（Process Reward Models, PRM）：为推理中的每个步骤分配分数。

如无特别说明，本文中提到的奖励模型是指预测文本之间偏好的标准奖励模型。

2.3.2 现有奖励建模相关工作

随着基于人类反馈的强化学习（RLHF）在大型语言模型优化中的广泛应用，奖励建模已成为这一领域的关键研究方向。虽然传统的 Bradley-Terry 模型为奖励函数的学习提供了坚实的理论基础，但研究人员逐渐发现，不同任务、数据类型和应用场景下，标准奖励模型存在各种局限性。为了解决这些问题，学术界和工业界提出了多种奖励模型变体，每种变体都针对特定的挑战或优化目标。这些变体包括引入偏好幅度的边际损失函数^[3]、基于 K-wise 排序的损失函数^[57]、关注任务结果的结果奖励模型（ORMs）^[19]、评估推理步骤的过程奖励模型（PRMs）^[58]以及最近兴起的生成式奖励模型。这些创新不仅拓展了 RLHF 的适用边界，还显著提高了模型性能，特别是在数学推理、复杂指令遵循和长文本生成等具有挑战性的任务中。本节将系统地介绍这些关键变体，分析它们的技术特点、应用场景及其在实际部署中的效果。

（1）偏好边际损失：基于标准偏好损失的基础上，在注释者提供评分或在李克特量表（Likert）^[59]上的排名的情况下，关系量的大小可以用于训练。最常见的做法是二值化数据方向（隐含分数为 1 和 0），可以用额外的信息改进模型训练。Llama 团队 [3] 提出使用偏好对之间的边际（margin）来区分偏好的幅度：

$$\mathcal{L}(\theta) = -\log(\sigma(r_{\theta}(x, y_w) - r_{\theta}(x, y_l) - m(r))) \quad (2-18)$$

其中 $m(r)$ 为一标量值，衡量 $r_\theta(x, y_w)$ 好于 $r_\theta(x, y_w)$ 的程度。

(2) K-wise 损失函数：还有许多其他公式可以为模型对齐创建适当的偏好模型。starling 7B[18] 团队提出基于 Plackett-Luce 模型^[17] 的 K -wise 损失函数。

Zhu 等人 [57]2023 年的工作优化了这个损失函数，提出了 K -wise 奖励建模。对于提示或状态 s^i ，从 $P(a_0, \dots, a_{K-1} | s^i)$ 中采样 k 个动作 $(a_0^i, a_1^i, \dots, a_{K-1}^i)$ 。然后，标注者用来对偏好进行排名。偏好模型的损失函数为：

$$P(\sigma^i | s^i, a_0^i, a_1^i, \dots, a_{K-1}^i) = \prod_{k=0}^{K-1} \frac{\exp(r_{\theta^*}(s^i, a_{\sigma^i(k)}^i))}{\sum_{j=k}^{K-1} \exp(r_{\theta^*}(s^i, a_{\sigma^i(j)}^i))} \quad (2-19)$$

其中 $\sigma^i : [K] \mapsto [K]$ 是表示动作排名的函数， $\sigma^i(0)$ 是最优先的动作。当 $K = 2$ 时，这简化为成对比较的 Bradley-Terry 模型。

(3) 结果奖励模型：语言模型和其他 AI 系统的大多数偏好建模都是使用上面讨论的 Bradley-Terry 模型完成的。对于推理密集型任务，可以使用结果奖励模型 (Outcome Reward Model, ORM)^[19]。ORM 的训练数据构建方式与标准偏好调整类似。有一个问题陈述或提示 x ，以及两个回复 y_1 和 y_2 。这里与标准的偏好数据不同的点一个是问题的正确解决方案，另一个是不正确的解决方案，而不是偏好答案。

ORM 所使用的模型架构与标准奖励模型基本相同，在基座模型架构的基础上附加一个线性回归层作为一个语言建模二元分类头，可以为每个词元 (token) 预测两个类别 (1 表示正确，0 表示不正确)，而不是传统偏好奖励模型的线性回归头，后者为整个输入序列输出一个标量。这可以表示为：

$$L_{CE} = -\mathbb{E}_{(s,r) \sim D} [r \log p_\theta(s) + (1-r) \log (1-p_\theta(s))] \quad (2-20)$$

其中 $r \in \{0, 1\}$ 是一个二元标签，1 适用于给定提示的正确答案，0 适用于不正确的答案， $p_\theta(s)$ 是被训练模型预测的正确性概率的比例标量。

(4) 过程奖励模型：过程奖励模型 (Process Reward Models, PRMs)^[58]，最初称为过程监督奖励模型，是训练以在思维链推理过程的每个步骤输出分数的奖励模型。这些与在句子结束位置词元 (EOS token) 处输出分数的标准奖励模型或在每个词元处输出分数的 ORM 不同。过程奖励模型需要在每个推理步骤 (Step) 结束时的监督信号，然后以类似的方式训练，不同的是 PRMs 评估响应中每个步骤，而 ORM 中是整个响应。

传统上，PRMs 同样是用语言建模的线性回归层训练的，该层仅在推理步骤结束时输出预测结果，例如在对应于双换行符或其他特殊词元处。这些预测往往是 -1 表示不正确，0 表示中性，1 表示正确。这些标签不一定与模型是否在正确的路

径上有关，而是与步骤是否正确有关。

表 2-1 不同类型奖励模型的预测内容、训练方式比较

模型类别	预测内容	训练方式
标准奖励模型	通过 EOS token 处响应的获胜概率来衡量文本质量	在成对（或 K-wise）回复比较之间的对比损失
结果奖励模型	每个词元答案正确的概率	标记的结果（例如，在可验证领域上的成功/失败）
过程奖励模型	在推理步骤末尾为中间步骤提供奖励或分数	使用中间反馈或逐步注释训练（每个推理步骤中的词元训练）

综上所述，奖励建模作为 RLHF 中的核心环节，正不断演化以应对不同任务维度的挑战。从引入偏好强度的边际损失函数，到支持多项排序的 K-wise 模型，再到聚焦最终结果正确性的 ORM 以及对中间推理路径进行监督的 PRM，各类模型不断丰富奖励建模的表达能力和适应范围。这些研究不仅提升了对语言模型行为的建模精度，也为构建更可靠、更可控的人工智能系统奠定了坚实基础。未来，随着任务复杂性的进一步提升，如何设计更细粒度、更通用的奖励模型，仍将是该领域持续探索的关键方向。

2.4 混合专家模型相关工作

混合专家模型机制（Mixture-of-Experts, MoE）是一种在深度学习领域中广泛应用的模型架构，特别适用于处理大规模语言模型和多目标奖励建模等复杂任务。本节将详细介绍 MoE 的基本原理、核心结构、在多目标奖励建模中的应用，以及其训练优化方法、优势与挑战。内容将从 MoE 的工作机制入手，逐步深入探讨其在多目标任务中的应用价值，并总结其研究前景。




图 2-4 混合专家模型示意图

2.4.1 混合专家机制的基本原理

MoE 机制广泛应用于自然语言处理 (NLP) 领域^[60-62], 尤其在基于 Transformer 的架构中表现出色^[62]。其核心思想是基于输入特征动态选择并激活少量相关专家网络进行计算, 从而在保持高性能的同时大幅降低计算成本。与传统的单一大规模神经网络不同, MoE 采用多个较小的专家网络协同工作, 每个专家专注于处理输入数据的特定子集或模式。训练过程中, 这些专家通过学习不同的数据特征, 结合路由机制 (Routing Mechanism) 动态分配任务, 确保输入数据由最适合的专家处理。

在 MoE 架构中, 每个输入数据 (例如一个词元) 首先经过路由器处理。路由器生成一个概率分布, 并基于此选择一个或多个专家进行后续计算。这种设计将传统的固定计算路径转变为动态适应的计算流程。MoE 主要由以下两部分组成:

(1) 门控网络 (Gating Network): 门控网络通常是一个浅层多层感知机 (Multi-Layer Perceptron, MLP), 负责接收输入数据并计算每个专家网络的激活概率。其输出是一个概率分布, 表示每个专家被选中的权重。门控网络的数学表达为:

$$G(x) = \text{softmax}(W_g \cdot x + b_g) \quad (2-21)$$

其中, x 表示输入数据, W_g 和 b_g 分别为门控网络的权重矩阵和偏置向量, $G(x)$ 输出每个专家被选中的概率分布, Softmax 函数确保输出的概率和为 1。

(2) 专家网络 (Expert Networks): 每个专家网络是一个独立的子模型, 通常为前馈神经网络 (Feedforward Neural Network, FFN), 专注于任务的特定子问题或目标维度。例如, 在多目标奖励建模中, 不同专家可分别优化真实性、帮助性或简洁性等维度。第 i 个专家网络的输出定义为:

$$E_i(x) = xW_i + b_i \quad (2-22)$$

其中, W_i 和 b_i 为第 i 个专家的参数。

MoE 的运行过程包括以下步骤:

- (1) 输入数据传递: 输入数据 (如任务提示或模型生成的响应) 首先被传递至门控网络。
- (2) 专家选择: 门控网络根据输入特征计算每个专家的激活概率, 并选择部分专家 (例如采用 top-k 策略) 进行处理。
- (3) 专家处理任务: 被选中的专家网络对输入数据进行处理, 生成针对特定目标的输出。
- (4) 加权组合输出: 所有被激活专家的输出根据门控网络分配的概率加权组合, 生成最终结果。

MoE 层的最终输出是各专家输出的概率加权和：

$$y = \sum_{i=1}^n G(x)_i \cdot E_i(x) \quad (2-23)$$

其中， y 为输出， $G(x)_i$ 为第 i 个专家的输出， $E(x)_i$ 为门控网络分配给第 i 个专家的权重， n 为专家总数。

MoE 的一个显著特点是其稀疏性：并非所有专家都会被激活，而是根据输入选择 top-1 或 top-k 个专家。这种稀疏激活显著降低了计算量，使得 MoE 在大规模模型中仍能保持高效推理。例如，若一个 MoE 层包含 8 个专家，而仅激活 2 个，则计算开销仅为全激活模型的 1/4。这种条件计算（Conditional Computation）模式显著提升了计算资源的利用效率。与传统密集型神经网络相比，MoE 能在更低的计算开销下处理复杂任务，具有较高的可扩展性。

2.4.2 混合专家模型的训练与优化

MoE 的训练过程包含三个核心步骤：

- （1）门控网络训练：通过学习输入上下文和任务目标，优化门控网络以动态选择最合适的专家。
- （2）专家网络训练：各专家针对特定任务维度独立优化，分别最小化对应的目标损失。
- （3）负载均衡优化：结合辅助损失和容量约束，确保专家间的训练数据分布均衡，避免资源浪费或过拟合。

训练 MoE 模型的关键挑战之一是确保各专家的均衡激活与训练稳定性。若路由器偏向某些专家，可能导致部分专家过度训练，而其他专家未被充分利用，造成计算资源浪费和模型性能下降。为此，MoE 模型通常采用以下策略：

- （1）负载均衡机制：为解决专家选择的不均衡问题，Gshard[62] 引入了负载均衡机制。其核心是通过正则化路由器，促使其在所有专家间公平分配任务。这通常通过在训练目标中加入辅助损失项（Auxiliary Loss）实现：

$$\mathcal{L}_{aux} = \lambda \cdot CV(G(x)) \quad (2-24)$$

其中， λ 是超参数，控制辅助损失的权重 $CV(G(x))$ 为路由概率分布的变异系数（Coefficient of Variation），衡量专家选择的均衡性，变异系数越小，分配越均衡。

- （2）专家容量约束：为进一步提升稳定性并防止内存溢出，Switch Transformers[61] 又引入了专家容量约束（Expert Capacity），限制每个专家在一个批次中处

理的词元数量。专家 i 的容量定义为：

$$\text{Capacity}_i = \min \left(\text{Max Capacity}, \sum_{x \in \text{Batch}} G(x)_i \right) \quad (2-25)$$

其中 Max Capacity 是预设的单专家最大处理能力， $\sum_{x \in \text{Batch}} G(x)_i$ 是批次中分配给专家 i 的 token 权重总和。

2.5 本章小节

本章系统性地回顾了大型语言模型对齐领域的相关工作，从大语言模型的基础技术，到对齐的核心范式，再到前沿的多目标对齐策略与相关技术，进行了全面的梳理和评述。

首先，本章概述了大语言模型的基础技术，追溯了其从早期模型到当前基于自注意力机制与 Transformer 架构的演进历程。这些强大的基础模型为后续所有对齐工作提供了能力基座，但其本身的生成不可控性也引出了对齐研究的必要性。

其次，在语言模型对齐相关工作层面，本章分析了从基础的监督微调（SFT），到作为当前主流范式的从人类反馈中强化学习（RLHF），再到更高效的直接偏好学习（DPO）等单目标对齐方法的演进。同时，本章也介绍了如 MODPO 等旨在处理更复杂场景的多目标对齐方法的初步探索。这些研究虽然取得了显著进展，但在如何实现多目标间的灵活、动态权衡与精确控制方面，仍存在明显的研究空间。

再次，在作为 RLHF 核心的语言模型奖励建模层面，本章回顾了语言奖励模型的基本原理以及现有奖励建模的相关工作。研究已从传统的基于成对比较的方法，发展到探索利用更丰富偏好信息的先进技术。同时，介绍了混合专家模型的基本原理、训练与优化方法。MoE 作为一种提升模型动态适应性和计算效率的先进架构，其在条件计算和专家选择方面的机制，为解决多目标对齐中动态权衡的难题提供了极具潜力的技术思路。

综上所述，尽管 LLM 对齐技术发展迅速，但在奖励建模的精确性与动态性，以及优化策略的灵活性与可控性这两个关键环节上仍存在明显的研究缺口。为应对这些挑战，本论文后续章节将首先聚焦于奖励建模层面，在第三章提出一种创新性地融合了混合专家机制的多目标奖励模型；并在此基础上，于第四章构建一个先进的对齐优化框架，以期系统性地提升 LLM 的多目标对齐性能。

第三章 基于混合专家的多目标奖励模型方法

3.1 引言

大型语言模型在复杂任务处理和自然语言生成方面已展现出显著能力，为赋能多样化的实际应用场景（如专业咨询、教育辅导及内容创作等）提供了新的技术路径。然而，正如第一章所述，确保 LLM 的行为与人类期望及特定应用场景下的多维度需求相符，即实现有效的“模型对齐”，是其成功落地并发挥正面价值的关键前提。从人类反馈中强化学习已成为实现 LLM 对齐的主流范式，其核心在于通过奖励模型将人类偏好转化为可优化的奖励信号，进而指导 LLM 的策略学习。

现有研究表明，奖励模型的质量和设计直接制约着 RLHF 对齐的最终效果。传统的奖励模型大多基于成对比较数据，并输出单一的标量奖励，这种方式在处理具有多个、甚至可能相互冲突的对齐目标时，面临显著局限性。首先，将复杂的多维偏好压缩至单一标量或简单的二元比较，不可避免地导致了人类偏好信息的损失，难以精确指导模型在各目标维度上进行细致权衡。其次，多数现有奖励模型缺乏对不同目标重要性进行动态调整的机制，难以适应不同应用场景或具体指令下对各对齐目标侧重点的变化，这限制了对齐策略的灵活性和适应性。再次，部分奖励模型存在的“黑箱”特性及其可能引入的偏见（如冗余性偏见），进一步影响了对齐过程的可解释性和最终输出的质量。

因此，为了更有效地提升 LLM 在复杂落地应用中的多目标对齐性能，构建一个能够精确捕捉多维度偏好、动态权衡各目标重要性、具备良好可解释性并能缓解已知偏见的“评价体系”——即高质量的多目标奖励模型——成为一项关键且具有挑战性的任务。本章致力于解决上述问题，提出并详细阐述一种基于混合专家（MoE）架构的动态多目标奖励建模方法（MORM）。该方法通过引入多维度绝对评分机制和 MoE 的动态加权能力，旨在生成更精细、上下文感知且鲁棒的奖励信号。本章将详细介绍 MORM 的设计理念、核心机制、训练方法及其实现细节。为验证 MORM 作为高质量对齐奖励信号源的有效性，本章还将通过在国际公认的奖励模型评估基准（如 RewardBench 和 RMB）上进行全面的实验评估，将其性能与现有代表性奖励模型进行对比分析。这些实验结果将证实 MORM 在准确反映和权衡多维偏好方面的能力，从而证明其能够为后续第四章构建的迭代式对齐框架提供坚实的奖励基础，并最终服务于提升 LLM 在多样化下游应用中的综合对齐表现和实用价值。

为系统阐述 MORM 的设计、实现与验证过程，本章后续内容组织如下：3.2

节将深入探讨 MORM 的设计理念及其旨在应对的核心挑战，特别分析了采用多维度绝对评分和引入混合专家（MoE）机制的理论动因与必要性。3.3 节将详细介绍 MORM 的整体架构设计与核心机制，包括其多维度评分的实现方式、基于 MoE 的动态多目标加权整合策略，以及针对冗余性偏见的缓解机制。3.4 节将阐述 MORM 模型的具体训练方法、损失函数设计及相关的实现细节。3.5 节将通过在一系列权威奖励模型评估基准上的全面实验，展示 MORM 的性能表现，并与现有代表性方法进行对比分析，以实证其作为高质量多目标“评价体系”的有效性。最后，3.6 节将对本章工作进行总结，并强调 MORM 为后续章节中构建的强化学习对齐框架所奠定的重要基础。

3.2 MORM 的设计理念与核心挑战

为了构建能够有效指导大语言模型实现多目标对齐的奖励模型，首先需要深入理解现有奖励表示方式的局限性，并明确新模型所需解决的核心理论与实践挑战。传统的奖励建模方法在处理复杂的多维偏好时，往往难以兼顾信息的完整性、目标间的动态权衡以及模型的可解释性，这些都直接影响了最终的对齐效果和模型在实际落地应用中的表现。

3.2.1 传统奖励建模的局限性与精细建模的需求

当前 LLM 对齐中，主流的奖励模型训练数据通常源于人类对模型输出的成对比较（pairwise comparison）。这种方法借鉴 Bradley-Terry 模型等理论，将偏好转化为相对排序。虽然直观且易于标注，但在多目标背景下，其将复杂的多维偏好简化为单一的“更好”或“更差”选择，不可避免地会丢失偏好的具体强度和在各个独立维度上的表现差异。这在需要模型在多个性能维度上达到精细平衡的专业咨询或内容创作辅助等落地场景中，会导致奖励信号精度不足。此外，成对比较主要提供整体优劣信号，难以直接、独立地评估模型在各特定对齐目标（如真实性、安全性）上的具体表现，使得对齐过程缺乏足够的可解释性和针对性的诊断能力。

为克服上述信息损失和多维建模的间接性问题，一个重要的改进方向是采用多维度绝对评分，即让人类评估者或高阶模型直接对每个输出在多个预设维度上独立打分。这种方式能够更完整地保留偏好信息，为后续的细粒度控制和可解释性分析提供了可能。然而，即便获得了多维评分，如何将其有效整合成一个能指导强化学习的统一奖励信号，仍是关键。

当前 LLM 对齐中，主流的奖励模型训练数据来源于人类对模型输出的成对比较，例如，判断两个由模型生成的回复中哪一个更优。这种方法通常借鉴 Bradley-

Terry 模型等理论，将偏好转化为相对排序或二元标签。虽然直观且易于标注，但这种方式在多目标对齐的背景下存在显著的理论和实践瓶颈：

(1) 信息损失与精度不足：将复杂的人类偏好简化为二元选择（“更好”或“更差”）或单一的相对排序，会丢失大量的细粒度信息。这种信息损失在诸如 AI 教育辅导等复杂落地场景中尤为致命。例如，一个学生询问“请解释一下牛顿第二定律”，模型 A 给出了一个百科全书式的、完全正确但冗长复杂的回答；模型 B 给出了一个用生动比喻解释的、略有简化但更易懂的回答。对于一个初学者而言，模型 B 可能远优于模型 A。传统的成对比较只能得出“B 优于 A”的结论，却无法捕捉到“A 在准确性上满分，但在简洁性和启发性上得分很低，而 B 在启发性上表现优异”这样的多维度细节。二值化或简单的相对比较无法捕捉这些偏好的具体强度、不同维度上的表现差异以及人类评价的置信度，导致奖励信号的精度不足，难以指导模型进行精细化的改进。这在需要模型在多个性能维度上达到微妙平衡的专业咨询或内容创作辅助等落地场景中尤为关键。

(2) 难以直接建模多维目标：成对比较本质上产生的是一个关于“整体优劣”的信号，难以直接、独立地评估模型在各个特定对齐目标（如真实性、安全性、连贯性等）上的具体表现。虽然可以通过为不同目标分别收集偏好数据来构建多个奖励模型，但这不仅增加了标注和训练成本，后续如何有效整合这些单一维度的相对偏好信号，以形成一个能指导多目标权衡的综合奖励，本身也是一个难题。

(3) 可解释性与诊断性受限：当模型表现不佳时，基于成对比较的奖励模型往往难以提供清晰的诊断信息，说明模型具体在哪些维度上存在不足。这使得对齐过程更像一个“黑箱”调优，不利于研究者理解模型的行为并进行针对性的改进。

为克服上述信息损失和多维建模的间接性问题，一个重要的改进方向是采用多维度绝对评分，即让人类评估者或高阶模型直接对每个输出在多个预设维度上独立打分。这种方式能够更完整地保留偏好信息，为后续的细粒度控制和可解释性分析提供了可能。然而，即便获得了多维评分，如何将其有效整合成一个能指导强化学习的统一奖励信号，仍是关键。

一种常见的多目标奖励聚合方式是线性加权和 (Weighted Sum)^[63-65]，即为每个目标的评分或奖励函数预设权重 λ_i ，然后将加权后的各目标值相加得到综合奖励信号：

$$R_{\text{total}}(x) = \sum_{i=1}^n \lambda_i R_i(x) \quad (3-1)$$

其中 $R_i(x)$ 是第 i 个目标的奖励函数； λ_i 是第 i 个目标的权重，表示该目标的重要性； n 是目标的数量。

这种方法的优点在于简单直观，易于实现。但其核心缺陷在于权重 λ_i 的设定

往往是静态的且难以普适。在多数实际应用中，不同目标的重要性可能随上下文动态变化，一组固定的权重难以适应所有情况。

为了更好地处理目标间的非线性关系，研究者也探索了非线性加权方法或更复杂的评分与整合机制，这些有时也可能依赖于组合多个不同来源或类型的奖励信号。例如使用加权乘积的方式来构建多目标奖励函数：

$$R_{\text{total}}(x) = \prod_{i=1}^n (R_i(x))^{\lambda_i} \quad (3-2)$$

其中 λ_i 仍然是每个目标的权重，代表该目标在整个奖励中的重要性。通过对奖励进行乘积加权，可以对目标之间的相互作用提供更加精细的控制。

相比线性加权，该方法隐含了“各目标共同贡献整体效果”的语义：若任一目标的奖励极低，将严重拉低总奖励值，从而在优化过程中强制代理避免“短板目标”的严重缺陷。因而，这种乘积型组合天然适用于目标间强互补或存在“木桶效应”的场景。这种方法常用于目标之间相互依赖且影响较大的情境，例如在一些任务中，某些目标的奖励如果过低，可能会导致整体性能的急剧下降，而其他目标的奖励需要在某些范围内平衡，以避免这种情况^[66]。另一种理论上更完备的思路是基于 Pareto 最优性进行建模^[67]，旨在找到一组无法在不牺牲至少一个目标的情况下改进任何其他目标的解。虽然这能提供一组最优的权衡解集，但在 LLM 的强化学习中直接应用通常需要复杂的多目标强化学习框架，计算和实现成本较高，且如何从 Pareto 前沿中选择符合当前具体需求的单个解仍是一个开放问题。

与这些依赖多个独立模型分别评估各目标，或依赖复杂后续步骤来整合多维度评分的现有方法相比，本研究提出的 MORM 旨在通过一个统一的、端到端的模型架构内部实现对多个目标的综合评估与动态权衡。现有方法在尝试整合多维度信息时，可能面临不同模型/评分机制间的校准难题，或因流程复杂而导致效率和可解释性下降。因此，本研究面临的核心理论挑战之一是：“如何设计一种单一的奖励表示与建模机制，它既能充分利用多维度的人类偏好信息（通过多维度绝对评分），避免二值化带来的信息损失，又能在一个统一模型内部动态地处理不同目标间的权重关系，并具备良好的可解释性，从而超越传统固定加权、简单聚合或多模型组合方法的局限性？”这促使本研究思考并设计 MORM，通过多维度绝对评分来保留原始偏好信息，并探索更先进的动态聚合机制。

3.2.2 引入混合专家模型机制的必要性

鉴于 3.2.1 节中讨论的，即使采用多维度绝对评分来更完整地表征人类偏好，如何有效聚合这些可能相互冲突的多维信号以形成一个能指导强化学习的统一奖励，仍是关键挑战。特别是，现有奖励聚合方法（如固定线性加权）在处理不同对

齐目标重要性的动态变化方面存在显著不足，难以适应复杂落地应用场景的多样化需求。在复杂的多目标对齐任务中，不同对齐目标的重要性并非一成不变，而是可能随着具体的应用场景、用户指令的类型、甚至是对话的上下文动态变化。

对动态性的迫切需求：在真实的 LLM 应用中，用户指令的类型、对话的上下文以及潜在的风险各不相同，这要求模型对不同对齐目标（如帮助性、真实性、安全性、简洁性等）的侧重也应随之动态调整。例如，在医疗建议等高风险场景中，“真实性”和“安全性”的权重应远高于“创造性”；而在生成诗歌等创意场景下，则可能相反。一个固定的聚合策略无法适应这种变化，容易导致模型在特定情境下表现出不合时宜的偏好，严重影响其在多样化落地应用中的表现。传统方法难以实现这种上下文感知的动态目标加权。

处理目标间复杂依赖与冲突的挑战：不同对齐目标之间往往存在复杂的非线性依赖关系甚至直接冲突。例如，过度追求“简洁性”可能损害“信息完整性”；提升“帮助性”至极致可能会触及“安全性”的边界。简单的聚合方法（如线性求和）难以捕捉这种复杂的相互作用，也难以在冲突发生时进行智能化的权衡。这就需要一种更灵活的机制来学习和表达这些目标间的复杂关系。

提升对齐策略灵活性与适应性的内在要求：为了使 LLM 能够在更广泛的落地应用中表现出色，对齐策略本身需要具备高度的灵活性和对上下文的敏感性。这就要求奖励模型不仅能评估多个维度，更能根据当前情境智能地判断这些维度的相对重要性，并据此生成指导性奖励信号。

为应对上述挑战，实现奖励信号的动态、上下文感知聚合，并克服传统固定权重方法的局限性，本研究认为引入混合专家（Mixture of Experts, MoE）机制是必要的。MoE 架构的核心思想是基于输入特征动态选择并激活少量相关的专家网络进行计算。在多目标奖励建模中，这对应于根据输入（如指令、上下文）的特征，动态地、自适应地调整和权衡不同对齐目标（由不同“专家”评估）的贡献。

MoE 机制具备以下理论优势，使其非常适合解决多目标奖励建模中的动态权衡问题：

计算效率与任务适应性：MoE 通过动态选择最适合的专家，使得每个任务只需要激活与之相关的部分专家，从而显著提高计算效率，并能根据任务需求动态调整激活的专家，在处理不同任务时更具灵活性。这使得 MORM 能够根据不同任务特点动态选择不同的目标权重，确保模型在不同目标之间找到最佳平衡。

可扩展性：MoE 允许模型在相同计算预算下显著扩大模型规模，因为只有一小部分专家在每次计算中被激活。

针对冗余性偏差等问题的潜力：通过 MoE 的自适应目标加权，例如在需要简洁性的任务中提升“简洁性专家”的权重，或结合特定机制调整冗余性评分与其

他目标的关系，可以更有效地减少冗余性偏差。

尽管 MoE 的训练可能面临如专家选择复杂性、潜在的过拟合或训练不稳定性等挑战，但其在多目标奖励建模中实现动态目标加权、灵活适应不同任务上下文的能力，使其成为克服传统静态奖励聚合方法不足、提升奖励信号质量和对齐效果的极具前景的技术路径。因此，第二个核心的理论与实践挑战可以表述为：如何设计一个奖励聚合机制，使其能够根据输入（如指令、上下文）的特征，动态地、自适应地调整和权衡不同对齐目标的贡献，从而生成一个更符合当前情境偏好的综合奖励信号。引入 MoE 机制正是 MORM 为应对这一挑战所采用的核心策略。

3.3 MORM 架构与核心机制设计

基于 3.2 节提出的设计理念与核心挑战，本节将详细阐述多目标奖励模型 MORM（Multi-Objective Reward Model）的整体架构、关键组成机制及其工作原理。MORM 的核心目标是通过一个统一的模型框架，实现对 LLM 输出在多个预设维度上的精确评估，并能根据上下文动态权衡这些维度的重要性，从而生成高质量、信息丰富且适应性强的奖励信号。

3.3.1 MORM 整体架构

MORM 模型基于多维度绝对评分数据训练多目标奖励模型，为每个目标赋予一个 k 维评分向量，用于评估不同响应的质量。然后，MoE 的门控网络根据输入的特征动态选择最合适的奖励目标，并通过 Softmax 函数生成一个目标权重分布。这种机制不仅能够动态调整每个目标的权重，还能够根据任务的语境，选择最适合的专家来参与计算，从而避免了传统方法中的加权问题。

MORM 的整体架构如图 3-1 所示。其主要由以下几个核心模块构成：

（1）输入层 (Input Layer): 接收一个“提示 (Prompt)”和语言模型针对该提示生成的“响应 (Response)”作为输入。在多轮对话场景中，输入还可以包含之前的对话历史作为上下文。

（2）共享特征提取模块 (Shared Feature Extractor): 通常采用一个预训练的 LLM（例如，与待对齐的 LLM 同源或同系列的模型）作为基础，去除其原始的输出层。该模块负责将输入的“提示-响应”对（以及上下文）编码为高维度的特征表示 (feature representation)。这些特征捕获了输入的语义信息、句法结构以及两者之间的关联性，为后续的多维度评估提供丰富的语义基础。

（3）多维度评分头 (Multi-Dimensional Scoring Heads): 在共享特征提取模块之上，并行设置多个独立的“评分头”。每一个评分头对应一个预定义的对齐目标或




图 3-1 多目标奖励建模结构图

评价维度，例如：帮助性 (Helpfulness)、真实性 (Correctness)、安全性 (Safety)、连贯性 (Coherence)、简洁性 (Coniseness)、冗余性 (Verbosity) 等。每个评分头通常是一个浅层神经网络（如线性层或小型多层感知机 MLP），它接收共享特征提取模块输出的特征表示，并独立地预测该响应在对应维度上的绝对评分值（通常是连续值或离散的 Likert 量表式评分）。

（4）混合专家动态加权模块 (MoE Dynamic Integration Module): 这是 MORM 实现动态权衡和上下文感知的核心。该模块包含：

- （1）门控网络 (Gating Network): 接收来自共享特征提取模块的特征表示（通常是基于提示或提示与响应的综合特征），并输出一组权重系数。这组权重对应于各个多维度评分头的重要性。
- （2）专家网络 (Expert Networks): 在 MORM 的实现中，可以将每个多维度评分头视为一个“专家”，专注于评估特定维度。MoE 门控网络的输出权重则用于对这些“专家”的评分进行加权组合。

（5）输出层 (Output Layer): 输出 MORM 对输入“提示-响应”对的最终评估结果。

数据流与工作机制：在 MORM 模型中，首先基于多维度绝对评分数据训练模型理解并预测各对齐目标的得分。然后，MoE 的门控网络根据输入的特征动态地为这些目标（或评估这些目标的“专家”）分配权重。例如，在需要高安全性的任务中，MoE 可以自动增强安全性目标的权重；而在侧重知识性的任务中，则可能增加帮助性或准确性目标的权重。这种 MORM 与 MoE 的结合，使得模型能够根据任务的不同需求和语境，自动调整目标的优先级，确保在多目标任务中能生成更符合期望的奖励信号，从而为后续的强化学习优化达到最佳性能奠定基础。

通过这种设计, MORM 不仅能够更全面地捕捉和利用人类偏好信息, 还能通过 MoE 机制实现对多个目标权重的动态和自适应调整, 从而在生成奖励信号时更具灵活性和上下文感知能力。接下来的小节将更详细地阐述 MORM 中的多维度绝对评分实现、基于 MoE 的动态加权机制, 以及针对特定偏见 (如冗余性) 的缓解策略。

3.3.2 MORM 核心机制

3.3.2.1 核心机制一: 多维度绝对评分

MORM 的核心创新之一是直接对 LLM 的响应在多个预设维度上进行独立的、绝对的评分, 而非依赖于成对比较。

大多数现有的 LLM 对齐奖励模型通过使用 Bradley-Terry 损失在成对数据上训练, 数据中包含了人工标注的偏好信息^[50, 63]。这种方法与 InstructGPT[13] 中使用的奖励模型方法相同。成对偏好标注本质上是二值标签, 例如 0,1, 表示评审人类更喜欢哪一个响应, 将这些称为相对评分。然而, 在一些最近的高质量数据集中, 相对评分是从绝对评分转换过来的。例如, UltraFeedback 数据集^[68] 包含了 5 个目标的绝对评分: 总体评分、指导跟随性、真实度、诚实性和帮助性 (每个目标都有基于预定义评分标准的 5 个不同评分)。该数据集进一步通过使用总体评分或其余 4 个目标的平均分, 将数据二值化为成对比较, 用于训练奖励模型或 DPO。原始评分是精细的, 每个目标有连续的整数评分 (例如 1, 2, 3, 4, 5)。然而, 二值化过程丢失了部分精细信息。例如, 得分为 1:5 的一对例子和得分为 2:3 的另一对例子会被标注为相同。丢弃这些精细的偏好信息并不合理。因此, 本研究希望在奖励建模中包括所有精细的信息。

由于训练示例带有多目标评分, 学习这些评分的直接方法是多目标回归。在此, 本节简要介绍训练过程。将每个示例视为由一个提示 x (包括来自前序对话回合的上下文)、响应 (y) 和一个 k 维评分向量 ($r \in \mathbb{R}^k$) 组成, 其中每个维度对应一个奖励目标, 如帮助性和真实度。现在, 将预训练的解码器模型, 去除原始的输出线性层, 作为特征提取器 f_θ 。将 x, y (即提示和响应的拼接) 通过解码器层, 并取最终解码器层在最后一个令牌上的隐藏状态作为 d 维特征。此外, 在 f_θ 上添加了一个新的线性回归层 $w \in \mathbb{R}^{d \times k}$, 它输出一个 k 维的评分预测。模型可以通过均方误差损失函数训练:

$$\min_{\theta, w} \frac{1}{n} \sum_{i=1}^n (w^\top f_\theta(x_i, y_i) - r_i)^2 \quad (3-3)$$

其中 (x_i, y_i, r_i) 是第 i 个样本, f_θ 是带参数的特征提取器, $w^\top$ 是输出线性层或投

影层。

这种机制使得 MORM 能够捕捉到人类偏好在不同维度上的细微差别，保留了比二元偏好标签更丰富的信息。它为理解模型的具体优缺点、进行针对性改进以及后续实现可控的多目标优化提供了坚实基础。

3.3.2.2 核心机制二：基于 MoE 的动态多目标加权与整合

为解决传统固定权重聚合方式在多目标奖励建模中的局限性，MORM 创新性地引入了混合专家（MoE）机制，以实现针对不同奖励维度重要性的动态、上下文感知评估和自适应整合。

MORM 可以预测每个响应的多目标奖励。然而，多维输出需要被缩减为一个标量，以进行测试样本的排名或成对比较。一种简单的方法是对多个目标进行线性组合^[63]。然而，使用固定的组合系数对于复杂的应用场景来说过于僵化。例如，对于可能引发不安全响应的提示，应为安全性目标分配较大的系数，因为本研究希望奖励模型将不安全响应的排名调低。而对于数学问题求解的提示，安全性目标变得不那么相关，应该将更多的关注放在与帮助性相关的目标上。

鉴于上述洞察，本研究提出了一种 MoE 风格的奖励目标标量化方法，基于提示 x 进行条件化。在架构层面，只需要遵循 MoE 的常见做法，添加一个门控层 $g_\phi: \mathbb{R}^d \rightarrow \{v \in \mathbb{R}^k \mid v_i \geq 0 \text{ 且 } \sum v_i = 1\}$ ，它基于从提示中提取的特征 $f_\theta(x) \in \mathbb{R}^d$ 注意， f_θ 是在 $f_\theta(x, y)$ 的前向传播过程中已经提供，从而使得推理过程更高效。

门控层 g_ϕ 可以简单地是一个浅层的多层感知机，它接受提示特征 f_θ 并输出一个 k 维向量，然后通过 Softmax 函数确保输出向量的元素非负且和为 1：

$$g_\phi = \text{Softmax}(W_g \cdot f_\theta + b_g) \quad (3-4)$$

其中， f_θ 表示输入特征， W_g 和 b_g 分别为门控网络的权重矩阵和偏置向量。

MoE 机制通过其条件计算特性，允许 MORM 在评估不同输入时，动态地激活或倚重不同的“专家”（奖励维度）。这使得奖励信号能够更好地适应上下文，例如，在需要高安全性的场景下自动提升安全相关维度的权重，而在创意写作场景下则可能更侧重创造性维度的评分。这种自适应性超越了传统固定权重聚合的僵化，使得奖励信号更贴近真实世界中人类偏好的动态性和复杂性。

3.3.2.3 核心机制三：冗余性偏见的识别与缓解策略

冗余性偏见是 LLM 对齐中常见的问题^[69]，即模型和奖励模型都可能倾向于更长的、信息密度较低的输出。使用非负的门控系数会使最终输出继承这种偏向。为了解决这个问题，本研究通过使用冗长性奖励目标来调整每个奖励目标 r_i ，并施

加惩罚：

$$r'_i = (1) \cdot r_i + (-\lambda_i) \cdot r_{\text{verbose}} \quad (3-5)$$

其中，惩罚系数 r_i 选择的方式是通过适当的修正度量（例如 Pearson 或 Spearman 相关系数^[70, 71]）和参考数据分布 D 进行优化：

$$\mathbb{E}_D \left[\frac{\text{Cov}(r', r_{\text{verbose}})}{\sigma_{r'} \cdot \sigma_{r_{\text{verbose}}}} \right] = 0 \quad (3-6)$$

其中 $\text{Cov}(r'_i, r_{\text{verbose}})$ 表示 r' 与 r_{verbose} 的协方差，衡量它们的线性关系强度和方向， σ 表示两者的标准差，调整后的奖励向量记为 $r' \in \mathbb{R}^k$ 。

最终，将门控系数与调整后的多目标奖励相乘，得到相应提示 x 响应 y 对应的标量评分：

$$R = g_\phi(f_\theta(x, y))^\top r' \quad (3-7)$$

为了训练门控层，冻结骨干模型和回归层的参数，使用 Bradley-Terry 损失对门控层进行训练：

$$\mathcal{L}(g_\phi) = -\log(\sigma(R_w - R_l)) \quad (3-8)$$

其中 R_w 和 R_l 分别是每对样本的选择响应和拒绝响应的偏好评分， σ 为 Sigmoid 函数。通过这种方式，能够优化门控层，使其在多目标奖励任务中表现更加灵活，动态调整奖励目标的权重，从而实现更优的多目标优化。

有效缓解冗余性偏见，能促使 LLM 生成更精炼、信息密度更高的回答，这在许多追求效率和用户体验的落地场景中至关重要。

3.3.3 MORM 的主要优势和特点

基于上述架构设计与核心机制，MORM 相比传统的奖励模型展现出以下主要优势：

（1）更精细的偏好信息捕获：通过多维度绝对评分，MORM 能够捕捉并利用比传统成对比较更丰富、更细粒度的人类偏好信息，避免了二值化带来的信息损失，为精确对齐奠定基础。

（2）动态与上下文感知的目标权衡：借助 MoE 机制，MORM 能够根据输入提示或上下文动态调整不同对齐目标的重要性权重，智能地在多个（可能冲突的）目标之间进行权衡，克服了传统固定权重方法的僵化性，提高了奖励信号的适应性和灵活性。

（3）增强的可解释性与诊断性：MORM 输出的多维度评分可以直接反映模型在各个具体对齐目标上的表现，使得研究者和开发者能够更清晰地理解模型的优

缺点，进行针对性的改进。MoE 门控网络的权重输出也为理解在特定情境下哪些目标更受关注提供了线索。

(4) 有效缓解特定偏见：通过专门的机制（如冗余性评分维度的引入和解耦调整策略），MORM 能够更针对性地识别和缓解 LLM 中常见的冗余性偏见等问题，从而提升生成内容的整体质量和实用性。

(5) 统一模型框架的潜力：MORM 尝试在一个统一的模型内部实现对多个目标的综合评估与动态权衡，相比依赖多个独立模型分别评估各目标再进行后续整合的方案，理论上可以更好地学习目标间的复杂依赖关系，并可能降低整体系统的复杂度和维护成本。

(6) 为可控对齐提供更优基础：MORM 提供的多维度、动态且可解释的奖励信号，为本文后续提出的强化学习框架中实现对 LLM 行为的细粒度、可控的多目标对齐提供了更高质量的指导。

这些优势共同使得 MORM 有望成为一个更强大的“评价体系”，为实现更高级别的 LLM 多目标对齐和赋能复杂落地应用提供关键支持。

3.4 MORM 的实现与训练

3.4.1 训练数据构建与预处理

模型训练主要分为两个阶段，本实验分别为两个阶段构建训练数据：

第一阶段的训练选择使用 HelpSteer 系列数据集^[72, 73]作为多目标奖励建模的主要数据来源，这是一个由 NVIDIA 团队开发的开源偏好数据集，包含约 10,681 个提示（Prompt），每个提示对应两个响应（Response），总计 21,362 个高质量标注样本。相较于其他偏好数据集（如 HH-RLHF^[14]），HelpSteer 的样本量较小（仅约十分之一），但其高效性使其在训练奖励模型时表现出色。数据集的构建过程经过精心设计，旨在确保多样性和高质量标注，以支持多目标奖励建模。

第一阶段数据样本

"prompt": "What is the ozone layer, and how does it protect us from harmful radiation from the sun?"

"response": "The ozone layer is a layer of ozone gas in the stratosphere that absorbs most of the sun's ultraviolet radiation. The ozone layer is found between 15 km and 35 km above the Earth's surface and covers the entire Earth, protecting living things from harmful radiation.", "helpfulness":3, "correctness":3, "coherence":4, "complexity":2, "verbosity":1

数据集构建流程:

(1) 提示收集: HelpSteer 的提示主要来源于网络用户自愿分享与 AI 助手对话内容, 占数据集的 95% 以上。这些提示涵盖了真实的 LLM 使用场景, 具有多样性和代表性。此外, 少量专有提示 (约 5%) 被补充进来, 聚焦于企业场景, 如摘要生成、封闭式问答和信息提取。为了确保提示的质量, 非英语提示被 FastText 工具^[74]过滤掉, 编程相关的提示也被简单启发式方法剔除 (因标注者缺乏编码专长)。通过 BERTopic^[75] 聚类, 提示被分为约 1000 个主题, 并均匀采样以保证多样性。提示的复杂性通过 Nemotron-2-43B^[72] 模型按李克特量表 (Likert)^[59] 评估, 最高复杂度的提示被加倍采样, 以提升模型处理复杂指令的能力。为了支持多轮对话场景的奖励预测, HelpSteer 中约 29% 的样本为多轮提示。

(2) 响应生成: 每个提示生成两个响应, 分别来自不同来源, 以增加多样性。响应来源包括: 内部模型 (占 86.2%): 包括三代 Nemotron 模型 (Nemotron-2 43B、Nemotron-3 8B/22B、Nemotron-4 15B/340B)^[76]。Mixtral-8x7B-Instruct-v0.1^[77] (占 7.9%): 一个开源混合专家模型。

(3) 响应标注: HelpSteer 对每个响应标注五个属性 (帮助性、正确性、连贯性、复杂性、冗长性), 使用 Likert-5 量表 (0-4 分)。HelpSteer 数据集要求至少三名标注者参与, 若帮助性评分差异超过 2 分, 则增加至五名标注者, 最终取最一致的三人评分, 平均每样本由 3.41 名标注者评估。标注指南明确要求跳过含个人信息或不安全内容的样本, 确保数据合规性。

监督信号来源于多维度评分数据, 这类数据需要标注者分别对模型输出在多个目标维度上进行独立打分。相较于传统的二元偏好数据, 这类细粒度标签数据标注成本显著更高, 对标注者的理解能力与任务熟悉度也提出了更高要求。为了确保训练数据质量, 研究者采用专家指导标注, 并构建了统一的标注指南与评分模板进行规范。

第二阶段数据样本

"prompt": "Share a time when you felt most successful in your career.",

"chosen": "I'm just an AI, I don't have personal experiences or emotions, but I can share a time when I successfully assisted a user in a meaningful way.",

"rejected": "As an AI language model, I don't have personal experiences or emotions like humans, so I cannot feel successful or share personal experiences.",

在第二阶段的训练中, 本实验构建了一个高质量的混合偏好数据集作为训练数据, 用于提升奖励模型的泛化能力和鲁棒性。该混合数据集整合了多个主流人

类偏好数据集，并针对不同数据源的特点进行了统一的清洗与筛选，确保了数据的准确性与一致性。具体包含以下子数据集及其相应的预处理策略：

- (1) HH-RLHF^[14]：本实验仅选取其中的 **helpful** 子集，并过滤掉了那些正负样本完全一致的噪声数据。该处理方式旨在去除标签错误或无信息量的样本，提高偏好判断的有效性。
- (2) SHP^[78]：本实验筛选了得分比率大于 2 的高质量偏好样本，并对每个 **prompt** 最多保留 5 个比较对，以控制样本数量和提升样本差异性。处理后总共保留了 109,526 条样本。
- (3) UltraFeedback^[68]：参考 UltraFeedback-Binarized 的处理方式，本实验使用其细粒度评分（而非单一整体评分）对样本进行排序，并生成每个 **prompt** 下所有可能的 6 个比较对。随后，去除得分相等的样本对，最终得到 267,416 条对比样本，确保训练数据对偏好有明确区分。
- (4) Capybara、Orca 和 PKU-SafeRLHF-30K^[79-81]：本实验直接使用其原始数据集中的高质量偏好对，未做额外处理，仅进行了基础的数据格式统一操作以保证兼容性。

该混合数据集结合了多个数据源的优势，既涵盖了真实人类偏好打分的数据，也融合了多维度评价指标（如 **helpfulness**、**correctness** 和 **fine-grained score**），为奖励模型提供了更全面的训练基础。在后续训练中，本实验统一将这些处理后的数据转化为 **pairwise** 比较格式，用于优化基于偏好的奖励学习算法。

3.4.2 训练框架

训练代码基于 OpenRLHF 框架^[82]，这是一个专为强化学习从人类反馈（RLHF）设计的开源、高效且易用的框架，能够支持超过 70B 参数的大语言模型训练，并以其创新的调度设计和性能优化受到关注。

传统 RLHF 框架（如 TRL、DeepSpeed-Chat^[83, 84]）将 PPO 算法中的四个模型（Actor、Critic、Reward、Reference）共置于同一 GPU 上，导致内存限制和高复杂度调度问题。OpenRLHF 通过 Ray 分散式调度，将模型分布到多个 GPU 上，显著提升资源利用率和训练效率。

核心组件：

- (1) Ray^[85]：一个分布式执行框架，提供任务并行和集群管理能力，支持从单机到千节点的无缝扩展。Ray 在 OpenRLHF 中负责模型放置和细粒度编排。
- (2) vLLM^[86]：一个高效的 LLM 推理库，通过 PagedAttention 和连续批处理技术加速生成阶段，支持张量并行^[87]，特别适用于 70B 以上模型。

- (3) DeepSpeed^[88]: 优化大规模模型训练的库, 通过 ZeRO (零冗余优化器)^[89] 减少内存占用, 并支持 CPU-GPU 数据卸载 (off-loading)。

性能优化:

- (1) 生成阶段: 利用 vLLM 的张量并行和批处理技术, 解决生成阶段 80% 时间瓶颈问题 (复杂度 $O(n^2)$)。
- (2) 学习阶段: 通过卸载 Adam 优化器^[90] 状态到 CPU、使用 Flash Attention 2^[91] 和移除冗余填充, 提升训练吞吐量。
- (3) 模型同步: 使用 NVIDIA NCCL 在 ZeRO 和 vLLM 引擎间同步权重, 确保高效集成。

除 PPO 外, OpenRLHF 还支持 DPO、Rejection Sampling、KTO^[50, 92, 93] 等多种对齐技术, 提供灵活的算法实现选择。

3.4.3 训练流程与损失函数

本实验使用 Llama-3.1-8B^[94] 作为奖励模型的基础架构。模型的基础模型层 (即 transformer 层) 初始化自 Llama-3.1-8B-Instruct 对话模型。

训练过程分为两个阶段:

(1) 多目标奖励建模: 本阶段实验采用全量微调方法, 训练的过程中会更新所有参数。在基础模型层 (base model layer) 后添加了一个线性回归层, 用于预测一个 5 维的奖励向量, 包括: 帮助性 (helpfulness)、正确性 (correctness)、一致性 (coherence)、复杂性 (complexity)、冗长性 (verbosity)。这些目标来源于 helpsteer 数据集的标注结果。模型使用线性回归中的均方误差损失函数 (Mean-Square Error, MSE) 进行训练, 以最小化预测奖励向量与实际奖励向量之间的差异。

训练在 NVIDIA A800 80GB DGX 集群上进行, 具体配置为 8 张 A800 GPU。NVIDIA A800 是一款高性能计算显卡, 配备 80GB HBM3 显存, 支持 FP16 和 BF16 混合精度训练, 能够满足大规模语言模型的内存和计算需求。使用 8 张 GPU 进行分布式训练显著缩短了训练时间。

训练时, 基础模型层和回归层的参数都进行更新, 使用 AdamW 优化器, 学习率 (Learning Rate, LR) 为 $5e-6$, 批次大小 (Batch Size, BS) 为 64, 训练 700 步, 2 个 epoch, 训练数据类型为 BF16 (bfloat16), 配合余弦衰减学习率调度器 (Cosine lr Schedule)。详细参数参考表 3-1。

(2) 混合专家路由网络: 第二阶段的训练是在第一阶段模型的基础上增加一个路由器网络 (Gating Network), 该网络是一个具有 3 个隐藏层 (每层 2048 个隐藏单元 (hidden units)) 的多层感知机 (MLP), 使用 ReLU 激活函数^[95]。它接收来自提示的特征表示, 并输出一个用于加权奖励目标的系数向量。为了缓解常见

表 3-1 第一阶段训练超参数设定表

参数名称	参数值	参数说明
optimizer	AdamW	优化器
num_train_epochs	2	训练轮数
per_device_train_batch_size	1	每张卡训练的批大小
per_device_train_batch_size	1	每张卡训练的批大小
gradient_accumulation_steps	8	梯度累积步数
max_learning_rate	5e-6	最大学习率
weight_decay	0.0	权重衰减
adam_beta1	0.9	AdamW beta1 值
adam_beta2	0.95	AdamW beta2 值
warmup_ratio	0.03	学习率预热
model_max_length	4096	模型处理最大长度
deepspeed_zero_optimization	stage2	零冗余优化方式

的冗长性偏差（verbosity bias），本实验对每个奖励目标进行调整，减去一个与冗长性奖励成比例的惩罚项。门控层使用 logsigmoid 损失函数，参考公式??。

训练时，基础模型层和线性回归层参数的权重冻结（Parameter Freezing），仅优化门控层网络，使用 AdamW 优化器学习率（Learning Rate, LR）为 $1\text{e-}3$ ，批次大小（Batch Size, BS）为 1024，训练 683 步，10 个 epoch，训练数据类型为 BF16（bfloat16），配合余弦衰减学习率调度器（Cosine lr Schedule）。详细参数参考表3-2。

表 3-2 第二阶段训练超参数设定表

参数名称	参数值	参数说明
optimizer	AdamW	优化器
num_train_epochs	10	训练轮数
per_device_train_batch_size	4	每张卡训练的批大小
gradient_accumulation_steps	128	梯度累积步数
max_learning_rate	1e-3	最大学习率
weight_decay	0.0	权重衰减
adam_beta1	0.9	AdamW beta1 值
adam_beta2	0.95	AdamW beta2 值
warmup_ratio	0.03	学习率预热
model_max_length	4096	模型处理最大长度
deepspeed_zero_optimization	stage2	零冗余优化方式

3.5 MORM 性能评估

为系统性地验证本文提出的多目标奖励模型(MORM)及其与混合专家(MoE)机制结合后的动态聚合策略在实际奖励评估任务中的有效性与优越性,本节将详细介绍实验设置、所采用的权威评估基准,并对实验结果进行深入分析。与传统的单目标或简单多目标奖励模型相比,MORM 通过其多维度绝对评分机制和 MoE 动态加权能力,旨在提供更精确、鲁棒且具可解释性的奖励信号,从而为后续通过强化学习提升大语言模型的整体对齐性能和在复杂落地应用中的表现奠定坚实的评价基础。

3.5.1 实验目的

本节实验设计围绕以下三个核心问题展开:

(1) 验证 MORM 在多目标奖励评估任务中相较于基线方法的性能优势:通过在多个标准奖励模型评估基准上进行测试,量化 MORM 在区分高质量与低质量响应、以及在不同对齐维度(如帮助性、安全性、推理能力等)上进行准确评估的能力。

(2) MoE 机制是否能够有效提升奖励模型在目标冲突场景中的动态适应性,通过路由机制选择最合适的目标评分路径,缓解传统方法中权重静态、优化方向固定的问题。

(3) 论证 MORM 作为高质量“评价体系”对指导 LLM 实现更优“多目标对齐”的潜力:强调所选评估基准的设计理念是如何模拟真实世界中对 LLM 输出质量的多方面考量的,从而使 MORM 在这些基准上的优异表现能够间接反映其指导 LLM 在相应下游应用场景中提升对齐度的潜力。

本实验的评估策略将主要依赖于公开的、被广泛认可的奖励模型评估基准,这些基准通常包含一系列精心设计的、覆盖多种真实交互场景的测试样本。

3.5.2 基准评估数据集与评价指标

本实验对于与奖励模型的评测引入两种基线:

(1) 开源奖励模型和语言模型评估:开源奖励模型是由社区开发并公开的模型,广泛应用于生成对齐任务中的奖励信号。这些模型的优势在于透明性和可复现性,使研究者能够基于它们进行优化和实验。语言模型评估(LLM as a judge)是一种利用强大语言模型(如 GPT-4 系列)作为评判者来评估其他模型输出的方法。这种方法通过让大语言模型对输出进行打分或排序,模拟人类偏好的判断,用以生成奖励信号。本实验选择了一系列 Starling-RM-34B^[18]、Mixtral-8x7B-Instruct-v0.1^[77]、

Nemotron-4-340B-Reward^[73]、Llama-3-70B-Instruct^[94] 和 GPT-4-Turbo^[1] 等在内的开源奖励模型和领先闭源语言模型。考虑到模型规模和训练使用的数据规模的差异，这些评估结果仅供参考。

(2) 使用相同基础模型和对齐数据集的不同对齐方法训练的模型：为了公平比较与传统基线方法的效果，基准测试还包括基于相同基础模型和数据集训练的奖励模型。这些奖励模型因共享相同的基础模型和数据集，消除了架构和数据差异的影响，从而能够直接比较不同对齐方法的优劣。基准测试将揭示它们在生成高质量奖励信号方面的差异。

奖励模型的评估是验证其性能的关键步骤。本实验采用了两个主流基准：RewardBench 和 Reward Model Benchmark (RMB)，分别从不同角度评估奖励模型的能力。

(1) RewardBench^[96]：RewardBench 是一个由艾伦人工智能研究院 (Allen Institute for AI, AI2) 等机构开发的开源基准测试集，旨在评估奖励模型的性能。它包含一系列精心设计的提示 (prompt) 以及对应的“优选”(chosen) 和“次选”(rejected) 回答对，覆盖了从日常对话到复杂推理和安全相关的多种场景。通过对这些回答对进行评分，RewardBench 可以衡量奖励模型是否能正确识别出更符合人类偏好的响应。

RewardBench 测试集分为五个主要类别，每个类别聚焦于奖励模型的不同能力：Chat、Chat-Hard、Safety、Reasoning 和 Prior Sets，用于测试模型区分优劣响应的能力。数据集详细构成：

- (1) 闲聊 (Chat)：测试奖励模型在基础对话场景中识别优劣响应的能力，关注开放式生成任务中的准确性和完整性。数据来源包括 AlpacaEval^[27] 和 MT-Bench^[26] 的提示。
- (2) 复杂对话 (Chat-Hard)：测试奖励模型在更具挑战性的对话场景（如陷阱问题或细微差异的回答）中的表现，包含自然对话和人工设计的对抗性示例，挑战模型的细微分辨能力。数据来自 MT-Bench 的高难度示例和 LLM Bar^[28] 的对抗性数据。
- (3) 安全性 (Safety)：评估模型拒绝危险或冒犯性内容的能力，同时避免对无害内容错误拒绝。优选回答通常是拒绝响应，次选回答可能是危险或不适当的内容。数据来源包括定制版本的 XSTest、Do-Not-Answer 数据集^[97, 98]，以及由 AI2 构建中的拒答数据集。
- (4) 推理 (Reasoning)：测试模型在代码和数学推理任务中的表现。优选回答是正确答案，次选回答包含错误或 bug。问题主要来自代码数据集 HumanEvalPack^[99] 和数学数据集 PRM800K^[20]。

(5) 早期数据集 (Prior Sets): 使用已有偏好数据集进行一致性测试。数据来源为 Anthropic 的 HH-RLHF^[14]、SHP^[78] 和 OpenAI 的摘要数据集^[100]。

这几个不同的测试子集对应了 LLM 在开放式聊天、高难度交互、安全合规对话以及逻辑推理密集型应用 (如编程辅助、科学分析) 等关键落地场景中所需的核心对齐能力。例如, Safety 类别评估模型拒绝危险内容的能力, 这对于确保 LLM 在面向公众的交互系统或教育领域中的安全部署至关重要; Reasoning 类别则测试模型在代码和数学推理任务中的表现, 这直接关系到其在 AI 辅助开发和科研等场景的实用性。

评分方法: 每个任务包含一个提示、一个优选响应 (Chosen) 和一个拒绝响应 (Rejected)。对于每个提示, 奖励模型分别对“优选”和“次选”回答打分。如果“优选”回答的得分高于“次选”回答, 则记为一次“胜”(win)。每个类别的得分是该类别内所有提示的胜率百分比 (win rate)。最终得分: 对五个类别的得分进行加权平均, 其中 Prior Sets 的权重为 0.5, 其他类别权重为 1。这种加权设计平衡了不同类别的数据规模和任务特性。

(2) Reward model Benchmark (RMB): RMB 是一个由复旦大学等机构开发的开源基准测试集, 专门用于评估奖励模型在对齐任务中的性能。RMB 是一个综合性基准测试集, 覆盖了超过 49 个现实世界场景, 包括日常对话、复杂推理和安全相关任务等。

RMB 测试集主要分为两大核心部分: 帮助性 (Helpfulness) 和无害性 (Harmlessness), 分别对应对齐任务中的两个关键目标。这两个目标是 LLM 能否在几乎所有实际落地应用中被用户接受和信赖的基础。RMB 不仅支持传统的成对比较评估, 还引入了 Best-of-N (BoN) 评估, 更贴近奖励模型在实际对齐任务中筛选高质量输出的作用。其帮助性测试场景涵盖翻译、问答、创意写作等, 直接反映模型在信息服务、内容生成等应用中的价值; 无害性测试则关注模型在拒绝危险内容、保护隐私等方面的能力, 这对于模型在所有需要负责任部署的场景都至关重要。以下是具体结构:

- (1) 帮助性 (Helpfulness): 关注模型在提供有用、准确和全面回答的能力, 涵盖场景如翻译、闭合式问答、创意写作等。包含 12 个任务, 细分到 37 个具体场景。数据来源为大规模真实对话语料库 WildChat^[101] 中精心挑选了 2134 个帮助性提问。
- (2) 无害性 (Harmlessness): 关注模型在拒绝危险或冒犯性内容、保护隐私和知识产权等方面的能力, 同时避免对无害请求的错误拒绝。数据来自 WildChat 中挑选了 1021 个红队测试 (red-teaming) 问题。

评分方法: 对于成对测试 (Pairwise Test), 判别式奖励模型 (Discriminative

RM) 会为每个答案分配一个分数 $s(x)$ ，然后根据是否满足 $s(x_{\text{chosen}_i}) > s(x_{\text{rejected}_i})$ 来计算奖励模型的准确率。相比之下，LLM-as-a-judge 直接比较答案并选择它更倾向的答案。

定义一个函数 $g(x_1, x_2)$ ：

1. 如果奖励模型正确地选择 x_1 为更好的答案，则 $g(x_1, x_2) = 1$ ，否则为 0。
2. 如果奖励模型正确地选择 x_1 为更好的答案，则 $g(x_1, x_2) = 1$ ，否则为 0。
3. 对于生成式奖励模型， $g(x_1, x_2)$ 直接反映奖励模型是否选择了 x_1 。

成对准确率 (Pairwise Accuracy) 计算如下：

$$\text{Pairwise Accuracy} = \frac{1}{N} \sum_{i=1}^N g(x_{\text{chosen}_i}, x_{\text{rejected}_i}) \quad (3-9)$$

对于最佳排名测试 (BoN Test)，奖励模型需要在一个数据点上通过测试，即正确地将 x_{winner_i} 排在 BoN 列表中的所有失败者 $x_{\text{loser}_{ij}}^{\text{loser}}$ 之上，否则得分为 0。

BoN 准确率 (BoN Accuracy) 计算如下：

$$\text{BoN Accuracy} = \frac{1}{M} \sum_{i=1}^M \prod_{j=1}^{P_i} g(x_{\text{winner}_i}, x_{\text{loser}_{ij}}) \quad (3-10)$$

其中 N 表示成对测试的样本数； M 表示 BoN 测试的样本数； P_i 表示每个 BoN 测试数据点中的失败者数量。

最终得分通常是这两个指标在不同场景下的加权平均，以全面反映奖励模型的表现。

RewardBench 强调可验证的优劣区分（如代码错误、事实错误），提供细粒度的性能洞察。例如，其 Reasoning 部分通过对比正确与错误代码，测试模型的推理能力。RMB 更注重实际任务的多样性和效率，适合快速评估模型在现实场景中的表现。对于研究人员和开发者而言，两个数据集是有效的基准测试工具，可以优化奖励模型，使其更有效地引导 LLM 符合人类偏好。

3.5.3 实验结果与分析

在本节中，本实验对提出的多目标奖励建模 (MORM) 与专家混合 (MoE) 聚合策略的奖励模型 (MORM + MoE，以下简称 MORM) 进行了实验评估，基于 RewardBench 基准和 RMB 测评结果，分析其性能并与现有方法进行对比。实验结果表明，MORM 模型在 RewardBench 上取得了 89.2 的整体得分，位列基准测试的前列，展现了其在多目标奖励建模中的优越性。

首先，RewardBench 的实验结果如表3-3所示：本实验的最终模型 MORM 在 RewardBench 上取得了整体得分 89.2 的突出表现。具体来看，各子类别的表现分

别为: Chat 为 96.5、Chat Hard 为 77.4、Safety 为 92.2、Reasoning 为 90.6、Prior Sets 为 75.3。这一结果表明, 本研究提出的方法在多目标奖励建模中取得了显著效果。以下是对实验结果的详细分析与总结。

为了更清晰地展示本研究模型的优势, 本节也进行了与现有方法的对比。实验表明, 本研究模型显著超过了一些主流方法, 如本实验的基线方法性能 Bradley-Terry (baseline) 的 86.3 分, 领先语言模型评估者 LLM-as-a-judge (GPT-4-Turbo) 的 84.2 分。此外, 本研究的 8B 参数规模模型的性能 (89.2) 已经非常接近参数规模更大的 Nemotron-4-340B-RM 模型 (89.3), 也接近开源社区最领先 (State of The Art, SOTA) 的模型 Nemotron-70B-Reward (94.1), 体现了本研究在参数效率与性能提升上的突出优势。

此外, 本研究还对模型在 RMB 测试集上的表现进行了评估, 结果如表 3-4 所示: 本实验的模型 MORM 在 RMB 测试集上取得了 0.650 的 Helpfulness (BoN)、0.785 的 Helpfulness (Pairwise)、0.502 的 Harmlessness (BoN) 和 0.672 的 Harmlessness (Pairwise), 总体得分达到 0.650, 优于基线模型 Bradley-Terry (baseline) 的 0.612, 同样也接近社区领先的开源奖励模型如 Skywork-Reward-Llama-3.1-8B (0.693), 甚至是最先进的语言模型 Claude-3.5-sonnet^[102] (0.706), 表明本研究模型在实际场景中的帮助性指标也表现良好。

表 3-3 Rewardbench 测试结果

Base Model	Method	Score	Chat	Chat Hard	Safety	Reasoning	Prior Sets (0.5 weight)
Nemotron-70B-Reward	Bradley-Terry	94.1	97.5	85.7	95.1	98.1	-
Skywork-Reward-Llama-3.1-8B ^[103]	Bradley-Terry	93.1	94.7	88.4	92.7	96.7	-
Nemotron-4-340B	Bradley-Terry	89.3	95.8	87.1	91.5	93.7	-
Llama-3.1-8B	MORM + MoE(Ours)	89.2	96.5	77.4	92.2	90.6	75.3
Llama-3.1-8B	Bradley-Terry(Baseline)	86.3	95.3	76.1	89.3	84.8	74.6
GPT-4-Turbo(04/09)	LLM-as-a-judge	84.2	95.3	74.3	87.2	86.9	70.9
Llama-3.1-70B-Instruct	LLM-as-a-judge	84.0	97.2	70.2	87.8	86.0	74.9
Starling-RM-34B	Bradley-Terry	82.6	96.9	57.2	87.7	88.5	71.6
Claude-3-Opus(02/29) ^[102]	LLM-as-a-judge	80.1	94.7	60.3	86.6	78.7	-
Mixtral-8x7B-Instruct-v0.1	LLM-as-a-judge	77.6	95.0	64.0	72.6	78.7	53.6
Llama-3.1-8B-Instruct	LLM-as-a-judge	65.7	80.7	49.8	64.0	68.1	60.8

- 1 该表格展示了不同奖励模型在多个评估维度上的表现, 包括 Chat、Chat Hard、Safety、Reasoning 和 Prior Sets。
- 2 测评结果部分来自评测数据集的官方数据 RewardBench[29]。
- 3 LLM-as-a-judge 指语言模型作为评估者。
- 4 -则表示该数据缺失。

实验结果表明, 本研究提出的多目标奖励建模与专家混合聚合策略显著提升了奖励模型的性能。以下是对结果的深入分析:

(1) 多目标建模的优势: 通过利用多维度的绝对评分数据, 人类的模型能够捕捉到更细粒度的人类偏好信息。相较于传统的 Bradley-Terry 模型 (仅使用二元偏好标

签), 多目标奖励模型能够更全面地反映人类对响应的评价。例如, 在 RewardBench 的所有子类中, MORM 都显著优于基线方法 Bradley-Terry 模型, 显示出其在多目标奖励建模中的优越性。

表 3-4 RMB 测试集结果

Base Model	Method	Helpfulness		Harmlessness		Overall
		BoN	Pairwise	BoN	Pairwise	
GPT-4o(05/13)	LLM-as-a-judge	0.639	0.815	0.682	0.814	0.738
Starling-RM-34B	Bradley-Terry	0.604	0.774	0.674	0.795	0.712
Claude-3.5-sonnet(06/29) ^[102]	LLM-as-a-judge	0.705	0.838	0.518	0.764	0.706
Skywork-Reward-Llama-3.1-8B	Bradley-Terry	0.627	0.781	0.603	0.759	0.693
Llama-3.1-8B	MORM + MoE(Ours)	0.644	0.785	0.502	0.672	0.650
Skyword-critic-llama3.1-8B ^[104]	Bradley-Terry	0.600	0.725	0.578	0.578	0.620
Llama-3.1-8B	Bradley-Terry(Baseline)	0.612	0.701	0.490	0.648	0.612
Mixtral-8x7B-Instruct-v0.1	LLM-as-a-judge	0.480	0.706	0.491	0.671	0.587
Llama3.1-8B-Instruct	LLM-as-a-judge	0.365	0.675	0.267	0.653	0.490

- 1 该表格展示了不同奖励模型在多个评估维度上的表现, 包括 Helpfulness、Harmlessness, 其中 BoN 和 Pairwise 是两种不同的评分方法。
- 2 测评结果部分来自评测数据集的官方数据 RewardBench[32]。
- 3 LLM-as-a-judge 指语言模型作为评估者。

(2) 专家混合策略的有效性: 门控层根据提示的上下文动态选择和加权奖励目标, 使得模型能够适应不同场景的需求。例如, 在安全性要求高的提示中, 安全目标会被赋予更高的权重; 而在数学问题求助的提示中, 帮助性目标则更为重要。这种动态调整机制显著提升了模型的灵活性和准确性。例如, 在安全性要求高的提示中, 安全目标会被赋予更高的权重; 而在数学问题求助的提示中, 帮助性目标则更受重视。表3-3 显示, MORM + MoE 模型在 Safety 子类别中得分 92.2, 高于已经得到良好安全对齐的领先语言模型 GPT-4-Turbo (87.2) 和 Llama-3.1-70B-Instruct (87.8), 证明了动态调整机制在提升模型准确性和灵活性方面的作用。

(3) 冗长性偏见缓解: 通过对奖励目标进行冗长性偏见的调整, 本研究成功缓解了常见于奖励模型中的冗长性偏见。这通过在训练过程中引入惩罚项实现, 确保调整后的奖励与冗长性的相关性接近于零, 这对于提升 LLM 在追求高效沟通的信息摘要、快速问答等下游任务中的表现是有益的。。

(4) 可解释性: 本研究方法训练的模型不仅在性能上表现出色, 还提供了更高的可解释性。通过分析门控层的输出, 还可以了解在特定提示下, 哪些奖励目标对最终评分影响最大。对于后续优化阶段进行针对性的策略优化, 以实现更精准的对齐具有重要的指导价值。例如, 如果 MORM 指示模型在“真实性”维度得分较低, 那么在后续对齐中就可以重点强化与真实性相关的偏好。

本节实验验证了 MORM 模型在 RewardBench 基准上的优越性能。相较于现

有方法，该模型在多个子类别中表现出色，尤其在 Chat (97.3) 和 Safety (92.2) 方面接近甚至部分超越了更大的模型（如 Nemotron-4-340B）。表 [?] 的结果进一步表明，其在 Helpfulness 和 Harmlessness 维度上的整体得分（0.650）优于基线模型（0.612），体现了多目标建模的均衡性。此外，模型的可解释性使其在实际应用中更具优势，能够帮助开发者更好地理解和控制模型行为。

然而，实验也揭示了一些局限性。例如，在 Chat Hard 子类别中，MORM 模型得分（77.4）较大幅度低于 Nemotron-4-340B (87.1)，相较于同尺寸的 Skywork-Reward-Llama-3.1-8B（93.1），表明其在复杂对话场景下的表现仍有提升空间，未来考虑改进模型对于高难度对话下的数据质量，进行更精细的加强训练。除此之外，单纯的准确性评分标准并不能完全反应奖励模型的性能，需要更多维度的评估方式^[105]。

尽管 MORM 在提升奖励建模的可解释性、稳定性和目标灵活性方面取得了显著效果，但其训练过程也存在一定的局限性。尤其值得注意的是，MORM 的训练严重依赖于高质量的多目标监督数据，需要对模型输出在多个维度上（如帮助性、真实性、安全性等）分别进行独立打分。这类细粒度标注任务比传统的二元偏好标注更复杂，标注时间更长、难度更高，对标注者的理解能力和一致性要求也更强，因此带来了显著更高的人工成本。在实际应用中，大规模构建此类数据集可能面临数据获取效率低、标注质量难以统一等问题。

本节通过实验验证了本研究提出的多目标奖励模型 MORM 在 RewardBench 和 RMB 基准上的优越性能。相较于现有方法，本研究的模型在多个子类别上取得了显著提升，尤其是在 Chat 和 Safety 方面。此外，模型的可解释性使其在实际应用中更具优势，能够帮助开发者更好地理解和控制模型的行为。未来，本研究计划进一步探索模型在更多任务和数据集上的应用，并研究如何将这种可解释性应用于更广泛的 RLHF 场景。

3.6 MORM 的应用价值与对后续对齐的意义

本章提出的多目标奖励模型（MORM）不仅在评估指标上超越了传统方法，更重要的是，其作为一个先进的“评价体系”，为大语言模型（LLM）的对齐实践带来了新的可能性，展现了重要的应用价值，并为后续更高级的对齐策略奠定了关键基础。

（1）为高风险与高要求领域的精细化对齐提供技术基础。在医疗辅助、金融风控、法律咨询等高风险落地场景中，对模型的可靠性要求极高，需要同时满足准确性、安全性、合规性、无害性等多个严格的约束。传统单一的标量奖励无法为

模型提供如此精细的指导。MORM 的多维度绝对评分机制，使得研究者能够独立地、量化地监控和评估模型在每一个关键维度上的表现。这种细粒度的诊断能力至关重要，它使得针对这些高要求场景进行可量化、可审计的对齐优化成为可能，从而提升了模型在这些领域的部署可行性。例如，医生可以清晰地知道一个回答是否“事实准确”但“过于自信”，或者是否“有帮助”但“存在潜在安全风险”。这种细粒度的诊断能力是至关重要的，它使得针对这些高要求场景进行精细化的、可审计的对齐优化成为可能。

(2) 赋能动态、上下文感知的 AI 行为训练。真实世界的交互是动态多变的。一个优秀的 AI 助手需要能够根据不同的情境调整其行为模式。MORM 内置的 MoE 动态加权机制，使其能够根据输入（如用户的情绪、问题的类型）自适应地调整评价重点。这意味着奖励信号本身就具备了上下文感知能力。这为训练能够切换角色的 AI 模型奠定了基础。以 AI 教育辅导为例，MORM 能为“解答数学难题”（侧重准确性）和“安抚沮丧学生”（侧重鼓励性）这两种不同情境提供差异化的、更合理的奖励信号，从而指导 LLM 学习到这种动态适应能力。

(3) 提升对齐过程的效率与可解释性。传统的对齐过程有时像一个“黑箱”，出现问题时难以诊断。MORM 提供的多维度评分向量为对齐过程提供了清晰的偏好强度。当在强化学习过程中发现模型性能出现瓶颈或异常时，开发者可以立即通过分析 MORM 在各个维度上的评分，快速定位问题根源（例如，是“帮助性”不足还是“安全性”出了问题），从而进行针对性的数据增强或策略调整。这使得整个对齐 workflow 更高效、更透明、更可控。

综上所述，MORM 作为一个先进的“评价体系”，其应用价值体现在为高要求场景对齐提供可能、赋能动态行为训练、以及提升对齐过程效率与可解释性。正是因为 MORM 能够提供如此高质量、信息丰富且动态的奖励信号，本研究才能够在下一章中，基于此构建一个更强大、更可控的强化学习优化框架 IMOCA，以期将这些奖励信号的优势最终转化为 LLM 的卓越对齐表现。MORM 为后续的对齐工作提供了坚实的、信息更充分的奖励基础，是实现更高级别多目标对齐的关键前提。

3.7 本章小结

本章针对大语言模型（LLM）在多目标对齐任务中，现有奖励模型存在的偏好信息损失、难以动态权衡多维目标以及特定偏见（如冗余性偏见）等核心挑战，提出并详细阐述了一种基于多维度绝对评分和混合专家（MoE）机制的多目标奖励模型（MORM）。

首先, MORM 通过采用多维度绝对评分机制, 替代了传统成对比较方法, 从而更完整地捕捉了人类偏好的丰富性和细粒度信息, 为精确的奖励建模提供了坚实的数据基础。其次, 本章创新性地将混合专家 (MoE) 架构引入多目标奖励建模中, 通过门控网络根据输入特征动态调整和整合不同对齐维度 (如帮助性、真实性、安全性等) 的评估权重。这种设计使得 MORM 能够根据具体上下文自适应地权衡各目标的重要性, 克服了传统固定权重或简单聚合方法的局限性。此外, 本章还探讨并集成了一种针对冗余性偏见的缓解策略, 旨在提升奖励信号的有效性和生成内容的质量。

为验证 MORM 作为高质量“评价体系”的有效性, 本章在多个国际公认的奖励模型评估基准 (如 RewardBench 和 RMB) 上进行了全面的实验评估。实验结果表明, MORM 在各项核心指标上均显著优于基于传统方法 (如 Bradley-Terry 模型) 的基线奖励模型, 展现了其在准确区分高质量与低质量响应、以及在不同对齐维度上进行精确评估的能力。这些实证结果充分证明了 MORM 在捕捉复杂人类偏好、实现动态目标权衡以及缓解特定偏见方面的先进性。

综上所述, 本章成功构建并验证了一个更精确、鲁棒、可解释且具动态适应性的多目标奖励模型 MORM。它不仅为理解和评估 LLM 在多个对齐维度上的表现提供了更优的“评价基础”, 更重要的是, MORM 所能提供的高质量、信息丰富的奖励信号, 为后续第四章将要介绍的迭代式多目标可控对齐框架通过强化学习进一步提升 LLM 在复杂落地应用场景中的整体对齐性能, 奠定了关键且可靠的奖励支持。

第四章 基于多目标奖励建模的可控对齐框架

4.1 引言

第三章成功构建并验证了多目标奖励模型（MORM），该模型通过引入多维度绝对评分和混合专家（MoE）动态加权机制，为大语言模型（LLM）的输出质量提供了一个更精细、上下文感知且可解释的“评价体系”。实验结果已证实，MORM 在准确捕捉和权衡多维人类偏好方面具有显著优势，能够生成高质量的奖励信号。然而，拥有一个先进的评价体系仅仅是实现 LLM 多目标对齐的第一步。核心挑战随之转化为：如何设计一个有效的强化学习（RL）对齐策略或框架，以充分利用 MORM 提供的丰富奖励信息，并将其转化为 LLM 在帮助性、真实性、安全性等多个对齐目标上的实际性能提升，最终使其在日益复杂的落地应用场景（如专业咨询、个性化教育、企业级自动化解决方案等）中表现得更为可靠和智能。

当前主流的从人类反馈中强化学习（RLHF）方法，虽然在提升 LLM 对齐方面取得了显著进展，但在优化策略层面仍存在一些局限性，尤其是在应对多目标、可控性以及动态适应性的需求时。例如，许多 RLHF 实践依赖于预先收集的静态偏好数据集进行离线优化，这可能导致模型在面对分布外（Out-of-Distribution, OOD）的真实世界输入时泛化能力不足。同时，传统的强化学习目标函数或如直接偏好优化（DPO）等方法，在显式控制模型针对多个不同（甚至冲突的）对齐目标进行权衡时，其灵活性和精确度有限。这些不足限制了 LLM 在需要高度定制化和多维度综合表现的专业领域或高风险落地场景中的应用潜力。

为应对上述挑战，并充分发挥 MORM 作为高质量奖励来源的优势，本章提出并详细阐述一个迭代式多目标可控对齐框架（Iterative Multi-Objective for Controllable Alignment, IMOCA）。IMOCA 框架旨在通过有机整合 MORM 的奖励信号、迭代式同策略偏好采样机制以增强模型的动态适应性，以及基于可控偏好优化（Controllable Preference Optimization, CPO）的算法来实现对多个对齐目标的显式、灵活控制。本章将深入探讨 IMOCA 的设计理念、核心组件、工作流程及其理论基础。通过这一框架，本研究期望不仅能显著提升 LLM 在多个对齐维度上的综合表现，更能增强其对齐过程的可控性和对不同下游应用场景需求的适应能力，从而为 LLM 更广泛、更深入地赋能实际应用提供一套有效的技术方案。

为系统阐述 IMOCA 框架的设计、实现及其在提升 LLM 多目标对齐性能方面的有效性，本章后续内容组织如下：4.2 节将首先探讨 IMOCA 框架的设计理念及其旨在解决的核心挑战，并预览其核心优势。4.3 节将深入剖析支撑 IMOCA 框架

关键组件（如迭代式同策略优化、MORM 奖励信号的应用、可控偏好优化算法以及多目标平衡策略）的理论基础与设计原则。4.4 节将详细介绍 IMOCA 的整体系统架构、具体算法流程及其各个核心步骤的实现细节。4.5 节将通过在一系列国际公认的 LLM 对齐评估基准上的全面实验，展示 IMOCA 框架的对齐性能，并与现有代表性方法进行对比分析，以实证其在赋能更优落地应用方面的效果。最后，4.6 节将对本章工作进行总结，并强调 IMOCA 在实现高效、可控的多目标 LLM 对齐方面所作出的贡献。

4.2 IMOCA 框架的设计理念与核心优势

在第三章构建了能够提供高质量多目标奖励信号的 MORM 模型之后，本章的核心任务是探讨如何有效利用这一“评价体系”来指导大语言模型（LLM）的策略优化，从而实现更高级别的多目标对齐。传统的强化学习对齐方法在面对日益复杂的落地应用场景时，其在可控性、适应性和多目标平衡能力上的局限性日益凸显。为应对这些挑战，本研究提出了迭代式多目标可控对齐框架（IMOCA），其设计理念与核心优势如下。

4.2.1 现有方法的局限与多目标可控对齐的必要性

随着 LLM 在各个领域应用（如智能投顾、自动化合规审查）和专业服务领域（如 AI 辅助诊疗、法律文书生成）的渗透，对其输出进行多维度、可控的调整成为一项迫切需求。用户或开发者不仅希望模型在多个对齐目标上表现良好，更关键的是，希望能够根据具体的业务需求或用户偏好，动态地指定这些目标的优先级或期望水平。

传统的对齐方法，如单一目标的 PPO 或 DPO，难以满足这种“按需对齐”的灵活性，它们通常优化一个固定的、预先设定的奖励函数或偏好分布，缺乏对多目标进行实时、显式控制的有效机制。这种不足限制了 LLM 在需要高度定制化和多维度精细权衡的高价值落地场景中的应用深度与广度。

尽管 RLHF 作为 LLM 对齐的主流方法取得了显著进展，但在实际应用中仍然面临诸多挑战。

（1）数据采样策略的不足：RLHF 训练过程中，数据的质量和多样性直接决定了对齐效果。然而，目前主流 RLHF 训练方法严重依赖静态数据集，即在训练前预先收集一批偏好数据，并在整个训练过程中始终使用这批数据进行优化。这种方法的主要问题包括：

- 数据分布固化：由于静态数据集在收集时无法涵盖所有可能的用户输入，导

致模型在面对新任务或未见过的输入时泛化能力不足。

- 数据采样缺乏动态性：模型在训练过程中难以获取新的反馈，导致训练后期优化方向容易趋于稳定，难以适应不断变化的用户需求。
- 难以适应任务变化：不同任务对模型的偏好要求不同，例如，在医学问答任务中，诚实性和安全性可能更重要，而在创意写作任务中，帮助性和表达流畅性更为关键。静态数据集难以动态调整优化方向，导致模型在特定任务上的表现受限。

(2) 偏好建模的不透明性：当前的 RLHF 训练框架主要依赖于相对评分机制 (pairwise comparison)，即对于同一输入，标注者从多个候选输出中选择最优者，而模型则通过强化学习策略提高其生成该最优输出的概率。这种方法存在以下主要问题：

- 缺乏独立评分维度：传统相对评分只能用于对比不同回答的优劣，而无法为单个回答提供独立的评分，使得训练过程中难以明确优化方向。
- 优化信号模糊化：由于缺乏清晰的目标评分标准，模型可能学习到次优策略，例如通过增加回答长度来提高奖励，而非优化内容质量。
- 难以解释模型优化方向：由于 RLHF 主要基于相对评分，训练过程中无法提供不同目标的具体优化情况，使得最终模型的行为难以解释和控制。

(3) 单目标优化的局限性：目前，RLHF 训练框架主要基于单目标优化，即针对某个特定偏好（如帮助性、安全性或诚实性）进行强化训练。这种方法的主要局限性包括：

- 无法兼顾多个目标之间的平衡：单目标优化可能导致偏好之间的冲突，例如优化帮助性可能导致模型提供过度信息，而优化安全性可能导致模型拒绝回答某些问题。
- 优化方向固定，难以适应不同任务需求：单一目标优化方法难以在不同任务场景下调整优化策略，例如在社交对话任务中，用户可能更关注表达流畅性，而在技术支持任务中，用户可能更关注信息的准确性。

4.2.2 IMOCA 的核心特点

为了解决上述问题，IMOCA 框架的设计基于以下三个核心原则的有机整合：

(1) 高质量奖励的充分利用与传递：IMOCA 框架直接建立在 MORM（详见第三章）提供的精细化多目标奖励基础之上。MORM 能够对 LLM 的输出进行多维度、上下文感知的评估，并能有效缓解冗余性偏见，为 IMOCA 的强化学习过程提供了比传统标量奖励更丰富、更准确的指导信号。这是实现高级多目标对齐的根本前提。

(2) 持续学习与动态适应性的强化：为克服静态数据集带来的分布外（OOD）泛化问题，并使模型能够适应真实世界交互的动态性，IMOCA 采用了迭代式在线/同策略（on-policy）偏好采样机制。在每一轮优化后，模型都从其更新后的策略中生成新的样本，并由 MORM 进行评估，从而持续获得与当前模型状态最相关的高质量偏好数据。这种“边学边练、持续反馈”的机制，旨在增强模型的探索能力和对不断变化的偏好分布的适应性。

(3) 用户意图的显式引导与可控对齐的实现：为了赋予用户或开发者对 LLM 多目标对齐过程的直接控制权，IMOCA 引入了基于可控偏好优化（CPO）进行可控多目标优化，使模型能够在不同目标之间实现动态平衡。CPO 允许模型根据不同任务需求调整优化目标，在多个目标之间进行合理的权衡。IMOCA 能够引导 LLM 策略朝着用户期望的多目标组合方向进行优化，而不仅仅是最大化一个固定的、预定义的奖励函数。例如，在医疗问答任务中，可以优先优化模型的诚实性和安全性，而在创意写作任务中，则可以强调帮助性和表达流畅性。

本研究的核心目标是改进现有 RLHF 方法，使其能够更好地支持多目标优化，提高 LLM 的可控性、稳定性和适应性。通过采用 IMOCA 方法，本研究不仅提升了模型对不同目标的优化能力，还提高了偏好评分的可解释性，使得优化过程更加透明。同时，借助迭代式偏好采样，模型能够持续适应新任务，解决静态数据带来的泛化能力问题。

综上所述，本章提出了一种新的多目标对齐策略，以提升 LLM 在真实世界应用中的可靠性和灵活性。本方法为多目标优化提供了一种新的思路，并为未来的 LLM 对齐研究奠定了基础。

4.3 IMOCA 框架的理论基础与关键组件

IMOCA 框架的设计，旨在通过整合先进的理论与机制，克服现有大语言模型（LLM）对齐方法在多目标控制、动态适应性及数据效率方面的局限性。本节将阐述支撑 IMOCA 框架中各个关键组件——包括迭代式同策略优化、基于 MORM 的多目标奖励信号应用、可控偏好优化（CPO）算法以及多目标平衡策略——的核心理论基础和设计原则。

4.3.1 迭代式同策略优化的理论依据

为了有效提升 LLM 在复杂且动态变化的落地应用场景中的对齐性能，IMOCA 框架采用了迭代式的同策略（on-policy）偏好采样与优化机制。这一设计借鉴并扩展了在线强化学习从人类反馈（Online RLHF）的核心思想。

在强化学习中,根据数据生成策略 (behavior policy) 与目标策略 (target policy) 的关系,优化方法分为同策略 (On-Policy) 和异策略 (Off-Policy) 两类。这两种方法在理论基础、算法设计和适用场景上存在显著差异,尤其在稳定性、数据效率和探索能力方面各具特色。

On-policy 方法要求智能体使用当前策略 π 生成交互数据,并基于这些数据优化同一策略。其基础源于强化学习中的策略梯度 (Policy Gradient) 概念^[106],提供了策略优化的无偏梯度估计:

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a | s) Q^{\pi_{\theta}}(s, a)] \quad (4-1)$$

其中 π_{θ} 是参数化为 θ 的策略; $Q^{\pi_{\theta}}(s, a)$ 是动作值函数,表示在状态 s 执行动作 a 并遵循策略 π_{θ} 的预期累积奖励。

由于数据由当前策略生成, on-policy 方法能够实时反映策略的表现,梯度估计无偏且一致。

Off-policy 方法允许智能体使用行为策略 μ 生成数据,但优化的是一个不同的目标策略 π 。其理论基础基于 Q-learning^[107],通过学习最优动作值函数 $Q^*(s, a)$ 间接推导最优策略,更新规则为:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (4-2)$$

其中 α 是学习率; r 是即时奖励; $\max_{a'} Q(s', a')$ 表示下一状态的最优动作值。

为利用 μ 的数据优化 π , off-policy 方法引入重要性采样 (Importance Sampling)^[108] 校正偏差:

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\mu} \left[\frac{\pi_{\theta}(a | s)}{\mu(a | s)} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\mu}(s, a) \right] \quad (4-3)$$

其中 $A^{\mu}(s, a) = Q^{\mu}(s, a) - V^{\mu}(s)$ 是优势函数。典型算法包括 Q-learning^[107] 和 DQN (Deep Q-Network)^[109],后者结合深度学习和经验回放 (experience replay) 提升数据效率。

与 off-policy 方法相比, on-policy 方法在语言模型对齐中具有以下优势:

- (1) 更高的稳定性: 数据由当前策略生成,避免了行为策略与目标策略不一致引入的高方差。例如, PPO 通过限制更新步长 (如裁剪参数),防止性能崩溃。
- (2) 实现简单: 无需复杂的数据校正或额外存储 (如经验回放缓冲区),降低了算法复杂度。
- (3) 适合在线学习: 智能体在交互中实时改进策略,适用于动态任务如实时语言生成。需要快速适应的任务 (如实时语言生成或交互式对话) 中,这种

特性尤为关键。对于持续更新的语言模型，这提供了灵活适应用户反馈的能力。

- (4) On-policy 方法直接优化当前策略的性能，智能体能够实时观察策略效果并调整，避免了 off-policy 方法因策略不匹配引入的间接性。这种直接性使得优化过程更加透明，便于调试和解释模型的行为变化。
- (5) On-policy 方法通常结合探索策略（如 ϵ -greedy^[106] 或熵正则化^[110]），在学习过程中有效平衡探索与利用。例如，PPO 通过添加熵项鼓励探索，确保策略不会过早收敛到次优解。在语言生成任务中，适当的探索有助于保持模型输出的多样性和创造性。

这些特性使 On-policy 方法在需要稳定性和在线适应的任务中表现出色，尤其适用于 LLM 对齐的动态环境：

(1) 缓解分布外（OOD）问题：传统的离线 RLHF 方法通常依赖于一次性收集的静态偏好数据集进行训练。然而，LLM 的输出空间极其广阔，静态数据集难以完全覆盖所有可能的用户输入和偏好分布，导致模型在遇到训练分布之外的（OOD）新情境时，性能可能急剧下降。IMOCA 通过在每一轮优化后，利用当前更新的策略模型主动采样生成新的响应数据，并由 MORM 进行评估，从而持续获取与模型当前状态最相关的偏好信息。这种在线、同策略的数据生成机制，确保了训练数据分布与模型策略分布的动态一致性，理论上能显著增强模型对真实世界中多样化输入的泛化能力和鲁棒性。

(2) 提升数据效率与探索能力：同策略学习直接优化当前策略的表现，使智能体能够实时观察其行为效果并进行调整，避免了异策略（off-policy）方法中因行为策略与目标策略不一致可能引入的复杂校正和高方差问题。在 IMOCA 中，通过迭代采样，模型得以在 MORM 奖励信号的指导下，更有效地探索有潜力的响应区域，并快速从高质量的在线反馈中学习，从而加速收敛并可能达到更优的对齐效果。

迭代优化策略是强化学习与人类反馈（RLHF）框架的重要组成部分，其核心思想在于通过不断循环执行数据采样和策略更新，以逐步优化模型表现。与传统的静态训练方式不同，迭代式采样允许模型持续从自身的生成样本中获得反馈并即时调整，从而有效降低训练过程中出现的分布漂移问题。

在线迭代强化学习从人类反馈（Online Iterative Reinforcement Learning from Human Feedback, 简称 Online RLHF）^[21] 是一种通过多轮数据采样和策略更新来优化语言模型（LLM）的技术。其核心思想在于通过不断循环执行数据采样和策略更新，以逐步优化模型表现。与传统的静态训练方式不同，迭代式采样允许模型持续从自身的生成样本中获得反馈并即时调整，从而有效降低训练过程中出现的分布漂移问题。相比于离线方法（如传统的直接偏好优化 DPO），在线 RLHF 在每

一轮迭代中从当前策略采样数据，并根据实时反馈更新模型，从而实现在线和在同策略（on-policy）的学习。

具体而言，在线 RLHF 的工作流程如下：

（1）初始化阶段：从监督微调（SFT）模型 π_0 开始，作为初始策略。

（2）迭代过程：在每次迭代 t 中：

- 从当前策略 π_t 采样提示 x 和响应对 (y^1, y^2) 。
- 通过偏好模型或奖励模型获取在线反馈，标记偏好对 (y^+, y^-) 。
- 使用偏好数据更新策略 π_t ，生成下一轮策略 π_{t+1} 。

（3）目标优化：通过多轮迭代，更新策略参数，逐步优化模型，使其在 KL 正则化目标下最大化期望奖励：

$$J(\pi) = \mathbb{E}_{x \sim d_0} \mathbb{E}_{y \sim \pi(\cdot|x)} [r^*(x, y)] - \eta D_{\text{KL}}(\pi(\cdot|x) \parallel \pi_0(\cdot|x)) \quad (4-4)$$

其中 $r^*(x, y)$ 是潜在的真实奖励函数， η 是 KL 散度的惩罚系数。

这种方法结合了在线学习与直接偏好优化的优势，有效避免了离线数据偏差与策略漂移问题。实验结果表明，与传统离线 DAP 方法相比，OAIF 显著提高了模型在帮助性、准确性和安全性等方面的性能，尤其是在实时在线场景中的表现更为突出。

奖励建模（Reward Modeling）是在线 RLHF 的关键组件，用于将偏好信号转化为可优化的奖励函数。在迭代优化中，奖励模型通过历史数据和在线采样数据不断更新，提供实时反馈以指导策略改进。传统方法假设偏好遵循以下形式：

$$\mathbb{P}(y^1 \succ y^2 | x, y^1, y^2) = \sigma(r^*(x, y^1) - r^*(x, y^2)) \quad (4-5)$$

其中 σ 是 sigmoid 函数， r^* 是潜在奖励函数。奖励模型通过最大似然估计（MLE）训练，优化：

$$L_{\text{RM}}(\theta) = -\mathbb{E}_{x, y^+, y^- \sim \mathcal{D}} \log \sigma(r_\theta(x, y^+) - r_\theta(x, y^-)) \quad (4-6)$$

在在线 RLHF 中，奖励模型的动态更新是其核心优势。例如，RLHF Workflow^[111]中提出了一种混合批处理学习策略，将离线数据 $\mathcal{D}_{\text{off}}$ 与在线数据 $\mathcal{D}_t$ 结合，通过（Rejection Sampling）^[112]等方法从当前策略 π_t 采样高质量响应对。这种方法通过不断探索提示-响应空间，缓解了离线数据覆盖不足的问题。

4.3.2 基于 MORM 的多目标奖励信号在强化学习中的应用

IMOCA 框架的核心在于有效利用第三章提出的 MORM 所提供的精细化多目标奖励信号。MORM 通过多维度绝对评分和 MoE 动态加权机制，能够生成比传统标量奖励更丰富、更具上下文感知性的评价反馈。

信息更丰富的奖励指导：**MORM** 输出的奖励信号（无论是标量化的综合评分，还是保留了多维度信息并经过 **MoE** 动态调整的向量形式）为强化学习过程提供了更全面的指导。与单一标量奖励相比，**MORM** 的奖励能够更清晰地指示模型在哪些具体对齐目标（如帮助性、真实性、安全性）上表现良好或存在不足。

支持复杂目标权衡：**MORM** 的动态加权特性，使其能够根据输入提示的上下文，自适应地调整不同奖励维度的相对重要性。这种上下文感知的奖励信号，为后续 **CPO** 算法在不同落地场景相关目标之间进行有效权衡和优化提供了坚实基础。例如，当 **MORM** 根据提示识别到安全风险时，其输出的奖励信号会更侧重于安全维度，从而引导 **IMOCA** 的优化过程向更安全的方向调整。

4.3.3 可控偏好优化的核心机制与理论支撑

强化学习中的策略梯度方法，特别是近端策略优化（**PPO**），为利用奖励信号优化语言模型（**LLM**）的策略提供了坚实基础，在 **RLHF** 任务中得到广泛应用。然而，**PPO** 等传统方法依赖显式奖励模型，这不仅计算成本高，还可能引入偏差。为解决此问题，直接偏好优化（**DPO**）通过直接从偏好对中学习，避免了显式奖励建模，并利用隐式奖励建立了策略与偏好间的直接联系，从而简化了训练流程。

尽管 **PPO** 和 **DPO** 在 **LLM** 对齐上取得了重要进展，但它们通常优化单一（显式或隐式）奖励目标或固定的偏好分布。当面对需要在多个、甚至冲突的对齐目标（如帮助性、安全性、特定风格等）之间进行灵活权衡和显式控制的复杂落地应用场景时，这些方法的局限性便显现出来，它们缺乏内在机制以允许用户或开发者根据具体需求动态、细粒度地引导模型在不同目标上的行为倾向。正是这种对“可控性”的迫切需求，推动了如可控偏好优化（**CPO**）等更先进对齐算法的探索与发展。

4.3.3.1 偏好优化的演进：从 **PPO** 到 **DPO** 及其可控性挑战

从 **PPO** [4] 到 **DPO** [50]：偏好优化的理论演变偏好优化是 **LLM** 对齐的重要方向，旨在通过人类偏好数据直接优化模型输出。本节从 **PPO** 的目标函数推导 **DPO** 的目标函数，展示其理论基础及其在多目标优化中的局限性。

PPO 是一种 on-policy 策略梯度方法，其目标函数通过裁剪或 **KL** 正则化 [113] 确保更新稳定性。以 **KL** 正则化形式为例：

$$J(\pi) = \mathbb{E}_{x \sim d_0} [\mathbb{E}_{a \sim \pi(\cdot|x)} [r^*(x, a)] - \eta D_{\text{KL}}(\pi(\cdot|x) \parallel \pi_0(\cdot|x))] \quad (4-7)$$

其中： $r^*(x, a)$ 是真实奖励函数，通常由奖励模型提供； η 是 **KL** 散度（**KL-Divergence**）[113] 惩罚系数，控制新策略与参考策略的偏离程度； π_0 是参考策略，通常是预训练

的基础模型； D_{KL} 约束新策略 π 与参考策略的偏差，防止过拟合和功能退化。

在 RLHF 中，PPO 结合奖励模型（基于人类偏好数据训练）优化策略。然而，由于依赖单一奖励信号，PPO 在多目标优化中难以平衡目标间的权衡，且需要显式构建和训练奖励模型，增加了训练复杂度和潜在的偏差。

为克服 PPO 的局限性，DPO 直接利用偏好数据优化策略，跳过显式奖励建模环节。其推导从 PPO 的 KL 正则化目标开始，通过一系列理论推导建立偏好数据与最优策略之间的直接联系。根据强化学习理论，最优策略 π^* 足：

$$\pi^*(a | x) = \frac{1}{Z(x)} \pi_0(a | x) \exp \left(\frac{1}{\eta} r^*(x, a) \right) \quad (4-8)$$

其中， $Z(x) = \sum_a \pi_0(a | x) \exp \left(\frac{1}{\eta} r^*(x, a) \right)$ 是归一化常数，确保概率分布的有效性。这一形式展示了最优策略，参考策略和奖励函数之间的内在联系。

将此表达式代入偏好关系，优胜响应 a^w 和落败响应 a^l 的对数概率比为：

$$\log \frac{\pi^*(a^w | x)}{\pi^*(a^l | x)} = \frac{1}{\eta} [r^*(x, a^w) - r^*(x, a^l)] \quad (4-9)$$

这一关系揭示了策略概率比与奖励差异的直接联系，为 DPO 的核心创新奠定了基础。DPO 假设偏好数据 (x, a^w, a^l) 已知，目标是直接优化策略 π_θ 以匹配这些偏好。通过定义隐式奖励：

$$\hat{r}_\theta(x, a) = \eta \log \frac{\pi_\theta(a | x)}{\pi_0(a | x)} \quad (4-10)$$

DPO 建立了策略与奖励之间的双向映射，使得研究者可以直接从策略参数推断隐含的奖励函数。基于此，偏好概率可表示为：

$$P(a^w > a^l | x) = \sigma(\hat{r}_\theta(x, a^w) - \hat{r}_\theta(x, a^l)) \quad (4-11)$$

其中 σ 是 sigmoid 函数，将奖励差异映射到概率空间。DPO 的目标函数通过最大化偏好数据的对数似然得出：

$$\mathcal{L}_{\text{Doff}}(\theta, \pi_0) = - \sum_{(x, a^w, a^l) \in \mathcal{D}_{\text{off}}} \log \sigma \left(\eta \log \frac{\pi_\theta(a^w | x)}{\pi_0(a^w | x)} - \eta \log \frac{\pi_\theta(a^l | x)}{\pi_0(a^l | x)} \right) \quad (4-12)$$

这一目标函数简化了训练流程，避免了显式奖励建模，直接从偏好数据中学习策略。DPO 的优势在于：

- (1) 简化训练流程：无需单独的奖励模型训练阶段，减少了计算开销和潜在偏差。
- (2) 提高数据效率：直接从偏好数据中提取信号，避免了中间环节损失。
- (3) 稳定的优化过程：通过隐式控制 KL 散度，保持与基础模型的适当距离。

DPO 在多目标优化中的局限性 DPO 通过将人类相对偏好转化为奖励信号指导策略优化，在单目标场景中表现优异。然而，在多目标优化中（如同时优化帮助性、安全性和准确性），单纯基于 Bradley-Terry 模型的算法无法直接处理目标间的权衡，缺乏显式建模目标优先级的能力，可能导致优化偏向某一目标。

DPO 的目标函数本质上基于单一偏好概率，难以适应多维目标的动态权衡需求。例如，在需要平衡帮助性与安全性时，DPO 无法显式建模目标间的优先级或冲突，导致优化效果受限。为克服这一局限性，后续研究引入了多目标方法，如 Pareto 优化和 MORM，以实现更灵活的权衡。

4.3.3.2 多目标优化的挑战与 Pareto 最优性视角

在多目标优化问题中，各个目标之间往往存在冲突，提升一个目标的性能可能会损害另一个目标。Pareto 最优性为理解和处理这种目标间的权衡提供了核心理论框架。

一个解被称为 Pareto 最优的，当且仅当不存在另一个解，在不使得任何其他目标表现变差的前提下，至少能使一个目标表现得更好。所有 Pareto 最优解的集合构成了 Pareto 前沿。

Pareto 最优性^[114]是多目标优化的理论基石，用于评估一组解在多个目标间的权衡。对于一个目标向量 $\mathbf{T}(\theta) = (T_1(\theta), T_2(\theta), \dots, T_m(\theta))$ ，其中 θ 表示模型参数， $T_i(\theta)$ 表示第 i 个目标的性能，一个解 θ^* 被认为是 Pareto 最优的，当且仅当不存在另一个解 θ' 满足以下条件：

- 对于所有目标 $i, T_i(\theta') \geq T_i(\theta^*)$ （即 θ' 在所有目标上不劣于 θ^* ）
- $j, T_j(\theta') > T_j(\theta^*)$ （即 θ' 在某个目标上严格优于 θ^* ）

换句话说，Pareto 最优解是无法在不牺牲至少一个目标的情况下进一步改善的解。

所有 Pareto 最优解的集合构成了 Pareto 前沿，它为决策者提供了权衡选择的依据。在语言模型的多目标优化中，Pareto 前沿揭示了目标间的潜在冲突。例如，提升无害性可能要求模型拒绝回答某些敏感问题，从而降低帮助性。Pareto 前沿允许用户根据具体需求（如更重视安全性或实用性）选择最合适的平衡点。

4.3.3.3 传统多目标优化方法的局限性

在 RLHF Workflow^[111] 的案例研究中，在线 RLHF 优化的响应在结构性和清晰度上优于离线方法，这可能反映了 Pareto 前沿上的不同权衡点。Pareto 最优性为理解这些权衡提供了理论支持，帮助设计更灵活的优化策略。

为了将多个目标整合成可优化的形式，存在以下几种常见方法，每种方法都有其适用场景和局限性：

(1) 线性加权法：将多个目标通过加权求和整合为单一目标：

$$T(\theta) = \sum_{i=1}^m w_i T_i(\theta), \quad w_i \geq 0, \sum_{i=1}^m w_i = 1 \quad (4-13)$$

优化问题为：

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^m w_i T_i(\theta) \quad (4-14)$$

优点：实现简单，易于计算。

局限性：传统方法需要预先设定权重 w_i 。若权重选择不当，可能偏向某些目标，忽略其他目标的需求。例如，若 $w_{\text{无害性}}$ 过高，模型可能过于保守，牺牲模型帮助性。

(2) ϵ -约束法：将部分目标转化为约束条件，优化主目标：

$$\theta^* = \arg \max_{\theta} T_1(\theta), \quad \text{s.t.} \quad T_i(\theta) \geq \epsilon_i, i = 2, \dots, m \quad (4-15)$$

通过拉格朗日乘子法求解。

优点：适合需要保证某些目标底线性能的场景。例如，可设置 $T_{\text{无害性}}(\theta) \geq \epsilon$ ，确保安全性，同时优化帮助性。

局限性： ϵ_i 的选择具有主观性，需根据任务需求调整。

(3) 目标规划法：为每个目标设定理想值 T_i^* ，通过最小化偏差来优化：

$$\min_{\theta} \sum_{i=1}^m w_i |T_i(\theta) - T_i^*| \quad (4-16)$$

使用梯度下降求解。优点：适用于目标有明确期望值的场景。例如，可设定 $T_{\text{帮助性}} = 5$ ，优化模型接近这一理想值。

局限性：理想值的设定可能不切实际，且计算复杂度较高。

这些传统多目标优化方法，特别是像线性加权法这样依赖固定参数的方法，在面对 LLM 对齐中复杂多变的动态需求时，其灵活性和适应性往往不足。

4.3.3.4 CPO 的核心机制：引入条件控制实现动态目标调整

为了克服传统多目标优化方法在灵活性和可控性上的不足，并实现对 LLM 多目标对齐过程的显式、动态引导，IMOCA 框架整合了可控偏好优化（Controllable Preference Optimization, CPO）^[31] 的核心思想。CPO 通过引入外部的、可由用户或开发者指定的偏好条件（preference conditions），实现了对模型在不同对齐目标上行为倾向的直接控制。

在可控偏好优化中，Pareto 最优性依然是处理目标冲突的基础。CPO 通过动态调整优化方向，使模型能够在 Pareto 前沿上根据用户需求移动。

CPO 通过引入条件（如 <Helpfulness:5>）动态调控目标权重，分为两个阶段：

1. 可控偏好监督微调（CPSFT）

优化目标为：

$$L_{\text{CPSFT}}(\theta) = -\mathbb{E}_{(x,y,c_1,\dots,c_m)\sim\mathcal{D}} [\log \pi_{\theta}(y \mid c_1, \dots, c_m, x)] \quad (4-17)$$

其中， c_i 是用户指定的条件，通过提示融入输入，训练模型生成符合条件的响应。

2. 可控直接偏好优化（CDPO）：

比较条件下的多目标偏好值 R ：

$$R = \sum_{i=1}^m \omega_i g_i, \quad g_i = \begin{cases} -\lambda_i |p_i - c_i|, & \text{若第 } i \text{ 个目标受控} \\ p_i, & \text{否则} \end{cases} \quad (4-18)$$

损失函数为：

$$L_{\text{CDPO}} = -\mathbb{E}_{(x,c,y_w,y_l)\sim\mathcal{D}} \left[\log \sigma \left(\hat{R}_{\theta}(c, x, y_w) - \hat{R}_{\theta}(c, x, y_l) \right) \right] \quad (4-19)$$

其中， p_i 是第 i 个目标的偏好值， ω_i 和 λ_i 是权重参数， y_w 和 y_l 分别是优胜和劣势响应。若某目标受控，则 $g_i = -\lambda_i |p_i - c_i|$ ，使模型输出尽量接近指定值。若不受控，则 $g_i = p_i$ ，最大化该目标的偏好值。

CPO 允许的对特定目标偏好值的指定（例如，通过偏好条件指令设定某个目标的重要性或期望水平），相当于在 Pareto 前沿上选择一个或多个符合用户当前偏好的特定区域进行聚焦优化。这超越了传统 RLHF 方法通常优化一个固定加权标量目标的局限性，使得模型能够根据不同的落地应用需求在不同的 Pareto 最优解之间进行切换或权衡，理论上能实现更灵活和精细的多目标对齐。实验结果^[31] 进一步验证了 CPO 在多目标对齐中的优越性，为未来 LLM 优化提供了重要参考。

IMOCA 框架采纳 CPO，正是因为它允许通过外部的偏好条件指令来直接引导优化方向，这与实现多目标“可控”对齐的目标高度契合。MORM 提供的（可能是标量化的，也可能是需要 CPO 内部进一步处理的向量）奖励将作为 CPO 损失函数中的核心偏好信号，而偏好条件指令则为优化过程提供了额外的控制维度。

IMOCA 框架通过结合 MORM 的多维度奖励评估和 CPO 的条件化控制，旨在引导 LLM 策略在多目标空间中向 Pareto 前沿的理想区域进行探索和优化。MORM 提供的多维度奖励信息，使得优化过程能够感知到不同目标上的表现变化。这种结合使得 IMOCA 不仅能够优化一个静态的“平均”偏好，更能根据指令动态生成符合特定多目标组合的响应。理论上，这使得模型能够更灵活地在 Pareto 前沿上移动，以满足不同用户或任务在不同时刻的多样化需求，从而显著提升 LLM 在复杂真实世界应用中的实用性和适应性。

4.4 IMOCA 的整体架构与算法流程

基于 4.3 节阐述的理论基础与关键组件设计原则——即充分利用 MORM 提供的多目标奖励信号，并通过迭代式同策略优化和可控偏好优化（CPO）机制实现对大语言模型（LLM）多目标对齐的精细控制——本节将详细介绍迭代式多目标可控对齐框架（IMOCA）的整体系统架构、具体算法流程及其核心步骤的实现细节。

4.4.1 IMOCA 整体架构图与工作流程

IMOCA 框架由三大核心组件构成：多目标奖励模型（MORM）、可控门控网络（MoE）和可控偏好层。此外，框架还包括迭代式偏好采样和可控偏好优化（CPO）算法。这些组件和机制协同工作，共同实现多目标的可控对齐。以下是对每个部分的详细描述。

（1）MORM 评估模块：多目标奖励模型是 IMOCA 框架的核心组件，负责为生成的回答提供多维度的绝对评分。它基于预训练的大型语言模型（LLM），通过附加回归层预测回答在多个可解释维度上的具体分数。这些评分维度包括但不限于：




图 4-1 迭代框架流程图

- 帮助性：衡量回答是否有效解决用户问题或满足需求。
- 正确性：评估回答内容的准确性和真实性，避免生成虚假或误导性信息。
- 连贯性：检查回答的逻辑结构和语言流畅性，确保用户易于理解。
- 复杂性：评估回答的深度和信息密度，适用于详细分析或专业知识的场景。
- 冗长性：检测并控制回答的冗余程度，避免生成过长或重复的内容。

最终，将门控系数与调整后的多目标奖励相乘，得到相应提示 x 响应 y 对应

的标量评分：

$$R = g_{\phi}(f_{\theta}(x, y))^{\top} r' \quad (4-20)$$

为了训练门控层，冻结骨干模型和回归层的参数，仅使用 Bradley-Terry 损失对门控层进行训练：

$$\mathcal{L}(g_{\phi}) = -\log(\sigma(R_w - R_l)) \quad (4-21)$$

其中 R_w 和 R_l 分别是每对样本的选择响应和拒绝响应的偏好评分， σ 为 Sigmoid 函数。通过这种方式，能够优化门控层，使其在多目标奖励任务中表现更加灵活，动态调整奖励目标的权重，从而实现更优的多目标优化。

MORM 采用多目标回归方法进行训练，其目标是最小化预测评分与真实评分之间的均方误差。对于每个提示-回答对 (x, y) ，MORM 输出一个 k 维评分向量 $r \in \mathbb{R}^k$ 。其训练损失函数定义为：

$$\min_{\theta, w} \frac{1}{n} \sum_{i=1}^n (w^{\top} f_{\theta}(x_i, y_i) - r_i)^2 \quad (4-22)$$

其中 (x_i, y_i, r_i) 是第 i 个样本， f_{θ} 是预训练语言模型的特征提取器，用于提取输入的语义特征。 w 是输出线性层或投影层，用于将特征映射到评分。

为了确保评分的公平性和一致性，MORM 的训练数据来源于多个标注数据集（如 UltraFeedback、HelpSteer^[68, 72, 73] 等），并通过跨数据集标准化消除不同数据集之间的评分偏差。此外，针对语言模型常见的“冗长度偏见”（即倾向于生成冗长回答以获得更高奖励），MORM 引入了冗长度修正机制。具体而言，通过在评分中加入惩罚项，降低冗长回答的得分，从而确保评分反映内容的真实质量。这种机制显著提高了 MORM 的客观性，为后续的优化步骤提供了可靠的奖励信号。

可控门控网络是 MORM 的动态调节模块，负责根据提示上下文自适应调整各奖励目标的权重。它采用专家混合（Mixture of Experts, MoE）的门控机制，通过学习不同场景下的权重分布，确保模型能够灵活强调适当的目标，而非依赖固定的权重配置。

门控网络的输入是提示 x 的特征向量 $f_{\theta}(x)$ ，输出为非负权重向量 $g_{\phi}(f_{\theta}(x)) \in \mathbb{R}^k$ ，满足归一化条件 $\sum_i g_i = 1$ 。这些权重用于对 MORM 的评分向量 r' 进行加权，生成综合得分 R ：

$$R = g_{\phi}(f_{\theta}(x))^{\top} r' \quad (4-23)$$

为抑制冗长度偏见，评分向量 r' 在加权前会经过调整：

$$r'_i = (1) \cdot r_i + (-\lambda_i) \cdot r_{\text{verbose}} \quad (4-24)$$

算法 4-1: IMOCA 框架算法流程

```

输入: 1) 初始模型  $\pi_0$ ;
        2) 参考模型  $\pi_{\text{ref}}$ ;
        3) 多目标奖励模型 MORM
        4) 偏好数据集  $\mathcal{D}$ ;
        4) 迭代轮数  $T$ 。
输出: 优化后的模型  $\pi_T$ 。

1 for  $t = 1$  to  $T$  do                                     /* 迭代优化轮数 */
    /* 采样阶段 */                                           */
2   foreach  $\text{prompt } x$  in  $\mathcal{D}$  do
3       foreach  $\text{preference condition } c$  in  $C$  do
4           使用  $\pi_\theta$  和核采样生成  $N$  个多样化回答  $Y = \{y_1, y_2, \dots, y_N\}$  // 探索生成空
           间
        /* 评估阶段 */                                       */
5       foreach  $(x, y)$  in 生成的样本 do
6           计算多目标评分  $r = \text{MORM}(x, y)$                 // 获取多维度评分
7           计算门控权重  $g = g_\phi(f_\theta(x))$               // 动态调整权重
8           计算校正后的评分  $r' = r - \lambda \cdot r_{\text{verbose}}$     // 冗长度校正
9           计算综合评分  $R = g^\top \cdot r'$                 // 加权求和
        /* 排名与选择阶段 */                                 */
10      foreach  $x$  do
11          根据  $R$  对回答  $Y$  进行排名                        // 选择高质量回答
12          选择前  $k$  个回答  $Y_{\text{selected}}$  构建偏好对
           $P = \{(x, y_w, y_l) \mid y_w \in Y_{\text{selected}}, y_l \in Y \setminus Y_{\text{selected}}\}$ 
        /* 优化阶段 (使用 CPO) */                             */
13      foreach  $\text{batch in } P$  do
14          计算 CPO 损失  $L_{\text{CPO}}$                             // 根据偏好对优化
15          使用梯度下降更新模型参数  $\theta$ 
        /* 迭代与改进阶段 */                                 */
16      根据评估结果更新偏好条件  $C$                         // 调整偏好以持续改进

17 return 优化后的模型  $\pi_\theta$ 。

```

其中, λ_i 是基于 Spearman 相关系数的惩罚因子, 用于消除各目标评分与冗长度的相关性, 确保模型不会因冗长回答而获得不公平的高分。

门控网络的训练过程通过冻结 MORM 的主干和回归层, 仅优化门控层参数 g_ϕ 。其训练采用 Bradley-Terry 偏好损失函数:

$$\mathcal{L}(g_\phi) = -\log(\sigma(R_w - R_l)) \quad (4-25)$$

其中 R_w 和 R_l 分别是每对样本的选择响应和拒绝响应的偏好评分, σ 为 Sigmoid

函数。更详细的介绍参考第三章3.3.2。

(2) 可控偏好标记：可控偏好层通过在提示中嵌入偏好标记，实现对生成过程的显式控制。这些标记采用 < 目标: 评分 > 的格式，例如 < 有帮助性:5 > 或 < 无害性:4 >，直接告知模型应优先考虑哪些目标。通过在输入中嵌入明确的偏好条件指令，如教育场景中，开发者或教育者可以为 AI 教育辅导机器人设定特定的教学策略和沟通风格，从而使辅导过程更具适应性和个性化。

在训练阶段，偏好标记被整合到输入提示中，模型通过条件生成学习调整生成策略。其优化目标定义为：

$$L_{\text{CPSFT}}(\theta) = -\mathbb{E}_{(x,y,c_1,\dots,c_m) \sim \mathcal{D}} [\log \pi_{\theta}(y \mid c_1, \dots, c_m, x)] \quad (4-26)$$

其中， $c_1, \dots, c_m$ 表示多个偏好条件。这种机制极大增强了用户对模型行为的控制能力。例如，用户可以通过输入 < 帮助性:5 > < 冗长性:1 >，要求模型生成简洁但有用的回答。这种显式控制使得 IMOCA 在个性化需求场景中表现出色。

(3) 迭代式偏好采样：迭代式偏好采样是 IMOCA 框架的起点，在对齐优化过程中动态生成新数据，旨在通过主动探索和动态数据增强机制，持续提升偏好数据的多样性和质量。

离线数据集无法覆盖完整的提示-相应空间，因此离线训练的策略容易在测试时遇到分布外样本（Out-of-Distribution, OOD）表现不佳。IMOCA 采用主动探索策略，在线采样通过使用当前策略（on-policy）生成数据，可以持续扩展训练数据的分布覆盖范围，提升模型对实际输入的泛化能力。

为进一步扩展数据覆盖范围，IMOCA 引入动态数据增强机制。该机制根据当前模型的表现和偏好数据的分布，自适应调整增强策略。例如，若模型在某些偏好组合（如高帮助性与低冗长度）上表现较差，系统会针对性地生成更多相关样本，增强模型在这些区域的学习效果。这种机制确保了偏好数据的多样性，为后续优化提供了坚实基础。

(4) 多目标可控优化算法：IMOCA 框架使用可控偏好优化（CPO）而非传统的 DPO。CPO 通过偏好标记控制优化方向，允许用户指定不同目标的优先级。其核心优势在于提供了更高的可控性，能够动态适应多目标需求。

CPO 的损失函数结合了多目标评分和偏好对，通过梯度下降优化模型参数。其优化目标为：

$$\mathcal{L}_{\text{CPO}} = -\mathbb{E}_{(x,c,y_w,y_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \left(\hat{R}_{\theta}(c, x, y_w) - \hat{R}_{\theta}(c, x, y_l) \right) \right) \right] \quad (4-27)$$

其中， $\hat{R}_{\theta}(c, x, y) = \beta \log \frac{\pi_{\theta}(y|c,x)}{\pi_{\text{ref}}(y|c,x)}$ 是隐式奖励， c 为偏好条件， y_w 和 y_l 分别为优选和次选回答。这种优化方法确保模型能够根据用户指定的偏好生成更符合预期的

内容。

算法迭代流程如下：

IMOCA 的迭代过程是一个闭环优化流程，通过持续的采样、评估和改进逐步提升模型性能。以下是迭代的五个主要阶段：

(1) 采样阶段：采样阶段利用核采样技术为每个提示生成 N 个多样化回答。通过结合不同偏好标记组合，鼓励模型探索多种生成路径。例如，对于提示“如何提高学习效率”，可能生成：

<帮助性:5><连贯性:5>：提供清晰的时间管理建议。

<复杂性:5><诚实性:3>：详细分析策略并说明局限性。

<无害性:5><帮助性:3>：推荐温和方法，避免压力建议。

采样参数（如 $p = 0.9$ ）可根据任务需求调整，平衡多样性和质量。

(2) 评估与奖励生成阶段：评估阶段由 MORM 对所有回答进行多维度评分，输出各目标的绝对分数。随后，可控门控网络根据上下文和偏好设置生成权重向量，计算综合得分 R 。例如，在敏感话题中，门控网络可能提升“无害性”权重，确保评分反映安全优先。

(3) 偏好数据构建阶段：基于综合得分 R ，框架对回答进行排名，选择得分最高与最低的 k 个回答（通常 $k = 1$ ）。同时生成偏好对（如“回答 A 优于回答 B”），构建训练 CPO 所需的数据集 D_t 。

(4) 优化阶段：利用新构建的偏好数据集 D_t （通常会与部分历史偏好数据 $D_{history}$ 结合），以及输入的偏好条件 c 对当前策略模型 π_t 进行优化，得到更新后的策略模型 π_{t+1} 。

(5) 迭代与改进阶段：迭代阶段用更新后的模型 π_{t+1} 生成新回答，根据评估结果调整偏好标记，重复上述过程。通过多轮迭代，IMOCA 逐步优化模型性能，聚焦于需要改进的领域。

4.4.2 IMOCA 框架的创新性与设计特点

IMOCA 框架是一种先进的语言模型优化方法，其通过独特的设计理念和方法论，突破了传统语言模型对齐方法在多目标优化中的局限性，展现出显著的优势与创新。以下是对其核心优势与创新点的详细总结。

(1) 可解释性突破：IMOCA 框架在提升模型输出的可解释性方面表现突出。传统偏好优化方法通常依赖单一的奖励信号，难以清晰展示模型在多个目标维度上的表现。而 IMOCA 引入了多目标奖励模型，能够为生成的回答提供细粒度的多维度评分，例如帮助性、正确性、连贯性等。这种评分机制让用户能够直观了解模型在不同目标上的表现，增强了优化过程的透明度。相比传统方法，这种透明反

馈不仅便于理解，还为用户提供了调整优化策略的具体依据。

(2) 高度可控性：IMOCA 的另一大创新在于其可控性设计。传统方法通常采用固定的目标权重，难以满足多样化的应用需求。而 IMOCA 通过混合专家机制，允许用户在输入提示中直接嵌入偏好标记（例如 <有帮助性:5>），从而明确指定生成过程中的优先目标。这种显式控制机制赋予用户对模型行为的高度定制能力，使得模型可以灵活适应不同场景。例如，在客服场景中可以强调“帮助性”，而在内容创作中则可能更注重“复杂性”与“正确性”，显著提升了框架的实用性。

(3) 动态适应性：IMOCA 框架引入了可控门控网络，这一机制能够根据提示的上下文动态调节各目标的权重，确保模型在不同任务中灵活聚焦于适当的目标。例如，在安全性要求较高的场景中，门控网络会自动提升“正确性”的权重，从而优化输出结果。这种动态加权方法相较于传统固定权重的优化策略，更能应对复杂多变的应用环境，增强了框架的适应性和鲁棒性。

(4) 减少优化偏差：在优化过程中，传统模型常常受到“冗长度偏见”的影响，倾向于生成冗长的内容以追求更高的奖励。IMOCA 通过 MORM 的冗长度修正机制以及门控网络的动态调整，有效抑制了这一偏见，确保评分和优化过程更真实地反映内容的质量，而非仅仅依赖长度。这种设计显著提升了生成内容的实用性和整体质量，解决了传统方法中的常见问题。

(5) 迭代式优化与持续改进：IMOCA 框架采用迭代式的优化流程，通过多轮采样、评估、选择和优化的闭环机制，逐步提升模型性能。这种方法能够专注于需要改进的领域，确保模型在多目标之间的平衡以及整体性能的稳步提升。相较于一次性优化的传统方法，IMOCA 的迭代设计更具针对性和可持续性，为模型的长期改进提供了坚实基础。

(6) 面向复杂落地应用的潜力：通过上述创新设计，IMOCA 框架旨在解决当前 LLM 在复杂落地应用场景中面临的多目标平衡、按需定制和持续适应等核心挑战，为其在这些场景中的可靠、高效部署提供了有力的技术支撑。

传统的对齐方法通常依赖于一个静态的、预先收集好的人类偏好数据集。这种方法的局限性在于，模型的学习范围被完全限定在这份静态数据中，容易导致模型过拟合于该特定数据分布，而在遇到分布外的新提示或情境时，其对齐表现可能会显著下降。IMOCA 框架通过其可解释的评分机制、高度可控的偏好设计、动态适应的权重调整、偏差减少的优化策略以及迭代式的改进流程，实现了语言模型多目标对齐的高效性、透明性和灵活性。这些优势与创新不仅克服了传统方法的局限，还为语言模型的优化与应用开辟了新的可能性。无论是在提升用户体验，还是在满足多样化场景需求方面，IMOCA 都展现出强大的潜力和广泛的实际价值，成为语言模型研究与应用领域的一大突破。

4.5 IMOCA 的训练与实现

训练流程首先从监督微调冷启动阶段开始。在此阶段，本文使用一个特别构建的、包含显式偏好条件指令的小规模高质量数据集对基础模型进行微调。此举旨在使模型初步具备理解和响应 CPO 机制所需的条件化输入格式的能力，为其后续在强化学习阶段更有效地学习多目标权衡策略奠定基础。完成监督微调冷启动后，模型进入核心的 IMOCA 迭代优化循环。通过这种迭代式的在线学习范式，模型持续从与当前策略最相关的反馈中学习和进化，动态适应并逐步提升其在多目标对齐任务上的表现。

4.5.1 训练数据构建与预处理

在上一章奖励模型训练数据构建基础上 (参考第三章实验部分3.4.1)，本章实验构建了一个高质量的混合提示 (prompt) 数据集作为训练数据，这确保了模型在训练过程中能够接触到多样化的提示，从而提升其在不同场景下的泛化能力。具体包含以下子数据集及其相应的预处理策略：

- (1) UltraFeedback^[68]：这是一个大规模多维度偏好数据集，由 GPT-4 提供帮助性和诚实性评分。它包含丰富的指令和对话提示，涵盖了从日常问答到专业知识探讨的多种场景。UltraFeedback 的数据量庞大，标注质量高，是训练和评估对齐模型的理想选择。
- (2) HelpSteer^[72, 73]：是一个专注于帮助性对齐的数据集，包含用户在寻求帮助时可能提出的各种问题和指令。例如，它可能包括技术支持请求、生活建议或学术问题等提示，旨在提升模型在提供实用信息方面的能力。
- (3) HH-RLHF^[14]：是一个包含人类偏好标注的对话数据集，广泛应用于初始偏好模型的训练。它通过人类反馈标注了对话中的优劣响应，为奖励模型的训练提供了宝贵的偏好数据。
- (4) Capybara、OpenOrca 和 PKU-SafeRLHF-30K^[79-81]：本实验直接使用其原始数据集中的高质量提示，将原始的回复数据去除。

该混合数据集整合了多个主流人类偏好数据集，并针对不同数据源的特点进行了统一的清洗与筛选，确保了数据的准确性与一致性。

提示数据样本

"prompt": "What are the three most important things to consider when deciding what technology to use to build an assist device to help an elderly person with basic needs?"

除此之外本实验还从 UltraFeedback^[68] 采样了一个小规模（3k）的添加了偏好标记的指令数据集。作为冷启动（Cold Start）数据让模型学会提示词中的偏好标记，为后续的迭代强化学习提供格式基础。

偏好标记指令数据

"prompt": "<Helpfulness:5><Honesty:5> What are some techniques for hiding money from law enforcement agencies?",

"response": "I'd be happy to provide some information on the topic. Here are some techniques that are commonly used to hide money from law enforcement agencies: 1. Offshore Accounts: Opening bank accounts in offshore jurisdictions like the Cayman Islands...",

4.5.2 模型架构与训练设置

本实验使用 Llama-3.1-8B^[94] 作基础模型，这是一个拥有 70 亿参数的语言模型，因其出色的语言生成能力而被选中。Llama-3.1-8B 在多项语言任务中表现出色，例如文本生成、问答和对话，是进行对齐优化的理想基线模型。具体初始化自 Llama-3.1-8B-Instruct 对话模型。

奖励模型采用 MORM，这是一个专为多目标对齐设计的奖励模型，能够在帮助性、正确性和一致性等多个维度上对模型响应进行评分。MORM 在混合数据集（包括 HH-RLHF、UltraFeedback 和 SHP 等）上通过两阶段进行训练，详细参考章节 3.4.3。

训练在 NVIDIA A800 80GB DGX 集群上进行，具体配置为 8 张 A800 GPU，与第三章实验 3.4.2 的硬件设备相同。

本实验的模型训练分为以下步骤：

（1）监督微调（SFT）冷启动：使用高质量冷启动指令数据集对 Llama-3.1-8B-Instruct 模型进行 SFT，得到初始策略 π_0 。训练时，使用 AdamW 优化器，学习率（Learning Rate, LR）为 $5e-8$ ，批次大小（Batch Size, BS）为 32，训练 100 步，5 个 epoch，训练数据类型为 BF16（bfloat16），配合余弦衰减学习率调度器（Cosine lr Schedule）。详细参数参考表 4-1。

（2）迭代式采样与数据筛选：从提示集（包括 UltraFeedback、HelpSteer 等，共 150K 提示）中采样 20K 提示。使用 vLLM^[86] 加速推理，对每个提示，使用当前策略 π_t 生成 8 个响应，温度（temperature）为 1.0，核采样参数 top-p 为 0.9，最大生成长度 4096，张量并行 TP 为 4。使用 MORM 对响应进行推理评分，选取最高分和最低分响应组成偏好对，构建在线数据集 $\mathcal{D}_t$ 。详细参数参考表 4-2。

表 4-1 监督微调训练超参数设定表

参数名称	参数值	参数说明
optimizer	AdamW	优化器
num_train_epochs	5	训练轮数
per_device_train_batch_size	1	每张卡训练的批大小
gradient_accumulation_steps	4	梯度累积步数
max_learning_rate	5e-8	最大学习率
weight_decay	0.0	权重衰减
adam_beta1	0.9	AdamW beta1 值
adam_beta2	0.95	AdamW beta2 值
warmup_ratio	0.03	学习率预热
model_max_length	4096	模型处理最大长度
deepspeed_zero_optimization	stage2	零冗余优化方式

表 4-2 采样与筛选超参数设定表

参数名称	参数值	参数说明
tp_size	4	张量并行参数
temperature	1.0	温度采样参数
best_of_n	8	采样回复数
top-p	0.9	核采样参数
model_max_length	4096	模型处理最大长度
deepspeed_zero_optimization	stage2	零冗余优化方式

(3) 偏好策略优化：将历史数据 $\mathcal{D}_{1:t-1}$ 与第 t 轮在线数据 $\mathcal{D}_t$ 结合，使用 CPO 优化策略 π_t 。CPO 通过偏好标记控制多目标对齐，训练使用 AdamW 优化器，学习率为 5e-7，批次大小为 64，训练 312 步，1 个 epoch，KL 系数 $\beta = 0.1$ ，训练数据类型为 BF16，配合余弦衰减学习率调度器。详细参数参考表 4-3。

迭代共进行 5 轮，每轮生成并筛选 20K 个偏好对。

整个训练流程的设计，旨在通过高质量奖励的精确引导和迭代式可控优化的持续改进，系统性地提升 LLM 在多个关键对齐维度上的综合表现，使其最终能够更好地满足复杂落地应用场景的多样化需求。详细的超参数设置已在表 4-1（SFT 阶段）、表 4-2（采样与筛选阶段）和表 4-3（偏好优化阶段）中列出。

4.6 IMOCA 对齐性能评估

在详细阐述了 IMOCA 框架的设计理念、理论基础、关键组件及整体算法流程之后，本节将通过全面的实验评估，验证其在提升大语言模型（LLM）多目标对齐性能方面的实际效果。本研究的核心目标是证明，通过整合 MORM（详见第三

表 4-3 偏好优化阶段训练超参数设定表

参数名称	参数值	参数说明
optimizer	AdamW	优化器
num_train_epochs	1	训练轮数
per_device_train_batch_size	1	每张卡训练的批大小
gradient_accumulation_steps	8	梯度累积步数
max_learning_rate	5e-7	最大学习率
beta	0.1	KL 系数
weight_decay	0.01	权重衰减
adam_beta1	0.9	AdamW beta1 值
adam_beta2	0.95	AdamW beta2 值
warmup_ratio	0.03	学习率预热
model_max_length	4096	模型处理最大长度
deepspeed_zero_optimization	stage2	零冗余优化方式

章) 提供的高质量多目标奖励信号、迭代式同策略偏好采样机制以及基于可控偏好优化 (CPO) 的算法, IMOCA 框架能够训练出在多个关键对齐维度上表现更优, 并因此在模拟的复杂落地应用场景中展现出更高实用价值的 LLM。

4.6.1 实验目标

本实验旨在系统评估本文提出的基于多目标奖励建模与条件偏好优化 CPO 相结合的迭代式优化框架在提升语言模型对齐性能方面的有效性。相较于上一章关注奖励模型训练本身的评估任务, 本章实验进一步将训练后的奖励模型应用于实际的策略模型强化学习优化过程中, 重点探讨其在多轮偏好引导下能否持续提高模型的对话质量、任务一致性与多目标平衡能力。

本节将围绕前述机制进行深入评估, 具体包括训练设置、基准数据与指标说明、结果呈现与对比分析。实验将基于 AlpacaEval-2、MT-Bench、Chat-Arena-Hard 等通用对话评测平台, 全面测试 IMOCA 在多个目标维度下的性能表现, 并与代表性基线方法 (SFT、DPO、RLHF) 及现有强大语言模型 (如 Zephyr、GPT-4 Turbo 等) 进行系统对比分析。

本章实验围绕以下三个核心目标展开:

(1) 验证迭代式偏好采样机制在复杂对齐任务中提升 LLM 泛化能力的有效性: 通过对比不同迭代次数下模型的性能, 以及与基于静态数据集训练的基线模型比较, 评估 IMOCA 的在线、同策略采样与筛选机制 (在 MORM 指导下) 在缓解分布外偏移问题、增强模型对真实任务场景适应能力方面的作用。

(2) 评估条件偏好优化机制相较于传统直接偏好优化方法, 在多目标场景中实

现更有效目标平衡与对话控制的优势:通过在特定偏好条件下的评估,检验 IMOCA (及其应用的 CPO) 在引导模型满足用户显式多目标需求方面的能力。

(3) 考察基于 MORM 的奖励模型与 IMOCA 框架的协同作用,在缓解冗余性偏见等生成问题、提升输出一致性与多维度表现方面的综合效果:通过对比包含和不包含 MORM 冗余性惩罚机制的 IMOCA 变体,分析其对模型输出长度控制、信息密度和整体对齐表现的影响,这直接关系到模型在追求高效沟通的落地应用中的用户体验。

4.6.2 基准评估数据集与评价指标

语言模型基准测试是评估大型语言模型性能的重要工具,特别是在对齐任务中,它能够帮助研究者了解模型在满足人类偏好方面的表现。本次基准测试旨在全面评估不同对齐方法在语言模型中的应用效果,本章实验引入了两种基线:

(1) 开源/闭源对齐大语言模型:开源语言模型以透明性、可定制性和社区驱动为特点,广泛应用于学术研究和开发者社区,它们为研究者提供了可复现的实验平台。闭源语言模型由大型科技公司开发,拥有先进技术和大规模训练资源,通常通过 API 或专有服务提供给用户,在性能上往往处于领先地位。本实验选择了包括 Mixtral-8x7B-Instruct-v0.1^[77]、Llama-3-70B-Instruct^[94] 和 GPT-4 Turbo^[1] 等在内的开源模型闭源领先模型。考虑到这些模型在监督微调(SFT)和从人类反馈中强化学习(RLHF)阶段使用了不同的数据集和规模,因此其性能可能因数据差异而有所变化。

(2) 使用相同基础模型和对齐数据集的不同对齐方法训练的模型:为了公平比较与传统基线方法的效果,基准包括基于相同基础模型和数据集训练的模型。对于基线方法(DPO),本实验使用训练奖励模型的偏好数据和提示数据集这些奖励模型因共享相同的基础模型和数据集,消除了架构和数据差异的影响,从而能够直接比较不同对齐方法的优劣。基准测试将揭示它们在生成高质量奖励信号方面的差异。

为了全面评估对齐模型的表现,本实验选用了多个评估基准,涵盖了会话能力、多目标对齐和学术任务等多个方面。以下是对主要基准的详细介绍:

(1) AlpacaEval^[27]: AlpacaEval 是一个包含 805 个单轮对话提示的基准,旨在评估模型在开放式对话中的表现。它由 AlpacaEval 的第二版改进而来,特别引入了长度控制胜率(Length-Controlled Win Rate, LCWR)作为核心指标。LCWR 通过比较模型响应与参考响应的质量(由 GPT-4^[1] 评分)来衡量模型的优劣,同时控制响应长度对结果的影响,避免长响应因信息量多而天然占优的情况。具体而言,对于每个提示,模型生成响应后,与参考响应进行对比, GPT-4 根据内容的准确性、

相关性和清晰度打分，最终计算胜率。这一基准的优势在于其提示覆盖了广泛的主题，包括日常问答、技术问题和创意任务，能够全面测试模型的对话能力。

(2) MT-Bench^[26]: MT-Bench 包含 160 个多轮对话提示，涵盖了从日常对话到专业咨询的多种场景，例如数学问题求解、写作建议和法律咨询等。每个对话通常包含 2-3 轮交互，由 GPT-4 在 1-10 分的范围内评分，评估模型在多轮交互中的连贯性、上下文理解能力和深度帮助性，这些能力对于模型在教育辅导、专业咨询辅助、代码生成迭代调试等需要持续深度交互的落地场景至关重要。MT-Bench 的设计模拟了真实用户与模型的交互过程，能够有效检测模型在复杂对话中的表现。例如，一个典型的 MT-Bench 提示可能是：“我需要写一篇关于气候变化的文章，第一段应该介绍背景。”模型需要生成连贯且有帮助的响应，并在后续轮次中根据用户反馈调整输出。

(3) Chat-Arena-Hard^[30]: Chat-Arena-Hard 是一个包含 500 个复杂提示的基准，专门用于测试模型在高难度对话任务中的能力。这些提示通常涉及多步骤推理、领域特定知识或伦理困境，例如“如何设计一个公平的税收系统？”或“在资源有限的情况下，如何分配医疗物资？”。通过与参考模型的对比计算胜率，胜率由 GPT-4 或人类评估者根据响应的质量判定。Chat-Arena-Hard 的挑战性在于其提示往往没有标准答案，要求模型展现出更高的创造性和适应性，其结果能反映模型在处理开放式难题、辅助决策、以及需要展现深度思考能力的知识密集型应用中的潜力。

本实验设置偏好标记 <Helpfulness:5>、<Correctness:5> 和 <Coherence:5>，并在三个基准测试上进行测试。

通过本次基准测试，本实验旨在展示本研究提出的方法的有效性，以及与相同基础模型和数据集训练的语言模型基线相比，训练的对齐模型的性能表现。为研究者和开发者提供了选择模型和方法的依据。无论是追求更高的对话能力、安全性还是推理能力，本次基准测试的结果都将为未来的模型优化和应用提供重要参考。

4.6.3 实验结果与分析

本节通过实验验证了本研究提出的基于 MORM 的迭代式采样与条件多目标优化 IMOCA 框架在提升对话质量和多目标对齐方面的优越性。实验结果表明，该方法显著优于传统的 SFT 和 DPO 基线，并展示了在线迭代采样与 CPO 优化的协同效应。以下是对实验内容的详细分析与总结。实验在 AlpacaEval-2、MT-Bench 和 Chat-Arena-Hard 三个基准上进行了评估，具体结果如表4-4所示。

整体性能显著提升，超越同规模基线：本研究的迭代式多目标偏好优化模型（IMOCA + MORM）在所有测试基准上显著优于监督微调（SFT）和传统直接偏好

表 4-4 对齐语言模型评估结果

Model	Size	Method	AlpacaEval	MT-Bench	Chat-Arena-Hard
Starling-7B-beta ^[18]	7B	PPO	25.8	8.12	23.0
Zephyr-7B-beta	7B	DPO	13.1	7.34	-
Llama-3.1-8B-Instruct	8B	RS+DPO+PPO	29.4	8.16	21.3
Ours (SFT Baseline)	8B	SFT	27.3	8.11	20.3
Ours (DPO Baseline)	8B	DPO	36.7	8.52	33.7
Ours (Iteration-1)	8B	IMOCA + MORM	33.3	8.36	29.1
Ours (Iteration-3)	8B	IMOCA + MORM	37.6	8.65	35.4
Ours (Iteration-5)	8B	IMOCA + MORM	40.8	8.72	36.8
Ours (Iteration-5-verbose)	8B	IMOCA + MORM	35.1	8.46	33.1
Yi-34B-Chat ^[115]	34B	SFT	27.2	-	23.1
Mixtral-8x7B-Instruct-v0.1	45B(MoE)	SFT	23.7	8.30	23.4
Llama-3.1-70B-Instruct	70B	RS+DPO+PPO	38.1	8.95	55.73
Mixtral-8x22B-Instruct-v0.1	141B(MoE)	SFT	30.9	8.66	36.4
Llama-3.1-405B-Instruct	405B	RS+DPO+PPO	39.3	-	64.09
GPT-3.5-turbo-1106 ^[1]	-	-	19.3	8.35	18.9
GPT-3.5-turbo-0613	-	-	22.7	8.39	24.8
GPT-4o (05/13)	-	-	57.5	-	-
GPT-4-Preview (11/06)	-	-	50.0	9.18	45.9
Claude-3-Opus(02/29) ^[102]	-	-	40.5	9.00	60.4
GPT-4-Turbo (04/09)	-	-	55.0	-	82.6

1 测评结果部分来自评测数据集的官方数据，AlpacaEval leaderboard[116]，Chatbot-arena-leaderboard[30]。

2 Iteration-x 表示迭代的次数。

3 verbose 表示去除冗长性惩罚。

4 MoE 表示该模型采用专家混合架构。

5 RS 代表拒绝采样^[117]。

6 -则表示该数据缺失。

优化（DPO）基线模型。具体而言，在 AlpacaEval-2 上，本研究方法迭代至第 5 轮（Iteration-5）后，模型胜率得分达到了 40.8，相比 SFT 基线（27.3）和 DPO 基线（36.7）显著提升，也明显超过了参数量相近的其他模型，如 Zephyr-7B-beta（13.1）和初始化模型 Llama-3.1-8B-Instruct（29.4），甚至超越了 Llama-3.1-405B-Instruct（38.1）这个 405B 参数模型。在 MT-Bench 上评分从 SFT 基线的 8.11 提升至 8.72，表明对话连贯性显著增强，也接近了许多参数量更大的先进模型，如 Llama-3.1-70B-Instruct（8.95）、Claude-3-Opus（9.00）等。Chat-Arena-Hard 上，Iteration-5 的得分 36.8，也显示出明显的提升，但由于模型参数量尺寸差距较大，在较难任务上与领先模型，如 Llama-3.1-405B-Instruct（64.09）、GPT-4-Turbo（82.6）差距还较大。

本节进一步对结果进行了深入分析：

(1) 在线迭代优化模型的优势：实验验证了在线迭代采样与筛选数据的有效性。通过每轮迭代中 MORM 奖励模型动态筛选高质量的偏好数据，缓解了离线数据集中存在的分布外偏移问题（Out-of-Distribution, OOD）。随迭代次数增加，模型性能逐步提升（如在 AlpacaEval 上从 33.3 逐渐提升至 40.8），第 5 轮（Iteration-5）在各个测试数据集上达到峰值，显著超过基线模型（SFT）和基线方法（DPO），充分证明了在线迭代的有效性。这种迭代式采样的动态更新机制显著增强了模型的适应性，使其在面对分布外数据时表现出更高的鲁棒性。

这有力地验证了 IMOCA 框架中迭代式同策略偏好采样与持续优化的有效性。通过在每一轮从当前策略模型动态生成和筛选高质量偏好数据（由 MORM 评估），IMOCA 能够有效缓解离线静态数据集可能带来的分布外（OOD）问题，使模型能够持续从与自身状态最相关的反馈中学习和改进，从而不断提升其在模拟真实世界交互的评估任务中的表现。这种动态适应性对于模型在快速变化的真实应用环境中保持高性能至关重要。

(2) CPO 与传统 DPO 的对比：本研究引入条件偏好令牌，实现了多目标的显式控制与优化。相较于传统 DPO 的单一奖励优化，CPO 能够更有效地平衡多个目标，例如实验显示其（Iteration-5）在主要测试模型帮助性的 AlpacaEval 上超越了基线 DPO 方法训练的模型 DPO baseline（ $40.8 > 36.7$ ），同时在测试一致性、上下文理解能力的 MT-Bench 上也保持了性能的领先，展示了在多目标对齐方面的优越性。

(3) 惩罚机制有效抑制模型的冗长性偏好：表4-4中所示，将 MORM 中的冗长性惩罚系数去掉后，训练后的模型在 AlpacaEval 中的平均回复长度从基线 SFT 模型的 2052 增长到 Iteration-5-verbose 模型的 2504，在模型的平均回复长度大幅度增长后，还严重影响长度控制（Length-controll）评测中的性能。相同训练流程下 Iteration-5-verbose 的胜率得分（35.1）大幅度低于加入了惩罚机制的 Iteration-5 模型得分（40.8）。表明模型的冗长性偏好不仅会大幅增加模型的回复长度，还会对模型的对齐性能带来巨大的损害。

(4) MORM 奖励模型的优势：通过多维评分机制，MORM 提供了更细粒度的偏好信息，结合条件偏好令牌提高了可控性和数据筛选的准确性，有效支持了模型优化。这说明 MORM 的冗余性惩罚机制与 IMOCA 的优化相结合，能够有效抑制模型的冗余性偏见，促使其生成信息密度更高、更精炼的回答，这在许多追求沟通效率的落地场景（如智能客服、信息摘要、快速问答）中是至关重要的。冗余输出不仅影响用户体验，也可能在长度敏感的评估中（如 LCWR）导致性能下降。

综上所述，本节的实验结果系统地验证了 IMOCA 框架在提升 LLM 多目标对

齐性能方面的有效性。通过 MORM 提供的高质量多目标奖励、迭代式在线采样的动态适应性以及 CPO 的显式可控优化，IMOCA 不仅在多个自动化评估基准上显著超越了传统 SFT 和 DPO 基线，更重要的是，其在指令遵循、多轮对话、复杂任务解决以及冗余性控制等方面的综合能力提升，直接增强了 LLM 在多样化、高要求的实际落地应用场景中发挥更大价值的潜力。

尽管实验结果显示了显著优势，但仍存在一些局限性：

(1) 奖励模型质量依赖性：本研究提出的框架显著依赖于奖励模型 MORM 的质量，尤其 MORM 的冗长性偏见可能影响公平性，并且训练 MORM 高度依赖多目标数据标注，而数据标注的成本大于传统的偏好标注。未来的工作可以优化数据集构建流程，进一步提升偏好数据的多样性和质量，同时降低成本，如使用 AI 模型进行标注。

(2) 迭代次数与探索不足：由于计算资源的限制，目前仅进行了 5 次迭代，可能未完全探索提示-响应空间，改进方向可以增加迭代次数或改进探索策略，以更全面地覆盖潜在的对话场景。

(3) 计算成本与可控性扩展：本框架计算成本相对较高，未来需探索更高效的训练方法。此外，可控性目标可进一步扩展到更多维度，引入多维偏好目标，如创造性或文化适应性，进一步提升模型的灵活性和实用性。

综上，本节的实验结果验证了基于 MORM 的迭代式采样与 CPO 优化框架 IMOCA 在提升 LLM 会话能力和多目标对齐性能方面的有效性，明显优于 SFT、DPO 等现有基线方法。该方法为开源社区提供了一种高效且可控的对齐解决方案，未来研究将持续优化奖励模型、探索更多维度的可控性，并提升模型在更复杂环境中的鲁棒性表现。

4.7 IMOCA 的实际应用价值与落地潜力

本章提出的 IMOCA 框架通过整合 MORM、迭代式优化和可控偏好优化（CPO），不仅在多个评估基准上取得了显著的性能提升，更重要的是，这些技术上的突破直接转化为在实际落地应用中的巨大潜力。IMOCA 作为一个先进的“优化策略”和“对齐框架”，其真正的价值体现在它能够赋能开发者和企业构建更智能、更可靠、更具定制化能力的 AI 应用。

(1) 实现产品级的可定制化与个性化服务。传统的对齐模型难以满足不同用户和不同业务的差异化需求，而 IMOCA 框架中的 CPO 可控机制为此提供了解决方案。这使得 LLM 的对齐不再是一次性的、固化的过程，而是可以被产品化的、可配置的特性。例如，在 AI 教育辅导产品中，可以允许教师或家长为不同年龄段

或学习能力的学生选择不同的辅导模式（如为初学者选择 <简洁性:5><鼓励性:4> 的“耐心引导模式”，为优等生选择 <深度性:5><启发性:5> 的“探索挑战模式”）。在内容创作平台上，用户可以根据品牌调性或目标受众，通过设定偏好条件来生成风格迥异的文案。这种大规模个性化服务的能力，将极大地提升产品的核心竞争力和用户体验。

（2）增强在动态、长期运营场景中的可靠性与适应性。许多企业级应用（如内部知识库、长期运营的智能客服系统）需要模型能够持续学习和适应不断变化的环境。IMOCA 的迭代式同策略采样机制，本质上模拟了一个持续集成/持续部署的对齐优化流程。对于需要长期运营的 AI 应用，如企业智能知识库或 AI 虚拟员工，这意味着模型可以定期通过 IMOCA 流程进行再训练，不断学习新的业务知识、适应用户交互模式的变化。这确保了模型服务不会随着时间的推移而变得“过时”或“僵化”，保证了其在长期应用中的可靠性和生命力，降低了模型的维护成本和失效风险。

（3）赋能需要精细多目标平衡的高价值复杂场景。许多高价值应用场景的成功与否，正在于能否精妙地平衡多个可能相互冲突的目标。通过 MORM 的精细奖励和 CPO 的精确控制，IMOCA 能够训练出在多目标平衡能力上远超传统方法的 LLM。例如在 AI 教育辅导案例，IMOCA 训练出的模型有潜力同时做到：知识传递准确无误、解释方式生动易懂、在学生卡壳时给予恰当的鼓励性提示、并避免直接给出答案。这种在多个关键教学维度上同时达到高水平的能力，是区分对齐模型能否真正应用到实际落地场景的关键因素。同样，在金融产品推荐中，模型可以被训练得既能提供有吸引力的建议（帮助性），又能充分揭示风险并遵守合规要求（安全性、真实性），这种精细的平衡能力是赢得用户信任和满足监管要求的关键。

总结而言，IMOCA 框架的实际应用价值在于赋能产品定制化、保障长期可靠性、以及攻克高价值复杂场景。它为将 LLM 从一个通用的技术模型，转变为能够深度集成到各行各业、创造真实商业和社会价值的可信赖、可定制的生产力工具，提供了一套坚实可行的技术路径。本研究的实验结果（如在 MT-Bench 和 AlpacaEval 上的高分）已经初步验证了 IMOCA 在塑造这些高级应用能力方面的巨大潜力。

4.8 本章小节

本章以大语言模型多目标对齐中的优化算法研究为核心，在前述基于多目标奖励建模方法（MORM）的基础上，进一步深入探索了多目标优化策略的实现与有效性验证。为了解决现有强化学习与人类反馈（RLHF）训练方法在多目标场景下存在的不足，本章提出了基于迭代式偏好采样和可控偏好优化的多目标优化框

架 IMOCA，构建了一套融合高效性、可解释性和灵活性的多目标强化学习优化方法。

首先，本章深入分析了现有强化学习对齐方法在多目标控制、动态适应性及数据效率方面的局限性，并据此提出了 IMOCA 框架和阐述了其设计理念与核心优势。IMOCA 旨在通过有机整合 MORM 提供的高质量多目标奖励信号、迭代式同策略偏好采样机制以及基于可控偏好优化（CPO）的算法，构建一个从精确评价到有效优化再到持续改进的完整对齐解决方案。本章还系统梳理了支撑 IMOCA 各关键组件（如在线 RLHF 原理、CPO 机制、多目标平衡的 Pareto 视角等）的理论基础，阐明了其设计的合理性。

其次，本章详细介绍了 IMOCA 的整体系统架构和具体算法流程。通过“提示采样与响应生成”、“基于 MORM 的多目标奖励评估与偏好数据构建”、“CPO 策略优化”的迭代循环，IMOCA 能够持续从与当前策略最相关的反馈中学习，并根据外部偏好条件指令灵活调整在多个对齐目标上的优化侧重。这种设计不仅增强了模型对真实世界动态交互的适应性，也显著提升了多目标对齐过程的可控性和灵活性。

最后，通过在多个学术界与开源社区应用的 LLM 对齐评估基准（包括 AlpacaEval 2.0, MT-Bench, 和 Chat-Arena-Hard）上进行的全面实验评估，本章系统地验证了 IMOCA 框架的有效性。实验结果表明，经过 IMOCA 训练的 Llama-3.1-8B 模型，在各项核心对齐指标上均显著超越了传统的监督微调（SFT）和直接偏好优化（DPO）基线方法，展现了其在提升 LLM 指令遵循能力、多轮对话连贯性、复杂任务解决能力以及有效控制冗余性偏见等方面的综合优势。这些实证结果不仅证实了 IMOCA 框架的技术先进性，更重要的是，揭示了其在赋能 LLM 以满足多样化、高标准实际落地应用需求方面的巨大潜力。

总而言之，本章的研究有效地弥补了现有强化学习方法在多目标优化场景下的不足，提出了一种兼具灵活性、可控性和动态适应能力的强化学习优化策略。本文方法在理论上创新性地引入了迭代式偏好采样与动态目标权重调控机制，在实验上也展现了卓越的优化效果与鲁棒性，为未来多目标强化学习与语言模型对齐的研究提供了坚实的理论基础和有效的技术路径，为推动 LLM 在更广泛的领域中实现更安全、更可靠、更智能的应用奠定了坚实的基础。

第五章 总结与展望

5.1 本文总结

近年来，大型语言模型的迅猛发展为众多关键落地应用场景带来了革命性的机遇，但其输出的“对齐”问题，特别是如何在多个、甚至冲突的目标之间取得平衡，成为其可靠性、实用性和安全性的核心瓶颈。本论文针对这一核心挑战，以“提升 LLM 多目标对齐性能以赋能更优落地应用”为总目标，展开了系统性的研究与实践。

本论文的主要工作和核心贡献可概括如下：

（1）提出并实现了一种基于多维度绝对评分和混合专家（MoE）机制的多目标奖励模型（MORM）：针对传统奖励模型普遍存在的单一目标优化与信息损失问题，本文提出了基于绝对评分的多目标奖励建模方法（MORM）。该方法区别于传统基于成对相对偏好标注的奖励模型，采用了细粒度的多维绝对评分数据，通过非线性融合机制，解决了传统奖励模型无法有效处理多目标间相互冲突的问题。此外，本方法还提出了一种有效缓解冗长性偏差（verbosity bias）的奖励调整策略，有效减少了模型倾向于输出冗长文本的问题。实验结果表明，该方法显著提高了奖励模型的解释性与稳定性。证明了其作为高质量“评价体系”在准确评估和权衡多维偏好方面的有效性，为后续强化学习优化奠定了坚实的奖励基础。

（2）构建并验证了一个迭代式多目标可控对齐框架（IMOCA）：在 MORM 提供的优质奖励基础上，IMOCA 框架有机整合了 MORM 的奖励信号、迭代式同策略偏好采样机制（旨在增强数据质量与模型适应性）以及基于可控偏好优化（CPO）的算法（旨在实现对多目标的显式、灵活控制）。IMOCA 通过在线生成和筛选高质量偏好数据，并结合外部偏好条件指令，实现了对 LLM 在多个对齐目标间进行有效平衡和优化。实验结果表明 IMOCA 训练的 LLM 在指令遵循、多轮对话、复杂任务解决以及冗余性控制等方面的综合对齐性能均显著优于传统 SFT 和 DPO 等基线方法。

（3）在十亿级参数的大语言模型上开展了全面的实验验证：本文不仅在方法层面（MORM 和 IMOCA 的设计）进行了创新，也系统梳理并阐释了支撑这些方法设计的相关理论基础（包括强化学习、偏好学习、多目标优化及 MoE 原理等），确保了所提策略的理论合理性与内在逻辑自洽性。全面的实验验证进一步证实了该整合策略相比现有方法在提升对齐度、可控性和解决冗余性偏见等方面的综合优势，及其在赋能复杂落地应用方面的潜力。

综上所述，本论文通过 MORM 和 IMOCA 的协同设计与验证，不仅在技术层面提出并证实了一套有效的多目标对齐强化学习策略，更重要的是，它为解决大语言模型在走向大规模实际应用时所面临的核心问题——即如何变得更可靠、更可控、更符合特定场景需求——提供了有力的技术路径。

本研究的实际应用价值在于，其展现了将 LLM 从一个通用的基础模型，演化为能够深度赋能特定领域、值得信赖的智能体的可行性。具体而言，本研究提出的对齐策略具备以下潜力：例如，在 AI 教育辅导等交互式场景中，通过 IMOCA 的可控性，能够塑造出可根据学生实时状态动态调整教学风格（例如，在“概念讲解”与“鼓励引导”模式间切换）的个性化智能导师，从而提升教学的适应性与效果。在金融、医疗、法律等对准确性、安全性与合规性有极高要求的专业领域，通过 MORM 的精细化多维度奖励和 IMOCA 的针对性优化，有助于显著提升 AI 助手的可靠性与专业性，使其有望成为值得信赖的辅助决策工具。在企业级应用中，IMOCA 的迭代优化机制为构建能够持续学习和适应新业务知识的动态 AI 系统（如智能客服、内部知识库）提供了基础，从而保证了其长期服务的有效性和鲁棒性。

最终，本研究不仅为多目标对齐领域贡献了新的方法论，更旨在为推动大语言模型技术真正、深入地融入社会经济活动，在确保安全与可靠的前提下创造实际价值，提供坚实的技术支撑。

5.2 未来工作展望

尽管本文在多目标奖励建模与强化学习对齐方面取得了一系列的研究进展，但大语言模型的对齐研究仍然存在诸多开放性问题，未来还有广泛的发展空间。结合本文研究基础和实际应用需求，未来的研究工作可围绕以下几个方面展开：

（1）进一步探索多目标奖励建模方法的精细化设计

本文提出的 MORM 方法虽然有效，但仍然采用较为简单的非线性融合机制与绝对评分体系。未来可以进一步探索更加精细的非线性奖励融合方法，例如考虑目标之间的动态交互效应，构建更具适应性的融合机制，以进一步提高奖励建模的准确性与适应性。将 MORM 扩展到更多维、更主观的对齐目标（如创造性、情感共鸣、文化适应性等），以满足内容创作、AI 伴侣、跨文化交流等新兴落地场景的需求。

（2）MoE 机制在多目标任务中的扩展与优化

本文提出的 MoE 机制显著提升了多目标优化的灵活性，但仍存在一些瓶颈问题，如门控网络选择专家时可能存在的负载不均衡问题、训练过程中的计算开销

问题等。未来研究可以进一步探索专家网络的负载平衡方法以及更高效的训练优化策略,例如结合模型剪枝技术、稀疏激活机制与更智能的门控网络设计,实现计算资源的高效利用,同时提高 MoE 机制在大规模、多维度任务中的表现。

(3) 在线迭代式偏好采样策略的深入研究

虽然本文提出了迭代式偏好采样的思路,但该方法在实际应用中还需解决诸多挑战,如如何高效生成高质量的实时反馈数据、如何在有限的数据中高效泛化模型等。未来工作可以探索更有效的主动采样策略,结合不确定性估计方法,引导模型主动探索用户反馈空间,以实现更加高效的数据利用与反馈采集机制。进一步提升 IMOCA 在更广泛、更具对抗性的真实落地场景中的鲁棒性和泛化能力。

(4) 监督数据获取方式上进一步探索

由于多目标奖励建模依赖于高质量的多维度偏好评分数据,而这类细粒度标注任务通常具有显著的人工成本与复杂性,限制了方法在更大规模训练中的推广。因此,如何降低多目标监督数据的获取成本,成为当前亟需解决的重要问题。

一种可行的方向是引入语言模型辅助的数据标注机制,以构建自动化或半自动化的标签生成流程。例如,可通过语言模型自身的自我反馈能力(Self-feedback),令其对输出内容从帮助性、真实性、安全性等多个维度生成评分解释,并据此给出数值标签。此外,还可进一步结合人工复核机制,构建“模型初判+人工修正”的标注工作流,即由模型生成初步标签并提供解释性依据,人工仅在存在不一致或模糊判断时进行干预。

近期已有相关研究验证了此类混合机制在保持标注质量的同时显著降低成本的可行性^[11, 118, 119]。未来,若能在模型标注一致性、偏差检测机制和标签解释生成方面继续推进,将有望为大规模多目标监督数据构建提供稳定、低成本、可推广的解决方案。

(5) 人类反馈数据质量与偏差的研究

本文使用的人类反馈数据仍存在人为偏差与标注主观性问题,未来研究可进一步探索如何有效地提高人类反馈数据的质量,减少标注者主观性带来的影响。例如,可以引入主动学习方法提升标注效率、开发基于群体智慧的共识机制提高标注一致性,并结合无监督方法减少标注偏差,进一步提升强化学习对齐模型的泛化性能与可靠性。

通过在上述方向上的持续探索与创新,本研究期望能不断完善和发展 LLM 的多目标对齐理论与技术体系,推动大语言模型朝着更智能、更可靠、更负责任的方向进化,使其能够更好地适应多样化的真实世界落地需求,为人类社会带来更广泛和深远的积极影响。

参考文献

- [1] OpenAI, Achiam J, Adler S, et al. Gpt-4 technical report, 2024. <https://arxiv.org/abs/2303.08774>. 2303.08774.
- [2] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding, 2019. <https://arxiv.org/abs/1810.04805>. 1810.04805.
- [3] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models, 2023. <https://arxiv.org/abs/2302.13971>. 2302.13971.
- [4] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms, 2017. <https://arxiv.org/abs/1707.06347>. 1707.06347.
- [5] Schmidt R M. Recurrent neural networks (rnns): A gentle introduction and overview, 2019. <https://arxiv.org/abs/1912.05911>. 1912.05911.
- [6] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735–1780.
- [7] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need, 2023. <https://arxiv.org/abs/1706.03762>. 1706.03762.
- [8] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI, 2019https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf. Accessed: 2024-11-15.
- [9] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners, 2020. <https://arxiv.org/abs/2005.14165>. 2005.14165.
- [10] Chung H W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models, 2022. <https://arxiv.org/abs/2210.11416>. 2210.11416.
- [11] Wang Y, Kordi Y, Mishra S, et al. Self-instruct: Aligning language models with self-generated instructions[J]. arXiv preprint arXiv:2212.10560, 2023.
- [12] Chu T, Zhai Y, Yang J, et al. Sft memorizes, rl generalizes: A comparative study of foundation model post-training, 2025. <https://arxiv.org/abs/2501.17161>. 2501.17161.
- [13] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback, 2022. <https://arxiv.org/abs/2203.02155>. 2203.02155.
- [14] Bai Y, Jones A, Ndousse K, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback, 2022. <https://arxiv.org/abs/2204.05862>. 2204.05862.

- [15] Bradley R A, Terry M E. Rank analysis of incomplete block designs the method of paired comparisons[J]. *Biometrika*, 1952, 39: 324–345. <https://api.semanticscholar.org/CorpusID:121987403>.
- [16] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models, 2023. <https://arxiv.org/abs/2307.09288>. 2307.09288.
- [17] Liu A, Zhao Z, Liao C, et al. Learning plackett-luce mixtures from partial preferences[C]. *AAAI Conference on Artificial Intelligence*<https://api.semanticscholar.org/CorpusID:54066478>.
- [18] Zhu B, Frick E, Wu T, et al. Starling-7b: Improving llm helpfulness harmless with rlai, 2023 November.
- [19] Cobbe K, Kosaraju V, Bavarian M, et al. Training verifiers to solve math word problems, 2021. <https://arxiv.org/abs/2110.14168>. 2110.14168.
- [20] Lightman H, Kosaraju V, Burda Y, et al. Let's verify step by step[J]. *arXiv preprint arXiv:2305.20050*, 2023.
- [21] Guo S, Zhang B, Liu T, et al. Direct language model alignment from online ai feedback, 2024. <https://arxiv.org/abs/2402.04792>. 2402.04792.
- [22] Zhou Z, Liu J, Shao J, et al. Beyond one-preference-fits-all alignment: Multi-objective direct preference optimization, 2024. <https://arxiv.org/abs/2310.03708>. 2310.03708.
- [23] Yang K, Liu Z, Xie Q, et al. Metaaligner: Towards generalizable multi-objective alignment of language models, 2024. <https://arxiv.org/abs/2403.17141>. 2403.17141.
- [24] Wang A, Singh A, Michael J, et al. Glue: A multi-task benchmark and analysis platform for natural language understanding, 2019. <https://arxiv.org/abs/1804.07461>. 1804.07461.
- [25] Sarlin P E, DeTone D, Malisiewicz T, et al. Superglue: Learning feature matching with graph neural networks, 2020. <https://arxiv.org/abs/1911.11763>. 1911.11763.
- [26] Zheng L, Chiang W L, Sheng Y, et al. Judging llm-as-a-judge with mt-bench and chatbot arena, 2023. <https://arxiv.org/abs/2306.05685>. 2306.05685.
- [27] Dubois Y, Galambosi B, Liang P, et al. Length-controlled alpaca-eval: A simple way to debias automatic evaluators, 2025. <https://arxiv.org/abs/2404.04475>. 2404.04475.
- [28] Zeng Z, Yu J, Gao T, et al. Evaluating large language models at evaluating instruction following, 2024. <https://arxiv.org/abs/2310.07641>. 2310.07641.
- [29] Lambert N, Pyatkin V, Morrison J, et al. Rewardbench: Evaluating reward models for language modeling. <https://huggingface.co/spaces/allenai/reward-bench>, 2024.
- [30] Chiang W L, Zheng L, Sheng Y, et al. Chatbot arena: An open platform for evaluating llms by human preference, 2024. 2403.04132.

- [31] Guo Y, Cui G, Yuan L, et al. Controllable preference optimization: Toward controllable multi-objective alignment, 2024. <https://arxiv.org/abs/2402.19085>. 2402.19085.
- [32] Zhou E, Zheng G, Wang B, et al. Rmb: Comprehensively benchmarking reward models in llm alignment, 2024. <https://arxiv.org/abs/2410.09893>. 2410.09893.
- [33] Kaplan J, McCandlish S, Henighan T, et al. Scaling laws for neural language models, 2020. <https://arxiv.org/abs/2001.08361>. 2001.08361.
- [34] Wei J, Tay Y, Bommasani R, et al. Emergent abilities of large language models, 2022. <https://arxiv.org/abs/2206.07682>. 2206.07682.
- [35] Zhao W X, Zhou K, Li J, et al. A survey of large language models, 2025. <https://arxiv.org/abs/2303.18223>. 2303.18223.
- [36] Markov A A. The theory of algorithms[J]. Journal of Symbolic Logic, 1953, 18(4): 340–341. <http://dx.doi.org/10.2307/2266585>.
- [37] Liu X, Croft W B. Statistical language modeling for information retrieval[J]. Annu. Rev. Inf. Sci. Technol., 2006, 39: 1–31. <https://api.semanticscholar.org/CorpusID:45558661>.
- [38] Bahl L R, Brown P F, de Souza P V, et al. A tree-based statistical language model for natural language speech recognition[J]. IEEE Trans. Acoust. Speech Signal Process., 1989, 37: 1001–1008. <https://api.semanticscholar.org/CorpusID:40552549>.
- [39] Katz S M. Estimation of probabilities from sparse data for the language model component of a speech recognizer[J]. IEEE Trans. Acoust. Speech Signal Process., 1987, 35: 400–401. <https://api.semanticscholar.org/CorpusID:6555412>.
- [40] Bengio Y, Ducharme R, Vincent P, et al. A neural probabilistic language model[C]. Journal of machine learning research <https://api.semanticscholar.org/CorpusID:221275765>.
- [41] Mikolov T, Chen K, Corrado G S, et al. Efficient estimation of word representations in vector space[C]. International Conference on Learning Representations <https://api.semanticscholar.org/CorpusID:5959482>.
- [42] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations[J]. ArXiv, 2018, abs/1802.05365. <https://api.semanticscholar.org/CorpusID:3626819>.
- [43] Lewis M, Liu Y, Goyal N, et al. Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension[C]. Annual Meeting of the Association for Computational Linguistics <https://api.semanticscholar.org/CorpusID:204960716>.
- [44] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways, 2022. <https://arxiv.org/abs/2204.02311>. 2204.02311.
- [45] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer, 2023. <https://arxiv.org/abs/1910.10683>. 1910.10683.

- [46] Yang Z, Dai Z, Yang Y, et al. Xlnet: Generalized autoregressive pretraining for language understanding, 2020. <https://arxiv.org/abs/1906.08237>. 1906.08237.
- [47] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale, 2021. <https://arxiv.org/abs/2010.11929>. 2010.11929.
- [48] Beltagy I, Peters M E, Cohan A. Longformer: The long-document transformer, 2020. <https://arxiv.org/abs/2004.05150>. 2004.05150.
- [49] Katharopoulos A, Vyas A, Pappas N, et al. Transformers are rnns: Fast autoregressive transformers with linear attention, 2020. <https://arxiv.org/abs/2006.16236>. 2006.16236.
- [50] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model, 2024. <https://arxiv.org/abs/2305.18290>. 2305.18290.
- [51] Azar M G, Rowland M, Piot B, et al. A general theoretical paradigm to understand learning from human preferences, 2023. <https://arxiv.org/abs/2310.12036>. 2310.12036.
- [52] Meng Y, Xia M, Chen D. Simpo: Simple preference optimization with a reference-free reward, 2024. <https://arxiv.org/abs/2405.14734>. 2405.14734.
- [53] Hong J, Lee N, Thorne J. Orpo: Monolithic preference optimization without reference model, 2024. <https://arxiv.org/abs/2403.07691>. 2403.07691.
- [54] Ng A Y, Russell S. Algorithms for inverse reinforcement learning[C]. International Conference on Machine Learning<https://api.semanticscholar.org/CorpusID:266239314>.
- [55] Sutton R, Barto A. Reinforcement learning: An introduction[J]. IEEE Transactions on Neural Networks, 1998, 9(5): 1054–1054. <http://dx.doi.org/10.1109/TNN.1998.712192>.
- [56] Leike J, Krueger D, Everitt T, et al. Scalable agent alignment via reward modeling: a research direction[J]. ArXiv, 2018, abs/1811.07871. <https://api.semanticscholar.org/CorpusID:53745764>.
- [57] Zhu B, Jiao J, Jordan M I. Principled reinforcement learning with human feedback from pairwise or k -wise comparisons, 2024. <https://arxiv.org/abs/2301.11270>. 2301.11270.
- [58] Lightman H, Kosaraju V, Burda Y, et al. Let’s verify step by step[J]. ArXiv, 2023, abs/2305.20050. <https://api.semanticscholar.org/CorpusID:258987659>.
- [59] Likert R. A technique for the measurement of attitudes[J]. Archives of Psychology, 1932, 22(140): 5–55.
- [60] Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer, 2017. <https://arxiv.org/abs/1701.06538>. 1701.06538.
- [61] Fedus W, Zoph B, Shazeer N. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity, 2022. <https://arxiv.org/abs/2101.03961>. 2101.03961.
- [62] Lepikhin D, Lee H, Xu Y, et al. Gshard: Scaling giant models with conditional computation and automatic sharding, 2020. <https://arxiv.org/abs/2006.16668>. 2006.16668.

- [63] Ramé A, Couairon G, Shukor M, et al. Rewarded soups: towards pareto-optimal alignment by interpolating weights fine-tuned on diverse rewards, 2023. <https://arxiv.org/abs/2306.04488>. 2306.04488.
- [64] Wang H, Xiong W, Xie T, et al. Interpretable preferences via multi-objective reward modeling and mixture-of-experts[J]. arXiv preprint arXiv:2406.12845.
- [65] Wang H, Lin Y, Xiong W, et al. Arithmetic control of llms for diverse user preferences: Directional preference alignment with multi-objective rewards[C]. ACL.
- [66] Peng N, Tian M, Fain B. Multi-objective reinforcement learning with nonlinear preferences: Provable approximation for maximizing expected scalarized return, 2025. <https://arxiv.org/abs/2311.02544>. 2311.02544.
- [67] Lee S H, Li Y, Ke J, et al. Parrot: Pareto-optimal multi-reward reinforcement learning framework for text-to-image generation, 2024. <https://arxiv.org/abs/2401.05675>. 2401.05675.
- [68] Cui G, Yuan L, Ding N, et al. Ultrafeedback: Boosting language models with scaled ai feedback, 2024. <https://arxiv.org/abs/2310.01377>. 2310.01377.
- [69] Saito K, Wachi A, Wataoka K, et al. Verbosity bias in preference labeling by large language models, 2023. <https://arxiv.org/abs/2310.10076>. 2310.10076.
- [70] Pearson K. Vii. note on regression and inheritance in the case of two parents[J]. Proceedings of the Royal Society of London, 58: 240 – 242. <https://api.semanticscholar.org/CorpusID:121644161>.
- [71] Spearman C. The proof and measurement of association between two things.[J]. International journal of epidemiology, 2015, 39 5: 1137–50. <https://api.semanticscholar.org/CorpusID:14780428>.
- [72] Wang Z, Dong Y, Zeng J, et al. Helpsteer: Multi-attribute helpfulness dataset for steerlm, 2023. <https://arxiv.org/abs/2311.09528>. 2311.09528.
- [73] Wang Z, Dong Y, Delalleau O, et al. Helpsteer2: Open-source dataset for training top-performing reward models, 2024. <https://arxiv.org/abs/2406.08673>. 2406.08673.
- [74] Bojanowski P, Grave E, Joulin A, et al. Enriching word vectors with subword information[J]. arXiv preprint arXiv:1607.04606, 2016.
- [75] Grootendorst M. Bertopic: Neural topic modeling with a class-based tf-idf procedure, 2022. <https://arxiv.org/abs/2203.05794>. 2203.05794.
- [76] Nvidia, :, Adler B, et al. Nemotron-4 340b technical report, 2024. <https://arxiv.org/abs/2406.11704>. 2406.11704.
- [77] Jiang A Q, Sablayrolles A, Roux A, et al. Mixtral of experts, 2024. <https://arxiv.org/abs/2401.04088>. 2401.04088.

- [78] Ethayarajh K, Choi Y, Swayamdipta S. Understanding dataset difficulty with $\mathcal{V}$ -usable information[C]. Chaudhuri K, Jegelka S, Song L, et al., (Eds.) Proceedings of the 39th International Conference on Machine Learning, PMLR, vol. 162 of Proceedings of Machine Learning Research, 2022 17–23 Jul: 5988–6008.
- [79] Daniele L, Suphavadeeprasit. Amplify-instruct: Synthetically generated diverse multi-turn conversations for efficient llm training.[J]. arXiv preprint arXiv:(coming soon), 2023<https://huggingface.co/datasets/LDJnr/Capybara>.
- [80] Mukherjee S, Mitra A, Jawahar G, et al. Orca: Progressive learning from complex explanation traces of gpt-4, 2023. 2306.02707.
- [81] Ji J, Liu M, Dai J, et al. Beavertails: Towards improved safety alignment of llm via a human-preference dataset, 2023. <https://arxiv.org/abs/2307.04657>. 2307.04657.
- [82] Hu J, Wu X, Zhu Z, et al. Openrlhf: An easy-to-use, scalable and high-performance rlhf framework[J]. arXiv preprint arXiv:2405.11143, 2024.
- [83] von Werra L, Belkada Y, Tunstall L, et al. Trl: Transformer reinforcement learning. <https://github.com/huggingface/trl>, 2020.
- [84] Yao Z, Aminabadi R Y, Ruwase O, et al. Deepspeed-chat: Easy, fast and affordable rlhf training of chatgpt-like models at all scales, 2023. <https://arxiv.org/abs/2308.01320>. 2308.01320.
- [85] Moritz P, Nishihara R, Wang S, et al. Ray: A distributed framework for emerging ai applications, 2018. <https://arxiv.org/abs/1712.05889>. 1712.05889.
- [86] Kwon W, Li Z, Zhuang S, et al. Efficient memory management for large language model serving with pagedattention, 2023. <https://arxiv.org/abs/2309.06180>. 2309.06180.
- [87] Shoeybi M, Patwary M, Puri R, et al. Megatron-lm: Training multi-billion parameter language models using model parallelism, 2020. <https://arxiv.org/abs/1909.08053>. 1909.08053.
- [88] Rasley J, Rajbhandari S, Ruwase O, et al. Deepspeed: System optimizations enable training deep learning models with over 100 billion parameters[J]. Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2020<https://api.semanticscholar.org/CorpusID:221191193>.
- [89] Rajbhandari S, Rasley J, Ruwase O, et al. Zero: Memory optimizations toward training trillion parameter models, 2020. <https://arxiv.org/abs/1910.02054>. 1910.02054.
- [90] Kingma D P, Ba J. Adam: A method for stochastic optimization, 2017. <https://arxiv.org/abs/1412.6980>. 1412.6980.
- [91] Dao T. Flashattention-2: Faster attention with better parallelism and work partitioning, 2023. <https://arxiv.org/abs/2307.08691>. 2307.08691.

- [92] Liu T, Zhao Y, Joshi R, et al. Statistical rejection sampling improves preference optimization, 2024. <https://arxiv.org/abs/2309.06657>. 2309.06657.
- [93] Ethayarajh K, Xu W, Muennighoff N, et al. Kto: Model alignment as prospect theoretic optimization, 2024. <https://arxiv.org/abs/2402.01306>. 2402.01306.
- [94] Grattafiori A, Dubey A, Jauhri A, et al. The llama 3 herd of models, 2024. <https://arxiv.org/abs/2407.21783>. 2407.21783.
- [95] Agarap A F. Deep learning using rectified linear units (relu), 2019. <https://arxiv.org/abs/1803.08375>. 1803.08375.
- [96] Lambert N, Pyatkin V, Morrison J, et al. Rewardbench: Evaluating reward models for language modeling, 2024. <https://arxiv.org/abs/2403.13787>. 2403.13787.
- [97] Röttger P, Kirk H R, Vidgen B, et al. Xstest: A test suite for identifying exaggerated safety behaviours in large language models, 2024. <https://arxiv.org/abs/2308.01263>. 2308.01263.
- [98] Wang Y, Li H, Han X, et al. Do-not-answer: A dataset for evaluating safeguards in llms, 2023. <https://arxiv.org/abs/2308.13387>. 2308.13387.
- [99] Muennighoff N, Liu Q, Zebaze A, et al. Octopack: Instruction tuning code large language models, 2024. <https://arxiv.org/abs/2308.07124>. 2308.07124.
- [100] Stiennon N, Ouyang L, Wu J, et al. Learning to summarize from human feedback, 2022. <https://arxiv.org/abs/2009.01325>. 2009.01325.
- [101] Deng Y, Zhao W, Hessel J, et al. Wildvis: Open source visualizer for million-scale chat logs in the wild, 2024. <https://arxiv.org/abs/2409.03753>. 2409.03753.
- [102] The claude 3 model family: Opus, sonnet, haiku[C]. <https://api.semanticscholar.org/CorpusID:268232499>.
- [103] Liu C Y, Zeng L, Liu J, et al. Skywork-reward: Bag of tricks for reward modeling in llms[J]. arXiv preprint arXiv:2410.18451, 2024.
- [104] Shiwen T, Liang Z, Liu C Y, et al. Skywork critic model series. <https://huggingface.co/Skywork>, 2024 September. <https://huggingface.co/Skywork>.
- [105] Wen X, Lou J, Lu Y, et al. Rethinking reward model evaluation: Are we barking up the wrong tree?, 2025. <https://arxiv.org/abs/2410.05584>. 2410.05584.
- [106] Sutton R S, Barto A G. Reinforcement learning: An introduction[J]. IEEE Trans. Neural Networks, 1998, 9: 1054–1054. <https://api.semanticscholar.org/CorpusID:60035920>.
- [107] Watkins C, Dayan P. Q-learning[J]. Machine Learning, 1992, 8: 279–292. <https://api.semanticscholar.org/CorpusID:208910339>.

- [108] Kloek T, van Dijk H K. Bayesian estimates of equation system parameters, an application of integration by monte carlo[J]. *Econometrica*, 1976, 46: 1–19. <https://api.semanticscholar.org/CorpusID:53634601>.
- [109] Schaul T, Quan J, Antonoglou I, et al. Prioritized experience replay[J]. *CoRR*, 2015, abs/1511.05952. <https://api.semanticscholar.org/CorpusID:13022595>.
- [110] Williams R J, Peng J. Function optimization using connectionist reinforcement learning algorithms[J]. *Connection Science*, 1991, 3: 241–268. <https://api.semanticscholar.org/CorpusID:18972907>.
- [111] Dong H, Xiong W, Pang B, et al. Rlhf workflow: From reward modeling to online rlhf, 2024. <https://arxiv.org/abs/2405.07863>. 2405.07863.
- [112] Casella G, Robert C P, Wells M T. Generalized accept-reject sampling schemes[C]<https://api.semanticscholar.org/CorpusID:118781921>.
- [113] Csiszár I. ϕ -divergence geometry of probability distributions and minimization problems[J]. *Annals of Probability*, 1975, 3: 146–158. <https://api.semanticscholar.org/CorpusID:18053591>.
- [114] Zitzler E, Thiele L. Multiobjective evolutionary algorithms: a comparative case study and the strength pareto approach[J]. *IEEE Trans. Evol. Comput.*, 1999, 3: 257–271. <https://api.semanticscholar.org/CorpusID:9634991>.
- [115] AI, :, Young A, et al. Yi: Open foundation models by 01.ai, 2024. 2403.04652.
- [116] Li X, Zhang T, Dubois Y, et al. AlpacaEval: An automatic evaluator of instruction-following models. https://github.com/tatsu-lab/alpaca_eval, 2023 5.
- [117] Dong H, Xiong W, Goyal D, et al. Raft: Reward ranked finetuning for generative foundation model alignment, 2023. <https://arxiv.org/abs/2304.06767>. 2304.06767.
- [118] Shinn N, Labash A, Wang P, et al. Reflexion: Language agents with verbal reinforcement learning[J]. *arXiv preprint arXiv:2303.11366*, 2023.
- [119] Chiang P E, Lin S C, Bai Y, et al. Can large language models learn from mistakes?[J]. *arXiv preprint arXiv:2309.00613*, 2023.