

密 级：公开

中图分类号：B829



湖南科技大学
Hunan University of Science and Technology

硕士学位论文

消除人工智能内隐偏见的伦理策略 ——基于女性吸引力测试的实验分析

研 究 生：彭乐平

导 师：杨盛军副教授

学 科：哲学

研究方向：伦理学理论与应用研究

2021 年 6 月

A Thesis Submitted for the Degree of Master

**Ethical Strategies to Eliminate Implicit Bias in
Artificial Intelligence**
——Experimental analysis based on female
attractiveness test

Candidate: Leping Peng
Supervisor and Rank: Assoc. Prof. Shengjun Yang

消除人工智能内隐偏见的伦理策略

——基于女性吸引力测试的实验分析

学 位 类 型	学术型学位
作 者 姓 名	彭乐平
作 者 学 号	18011101002
学科（专业学位类别）	哲学
研究方向（专业领域）	伦理学理论与应用研究
导 师 姓 名 及 职 称	杨盛军副教授
实践导师姓名及职称	
所 在 学 院	马克思主义学院
论 文 提 交 日 期	2021 年 6 月

摘要

内隐偏见无处不在，它影响我们生活的各个方面却不被意识，它通常表现为对某一类事物的刻板印象，由人训练出来的人工智能无疑将会重复着这一偏见。本文系统阐述了内隐偏见的释义和成因，并研究了它如何影响道德判断和评价，从意识和控制论，归因论和深层自我理论的角度分析了各个理论对于内隐偏见道德责任的态度。在这些理论基础之上，我们对基于女性吸引力测试的人工智能招聘系统实验样本进行分析，该系统未来旨在用于封面女郎、影视媒体的招聘工作，人工智能被广泛的应用于招聘系统，如亚马逊、谷歌、微软等，本实验项目系统也将被广泛用于广告、电影等媒体的模特及演员求职招聘筛选。此次实验提出了两个假设，假设 1 为中德两国实验参与者对亚欧数据集中女性图片吸引力评比结果是有内隐偏见的。假设 2 为人工智能会复制人类的偏见，在第三部分实验中，这两个假设分别得以证明。那么如何消除人工智能的内隐偏见？该实验通过使用公平的预处理方法来实现这一目标，首先使用生成式对抗网络（GAN）的方法对面部美容预测系统数据库进行了扩充和多样化，解决了训练数据的偏见问题，通过对平衡样本加权重量的反复推算之后得出数据无偏输入预处理的权重比率最佳值，并结合先进的卷积神经网络（CNN）算法探索出一个无偏见人工智能网络，该人工智能机器学习的精度（这里考察参数皮尔逊相关系数、平均绝对误差和均方根误差）均优于同类已发表的排名领先的人工智能面部美容预测系统，为其他人工智能消除偏见提供了一个成功的示范。结合该实验，本文分析了人工智能产生偏见的可性原因是由于训练数据集、AI 算法存在偏见以及人机交互过程中产生的内隐偏见，提出并探讨了以人为本的普遍立法原则作为无偏见人工智能设计的伦理原则可行性。最后本文提出了通过建立道德算法、多元化样本集、提高女性在人工智能领域的弱势地位，以及加大对人工智能行业的伦理道德培训等多种方式来消除人工智能内隐偏见。

关键词：人工智能；机器学习；内隐偏见；算法；道德情绪主义；道德理性主义；责任；伦理；

Abstract

Implicit bias is everywhere. It affects all aspects of our lives without being conscious. It usually manifests as a stereotype of a certain kind of thing. It is conceivable that artificial intelligence trained by humans undoubtedly repeats this prejudice. This article systematically expounds on the interpretation and causes of implicit prejudice, and studies how it affects moral judgment and evaluation. From the perspectives of consciousness and cybernetics, attribution theory, and deep self theories, it analyzes the moral responsibility of each theory for implicit attitude. On the basis of these theories, we analyze the experimental samples of the artificial intelligence recruitment system based on facial beauty prediction (FBP) used in the cover girl recruitment system. Artificial intelligence is widely used in recruitment systems, such as Amazon, Google, Microsoft, etc. This experiment system will also be widely used in the recruitment and selection of models and actors in advertising, movies, and other media. We put forward two hypotheses from the experiment. Hypothesis 1 is that the results of the Chinese and German annotations appraisal of the attractiveness of female images in the Asia-Europe data set are implicit biased. Hypothesis 2 is that artificial intelligence will copy human prejudices. Both hypotheses have been supported by our experiments. How to eliminate the implicit bias of artificial intelligence? We use a fair preprocessing method to achieve this goal. First, we use the Generative Adversarial Network (GAN) method to expand and diversify our facial beauty prediction system database to solve the problem of bias in training data. After repeated calculations of the weighted weights of the balanced samples, the best value of the weight ratio of the unbiased input preprocessing of the data is obtained, and an unbiased artificial intelligence network is explored in combination with the advanced convolutional neural network (CNN) algorithm. The accuracy of intelligent machine learning (the parameters Pearson correlation coefficient, average absolute error and root mean square error are examined here) are better than the published ranking leading artificial intelligence FBP systems, we provided success for other artificial intelligence to eliminate bias demonstration. Based on the experiment, this article analyzes that the biases of artificial intelligence may be due to the biases of the training data set, AI algorithms, and the implicit biases generated in the process of human-computer interaction. Furthermore, we proposed and explored the feasibility of Kant's human-oriented Formula of Universal Law as an ethical principle for unbiased artificial intelligence design. In the last chapter of the article, this study proposed a variety of ways to eliminate artificial intelligence implicit biases by establishing moral algorithms, diversifying sample sets, improving women's disadvantaged position in the field of artificial intelligence, and increasing ethical and moral training in the AI industry.

Keywords: Artificial Intelligence; Machine Learning; Implicit Bias; Moral Emotionalism; Algorithm; Moral Rationalism; Responsibility; Ethics

目 录

摘 要.....	i
Abstract	ii
第 1 章 绪论	1
1.1 课题的研究背景和研究意义	1
1.1.1 课题的研究背景	1
1.1.2 课题的研究意义	2
1.2 国内外研究现状	4
1.2.1 国内研究现状	4
1.2.2 国外研究现状	6
1.3 研究方法与创新点	9
1.3.1 研究方法	9
1.3.2 创新点	9
第 2 章 内隐偏见的释义、成因及道德影响	11
2.1 内隐偏见释义	11
2.1.1 偏见与偏好的分析	11
2.1.2 内隐偏见的内涵	11
2.1.3 内隐偏见的主要表现	13
2.1.4 内隐偏见的特征	16
2.2 内隐偏见形成的一般原因	17
2.2.1 受大脑思考方式的影响	17
2.2.2 认知一致性原则	18
2.2.3 早期经历导致特殊偏好	19
2.2.4 社会文化的长期沉淀	20
2.3 内隐偏见对道德判断与评价的影响	21
2.3.1 内隐偏见影响道德判断	21
2.3.2 内隐偏见助长道德情感主义	22
2.3.3 内隐偏见规避道德责任	23
第 3 章 人工智能的内隐偏见：基于女性吸引力测试的实验分析	27
3.1 实验过程及结论	27
3.1.1 实验设计	27
3.1.2 实验步骤	29

3.1.3 实验结论	31
3.2 人工智能内隐偏见的表现	32
3.2.1 人工智能的种族无意识偏见	32
3.2.2 人工智能的审美判断偏见	33
3.2.3 人工智能的文化无意识偏见	35
3.3 人工智能内隐偏见的可能性原因	36
3.3.1 训练数据存在内隐偏见	36
3.3.2 AI 算法存在内隐偏见	37
3.3.3 人机交互产生内隐偏见	39
第 4 章 消除人工智能内隐偏见的伦理策略	41
4.1 确立人工智能研发的伦理原则	41
4.1.1 以人为本的普遍立法原则	41
4.1.2 在道德情绪主义中设定理性主义指标	43
4.2 完善人工智能道德算法的建设	44
4.2.1 提升算法的透明性	44
4.2.2 完善算法的可解释性	45
4.2.3 提高样本及数据集的多样性	46
4.3 加强对研发主体的道德培育	47
4.3.1 提倡研发企业的多元文化建设	47
4.3.2 增加研发主体女性的从业比例	48
4.3.3 加强研发主体的伦理道德教育	50
4.3.4 提高行业伦理协会的监管效果	51
第 5 章 结语	53
参考文献	55
附录 A 攻读学位期间发表的论文与科研成果清单	59
致 谢	61

第1章 绪论

内隐偏见在日常生活中无处不在，它是导致人类偏见的重要原因却常常被忽视。人类的内隐偏见将无可避免的被人工智能所复制。本章将重点介绍人工智能内隐偏见在国内外的研究现状及意义，针对国内研究现状的材料搜集主要通过各级政府政策官网及知网学术平台，针对国外的研究现状调查则通过联合国及各国政府官方文件的查询及 Web of Science 数据库论文查询搜索来实现。在对国内外文献资料进行梳理和研究之后，本人发现大部分的研究都停留在对人工智能产生偏见这一现象的陈述和罗列上，也提出了一些解决方案，但大多是概念性和理论性的解决方案，本文将采取的理论实验相结合的研究方式不管是从目前国内还是国外的研究结果来看都是有创新价值的其有示范性意义的。这项研究综合了一些图像视觉、神经科学、心理学、哲学、法规的综合交叉研究，人工智能是 21 世纪无法绕开的主题，只有各学科携手一起解决人工智能带来的偏见伦理问题才能让其更好的为人类服务。

1.1 课题的研究背景和研究意义

1.1.1 课题的研究背景

人工智能无疑是21世纪最热门的话题，人工智能如今已经渗透到人类生活、工作等方方面面，“人工智能”的概念最早是在1956年在达特茅斯学院举行的机器智能学术会议上提出的。经过60多年的历程，随着机器学习的不断发展，人工智能进入了一个全速发展的新阶段，以机器学习为核心技术标志着人工智能进入新纪元。因为机器学习是使计算机智能化的基本方法。从1950年艾伦·图灵(Alan Mathison Turing) 提出“机器会思考吗”这个标志性的问题以来，到深度学习的实际应用有了很大的进展。近年来与机器学习有关的学术活动空前活跃，人工智能机器学习在不断的深入各个领域的时候也给人类带来了不少问题和困惑，围绕人工智能带来的机会和挑战也是哲学研究的热点。

由人类训练主导的机器学习无可避免的使人工智能复制了人类的偏见，其中也包括人类的内隐偏见，内隐偏见是可能无意识或无法控制的偏见，它几乎存在于每一个人，并且由此引发的社会问题层出不穷，这些内隐态度大部分是通过我们的经验中学到的，并且根深蒂固，以至于我们可能对它们无视，但很多情况下瞬间产生的无意识内隐偏见则可能是对行为对象区别对待和歧视性做法的根源。例如，尽管美国人认为自己没有偏见，但在测量无意识的刻板印象时，“90%的白人和50%的黑人将消极特

征与黑人形象联系起来。^①”从童年初期开始，白人儿童和有色儿童就喜欢白色洋娃娃。^②2010年，儿童心理学家斯宾塞（Margaret Beale Spencer）的团队对133名来自特定经济和人口要求的学校的孩子进行了测试，该测试显示，白人儿童对“白色偏见”的反应率很高，他们将自己皮肤的颜色识别为积极的，而较黑的皮肤则识别为消极的。斯宾塞博士说，即使是黑人孩子也对白人有偏见，但远少于白人孩子^③。2018年10月，根据路透社的报道，亚马逊开发的AI招聘工具“不喜欢女人”，自2014年以来，该招聘研发团队一直在构建计算机程序，使用AI招聘引擎来审查求职者的简历，以有效地找到顶尖的人才。从根据以往十年由AI招聘引擎发送给亚马逊的简历来看大部分都是男性，并且在考虑应聘候选人的大学水平时，该招聘系统还自动降低了两所女子大学的等级水平，不仅如此，甚至还将“妇女”这一关键词与“女子象棋俱乐部队长”相关联^④，作为与谷歌、Facebook并驾齐驱的AI公司，亚马逊陷入的这则AI歧视丑闻在人工智能领域引起了不小的反响，并引发了各界的热议。2020年5月25日，在美国明尼苏达州，一名黑人男子因被警察跪压在地上7分钟而身亡。美国明尼阿波利斯市市长雅各布·弗赖接受哥伦比亚广播公司采访时表示，“我不知道是否有明确或隐含的种族主义，但种族主义肯定牵涉其中”^⑤。

基于对内隐偏见的研究和了解，2019年，在与德国Reutlingen大学ViSiR团队的国际合作研究项目中，我们提出人类的内隐偏见将导致人工智能的偏见假设，并以实验项目着手证明，由实验结果得出：由不同种族人群训练出来的人工智能选美机器人都只喜欢“自己人”，人工智能显示着某种意义上的种族主义。更重要的是参与实验的每个人都宣称自己并非种族主义者，但却为自己无意识表现出来的种族倾向而感到震惊，无意识的内隐偏见对人类行为产生着如此重大的影响却容易被忽视，那些被忽视了的偏见让机器人的公平性何以保证？带着这样的疑问，我开始了这个课题的研究。

1.1.2 课题的研究意义

首先，从图像视觉领域来看，AI偏见广泛存在于图像处理领域。人工智能将来自美国的白人传统新娘的图片标记为“新娘”，“礼服”，“妇女”和“婚礼”，而将来自北印度地区的新娘的照片标记为“表演艺术”和“服装”^⑥；在司法系统AI图像识别机器人错误地识别黑人为高犯罪风险^⑦，并且互联网用户发现Google的照片应用程序

① Moule J. Understanding unconscious bias and unintentional racism: Acknowledging our possible biases and working together openly is essential for developing community in our schools [J]. Phi Delta Kappan, 2009(1):321-326.

② Ahuja G. What a Doll Tells Us about Race[EB].abc News, 2009(3).

③ Spencer M. Study: White and black children biased toward lighter skin [EB].CNN world, 2010(5).

④ Dastin J. Amazon scraps secret AI recruiting tool that showed bias against women. [EB].Reuters, 2018(10).

⑤ CBS NEWS . Minneapolis mayor says George Floyd would "be alive today if he were white"[EB].CBS NEWS,2020(5).

⑥ Shankar S, Halpern Y, Breck E, et al J. No Classification without Representation: Assessing Geodiversity Issues in Open Data Sets for the Developing World [DB]. arXiv, 2017(11).

⑦ Angwin J, Larson J. Bias in criminal risk scores is mathematically inevitable researchers say [EB]. Propublica, 2016(12).

的自动标签将两位黑人的图像分类为大猩猩^①。2016年，总部位于中国香港的科技公司“Beauty.ai”主办了一场由人工智能当裁判的选美比赛，但由于数据集中没有足够的少数族裔，因此人工智能可以判断“美女”的对象不足，于是便有了AI裁判不喜欢黑皮肤的女人的审美偏见结果^②。试想一下，如果这是一个封面模特职位，那毫无疑问，黑色皮肤的候选人将被淘汰。本项目研究将解决这种不公平现象，提供多元化的数据集，并消除训练和算法偏差，以构建一个公平而道德的人工智能机器人。

此外，通过这项研究，我们希望通过研究无意识的偏见如何影响人工智能的决策而引起社会对无意识偏见更多的关注，并了解内隐偏见也需要承担道德责任。人工智能在图片分类注释过程中难免会因为刻板印象而做出带偏见的分类，如将“女人”与“护士”相关联，“教授”与“老年人”相关联，“男人”与“汽车司机”相关联，等等此类带着刻板印象的分类标签层出不穷，主要原因是研究人员在对样本进行人工分类时将其自身的偏见赋予了图片分类器。令人欣慰的是，许多公司开始关注无意识的偏见可能带来的负面影响并做出不懈的努力，如今，越来越多的公司使用人工智能招聘系统，例如Facebook，领英，联合利华，以及前文提到的有过AI不公平招聘系统记录前科的亚马逊和谷歌。Facebook设计了一个网页，以广泛提供无意识的偏见培训视频，Google通过90分钟的无意识偏见培训计划为约60,000名员工提供了服务，无疑这将有助于减少人机交互过程中的人为偏见，但是培训的经济成本也很高，如果有一个类似于本研究的人工智能系统能够更好地规避人类无意识的偏见，这将是一个可行的选择。图像处理系统的公平性对于整个AI招聘系统非常重要。本研究在理论和实践上为解决不公平AI系统提供了一个切实可行的方案，并且该设计理念可以延伸至其他人工智能的设计。

最后，基于这个研究，论文探讨了人工智能领域道德在可行性方面可能面临的困境和可以借鉴的道德原则，这其中综合了一些图像视觉、神经科学、心理学、哲学、法制法规的综合性交叉研究，我们仅想说明伦理的研究并非某单个科学领域的责任，在人工智能伦理的研究更是如此，它过去是，将来也一定是一门综合性研究学科，因此，我们希望人工智能的伦理问题能在各科学界引起广泛的关注，倡议跨学科的合作研究，人工智能是21世纪无法绕开的主题，只有各学科携手才能更好的更有效率的接近它，了解它。

① Crawford K. Artificial Intelligence's White Guy Problem[EB].The New York Times, 2016(6).

② The Guardian. A beauty contest was judged by AI and the robots didn't like dark skin[EB]. The Guardian,2016(8).

1.2 国内外研究现状

1.2.1 国内研究现状

从国家和政府层面，“人工智能：技术、伦理与法律”的人工智能研讨性会议于2017年4月由腾讯研究院和中国科学院科技战略咨询研究院联合主办，该会议重点提出了现阶段人工智能在伦理方面面临的诸多困境与对法律法规完善的策略。^①接着于2017年7月国务院就人工智能的发展问题推出了《新一代人工智能发展规划》，提出通过人工智能实现科学技术世界强国战略的愿景，并且该规划首次正式提出开展人工智能行为科学伦理研究及制定法律，法规和伦理准则以促进人工智能的发展等。至此，在政府官方层面一改之前将议题重点倾斜于人工智能技术和科学方面，人工智能伦理问题也开始成为关注焦点。从2017年至今，全国各地由中国科学院、各高校、各研究机构及学会举办的以人工智能为主题的大会在各地如火如荼的进行，人工智能这一议题达到了前所未有的关注度，人工智能引发的伦理问题也在各学术会议上被一次次纳入讨论主题。2018年1月，国家标准化管理委员会发布了中国《人工智能标准化白皮书2018》，白皮书首次从政府层面提出了中国在人工智能伦理上的人类利益和责任原则。在此白皮书基础之上，于2020年7月，国家标准化管理委员会又联合中央网信办、国家发展改革委、科技部、工业和信息化部一起共同发布了关于印发《国家新一代人工智能标准体系建设指南》的通知，将安全/伦理作为人工智能标准体系结构构成之一，该专项主要涉及安全与隐私保护、伦理等部分在人工智能领域的应用^②。

在学界，从2017年开始对人工智能伦理的探讨逐渐成爆发式热点热议形式。以权威学术网站知网为例，在期刊（中文）菜单栏分类下搜索主题关键词“人工智能偏见”的结果比较少，为88条，“人工智能歧视”为108条，“人工智能内隐偏见”为0条，“人工智能无意识偏见”结果为1条，由此可见目前研究人工智能偏见和歧视的论文发表量不是很高，研究重点主要集中在对算法歧视上，考虑到偏见和歧视与伦理的相关性，扩大期刊搜索主题关键词“人工智能伦理”的期刊结果为2026条，其中核心期刊发表量为403条，中文社会科学引文索引为395条，搜索年度和范围涵盖了从1985年至2020年的所有期刊。“人工智能伦理”这一议题引发了广泛的研究热，几乎各个领域都有参与，由此可见其应用范围之广，是一门综合性研究学科。从研究的主要学科领域来看，其中31.37%左右的文章集中发表在自动化技术，伦理学和新闻与传媒学科领域的论文量分别位列第二和第三位（见图1.1）。从发表量上来看，人工智能确实火了，但如果深入到伦理学科领域，则更多的是虚火，大量的论文虽然与伦理粘钩，但实际上也只是提及，更多是在技术工程层面进行研究，这个可以从发表的主要学科领域得知，伦理研究领域发表的文章不足发表总量的10%。

①科技战略咨询研究院. 2017 人工智能:技术、伦理与法律”研讨会在京召开[EB].中国科学院,2017（4）.

② 徐锐.论我国人工智能的伦理规范建设[J].岭南学刊, 2019(1): 111-117




图1.1 主题关键词“人工智能伦理”在各学科领域期刊的发表量情况

从发表时间上来看，从2017年开始该主题的论文发表量有显著增加（见图1.2），2017年至2020年发表的论文量占论文总量的90%以上，特别是从2018年的183篇跳跃式增长至2019年的743篇。

数据来源：文献总数：2026 篇；检索条件：（主题%='人工智能伦理' or 题名%='人工智能伦理'）；检索范围：期刊。




图1.2 主题关键词“人工智能伦理”在各期刊发表年度的发表量情况

从受肯定程度的论文来分析，不管是单从高引量期刊文章来看还是总体来看，探讨人工智能法律规制层面的研究比较多，讨论主题大多为机器人是否具有法律人格，以及如何完善人工智能领域的法律法规，涉及伦理及道德学科的研究相对较少：

Author-作者	Title-题名	Source-刊名	Year-年
马长山	人工智能的社会风险及其法律规制	法律科学(西北政法大学学报)	2018
段伟文	人工智能时代的价值审度与伦理调适	中国人民大学学报	2017
张玉洁	论人工智能时代的机器人权利及其风险规制	东方法学	2017
郑戈	人工智能与法律的未来	探索与争鸣	2017
张坤颖,张家年	人工智能教育应用与研究中的新区、误区、盲区与禁区	远程教育杂志	2017
袁曾	人工智能有限法律人格审视	东方法学	2017
吴汉东	人工智能时代的制度安排与法律规制	法律科学(西北政法大学学报)	2017
闫志明,唐夏夏,秦旋,张飞,段元美	教育人工智能(EAI)的内涵、关键技术与应用趋势——美国《为人工智能的未来做好准备》和《国家人工智能研发战略规划》报告解析	远程教育杂志	2017
何哲	通向人工智能时代——兼论美国人工智能战略方向及对中国人工智能战略的借鉴	电子政务	2016
翟振明,彭晓芸	“强人工智能”将如何改变世界——人工智能的技术飞跃与应用伦理前瞻	人民论坛·学术前沿	2016

图1.3 主题关键词“人工智能伦理”高引排名前10的论文

从伦理学发表的论文来看，主要集中在机器人是否具有道德主体地位这一问题上，大部分哲学伦理研究认为机器人不具备道德主体地位的因为拥有心智是成为道德主体的必要条件，而机器人不具备该条件。

1.2.2 国外研究现状

在官方及社会组织层面，2016年8月，联合国教科文组织和世界科学知识与技术伦理委员会联合发布了关于机器人伦理的报告。该报告讨论了机器人在不同的行业和领域的广泛应用以及可能面临的道德伦理问题，并希望这份报告可以引发公众的广泛关注，并参与到机器人伦理问题的研究和讨论之中。2016年10月，英国下议院科学技术委员会发表了《Robotics and artificial intelligence》报告，报告指出了人工智能与机器人在伦理与法律法规领域急需解决的问题，其中包括安全验证与确认、决策透明化、最小化偏见、隐私和许可、问责制和责任、治理的标准和法规，但就这些问题并没有提出实际解决方案。^①2018年4月，英国上议院人工智能专责委员会发布了《AI in the UK: ready, willing and able?》，其专列章节强调了人工智能的可访问和可控制性，重点提出了人工智能技术必须透明化和具有可解释性，并且提出了解决人工智能的偏见问题的一些举措^②。美国奥巴马政府2016年发表了名为《为人工智能的未来做准备》的白皮书，强调了人工智能未来的重点工作之一是实现公平、公正、负责任、安全和可控。同年，由奥巴马政府白宫主办，由微软研究员Kate Crawford和Google研究员Meredith Whittaker主持的AI Now专题讨论会召开，该活动重点关注AI在社会领域的近期影响：

①英国下议院科学技术委员会. Robotics and artificial intelligence [R]. 英国下议院科学技术委员会, 2016 (10).

②英国上议院人工智能专责委员会. AI in the UK: ready, willing and able? [R]. 英国上议院人工智能专责委员会, 2018(4).

不平等，劳工，道德和医疗保健，偏见和多样性研究。电气和电子工程师协会（IEEE）于2017年4月成立IEEE全球倡议，由250多位AI、道德和相关问题的全球各行业专家组成。IEEE全球倡议的目标是就如何将这些智能和自主技术与优先考虑人类福祉的道德价值观和道德原则达成广泛共识。公众对其第一版道德规范设计文件的意见和建议收到了来自世界各国（包括中国，日本，印度，墨西哥和俄罗斯）的一百五十页反馈。IEEE全球计划还确定了许多需要标准的领域，因此，IEEE发起了IEEE P7000™系列的以道德为导向的标准。欧洲议会于2017年2月通过了关于机器人技术的民法规则，其中包括对民法委员会机器人技术规则的建议此外。在数据保护和公民隐私保护方面，欧盟于2018年5月正式实施《通用数据保护条例》，在欧盟地区该新条例的颁发意味着政府对个人信息及隐私的保护和监管达到了最严格的水平，因此堪称史上最严格的数据保护条例。这项条例的颁布甚至改变了人们的日常生活，比如入职、办理各项私人或公共业务、签署合同、各种网络软件的使用等，都必须遵守并签署这一条例。该条例一直影响到第40届数据保护与隐私专员国际大会的召开，该会在通用数据保护条例的基础上进行完善，更是将数据保护达到了前所未有的最高水准^①。在人工智能性别平等研究方面，从2018年12月世界经济论坛颁发的《2018年全球性别差距报告》中可得知男性女性在人工智能行业就业的极度不平衡，该行业女性的从业比例仅为22%^②。2019年3月联合国教科文组织部门发布了《如果可以，我会脸红：通过教育消除数字技能中的性别差异》显示女性在人工智能机器学习领域的就业比例仅占12%。提出了通过加强女性数字化教育来消除人工智能行业男女比例失调及由此可能导致的女性歧视的风险。^③2019年欧盟发布了《歧视、人工智能和算法决策的研究》，该研究系统介绍了人工智能导致歧视的原因和可能引发的歧视风险，并提出了不歧视法的法律建设和规避歧视的伦理建议，这是目前为止较为全面的人工智能歧视的针对性研究。

对于国外文献的研究，本人主要通过Web of Science的数据库进行检索调查，从时间上调查结果涵盖了从1990年以来的论文数据，通过搜索主题关键词“人工智能伦理”（AI ETHICS）在该数据库所有学科项目下的综合结果为620篇，其中近25%的论文发表在计算机人工智能学科领域期刊，在哲学和伦理学两个学科的搜索结果71条，分别位列第二和第三，总占比为21%左右，其中包括同时属于多个学科的期刊，这个相对于国内伦理学领域仅占10%的发表量来看，国外哲学伦理学科领域内对人工智能伦理方面的研究参与度较国内要高。

① 第40届数据保护与隐私专员国际大会.人工智能伦理与数据保护 [M].2018(10).

② 世界经济论坛.2018年全球性别差距报告 [M].2018(12).

③ 联合国教科文组织部门. 如果可以，我会脸红：通过教育消除数字技能中的性别差异[M].2019(3).

Select	Field: Web of Science Categories	Record Count	% of 620	Bar Chart
☐	COMPUTER SCIENCE ARTIFICIAL INTELLIGENCE	150	24.194 %	
☐	ETHICS	77	12.419 %	
☐	PHILOSOPHY	55	8.871 %	
☐	COMPUTER SCIENCE THEORY METHODS	48	7.742 %	
☐	COMPUTER SCIENCE INTERDISCIPLINARY APPLICATIONS	43	6.935 %	
☐	COMPUTER SCIENCE INFORMATION SYSTEMS	37	5.968 %	
☐	MULTIDISCIPLINARY SCIENCES	31	5.000 %	
☐	ENGINEERING ELECTRICAL ELECTRONIC	30	4.839 %	
☐	INFORMATION SCIENCE LIBRARY SCIENCE	29	4.677 %	
☐	SOCIAL SCIENCES BIOMEDICAL	29	4.677 %	

图1.4 搜索主题关键词AI ETHICS在Web of Science上论文发表的各学科情况

从检索结果可以得知，自2017年开始以人工智能伦理为研究主题的论文数量显著增加，特别是2019年从2018年67篇跳跃式增长到178篇，由此可见近两年的国外研究关于人工智能伦理方面十分火热。其中引用量最多的论文为如图1.5：

刊物类别	作者	论文名称	刊物名称	自2017年被引次数
J	King, TC; Aggarwal, N; Taddeo, M; Floridi, L	Artificial Intelligence Crime: An Interdisciplinary Analysis of Foreseeable Threats and Solutions	SCIENCE AND ENGINEERING ETHICS	8
J	Davenport, T; Guha, A; Grewal, D; Bressgott, T	How artificial intelligence will change the future of marketing	JOURNAL OF THE ACADEMY OF MARKETING SCIENCE	25
J	Tran, BX; Vu, GT; Ha, GI; Vuong, QH; Ho, MT; Vuong, TT; La, VP; Ho, MT; Nghiem, KCP; Nguyen, HLT; Latkin, CA; Tam, VVWS; Cheung, NM; Nguyen, HKT; Ho, CSH; Ho, RCM	Global Evolution of Research in Artificial Intelligence in Health and Medicine: A Bibliometric Study	JOURNAL OF CLINICAL MEDICINE	30
J	Pan, XN; Hamilton, AFD	Why and how to use virtual reality to study human social interaction: The challenges of exploring a new research landscape	BRITISH JOURNAL OF PSYCHOLOGY	76
J	Cath, C; Wachter, S; Mittelstadt, B; Taddeo, M; Floridi, L	Artificial Intelligence and the 'Good Society': the US, EU, and UK approach	SCIENCE AND ENGINEERING ETHICS	126
J	Wirtz, J; Patterson, PG; Kunz, WH; Gruber, T; Lu, VN; Paluch, S; Martins, A	Brave new world: service robots in the frontline	JOURNAL OF SERVICE MANAGEMENT	315

图1.5 在Web of Science上以人工智能伦理为研究主题的高引文章列表

其中由牛津大学互联网学院发表在“科学与工程伦理”上的这篇“人工智能和‘好社会’：美国、欧盟和英国的做法”较为全面的解读和比较了2016年10月，由美国白宫科学技术政策办公室、欧洲议会和英国下议院各自针对广泛使用人工智能的三份报告，该文总结出“透明度，问责制和对经济和社会积极影响”是表明“良好AI社会”的关键价值点，这些观点似乎是这三份报告的基础^①。

搜索人工智能偏见（AI bias）的结果为788条，搜索人工智能偏见伦理（AI bias ethics）的结果比较少，为71条，但大部分集中发表在计算机、工程电气电子、物理学等自然学科领域期刊，且大多停留在反映人工智能存在偏见这一现象上，并没有深入到伦理道德和哲学领域，发表在伦理学和哲学领域期刊论文仅15篇。搜索人工智能道

① Cath C, Wachter S, Mittelstadt B. et al. Artificial Intelligence and the 'Good Society': the US, EU, and UK approach[J]. Sci Eng Ethics, 2018(24): 505–528.

德（AI moral）的结果为234条，同样集中热门在近两年，研究主要集中在计算机人工智能学科领域，哲学和伦理学分别排列第二位和第三位^①。

1.3 研究方法与创新点

1.3.1 研究方法

- 1) 文献研究法。本文通过对大量国内外文献资料的查阅、研究、梳理，形成了该文的理论和论证基础，这些文献资料包括各种政策性规范、报告、期刊论文、报纸新闻、学术专著、网络新闻、影像资料等。
- 2) 实验法。本文通过结合“封面女郎招聘系统的女性吸引力测试”实验，用实验的方法解释了人工智能内隐偏见形成的原因，验证了人工智能内隐偏见存在的普遍性，以及为如何消除人工智能内隐偏见提供了成功的实验范例。
- 3) 跨学科研究法。本文涉及学科较广，是包括计算机学、心理学、神经科学、道德哲学、伦理学等的跨学科研究，人工智能伦理问题的研究从来不是单一学科能解决的问题。
- 4) 数量分析法。在本文实验部分涉及的验证指标使用了数量分析法，以及在全文的论证过程中有一些统计数据调查。

1.3.2 创新点

- 1) 理论与实验相结合。在对本课题做文献梳理后，本人发现大部分的研究都停留在对人工智能产生偏见这一现象的陈述和罗列上，也提出了一些解决方案，但大多是概念性和理论性的解决方案，本文理论与实际相结合的研究方式不管是从目前国内还是国外的研究结果来看都是有创新价值的。
- 2) 跨学科的实际案例分析。在对国内外研究现状的调查中，本人发现大多是针对人工智能伦理方面单一性学科的研究，但本文涉及学科较广，是包括计算机学、心理学、神经科学、道德哲学、伦理学等的跨学科研究。
- 3) 提出了内隐偏见和人工智能偏见的联结。通过对文献分析，过往虽然几乎都在集中研究和验证人的偏见是导致人工智能产生偏见的主要原因，但没有分析人的内隐偏见对人工智能偏见的重要影响，内隐偏见的研究在人工智能领域似乎被忽视。

^①所有数据查询更新时间为2021年3月31日。

第2章 内隐偏见的释义、成因及道德影响

什么是内隐偏见？它如何表现出来？你是隐性的种族主义者吗？如果是为何你没有意识到？它是如何形成的？对于自己的无意识的偏见，人类需要承担道德责任吗？这些问题都是本章即将回答的问题。

2.1 内隐偏见释义

2.1.1 偏见与偏好的分析

偏见（Bias 或者 Prejudice）“表示人们对各种可能判断的反应的位移”，这种偏见可能会偏向于有利或不利的评估。^①偏见被定义为偏向于赞成或反对一个事物，个人或群体与另一个事物，个人或群体的偏见，通常以一种不公平的方式。奥尔波特在他的《偏见的本质》一书中解释说：“人类的思想必须借助分类来思考”，“类别一旦形成，便是正常偏见的基础。”^②偏见可以被视为刻板印象和偏见的总体定义，因为这是我们将特质（通常是消极的）与特定人群联系起来的方式。偏见可以以“积极”（偏爱）和“消极”（不公正的歧视）两种方式表现出来^③。偏爱也是偏见的一种表现形式，偏爱的结果是对其中一部分对象的消极抵制，并且可能会由此而导致一定的伦理结果。Tarrant等人的研究表明，当人们认为团内和团外音乐喜好不同时，就会出现对团外人士的消极态度，我们假设当人们相信音乐喜好相似时，这种态度会变得更加积极。^④奥尔波特也指出偏爱会在内群体成员之间不可避免地产生，但不同的内群体在对待外群体的态度上的差异可能是很大的。对自己国家或民族的偏爱来自习惯，我们用自己民族的语言来思考；它的成功是我们的；它为我们提供了个人安全的框架。但是，群体经常并不满足于其成员的这种“自然”认同；他们以多种方式刺激它——通常以牺牲外群体为代价。^⑤同时“个人偏好”作为“新的种族主义”在悄然盛行^⑥。

2.1.2 内隐偏见的内涵

内隐刻板印象最初是由心理学家Mahzarin Banaji和Anthony Greenwald在1995年定义的，在社会认同理论中，内隐偏见（implicit bias）或内在的刻板印象（implicit stereotype），是个人对某社会群体外的特殊特质的预反射意识。^⑦内隐偏见指的是对社

① Greenwald A, Krieger L. Implicit Bias: Scientific Foundations[J]. California Law Review, 2006(4), 945-967.

② 戈登·奥尔波特著，杜伟华译. 偏见的本质[M]. 北京师范大学出版社, 2017.

③ Howard A, Borenstein J. The Ugly Truth About Ourselves and Our Robot Creations: The Problem of Bias and Social Inequity[J]. Sci Eng Ethics, 2018(24), 1521-1536

④ Tarrant M., Hargreaves D. J., North, A. C. Social categorization, self-esteem, and the estimated musical preferences of male adolescents. Journal of Social Psychology, 2001, 141(5), 565-581.

⑤ Robinson B. A. "Personal Preference" as the New Racism: Gay Desire and Racial Cleansing in Cyberspace[J]. Sociology of Race and Ethnicity, 2015, 1 (2) 317-330.

⑥ Greenwald AG, Banaji, MR. Implicit social cognition: Attitudes, self-esteem, and stereotypes[J]. Psychological Review, 1995 (102): 4-27

会群体的评价，而这些评价在很大程度上是在意识或控制之外的。内隐偏见是我们根据先前的经验，个人的根深蒂固的思维模式，假设或解释做出判断或决定，而我们并不知道正在这样做。内隐偏见常在有意识的意图之前起作用，因此很多学者也将无意识偏见（unconscious bias）等同于内隐偏见。

一个人说的话并不一定能很好地代表他/她的整体感受和想法，也不一定能很好地表现自己的行为。可以说，在评价一个人内隐态度时我们而不必直接询问他们“您如何看待伊斯兰教”、“亚洲人和金发美女你觉得哪个更漂亮”的调查是明确而直接的，从某种意义上说，既明确报告了受试者的判断，又直接向受试者询问了研究人员感兴趣的话题。因此，隐性措施可能被认为是间接评估人们的思想，感觉和行为的工具，也就是说，无需依靠“自我报告”。取而代之的问法可能是“您对穆罕默德（常用的伊斯兰教名字）有什么看法”、“这些照片里您觉得哪些更吸引您”的调查是显式和间接的，结果明确报告了受试者的判断，但研究人员可以通过其判断推断出其对种族的刻板印象和态度。在第三章的实验设计也是基于此间接问法，我们不会直接询问受试者更喜欢亚洲人还是欧洲人，而是从实验结果去判断。同样隐性偏见的测试可以预测偏见行为，例如顺序启动^①和隐式联想测试（IAT）^②在某些情况下甚至可能比传统的自我报告更好。

内隐刻板印象被认为是受经验影响，并基于特定素质和社会类别（包括种族和/或性别）之间的学习联系。^③我们的内隐态度反映了人们不断受到刻板印象的刻画各种不同类别的成员和项目：种族群体，职业，妇女，国籍，同性恋社区成员，道德和政治价值观等。即使个人有时不知道自己拥有这种刻板印象，他们的观念和行为也会受到他们所隐含的刻板印象的影响。内隐偏见是内隐社会认知的一个方面：感知，态度和定型观念可由环境激活，并在有意识的意图或认可之前起作用。也许最令人惊讶的是，隐性偏见不管是在曾受到过“针对性”偏见的群体成员中以及那些致力于消除偏见的人们中都普遍存在。即使个人明确拒绝偏见，内隐偏见也会持续存在。

2.1.3 内隐偏见的主要表现

2.1.3.1 种族歧视

根据联合国的定义，“种族歧视”（racial discrimination）是指基于种族、肤色、世系或民族或人种的任何区别、排斥、限制或优惠，其目的或效果为取消或损害政治、

① Fazio R & Olson M. Implicit Measures in Social Cognition Research: Their Meaning and Use[J]. Annual review of psychology 2003 (54): 297-327.

② Greenwald A G, McGhee. D E, Schwartz J L K. Measuring individual differences in implicit cognition: The implicit association test[J]. Journal of Personality and Social Psychology, 1998 (74): 1464-1480.

③ Hahn A, Judd C M, Hirsh H K, . et al. Awareness of implicit attitudes[J]. Journal of Experimental Psychology: General, 2014 (143): 1369-1392.

经济、社会、文化或公共生活任何其他方面人权及基本自由在平等地位上的承认、享受或行使^①。

一些社会学家认为，特别是在西方，种族主义在社会上经常受到消极的制裁，于是种族主义已经从公然变为带种族主义偏见的隐性表达。种族主义的“较新的”（更隐蔽和更不易发现）形式被认为嵌入社会进程和结构中更加难以探索和挑战。有人提出，尽管在许多国家，公开或明显的种族主义已越来越成为一种禁忌，即使在那些表现出平等主义明确态度的国家中，隐性或厌恶的种族主义仍然在潜意识中得以维持^②，作为社会心理学的内隐联想和内隐态度（内隐认知的组成部分），心理学家对这一过程进行了广泛的研究。内隐态度是在没有意识地意识到态度对象或自我的情况下进行的评估，这些评估通常是有利的或不利的。它们来自个人经验中的各种影响。^③内在态度没有被有意识地识别（或被错误地识别）过去的经历的痕迹，这些经历调解了对社会对象的有利或不利的感觉，思想或行为。这些感觉，思想或行为会对个人可能不了解的行为产生影响。^④因此，当我们潜入不同颜色的面孔时，潜意识种族主义会影响我们的视觉处理以及我们的思维方式。例如，在思考犯罪时，斯坦福大学的社会心理学家詹妮弗·L·埃伯哈特（Jennifer L. Eberhardt）认为，“黑与犯罪如此相关，您已经准备好挑选出这些犯罪对象。^⑤”这种接触会影响我们的思想，并且会在我们对他人甚至对物体的行为中引起潜意识种族歧视。因此，种族主义思想和行动可能源于我们所不知道的成见和恐惧^⑥。人类潜意识里的隐性的种族偏见却在人工智能领域表现得十分显性。计算机视觉系统错误地将黑色人种标记为高犯罪风险^⑦，并且用户发现Google的照片应用程序将自动将黑人的图像分类为大猩猩^⑧。人工智能选美系统的机器人裁判不喜欢黑皮肤的女人^⑨，试想一下，如果这是一个封面模特职位，那毫无疑问，黑色皮肤的候选人将被淘汰。微软的聊天机器人Tay通过机器学习技术，在Twitter社交平台自主学习，短时间内便把自己打造成了一个种族主义者，并在Twitter上发表了大量令人乍舌的种族主义言论。

① United Nations. International Convention on the Elimination of All Forms of Racial Discrimination[S]. United Nations. 1969.

② Greenwald, A.G.; Banaji, M.R. (1995). "Implicit social cognition: Attitudes, self-esteem, and stereotypes". Psychological Review. 102 (1): 4–27.

③ Devos T. "Attitudes and attitude change". Implicit attitudes 101: Theoretical and empirical Insights[J]. New York: Psychology Press, 2008: 61–84.

④ Gawronski B, Payne B K. Handbook of Implicit Social Cognition: Measurement[M]. Theory and Application, 2010.

⑤ Eberhardt J L, Purdie V J, Goff P A, et al. Seeing Black: Race, Crime, and Visual Processing[J]. Journal of Personality and Social Psychology, 2004 (6): 876–93.

⑥ Belenko S, Cassia S. Drugs, Crime, and Justice[M]. Sage, 2014.

⑦ Angwin J, Larson J. Bias in criminal risk scores is mathematically inevitable researchers say [EB]. Propublica, 2016(12).

⑧ Crawford K. Artificial Intelligence's White Guy Problem[EB]. The New York Times, 2016(6).

⑨ The Guardian. A beauty contest was judged by AI and the robots didn't like dark skin[EB]. The Guardian, 2016(8).

2.1.3.2 性别偏见

性别偏见被定义为在特定情况下（例如，在职业中或在主要社会角色中）一种性别被认为比另一种性别更具优势^①。性别偏见导致的结果是对于职业或者主要社会角色的刻板印象，例如，通常人类的内隐偏见会将“护士”与“女性”关联，“医生”与“男性”关联。哈佛大学肯尼迪政府学院和哈佛商学院的研究表明，人们认为“女性在数学任务和言语任务上比男性差。”^②耶鲁大学的一项招聘研究表明，“男性”候选人被认为更有才华和经验，他们被更多地选中，而且薪水更高。^③同时，内隐联系测试也揭示了男性与科学和数学之间以及女性与艺术和语言之间的内在联系。^④人们发现，年仅9岁的女孩具有内隐的男性数学刻板印象和对语言的偏爱而不是数学。^⑤与数学相比，女性对数学的负面联想更强，而与性别认同相关的女性越强，她们对数学的否定性越强。在一项揭示虚假名声效应的测试中，与不知名的女性名字相比，不知名的男性名字更容易被错误地识别为著名人物；这是对男性成就的内在刻板印象的证据^⑥。性别偏见在高科技行业尤为普遍，白宫的科技政策办公室和人事管理办公室的机构间报告显示偏见包括隐形偏见抑制了女性的发展，女性在自然科学，技术，工程和数学领域的代表性不足^⑦。2019年3月联合国教科文组织部门发布了“如果可以，我会脸红：通过教育消除数字技能中的性别差异（I'd blush if I could: Closing Gender Divides in Digital Skill Through Education），提示了高科技行业对女性数字技能的性别偏见，该报告统计在机器学习领域工作的女性比例仅为12%，建议通过教育提高女性的数字技能是解决人工智能就业性别偏见的当务之急^⑧。Google 和亚马逊致力于性别平等，但基于历史数据的智能招聘系统都存在着歧视女性的现象。

2.1.3.3 组内偏爱

组内偏爱（In-group favoritism），有时也被称为组内外偏见，组内偏见，组间偏见，或组内优先，是一种偏爱团体内成员而不是团体外成员的模式。这可以通过对他人的评估，资源分配以及许多其他方式来表达。^⑨组内偏爱和种族偏见息息相关，在很多情况下能导致种族偏见。在人力资源行业也称“亲和力偏见”，意为招聘人员常青

①Costa-jussà MR. An analysis of gender bias studies in natural language processing[J]. Nat Mach Intell, 2019(1): 495-496.

②Johns M, Schmader T, Martens A. Knowing Is Half the Battle: Teaching Stereotype Threat as a Means of Improving Women's Math Performance[J]. Psychological Science, 2005(16):175-179.

③Moss-Racusin C A, Dovidio J F, Brescoll V L, et al. Faculty's subtle gender biases favor male students[J]. Proceedings of the National Academy of Sciences, 2012; 109 (41): 16474-16479.

④Nosek B. A, Banaji M. R, Greenwald A. G. Math = male, me = female, therefore math ≠ me[J]. Journal of Personality and Social Psychology. 2002; 83 (1): 44-59.

⑤Steffens M. C, Jelenec P, Noack P. On the leaky math pipeline: Comparing implicit math-gender stereotypes and math withdrawal in female and male children and adolescents[J]. Journal of Educational Psychology, 2010; 102 (4): 947-963.

⑥Banaji M. R., Greenwald, A. G. Implicit gender stereotyping in judgments of fame [J]. Journal of Personality and Social Psychology, 1995, 68 (2): 181-198.

⑦Handelsman J, Ward W. Increasing Diversity in the STEM Workforce by Reducing the Impact of Bias [EB]. The White House, 2016.

⑧联合国教科文组织部门. 如果可以，我会脸红：通过教育消除数字技能中的性别差异[M].2019(3).

⑨Aronson E., Wilson T. D., Akert R. Social psychology[M]. Upper Saddle River: Prentice Hall, 2010.

睐于持有与自己或者公司有相同特质、符合企业文化的候选人。研究表明，由于文化群体的形成，群体内偏爱会出现。^①同样，人们更愿意帮助与他们有偶然相似之处的其他人，例如生日或名字^②。

尽管研究表明我们仍然可以对自己的群体持有隐性偏见，但我们通常倾向于持有有利于我们自己的群体的隐性偏见。2008年总统大选期间进行的一项研究展示了群体身份的动态变化。该研究是使用经济学独裁者游戏在马萨诸塞州剑桥市的395名民主党人中的进行的。给受试者6美元以在他们自己和另一个人之间分配。除了在民主初选中支持的候选人以外，收件人都保持匿名。在三个不同的时期收集数据。6月10日至18日（在希拉里·克林顿在6月7日的让步演说之后）；8月9日至14日，在25日举行的民主党全国代表大会之前；并于9月2日至5日举行总统选举。结果显示，从6月一直到8月的民主党全国代表大会，男性表现出明显的群体偏爱。但是，这种群体内偏见并未在9月出现。妇女在整个过程中均未表现出明显的组内偏爱。实验表明，小组身份是灵活的，可以随时间变化。研究人员认为，由于在选举中成为民主党提名人的竞争仍是最近的，因此在6月出现了群体内偏见。缺乏实际的选举冲突（针对共和党），导致人们对整个重要群体的感觉一直持续到整个八月。直到9月，团体内偏爱消退才出现，因为现在团体之间共享了一个上级的目标。总统选举的结果表明，奥巴马能够在主要选民偏爱克林顿的主要州（例如宾夕法尼亚州和俄亥俄州）获得广泛支持^③。

2.1.3.4 其他刻板印象

虽然内隐刻板印象的研究方向主要集中在性别和种族这两个方面。但是，在其他领域也无不显示着内隐偏见，例如年龄，体重和职业。内隐联想测验（IAT）揭示了隐性刻板印象，反映了有关青少年的明确刻板印象。这些测试的结果表明，与成年人相比，青少年更容易与时髦和反抗这样的词相关联^④。此外，一项IAT研究显示，与老年人相比，老年人对年轻人的偏见更高；与年轻人相比，年轻人对年轻人的内隐偏见较低。研究还发现，妇女和受过更多教育的参与者对年轻人的内隐偏见较低^⑤。IAT还揭示了肥胖个体与低工作绩效之间的内隐刻板印象。像懒惰的人和无能的人这样的词与肥胖的人的形象比与瘦弱的人的形象更相关，瘦的面试者比超重的面试者更强^⑥。较瘦的人更有可能自动将负面属性（坏的，懒惰的）与胖人联系起来，他们比胖人更喜

① Efferson C., Lalive R., Fehr Ernst. The Coevolution of Cultural Groups and Ingroup Favoritism[J]. Science, 2008; 321 (5897): 1844–1849.

② Sachdev I., Bourhis R.Y. Status differentials and intergroup behaviour[J]. European Journal of Social Psychology, 1987; 17 (3): 277–293.

③ Rand D. G., Pfeiffer T., Dreber A., et al. Dynamic remodeling of in-group bias during the 2008 presidential election[J]. Proceedings of the National Academy of Sciences, 2009; 106 (15): 6187–6191.

④ Gross E. F., Hardin C. D. Implicit and explicit stereotyping of adolescents[J]. Social Justice Research, 2007; 20 (2): 140–160.

⑤ Chopik W. J., Giasson H. L. Age Differences in Explicit and Implicit Age Attitudes Across the Life Span[J]. The Gerontologist, 2017; 57 (suppl_2): 169–177.

⑥ Agerström J., Rooth D. The role of automatic obesity stereotypes in real hiring discrimination[J]. Journal of Applied Psychology, 2011; 96 (4): 790–805.

欢瘦人，并且明确地将胖人定为较瘦人更懒惰，动力更弱的人^①。像显性刻板印象一样，隐性刻板印象可能同时包含正面特征和负面特征，从职业内隐刻板印象的例子中可以看出，人们认为学龄前教师既热情又无能，而律师则被认为既冷又能干^②。

2.1.4 内隐偏见的特征

2.1.4.1 普遍性

在华盛顿大学的西雅图新闻发布会上心理学家Greenwald等证实了影响90%至95%的人的无意识偏见^③，这个实验证明了90年代初心理学家Mahzarin Banaji和Anthony Greenwald对内隐偏见的解释，他们认为不管你承不承认，内隐偏见总是存在的。此外，为了进一步探索内隐偏见的成因，神经学科专家们已经开始利用神经信号来检测隐性种族偏见，研究人员通过脑电图（EEG）监测参与人员的错误相关负波（ERN）时发现隐形的种族偏见十分普遍^④。

内隐偏见无处不在，甚至包括那些宣称对公正性承诺的人，例如法官。对于一个被告，这些偏见可能会在决策，指控，保释，辩诉交易，审前动议，证据动议，证人可信度，律师的说服力，定罪决定，量刑建议，量刑本身，上诉等等。在每个阶段，即使是很小的偏差也可能会聚集成一个实质性的影响。像所有其他人群一样，警官也无法避免隐性偏见。Eberhardt等对警察进行了研究，发现当直接问“谁看起来很犯罪”时，他们选择了黑人面孔而不是白人面孔^⑤，而且，自动隐性偏见也可能导致军官误解黑人的行为是可疑或激进的。这是由于黑人的刻板印象普遍存在于美国文化中，结果白人对黑人的思想和行为可能会受到种族刻板印象的自动激活的影响。

2.1.4.2 隐蔽性

内隐偏见之所以被称为隐性偏见，是因为它不易被察觉，它是以无意识的方式影响人们的理解。这些偏见都是在没有个人意识或故意控制的情况下非自愿地激活的。内隐偏见潜伏在潜意识的深处，不同于人们出于社会或政治正确性的目的可能选择隐瞒的已知偏见，相反，内隐偏见通过内省获得的效果是有限的。在分别为哈佛大学和华盛顿大学心理学教授马扎林·贝基和安东尼·格林沃尔德的心理学专著《盲点》里通过调查得出，那些自称为公平公正的白人，也会存在内隐偏见，它的隐蔽性让自认十分注意行为判断公正的“好人”都无法察觉，他们在美国150万白人进行完内隐种族测试

① Schwartz M. B., Vartanian L. R., Nosek B. A., et al. The Influence of One's Own Body Weight on Implicit and Explicit Anti-fat Bias[J]. Obesity 2006;14 (3): 440-447.

② Carlsson R, Björklund F. Implicit stereotype content: mixed stereotypes can be measured with the implicit association test[J]. Social Psychology, 2010;41 (4): 213-222.

③ Yale News. Roots of Unconscious Prejudice Affect 90 to 95 Percent of People, Psychologists from Yale and University of Washington Show [EB]. Yale News. 1998 (9).

④ Amodio D.M, Harmon-Jones E, Devine P.G, Curtin J.J, et al. Neural Signals for the Detection of Unintentional Race Bias[J]. Psychological Science. 2004;15(2):88-93.

⑤ Eberhardt J L, Purdie. V J, Goff P A, et al. Seeing Black: Race, Crime, and Visual Processing[J]. Journal of Personality and Social Psychology, 2004 (6): 876-93.

之后发现，即便其中40%的人都宣称自己是崇尚平等的，但他们却得出一个内隐的种族偏见的结果^①。谢菲尔德大学哲学系教授Holroyd总结了内隐偏见为何是隐蔽的两个原因，原因之一是，个人可能不会对他们本来希望没有的联系不坦率或坦率。另一个原因是，关联具有自动过程的特征，这使行动者难以识别和报告^②。

由于内隐偏见的不易察觉，内隐联想测验（IAT）由Anthony Greenwald, Debbie McGhee和Jordan Schwartz于1998年引入实践中。IAT是社会心理学领域一项有争议的评估，旨在衡量概念（例如，黑人，同性恋者）与评估（例如，好，坏）或定型观念（例如，运动，笨拙）之间的关联强度。它通常用于评估测试对象所隐含的刻板印象。它的主要思想是，当密切相关的项目共享相同的响应密钥时，做出响应变得更加容易，举例来说，在考察异性恋的内隐偏见时，他们对将异性恋者+好/异性恋者+坏做配对选择的反应速度要比在同志+好/异性恋者+坏更快地完成任务配对。IAT测试的格式用途广泛，已用于调查种族，性别，性别，年龄和宗教信仰方面的偏见，以及评估自尊心。IAT现在广泛用于社会心理学研究，并且在某种程度上还用于临床，认知和发展心理学研究。但是关于IAT的有效性，可靠性以及测试结果是否是隐含偏差的一直是极具争议的，^③并且IAT表现出不一致的内部一致性，其重测可靠性为0.60，这是一个相对较弱的水平^④。

2.2 内隐偏见形成的一般原因

2.2.1 受大脑思考方式的影响

内隐偏见形成的原因之一为我们习惯了使用大脑快速，情绪化，无意识的思维方式。根据丹尼尔·卡尼曼的研究，大脑中有两个系统可以组织我们的日常生活：系统1和系统2。系统1更多地用于快速，情绪化，无意识的活动（如开车，说话，打扫卫生等），几乎不需要甚至不费吹灰之力，但这通常很容易出错。系统2是缓慢，逻辑，努力，有意识的思考，其中理性占主导地位。系统1是一种思维捷径，我们采用这种捷径，经验法则，有根据的猜测和使用“常识”都是思维捷径的形式，因为它不需要付出太多努力，换句话说就是一种懒惰行为^⑤。内隐偏见是不正确地采用这些认知捷径之一的结果，所以我们错误地依靠这些无意识的刻板印象在一个非常复杂的世界中提供判断指导，尤其是当我们承受巨大压力时，则更有可能依靠这些偏见而不是检查所有相关的周围信息。

① 马扎林·贝基，安东尼·格林沃尔德·葛樱楠译·盲点[M]·中信出版社，2014:188.

② Jules Holroyd. Implicit bias, awareness and imperfect cognitions[J]. Consciousness and Cognition, 2015: 511-523,

③ Ortnier T. M.; Van D.V., Fons J.R. Behavior-based assessment in psychology : going beyond self-report in the personality, affective, motivation, and social domains[M]. Hogrefe Publishing, 2015.

④ Nosek B. A, Greenwald A. G., Banaji M. R. Understanding and using the Implicit Association Test: II. Method variables and construct validity[J]. Personality and Social Psychology Bulletin, 2005; 31 (2): 166-180.

⑤ 丹尼尔·卡尼曼著，胡晓姣，李爱民等译·思考，快与慢[M]·中信出版社，2012:1-13.

系统1的思维方式	系统2的思维方式
快速的	缓慢的
直觉性的	理性的
自动的	复杂的
少量/不需要努力的	需要努力的
情绪化的	更具逻辑的
无意识的	有意识的

表2.1 影响大脑思维方式的两个系统

另外，戈登·奥尔波特在《偏见的本质》中指出，人脑必须借助分类来进行思考。分类一旦形成，这些类别就成了正常预判的基础^①。我们日常中很多预判都依赖于分类而这些分类可以帮助我们更高效的生活。并且他还进一步指出，当这种预判跟事实不相符时，我们大脑会建立起二次防御机制（re-fencing），如果我们发现一个苏格兰人很吝啬，就会感到高兴，因为他证明了我们的预判^①。因为有机会说出“我早就告诉过你”是一件很让人开心的事，这说明我们对他人的刻板印象得到了肯定的证明，但如果事实与我们的预判相违背，我们的大脑则更倾向于消极的抵触并抗拒。奥尔波特的这些理论在一定程度上支持了卡尼曼的理论，即分类一旦形成，就会是系统1发挥其作用，做出快速的、无意识的判断。

其次，菲利普斯等人发现，隐性偏见还与人类脑部的结构有关，内隐偏见的估计值与被称为杏仁核的大脑结构的激活呈正相关。由于杏仁核牵涉到情感反应的控制，因此他的研究结果表明，内隐态度可能源于对刺激的自动情绪反应，而外显态度则可能更冷静（在认知上得到更好的控制）^②，此外前额叶皮层也以不同的处理速度处理自动的无意识的和理性的有意识的判断^③。

2.2.2 认知一致性原则

社会心理学中一个古老的原则是，人们喜欢对相关态度对象进行一致性评估。例如，根据这个原则，如果我喜欢自己并且我是女性，那么我也应该喜欢女性。这种预测意味着应该在自尊，性别认同和性别态度等变量之间观察到认知的一致性。研究表明，甚至在上幼儿园之前，孩子们就已经使用他们的小组成员身份（例如，种族，性别，年龄组等）来指导有关心理和行为特征的推论。在这么小的年龄，他们已经开始寻找模式并认识到它们与其他群体的不同之处，孩子们不仅会认识到让他们与其他群

① 戈登·奥尔波特著，杜伟华译. 偏见的本质[M].北京师范大学出版社, 2017.
② Elizabeth A. P., Kevin J. O'C., William A. C., et al. Performance on Indirect Measures of Race Evaluation Predicts Amygdala Activation[J]. J Cogn Neurosci, 2000; 12 (5): 729-738.
③Bucciarelli M., Khemlani S., Johnson-Laird, P.N..The psychology of moral reasoning. Judgment and Decision Making[J]. 2008: 121-139.

体脱颖而出的原因，而且他们相信“与我相似的事物是好事，而与我不同的事物则是坏事”，孩子们不仅注意到自己与他人之间的相似之处或不同之处，认识到让他与众不同的因素，然后对那些外来群体（一个个人无法识别的社会群体）形成负面意见，这会助长内隐偏见的发展^①。

在认知一致性原则上发展起来的社会认同理论也很好的解释了隐性偏见的成因。埃弗森（Efferson），拉利夫（Lalive）和费尔（Fehr）于2008年发表了此类研究报告，文化群体的形成改变了个人面临的选择压力，因此导致某些行为特征是有利的^②。因此，如果在过去的文化环境中存在这样的选择压力，即某个群体中的成员与某个行为规范相关联，则群体内偏见的出现会有利于同一组的人的行动。根据社会认同理论，群体偏见的关键决定因素之一是需要提高自尊心。积极地看待自己的欲望被转移到群体中，从而形成了以积极的眼光看待自己的群体，而相比之下，却以消极的眼光看待外部群体的趋势。^③社会认同理论认为来自于社会群体和类别中的成员身份是自我概念的重要组成部分。当人们根据自我包容的社会类别（例如，性别，阶级，团队）来定义和评估自己时，有两个过程起作用：（1）分类，在感知上会加剧组内和组外之间的差异，以及组内成员（包括自我）在刻板印象维度上的相似性；（2）自我增强，因为自我概念是根据群体成员资格来定义的，所以在行为和感知上都力求在群体内而不是群体外。社会身份在认知上被表示为描述和规定信念，态度，更具体地说，根据社会认同理论，沿着这一连续性在个人和社会认同转变之间存在一个连续性，该连续性决定了与群体相关的或者个人特征影响一个人的感受和行为的程度^④。

2.2.3 早期经历导致特殊偏好

中国有句俗语：“一招被蛇咬，十年怕井绳”。由个人早期特殊的经历背景也会形成特殊的认知偏好，这些特殊的经历在其个人的心理根深蒂固以至于它会无意识的影响到个人生活的方方面面。一个典型的概念是隐性态度源于过去（并在很大程度上被遗忘）的经历，而显性态度则反映了最近的事件或可记起的事件。^⑤在支持该假设的研究中^⑥，吸烟者对其习惯的内在态度与他们最早的吸烟经历（主要是令人不快的）

（例如，从第一支香烟中反感烟草烟雾和恶心）相伴而生。因此，如果早期的经历不愉快，那么自动的态度是负面的。相比之下，吸烟者的明确态度与他们最近的吸烟经

① Baron A., Dunham Y., Banaji M., Carey S. Constraints on the Acquisition of Social Category Concepts[J]. Journal of Cognition and Development, 2014;15: 238-268.

② Fu F., Tarnita, C. E., Christakis N A, et al. Evolution of in-group favoritism. Scientific Reports, 2012. 2: 460.

③ Billig M., Tajfel H. Social categorization and similarity in intergroup behaviour[J]. European Journal of Social Psychology, 1973; 3 (1): 27-52.

④ Tajfel H., Turner J.C. An integrative theory of intergroup conflict[J]. The Social Psychology of Intergroup Relations. Brooks-Cole, 1979: 33-47.

⑤ Rudman L.A. Sources of Implicit Attitudes[J]. Current Directions in Psychological Science. 2004;13(2):79-82.

⑥ Rudman L. A., Heppen J. B. Implicit romantic fantasies and women's interest in personal power: A glass slipper effect?[J]. Personality and Social Psychology Bulletin, 2003; 29:1357-1370.

历（主要是积极的（例如，喝咖啡时和和朋友一起吸烟））有所不同。本人也有类似经历，儿童时期第一次吸烟被呛的经历深刻影响了我对吸烟的负面态度。此外还有一些特殊成长经历也会影响个人的内隐态度，例如，离婚子女可能只与具有其偏好特征的伴侣接触，所以接触的机会有限，有过抑郁症经历的人对事情普遍具有消极的认知偏见^①。

2.2.4 社会文化的长期沉淀

媒体、文化和个人的教育背景的影响也可以促进人们对社会外联成员形成的隐性联想的兴起。信息大爆炸的时代，各种媒体信息变得越来越容易获得，尽管有很多好处，但它也可能导致隐性偏见。电视刻画个人的形象，或语言期刊文章使用的描述方式，都可能会根深蒂固我们脑海中的特定偏见。尽管隐性偏见中涉及的某些认知过程是普遍的，例如语义联想和图式的使用，但这些认知的内容和含义是由文化资源和文字所决定的。这些文化资源和文字反过来在地理上和整个社交网络中都各不相同，它们本身都受到历史进程的影响。隐性偏见对社会环境的响应可以解释为文化中种族化联想的认知反映^②。

此外社会教育也对隐性偏见的形成有着重要影响，社会教育不仅包括学校的传统教育，也包括家庭教育和自我学习。学习是获得新的理解，知识，行为，技能，价值观，态度和偏好的过程^③。人从出生时的一张白纸到接受教育和学习，汲取知识，慢慢形成其价值观和对周围事物的理解能力，毋庸置疑教育和学习对一个人的意志和思维起着至关重要的作用。人们经常发现教育是种族偏见的重要决定因素并且有初步证据表明，这种教育效果因国家而异^④。例如，研究学者调查得出，波兰的教育体制对学生产生民族主义和偏见起着决定性作用^⑤。在医学界，因医护人员对肥胖个体的态度助长了歧视，并导致不良的健康状况，医学教育环境可能对肥胖产生显性和内隐偏见，研究者通过创新的教育干预措施（阅读有关肥胖的戏剧）发现其对降低对肥胖者的内隐偏见有显著作用^⑥。

① Jonas E., Ernst H.W. K., Nazanin D.. The combined cognitive bias hypothesis in depression[J]. Clinical Psychology Review, 2012: 413-424.

② Keith Payne B., Vuletich H. A., Brown-Iannuzzi J. L. Historical roots of implicit bias in slavery [J]. Proceedings of the National Academy of Sciences, 2019; 116 (24) 11693-11698,

③ Richard G., Psychology: The Science of Mind and Behaviour[M]. Hodder Education, 2010.

④ Evelyn H. , Peer S., Mérove G. Education and Ethnic Prejudice in Europe: Explanations for cross-national variances in the educational effect on ethnic prejudice [J].Scandinavian Journal of Educational Research, 2002; 46: 5-24

⑤ Piotr Ż. Nation, national remembrance, and education – Polish schools as factories of nationalism and prejudice[J]. Nationalities Papers, 2017; 46:6: 1046-1062

⑥ Matharu K., Shapiro J., Hammer R., et al. Reducing obesity prejudice in medical education[J]. Education for health (Abingdon, England), 2014: 27(3), 231-237.

2.3 内隐偏见对道德判断与评价的影响

2.3.1 内隐偏见影响道德判断

道德判断一直是道德心理学和哲学关注的核心课题之一，并且不同的理论对如何引起道德判断着不同的解释。如新科尔伯格主义者詹姆斯·雷斯（James Rest）在他的道德发展理论四要素模型（Four Component Model）中将道德判断（moral judgment）定义为“正确推理在特定情况下应该做什么的能力”，一个心理过程经过四要素模型激活并发挥最佳作用。首先，一个人必须解释情况。第二，一个人必须进行道德推理。也就是说，他或她必须权衡任何相互竞争的道德问题，并就应采取的措施形成成熟而负责任的判断。第三，道德判断必须优先于其他价值观和行动选择。最后，这个人必须将他们的道德意图付诸行动。道德判断一词存在争议，反映在认知心理学上的广泛辩论，关于显式推理与更隐式和无意识的过程的作用存在争议。中心问题是：当人们说一个行动是对还是错，是好是坏时，他们的判断是有意识的，经过深思熟虑的过程（即道德推理）的结果，还是无意识的动机和直觉的结果？当然，人们可以为自己的信仰提供道德理由，但是一些理论家将这些理由视为真正激励人的信仰，而另一些理论家则将这些理由视为道德判断的事后合理化，其真正根源是无意识的过程。道德情感主义学派则认为，道德判断的根源来自于情感，而理性推理只是用来证明事实和解释相关概念的手段。晚近还有心理学家主张道德判断的可同时实行的双重机制，即理性的推理和感性的情感都可能在道德判断中发挥重要作用并最终导致不同类型的判断，如后果主义判断与理性推理相关，而义务论判断则与情感相关。认知神经科学医学临床研究得出人类前额叶皮层（PFC）在社会认知和道德判断中起着重要作用，而前额叶皮层以不同的处理速度处理社会认知和道德判断等高阶功能，例如，可以在几毫秒内（称为隐式，快速或自动处理）或在更长的时间段内得出（称为“他人”的印象和判断力，显式，缓慢或受控的处理）。PFC可以在人类的自觉意识之外进行上述大多数功能，源自PFC内部和外部的神经区域的多个认知和感觉过程之间交互的复杂性，这些交互作用为复杂的社会行为和道德判断提供了基础。本文支持认知神经科学的观点，内隐态度和外显态度都共同影响着道德判断，这些研究表明了情感的重要性，但与此同时他们也认为理性的推理可以在道德判断中发挥有限但非常重要的作用。^①

2.3.2 内隐偏见助长道德情感主义

道德情感理论通常认为道德与不道德之间的区别是通过对经验的情感反应发现的。哲学家休谟（David Hume）认为，道德更多地基于观念，而非逻辑推理^②。这意味着人

^①Greene J., Haidt J. How (and where) does moral judgment work? [J]. Trends in Cognitive Sciences, 2002(6) 517-523.

^② Bucciarelli M, Khemlani S, Johnson-Laird, P.N. The psychology of moral reasoning[J]. Judgment and Decision Making, 2008.

们的道德更多地基于他们的情感和感受，而不是对任何给定情况的逻辑分析。休谟认为道德与激情，爱，幸福和其他情感联系在一起，因此并非基于理性。乔纳森·海特（Jonathan Haidt）同意了休谟的观点，在他的社会直觉主义者模型中认为，关于道德状况或思想的推理遵循最初的直觉。^①道德心理学长期以来一直专注于推理，但道德情感主义的支持研究却表明，道德判断更多是基于情感出发，是情感直觉的问题，而不是理性而刻意的推理。海特对道德推理的基本立场是：“道德直觉（包括道德情感）首先出现并直接引起道德判断”。他将道德直觉的特征描述为“道德判断意识中的突然出现的，包括情感的评价（好-坏，喜欢-不喜欢），而没有任何意识地意识到其实已经经历了搜索，评估证据或推理结论的步骤”^①。内隐偏见的无意识性让人们在第一时间的情感（或者激情）做出偏见的反应。理性主义认为道德判断依赖于道德推理，内隐偏见则忽略了道德推理的逻辑性和因果性，认为道德推理不过是为了事后证明其道德直觉的合理性，这就助长了道德情感主义的发展。

在1990年代，人们对情感的革命由于对“自动性”的新关注而得到加强，“自动性”是头脑无意识地自动解决许多问题的能力，包括高层社会问题^②。最近的综合模型，社会直觉主义者模型，将对自动化的研究与进化心理学中的神经科学和理论相结合。该模型表明道德判断与审美判断非常相似：我们看到一个动作或听到一个故事，立即感到被认可或被拒绝。最好将这些感觉视为充满情感的直觉，因为它们在意中突然毫不费力地出现，并具有情感评价（好的或坏的），但没有任何经过搜索，权衡证据或推断结论的感觉。这些直觉，例如关于互惠，忠诚，纯正，受苦的直觉，是由自然选择和文化力量所塑造的。人们当然参与道德推理，但是正如非正式推理研究所建议的^③，这些过程通常是支持既定结论而付出的单方面努力。（正如威廉·詹姆斯（William James）所说，“很多人认为他们只是在重新调整偏见时就在思考。”）道德推理很重要，但主要在人们试图相互影响并与朋友达成共识的社会环境中很重要。

社会心理学的最新发现支持这种对快速、自动的情感反应的重视，例如：（1）人们评估他人并自动应用道德上有负担的刻板印象；（2）维持关系和抵御威胁性想法的动机偏向判断，并激发随后的推理；（3）人们可以很容易构建事后理由来证明他们的行为和判断。^④

2.3.3 内隐偏见规避道德责任

个人在道德上对自己的内隐偏见负责吗？显然，如今最有影响力的道德责任描述理论包括一些标准是这样描述的：行为是有意图的，可控制的和单独引起的，以便使

① Haidt J. The emotional dog and its rational tail: A social intuitionist approach to moral judgment[J]. Psychological Review, 2001; 108 (4): 814-834.

② Bargh J.A., Chartrand T.L. The unbearable automaticity of being [J]Am. Psychol., 1999;54: 462-479.

③ Galotti K.M. Approaches to studying formal and everyday reasoning[J]. Psychol. Bull., 1989;105:331-351

④ Greene J., Haidt J. How (and where) does moral judgment work? [J]. Trends in Cognitive Sciences,2002(6) 517-523.

该个人完全承担责任^①。相反,根据 Weiner 的描述,当一个原因被认为是不可控制的时,责任感就会减弱^②。隐性偏见通常被宣传为无意识的或者不可控制的,这为内隐偏见提供了规避道德责任的借口。

内隐偏见的心理学研究与关于道德责任的哲学研究之间有着重要且多方面的联系,这种联系表现为隐性偏见在道德上非常重要,任何关心公正与正义的人都应该知道谁对此负责,一种观点来自意识论的观点主要集中于意识主体应该了解隐性偏见,而不是他们做什么知道。这种方法将道德责任标记为一个人的社会 and 认知环境。例如,凯利和罗德(Kelly & Roedder)认为,“机敏的评分者”负责调整自己的成绩,以弥补自己可能的偏见,因为她应该意识到并强迫自己进行隐性偏见的研究^③。按照类似的精神,Washington & Kelly 比较了具有相同心理特征的两个假设的平等主义者,他们之间的唯一区别是“老派平等主义者”在1980年评估简历,而“新平等主义者”在2014年这样做,虽然他们都没有人听说过内隐的偏见,但华盛顿和凯利认为,新道德主义者在道德上应受罪责,而旧派平等主义者则不应该。鉴于1980年和2014年的比较心理学研究现状,只有新平等主义者才可能而且应该知道他可能存在的隐性偏见。这里的基本直觉是,对责任的评估随行动者的社会和社会认知环境的变化而变化^④。

然而,相对于“受控”认知过程而言,隐性过程通常被定义为客观的,表明它们可能以绕过人的行为能力的方式影响行为。早期的研究表明,隐性偏见仅反映了对刻板印象的认识,而不是个人态度,也暗示这些状态反映了“发生于”主体的过程。然而,最近,哲学家对这些和其他数据对与道德责任有关的概念的影响提出了质疑。也许在责任文献中最了解控制的方式是一种心理机制,该机制可使行动者采取与众不同的行为,而在有充分理由的情况下则可以采取其他行动(Fischer & Ravizza)^⑤。这种控制的“原因-响应”观点所面临的问题是,是否应将自动化行为(在没有明确推理的情况下展开)视为行为人的控制之下。有人认为,自动化和控制不是互斥的。Suhler 和 Churchland 提供了无意识控制的说明,这种控制本身就可以承接自动性,且表面上足以承担承保责任^⑥。其他人则将自动性和其他自动性(例如梦游)区分开来。从这个意义上说,可以通过行为人通过先前的受控选择对他们的自动行动进行“预编程”的能力来得出相关的道德区分。它可以根据行为人有意识地监视其自动行动的能力得出^⑦;或者可能只是假定的内在态度不是自动的,因为它们很容易改变(例如,即将发布的

① Shaver K.G. The attribution of blame: Causality, responsibility, and blameworthiness[M]. Springer Verlag, New York, 1985.

② Weiner B. Judgments of responsibility: A foundation for a theory of social conduct[M]. Guilford Press, New York (1995)

③ Kelly D., Roedder E. Racial Cognition and the Ethics of Implicit Bias[J]. Philosophy Compass, 2008; 3: 522-540.

④ Washington N., Kelly D. Implicit bias and philosophy. Moral responsibility, structural injustice, and ethics by [M]. Oxford University Press, 2016: 11-26.

⑤ Fischer J.M., Ravizza M. Précis of Responsibility and Control: A Theory of Moral Responsibility[J]. Philosophy and Phenomenological Research, 2000; 61: 441-445.

⑥ Suhler C. L., Churchland P. S. Control: conscious and otherwise[J]. Trends in Cognitive Sciences, 2009; 13: 341-347.

⑦ Levy N., Bayne T. Doing without deliberation: Automatism, automaticity, and moral accountability[J]. International Review of Psychiatry, 2004; 16: 209-215.

Buckwalter)。其他学者如 Holroyd、Levy & Mandelbaum、Sie & Voorst Vader-Bours 也坚持区分对人的态度或行为的“间接”控制和“直接”控制。Holroyd 认为，在很多事情上我们没有直接的控制权，但是我们通常要对这些事情负责，例如学习技能，说外语，甚至持有某些信念^①。这些能力或状态无法直接拥有；相反，他们需要时间和精力来获取。这表明我们可以对我们只能间接进行远程控制的态度或行为负责。

道德责任的“归因论”和深层自我理论（Deep Self Theories）是意识和控制论点的替代方案，也是我推崇的观点。根据这些理论，对一个行为者负责的行为就是该行为“反省”该行为者“自己”。一种常见的说法是，责任承担行为归因于代理人，因为他们会反思代理人的“深层自我”，其中深层自我代表的是人的基本评价立场。归因论者一致认为，人们可以对无意识的行为承担道德责任。另一种方法是在行为人的“关怀”中而不是在她的理性判断中看到“深层自我”的来源（Shoemaker 2003, 2011; Jaworska 2007; Sripada 2016）。关怀被认为是具有动机，隐性偏见是否能反映代理人的关怀（Brownstein 2016, 2018）。即使在隐性偏见不归因于代理人的深层自我的情况下，也有可能持有由于隐性的偏见而违反她所承担的某些义务。然而，我认为当你的无意识偏见对他人造成伤害时，你有必要采取补救和中止措施以弥补这一伤害，况且在经验文献中已经公认，隐性偏见会导致多种歧视行为，有些甚至导致了明显的伤害行为。在牛津大学出版的《Implicit bias and philosophy》第二卷里道德专家 Sie 和 Vader-Bours 认为当刻板印象是有害的，并且当这种刻板印象所带来的伤害结果被个人及其他集体、社会、组织所意识到的情况下，我们有责任对这种内隐偏见进行纠正以终止伤害。该书的另一作者 Zheng 还从两方面解释了为什么内隐偏见需要承担道德责任：责任的第一条途径即可归因性始于形而上学和行动理论。它是从“行动问题”中产生的，也就是说，要了解自己是作为行动者的问题，因为他们对世界具有自然主义的印象，在这个世界中，我们和其他所有事物一样，都是紧密联系的因果链中的一部分。Zheng 的这第一种观点从很大程度上继承了康德的形而上学道德观点。与此形成对比的是责任的第二种途径-问责制，它起源于道德和政治哲学。它是一贯的实践，“责任”在第一阶段就作为解决道德分工问题的解决方案而出现。人们被赋予角色职责，以履行为实现我们的社会目标而应履行的特定职责和任务（即通常也是道德目标）。因此，这种实质性角色责任的概念引起了道德责任的第二种不同概念。当在适当的情况下，其他人可以使我们对我们的职责和任务抱有某些期望和要求，并在我们无法履行职责时对我们进行制裁，那么我们就此责任制在道义上负有责任。当一个人的行为

^① Holroyd J. Responsibility for Implicit Bias[J]. Journal of Social Philosophy, 2012; 43: 274-306.

给他人带来负面影响时，产生了无法解决的社会问题。即使相关人员没有恶意或过失，也必须以某种方式并由某人承担这些费用，因为有些受害者应该得到补救^①。

^① Zheng R . Implicit bias and philosophy. Moral responsibility, structural injustice, and ethics [M]. Oxford University Press,2016:65-66.

第3章 人工智能的内隐偏见：基于女性吸引力测试的实验分析

如今，人工智能被广泛的应用于招聘系统，如亚马逊、谷歌等，本实验项目系统将被广泛用于广告、电影等媒体的模特及演员求职系统，招聘筛选工作是一项繁重的任务，人工智能可以将招聘人员从该任务中解放出来。同时为帮助各研究人员理解人工智能内隐偏见的形成过程及原因提供一个完整的案例说明，以及为如何解决人工智能内隐偏见问题提供一个成功的范例，且该范例也同样适用于其他人工智能系统。通过从实验中观察到人工智能表现出的种族无意识偏见、审美判断偏见以及文化无意识偏见来分析人工智能内隐偏见的可能性原因：人工智能训练数据存在内隐偏见、AI的算法偏见以及在人机交互过程中产生的偏见。

3.1 实验过程及结论

3.1.1 实验设计

该实验的设计思路是基于封面女郎招聘系统“女性吸引力测试项目”的样本来分析监督式人工智能的内隐偏见及探索解决人工智能内隐偏见的可行性方式。

首先我们提出假设 1：中德两国实验参与者对亚欧数据集中女性图片吸引力评比结果是有内隐偏见的。我们使用我们最新的数据集，该数据集总共包括 12034 张来自不同种族，具有不同社会背景的人的图像，总共有 540 万个注解。我们邀请中德两国实验参与者为数据集内的图片评分，得出评比结果以证明假设 1 是否成立，并将此评比结果标注为正确的 t 标注数据（即 Ground Truth，简称 GT）。

在此基础上，我们提出假设 2：人工智能会复制人类的偏见。我们使用 CNN 预测面部美学分数并引入 AestheticNet.SCUT-FBP 5500 数据集是用于深度学习任务的小型数据集，通过数据训练，计算出该训练结果与 GT 的皮尔逊相关系数（Pearson correlation coefficient，简称 PC）来考量监督学习人工智能的有效性，偏向网络的评估为了测量面部吸引力预测中网络的准确性，通常使用皮尔逊相关系数，平均绝对误差（MAE）和均方根误差 RMSE，Pearson 相关系数是一个介于-1 和 1 之间的值，是用于度量两个变量 X 和 Y 之间的相关（线性相关）；当其绝对值越大，则两个变量之间的相关性就越高，这种相关性包括正相关和负相关。如果相关系数等于 0，则表示它们之间没有线性相关；如果相关系数为 1，则表示它们是线性相等的。即机器学习之后的评分结果完全等同于中德两国实验参与者的人工结果，但由于各种可能存在的误差，所以完全相同的结果几乎是不可能，我们在此设定评估值 $PC=0.8$ ，这是在参考了其他主要数据库后的理想值，当该实验的 $PC \geq 0.8$ 时，即肯定监督学习机器人的学习的成果，

即该机器人会做出跟监督者相似的决定，这也是假设2是否成立的关键。

如果假设2成立，则我们会着手设计一个无偏网络，以解决人工智能中的偏见问题，总的来说，有以下三种主要途径可以实现无偏预测的目标：“公平的预处理，公平的处理中和公平的后处理^①。”

实验工具和方法：

机器学习在过去的几十年中得到了发展，并且由于系统中的知识不是由专家提供的事实而脱颖而出。与人类感知一致的面部美容预测（FBP）是一个重要的视觉识别问题，并且在最近几十年中受到广泛研究。

在人脸分析系统中，目前最先进的卷积神经网络（Convolutional Neural Networks, CNN）通常用于人脸识别任务，是一类包含卷积计算且具有深度结构的前馈神经网络（Feedforward Neural Networks），它是深度学习（deep learning）的代表和常用算法之一，可以卷积神经网络进行监督式学习和非监督式学习^②，据观察，所有深层的CNN模型都优于具有手工几何特征或外观特征的浅层预测因子。所以CNN模型是目前机器学习最前沿的主流计算方法，它代替了人工模型产生的大量繁琐耗时的计算。

随着卷积神经网络（CNN）和大型图像存储库，面部图像和视频任务变得更加强大，在数据库方面，SCUT-FBP500数据集中包含500个具有吸引力等级的亚裔女性受试者。由于“FBP是一个多范式计算问题”，后来数据库升级为SCUT-FBP5500并于2018年推出，其中包括新增的5500张正面面孔数据，这些面孔具有多种属性：男性/女性，亚洲/高加索人，年龄，美丽分数等。AlexNet, ResNet-18和ResNeXt-50上评估了他们的数据库“使用特征和预测器的不同组合以及各种深度学习方法”，并获得了PC: 0.8777；平均平均误差MAE: 0.2518；均方根误差RMSE: 0.3325作为基准。即使我们训练巨型机器人来为我们收集，存储和操纵数据，但这些数据的最终观察者，解释者和使用者最终还是人类。

datasets			annotations										
since	name	faces	age	gender	ethnic	height	weight	sports	glasses	attractiveness	complexion	hair colour	hair style
2013	MCSO Criminals	750	✓	✓	✓	✓	✓	×	×	✓	×	×	×
2013	Olympics	1914	✓	✓	✓	✓	✓	✓	×	✓	×	×	×
2016	LFW	1578	✓	×	✓	×	×	×	✓	✓	×	×	×
2018	SCUT-FBP*	2750	✓	✓	✓	×	×	×	×	✓	×	×	×
2020	synthesised our GAN	2942	✓	✓	✓	×	×	×	✓	✓	✓	✓	✓
2021	FairFace	2100	✓	✓	✓	×	×	×	×	×	×	×	×
Σ		12034	✓		✓					✓			

图 3.1 项目数据库 AestheticNet 在综合了全球前几位知名数据的基础上丰富了数据数量和内容属性

①Bellamy R. K. E., Dey K., Hind M, et al. AI Fairness 360: An Extensible Toolkit for Detecting, Understanding, and Mitigating Unwanted Algorithmic Bias[DB]. arXiv 2018.

② Goodfellow I., Bengio Y., Courville A. Deep learning [J]. Cambridge: MIT press, 2016: 326-366

在以上这些数据库的基础上，我们开发了自己的数据 AestheticNet，并通过生成亚洲或欧洲或混合图像为输入，新合成图像为输出的 Generative Adversarial Networks (GAN) 图像来进行训练的集合库并丰富了该数据库总共包含 12034 张各色人种图片样本及多种属性。

3.1.2 实验步骤

步骤一：由中德两方对求职系统面部数据库中 12034 张含各色人种的女性图片样本进行基于机器学习的女性吸引力测试研究，前期实验人数 80 人，中方实验参与人数 40 人，德方实验参与人数 40 人，实验后期随着德国学生参与热情的不断提高，截止至今德方实验参与人员增加至 150 人。我们让中、德两组不同国籍实验人员就同一图片库中女性的相貌进行评判，得出两组由人工选美的实验结果。




图 3.2 ViSIR 研究所 (Tobias Gerlach, L Peng, 2020)^①由中国实验参与者评出的审美结果，红色柱状条代表亚洲面孔的评分，蓝色柱状条代表欧洲面孔评分。




图 3.3 ViSIR 研究所 (Tobias Gerlach, L Peng, 2020) 由德国实验参与者评出的审美结果，红色柱状条代表亚洲面孔的评分，蓝色柱状条代表欧洲面孔评分。

^① Gerlach T., Danner M., Peng, L.P., et al. Who Loves Virtue as much as He Loves Beauty?: Deep Learning based Estimator for Aesthetics of Portraits[J]. VISIGRAPP 2020: 521-528.

步骤二：由机器人通过对中德两组监督人的学习，得出机器人选美的实验结果，在此皮尔逊相关系数考量监督学习人工智能的有效性，Pearson 相关系数 0.9601，接近 1，相对目前前沿的机器学习的系统该实验的训练结果精度相当高，已处于领先地位，训练结果的精度直接反应了机器智能学习的能力，归一化均方误差为 3.896% 和归一化均方根误差为 5.580%，这两个指标均是用来衡量计算精度的一种方式，其值越小则表示精度越高。这几个重要参考值均高于现存在的同类人工智能系统，证明了该实验机器学习的可靠性。

	PC	nMAE (%)	nRMSE (%)
AlexNet	0.8298	7.345	9.548
ResNet-18	0.8513	7.045	9.258
ResNeXt-50	0.8777	6.295	8.313
HMTNet	0.8783	6.2525	
8.158 AaNet	0.9055	5.590	7.385
P-AaNet	0.8965	5.713	7.588
2M BeautyNet	0.8996		
EfficientNetB3 based AestheticNet (ours)	0.9011	5.841	7.663
VGG-Face based AestheticNet (ours)	0.9363	4.400	6.261
AestheticNet (ours)	0.9601	3.896	5.580

图 3.4 ViSIR 研究所（Micheal Danner, Leping Peng, 2021）,在 AestheichNet 数据库基础上训练的人工智能精度明显高于其他主流数据库。

步骤三：在此基础上探索解决机器人偏见的途径，在实验设计部分已提及目前三种主要途径可以实现无偏预测的目标：“公平的预处理，公平的处理中和公平的后处理”，在该研究中我们主要侧重于第一种方法及预处理方法，即要使用此有偏见的数据创建公平的网络，我们需要对注释进行均衡以得到公平的结果。我们训练网络的主要方法是均衡训练数据，我们使用了数据预处理和重采样的方法，如果不进行处理，则结果如图 3.2 和 3.3 所示，德国和中国注释在它们的分布中显示，可以看出，他们显然有偏见。如果对网络进行此数据训练，则偏见将反映在评估结果中。偏见也清楚地显示在图 3.4 中，如前所述，内隐偏见会影响这些结果。基于这些数据，我们的预测基于亚洲人脸的 FBP，中国注释者对亚洲人脸的评价较高。因此，它预测出亚洲面孔更高的美学分数，如果我们仅在德国注释的“欧洲面孔”上训练机器，这也是相同的，但分数差异会有所不同，如图可以得出德国注释者的偏见程度比中国注释者要高，这就是下一步要引入权重比率（Ratio）的原因。要使用此有偏见的数据创建公平的网络，我们需要对注释进行均衡以得到公平的结果。在该研究中，均衡训练数据意味着逐渐

增加随机中中国注释的数据。我们从 1 的比率（德国和中国注释的分布均匀）开始尝试计算，使中国注释者的数据逐渐在训练数据中增加。这种方法的目标是要获得均衡的审美得分，如图 3.5 所示。亚洲和欧洲面孔的美学得分应该不会有太大的得分差异，亚洲和欧洲面孔之间的平均审美得分相差约 5%。通过这种方式，我们可以创建一个在所有不同种族类别中均具有公平表现的模型。这证明，通过对训练数据进行重新采样并平衡它们，可以通过保留评估的精度来创建偏差较小的 AI。该实验的结果显示在图 3.5 中，因为所有条形图的高度都相似，因此评估的偏见要小得多。并非所有条形都具有完全相同的高度，这是由于一些无法避免的噪点造成的。现实世界中的数据会影响诸如机器学习中的分类等任务。这种噪点也会影响人类的审美预测，但是在细微差异下，我们可以认为我们的网络是公平的。训练数据分布的均衡是基于因子的方法来的。首先，我们计算了中国和欧洲注释之间的比率，其次，采用随机方法计算出均衡分布的因子，这需从 1 开始计算，最佳比率是通过网格搜索随机找到的，我们以 1.0（1.0、1.1、1.2、1.3，...，2.5）为单位，以介于 1.0 到 2.5 之间的每个比率训练机器，1.0 的偏差最高，直到 1.9 为最优止，然后再升高计算，由此反复，得出最小的偏差是通过比率 1.9 获得的。在当前示例中，使用的系数为 1.9（中国* 1.9）。这意味着中国注解的数量几乎是欧洲注解的两倍这种方法的目标是获得公平的审美得分。




图 3.5 ViSIR 研究所（Micheal Danner, Leping Peng, 2021）,预处理后相对公平的评分结果。

3.1.3 实验结论

我们的数据库在涵盖了从多种不同的数据库照片来源，一共 12034 张，在年龄、种族、有无眼镜等多方面将标签属性多元化，以提高机器学习的对数据识别的多元性，减少了机器人对少数数据样本的不识别或歧视。在该研究中，我们使用卷积神经网络（CNN）进行面部美学分数预测，并引入 AestheticNet 作为研究方法。由于 SCUT-FBP

5500 数据集是用于深度学习任务的小型数据集，并且其中亚洲面孔的比例较低，因此我们使用数据增强方法来扩大模型的样本量，通过生成以亚洲或欧洲或混合图像为输入，新合成图像为输出的 GANs 图像来进行训练的集合。事实证明，这种增强方法优于诸如裁剪和旋转之类的几何变换。所有图像均通过归一化方法进行预处理，以统一面部姿势，面部标志位置和图像大小。这种方法丰富了数据库的多样性，提高了机器学习的精度。然而这种高精度的机器学习也完美的复制了人类的偏见，由于德国学生对欧洲女性的喜爱，中国学生对亚洲肖像的评价较高导致了这台高精度学习机器人也得出了几乎一样的评分。由此，我们可以通过该实验证明，我们在实验设计之初的假设 1 和假设 2 均成立，人类的内隐偏见的普遍存在性，以在机器学习领域，机器人无可避免的复制了人类的偏见，虽然我们无法打造绝对公平的机器人，但我们可以通过三种主要途径可以实现无偏预测的目标：“公平的预处理，公平的处理中和公平的后处理”来打造相对公平的人工智能，此案例详细探讨了通过预处理的手段来实现公平机器人，在未来的工作中将继续研究处理中和后处理的方式。无偏见决策在机器学习任务中是一个具有挑战性的问题，但未来它将成为 AI 最重要的优势之一的巨大潜力。该项学习已经展示了一种消除偏见的方法，并且该方法可以复制到多个相似的人工智能网络中。

3.2 人工智能内隐偏见的表现

3.2.1 人工智能的种族无意识偏见

尽管我们尽力避免这种偏见，但它在我们世界的每一个地方都表现出来。内隐偏见表现为我们对人群的态度，信念和刻板印象。偏见会影响我们对待他人的方式，甚至是不由自主地做出反应。无人驾驶汽车更容易识别白人行人的例子就是隐性偏见，这种偏见导致肤色之间的安全性完全不同。将黑人错误地归类为重复犯罪的可能性更高，这是隐性偏见，会导致更严厉的刑事判决。执法部门使用的面部识别工具将深色皮肤女性误认为是男性，而浅肤色男人的错误率却很低。在美国警察暴行达到顶峰的时候，我们可以看到这种有偏见的的数据如何导致灾难性甚至暴力的后果。

与无人驾驶汽车的隐性偏见相似，在本实验中，训练机器人时亚洲人则更容易识别亚洲面孔（如图 3.6），训练机器人时白人似乎更容易识别白色皮肤（如图 3.7），这种内隐偏见不易察觉，尽管参与实验的志愿者都没有意识到自己存在偏见，但实验的结果却表明每个人都表现出隐性的偏见。机器学习由于接受人为训练督导，因此也会将人的偏见“学以致用”，实验证明机器学习重复了人类偏见。很明显，由欧洲人训练的 AI 招聘官不会选择亚洲候选人，而亚洲人训练的 AI 招聘官则很少选择欧洲候选人。该实验结果明显显示了“牺牲外群体为代价”的种族偏见，候选人排名结果压倒性的胜于外群体。



图 3.6 为由中国实验人员选出来吸引力排分在前 21 位的照片



图 3.7 为由德国实验人员选出来吸引力排分在前 21 位的照片

3.2.2 人工智能的审美判断偏见

人工智能审美对年龄的偏见：

年龄歧视被定义为对老年人的消极或正面刻板印象，偏见和/或歧视（或对老年人有利）。年龄歧视可以是隐性的也可以是显性的，可以在微观，中观或宏观层面上表达”^①。内隐的年龄歧视是指在没有意识的情况下运作并在日常生活中自动产生的思想，感觉和判断。^②这些可能是正面和负面思想和情感的混合体，但是老年医学专家 Becca Levy 报告说，它们“往往大多是负面的”^③。

实验显示，吸引力与年纪成负相关，年龄越大的样本得到的评分越低，20 岁至 35 岁为审美最受欢迎的年龄阶段。“年龄大的女性在吸引力上不如年轻的”这种负面的判断造成了年龄歧视。

① Iversen T.N., Larsen L., Solem P.E. A conceptual analysis of ageism[J]. Nordic Psychology,2009, 61 (3): 4–22.

② Nelson T.D., ed. Ageism: Stereotyping and Prejudice against Older Persons [M]. MIT Press.2012

③ Levy B. R. Eradication of Ageism requires addressing the enemy within[J]. The Gerontologist,2001, 41 (5): 578–579.




图 3.8 人工智能评估年龄和审美的相关性

人工智能审美对佩戴眼镜的偏见：

研究表明，眼镜对审美判断有负相关的影响，戴眼镜的人相对不戴眼镜的人有较少的吸引力。(Terry and Kroger, 1976, Thornton, 1944)^①，《日本商业内幕》（Business Insider Japan）在2019年10月对1400多名职场人员进行的一项调查中发表了一篇文章，该调查发现女性工作者被要求不要在工作中戴眼镜，因为她们在美学上不讨好。在该报告显示的求职信息站点上，还有建议诸如事先了解外貌歧视措施，因为“眼镜在酒店业不受欢迎”，戴眼镜给人一种“难以理解的面部表情”外，也让人感觉冷漠，甚至有公司负责人明确发表“我不喜欢戴眼镜的女人”的外貌歧视言论^②。

在该实验结果显示，人工智能重复了人类的审美偏见，很明显对戴眼镜的女性做出了外貌上的负面判断。




图3.9 人工智能对戴眼镜者的外貌偏见，右侧未戴眼镜者的评分明显高于戴眼镜者的评分

① Terry R. L., Kroger D. L. Effects of eye correctives on ratings of attractiveness[J]. Perceptual and Motor Skills, 1976: 562.

② Aydin R. Women in Japan Are Being Told Not to Wear Glasses in the Workplace — Here Are 5 Sexist Dress Codes From Around the World[EB]. Thrive Global, 2019, 11.

3.2.3 人工智能的文化无意识偏见

多媒体的兴起为文化教育提供了便利，也给中、西方了解对方文化提供了很好的工具手段。但同时，媒体文化也反应着主流文化的价值观及对少数民族和外来文化的评判和态度。在亚洲，电视广告逐渐西式化，电视屏幕上也常见欧美模特，我们对白人面孔逐渐熟悉，欧美电影对中国电影市场也占据着重要角色，大部分人都能轻而易举的叫出一两个好莱坞明星的名字。在亚洲，撑伞很常见用于夏天防晒保护。“白皮肤”已成为富裕的亚洲的消费者文化^①，出现在中国皮肤美容产品广告中的模特和名人代言人也皮肤白皙^②。在 Collins, Glenn 和 Hunter 的研究中，所有有色女人在其种族/族裔社区中都应对霸权肤色意识，较浅的肤色和白种人的面部特征被认为更具吸引力，这种吸引力昭示着霸权文化理念，也存在于媒体，比如同样的媒体制作人也青睐在接近白人身体特征方面的有色女性，并认为这样很有吸引力。这就是霸权意识形态的另一种再现^③。同时亚洲和西方信息传播的不平衡也会加剧文化的无意识偏见，比如欧美的电影市场，亚洲电影也很难进入好莱坞，欧美本土广告也很少使用亚洲模特，亚洲文化并没有进入主流的欧洲媒体世界，欧美人相对亚洲人持较高偏见的原因。

人工智能的文化无意识偏见主要表现在实验结果中可以得出欧洲人对中国人的偏见要比中国人对欧洲人的偏见高，这从该实验的图 3.10 和 3.11 可以看出，在图 3.10 中可以看出，人工智能评价的亚洲人得分比欧洲人得分仅高约 0.03，而在 3.11 中人工智能评价的欧洲人得分却比亚洲人得分高 0.09。




图 3.10 基于中国人训练的人工智能审美评价。左边为人工评比偏见结果，右边为人工智能通过学习后的偏见评比结果。

①Sahay S., Piran N. Skin-color preferences and body satisfaction among South Asian-Canadian and European-Canadian female university students[J]. The Journal of Social Psychology, 1997;137(2):161-172.

②Xie Q., Zhang M. White or tan? A cross-cultural analysis of skin beauty advertisements between China and the United States[J]. Asian Journal of Communication, 2013;23: 538-554.

③Thakore B.K. Must-See TV: South Asian Characterizations in American Popular Media[J]. Sociology Compass, 2014, 8: 149-156.




图 3.11 基于德国人训练的人工智能审美评价。左边为人工评比偏见结果，右边为人工智能通过学习后的偏见评比结果。

3.3 人工智能内隐偏见的可能性原因

3.3.1 训练数据存在内隐偏见

导致 AI 产生偏见的一个主要因素是训练数据。当一个数据集包含一个子组而不是另一个子组的大量信息时，就会产生偏见，例如，主要的搜索引擎及其算法是在西方开发的，因此，算法通常更可能在西式婚礼中识别新娘和新郎，而在非洲婚礼中则无法识别。大多数机器学习任务都是通过使用大型的、带注释的数据集来训练的。例如，自然杂志社发表了关于图像视觉人工智能偏见的评论，研究者们通常会利用网站来构建数据集，例如使用特定的单词搜索在各大网站上收集。接下来，这些数据将被分类标注，而这项工作通常是由学生来做，或者分包给一些外包网站来做。这种方法会在分类标注的过程中无意产生出包含了种族、性别和文化偏见的数据集^①。数据集不仅是提供算法的原材料，而且是政治干预手段。因此，在 AI 系统中有关“偏见”的许多讨论都没有抓住这个标记：没有可以建立训练数据的“中立”，“自然”或“非政治”有利点。通过改变人口统计特征，删除令人反感的用语或寻求肤色平等的表示，没有简单的技术“解决方案”。收集图像，对图像进行分类并标记图像的整个工作本身就是一种政治形式，充满了关于谁来决定图像的含义以及这些代表所从事的社会和政治工作类型的问题。哲学，艺术史和媒体理论的整个子领域都致力于消除图像与意义之间不稳定关系的所有细微差别。尽管人们普遍认为 AI 及其使用的数据是客观，科学地对世界进行了分类，但到处都有政治，意识形态，偏见以及所有主观的历史。当我们调查使用最广泛的训练集时，我们发现这是规则而不是例外^②。

① Zou J., Schiebinger L. AI can be sexist and racist — it's time to make it fair[EB]. Nature comment, 2018.

② Mitchell W. J. T. Picture Theory: Essays on Verbal and Visual Representation[M]. The University of Chicago press, 2007.

来自英国科学史学会的 2019 年 Aryton 奖联合获奖者凯特·克劳福德和特雷弗·帕格伦(Kate Crawford & Trevor Paglen)在其研究中对机器学习训练集的偏见问题做了详细的介绍, 其文中指出提到 ImageNet 是机器学习中使用最广泛的训练集之一, 但它却下架了 600000 张照片, 因为这些照片被批评带有偏见, 在 2019 年 1 月, ImageNet 的“人员”类别中的图像开始消失。突然, 斯坦福大学的服务器上也不再可以访问 120 万张照片, 一个男人喝啤酒的照片被称为“酒精饮料”的照片消失了, 一个穿着比基尼的女人被称为“板鞋”的照片和一个被归类为“失败者”的年轻男孩的照片也消失了, 一名男子吃三明治的照片(标为“自私的人”)遇到了同样的命运。之后, 微软已经效仿。一方面, 从互联网上删除这些有问题的数据集似乎是一个胜利。通过使其不再可访问来解决最明显的隐私和道德违规行为。但是, 这些训练集已经下载了无数次, 并已进入许多生产 AI 系统和学术论文中。通过彻底擦除它们, 不仅失去了 AI 历史的重要组成部分, 而且研究人员无法看到这些假设, 标签和分类方法如何在新系统中复制, 也无法追踪在其中出现的偏斜和偏见的出处。工作系统、面部识别和情感识别 AI 系统已经在招聘, 教育和医疗保健等各行各业中得到推广, 它们是机场安全检查的一部分, 无法看到训练 AI 系统的基础将消除一种重要的取证方法, 以了解其工作原理, 这将具有严重的后果^①。

比如在本项目中, 我们的训练数据如果只是简单的沿用其他数据库, 就会造成样本数据不平衡的结果, 因为其他数据集亚洲图片的数量明显低于欧洲面孔, 我们在此基础上利用 GAN 生成了大量亚洲及其他种族面孔以填充数据库缺陷, 结果显示因为训练数据优于其他数据库, 所以该实验的训练精度也要明显优于其他同类数据库。但是也有研究指出, 即便是大型数据也不一定比小型数据集更公平^②。训练数据的不公会直接导致机器学习预处理的偏见, 从而导致最终带有偏见的结果, 但这似乎一直以来都是一个非常棘手的问题。

3.3.2 AI 算法存在内隐偏见

算法偏见并不是新事物。AI 算法的内隐偏见也称算法的潜在偏见或预先存在偏差, 算法可能会基于历史数据或由于社会中已经存在的刻板印象而错误的识别事物。如今, 越来越多的算法决策是使用基于历史数据的预测模型做出的, 包括信用评分, 保险, 个性化定价和推荐, 对求职者的自动简历筛选, 警察对潜在犯罪嫌疑人的分析以及更多案件。数据挖掘和机器学习技术以及大数据决策的渗透已经提高了公众的认识, 即数据驱动的决策可能导致对人群的歧视, 这是因为大多数数据挖掘方法都是基于这样

^① Crawford K., Paglen T. The Politics of Images in Machine Learning Training Sets[Z]. Excavating AI, 2019.

^② Kaplan R.M., Chambers D.A., Glasgow R.E. Big Data and Large Sample Size: A Cautionary Note on the Potential for Bias[J]. Clinical And Translational Science, 2014; 7: 342-346.

的假设，即历史数据集是正确的，而这似乎常常与现实相去甚远^①。算法能够处理更大范围的输入和变量以做出决策，并且这样做的速度和可靠性远远超过了人类的能力。从我们投放的广告，到提供的产品，再到在网上搜索后向我们展示的结果，算法而不是幕后的人都在做出这些决策。但是，由于算法只是简单地展示了人类使用可能由人类，机器或两者的组合提供的数据（在过程中的某个时刻，即历史时刻）所定义的计算结果，因此它们常常会无意间复制人类的偏见。

潜在偏见的一个例子是 Passport AI，通过将面孔与白人“标准”进行比较，正常的亚洲裔用户照片被报告闭上了眼睛^②。在 1970 年代和 1980 年代，英国圣乔治医学院使用计算机程序对申请人进行初步筛选。该计划模仿了录取人员过去的选择，但由于女性或名字听起来不是欧洲名字，因此拒绝了对多达 60 名申请人的面试。这种偏见算法程序已经在之前的录取工作中被嵌入，英国种族平等委员会认定圣乔治医学院在 1988 年招生过程中犯有种族歧视和性别歧视的罪行^③。相似的情形发生在亚马逊的招聘系统，亚马逊不得不取消一种自动招聘工具，该工具相比女性候选人更青睐男性候选人，因为该算法是根据历史模式进行训练的，而这种模式主要是男性被录用的^④。根据 Pro Publica 的解释，在 2013 年和 2014 年该公司软件为警务系统提供的检查犯罪风险分数在预测暴力犯罪方面仍然不可靠，只有 20% 的犯罪在两年内实际发生。Pro Publica 还声称该算法错误地将黑人被告标记为未来的罪犯，以这种方式错误地给黑人贴上标签，其比率几乎是白人被告的两倍。哈佛大学 2012 年发表在《社会问题杂志》上的一项研究表明，当搜索以传统非裔美国人名字命名的服务时，更可能出现允许搜索人们的逮捕记录的服务广告^⑤。

在本案例中，我们使用了先进的卷积神经网络（CNN）算法来进行运算，不可否认，CNNs 在计算机视觉领域表现出来的王牌地位无可撼动，在许多类型的任务中也表现出了惊人的性能。但这个方法并不是万能的，比如它只是单一算法，不同的任务需要单独训练，这就加大了运算的时间和复杂性，再者它的合并层有一个很大的缺点，因为它可能会丢失了有价值的信息，例如，如果需要用来进行人脸识别器，卷积神经网络可能会将部分和整体之间的关系分裂开来，这就导致我们不得不必须结合一些其他的特征（嘴巴，双眼，椭圆的面和鼻子）才能说明是一张脸，由于忽略了局部和整体的关系，其人脸识别的结果可能会导致偏见。

① Žliobaitė I. Measuring discrimination in algorithmic decision making[J]. Data Min Knowl, 2017;31:1060–1089.

② Howard A., Borenstein J. The Ugly Truth About Ourselves and Our Robot Creations: The Problem of Bias and Social Inequity[J]. Science and Engineering Ethics, 2018, 24: 1521-1536.

③ Garcia M. Racist in the Machine: The Disturbing Implications of Algorithmic Bias[J]. World Policy Journal Duke University Press 2016/2017: 111-117.

④ Dastin J. Amazon scraps secret AI recruiting tool that showed bias against women. [EB]. Reuters, 2018(10).

⑤ Kirkpatrick K. Battling algorithmic bias how do we ensure algorithms treat us fairly? [J]. Communications of the ACM, 2016, 59: 16-17.

3.3.3 人机交互产生内隐偏见

在人机交互(human computer interaction, HCI)的过程中是最容易产生数据偏见的过程, 计算机产生的那一天, 人机交互就产生了, 所以换句话说, 人机交互的发展历史, 就是从人和计算相互适应发展的历史。人机交互这一名词的起源可以追溯到 1960 年约瑟夫·利克莱德(J. C. Licklider)发表的一篇名为 Man-Computer Symbiosis 的文章, 他指出人机共生的主要目的是: 1) 让计算机在解决问题的过程中促进公式化思维, 以及 2) 使人和计算机能够协作做出决策和控制复杂情况, 而又不依赖于预定程序^①。换句话说人机交互的目标是为了更好的为人服务, 提升用户体验和效率。人机交互中的“机”可以指各种机器, 也可以指计算机和软件。人机交互发展的数十年中同样也是人工智能的发展的数十年, 比如人机对话的需求推动了相关人工智能技术的发展, 例如苹果的 Siri、微软的小冰、谷歌的 GoogleHome、亚马逊的 Alexa 和目前很多家庭都具备的各种智能家居系统, 而且这些家居系统都具备语音功能等, 这些都是为了解决传统人机对话方式低效且非常不自然的问题而创造出来的人工智能应用^②。新冠病毒的爆发也促成了一系列智能病毒跟踪和预警系统的诞生, 如果你在超市遇到疑似病毒携带者, 系统则会发送远离预警, 并且系统可以很好的监控超市人流情况, 已使用户可以错开购物高峰期。人机交互需求的不断提高也在不断驱动着人工智能的发展与进步。到最近几年, 似乎很奇妙甚至古怪的想法和技术现在已经在研究领域中得到肯定, 甚至开始进入主流用户社区。这些范围包括用于评估用户状态的技术和设备(例如, 眼睛跟踪, 面部表情识别, 可穿戴式计算机, 例如收集生理数据的手环, 用于检测表情或困惑的“表情眼镜”, 充当社会智能主体的集成系统(例如, 机器人化身与自闭症儿童互动以促进社交技能的获得, 老年陪护型机器人)等, 人机交互技术的新发展使一系列新型的人机交互成为可能, 并缩小了人机界面上人机之间的距离。机器越来越能够感知或推断用户属性, 并使用越来越多的可用“模式”与用户进行交互(例如, 用于神经虚拟现实(VR)技术)。

但同时, 人机交互过程中不论是从交互设备还是虚拟软件, 都有可能因为用户体验、情景理解等方面产生不同的偏见。人机交互过程中一个显而易见的问题是: 由于计算机用户间文化传统、生活和教育背景、知识水平、思维方式等都各不相, 所以用户的使用习惯也不尽相同, 比如, 一个左撇子和普通人的使用习惯就完全不同, 另外, 中国人和外国人的思维方式可能不同。总之, 人机交互过程是一个极易产生人工智能偏见的过程。

^① Licklider J. C. R. Man-Computer Symbiosis[J]. IRE Transactions on Human Factors in Electronics, 1960, 3: 4-11.

^② 范向民, 范俊君, 田丰等. 人机交互与人工智能: 从交替浮沉到协同共进[J]. 中国科学: 信息科学, 2019, 49(03): 361-368.

第4章 消除人工智能内隐偏见的伦理策略

人工智能研发的伦理原则如何确立一直是伦理界比较关注的议题，本文将从康德的普遍立法原则出发，从人工智能民用领域和军用领域来探讨以其为伦理指导原则的可行性，在康德绝对命令的基础上，结合现实情况，提出了在道德情绪主义中设定理性主义指标的新主张。算法伦理学是社会科学，法律和哲学等各个学科中的新兴话题，也是人工智能的一个新兴话题。由算法决策所造成的歧视和偏见风险层出不穷，欧洲委员会的新研究“歧视，人工智能和算法决策”系统的阐述了这些风险。在本章中，本人主张在提升算法透明性、可解释性和提高样本及数据集的多样性来探索一个较为完善的人工智能道德算法建设。人工智能研发主体的道德培育对创建公平公正的 AI 具有重要意义，研发主体的道德程度一定意义上决定了研发产品的道德程度，在本章中，本文将从多元文化建设、性别平等、伦理道德教育以及行业监管这些方面综合探讨如何加强研发主体的道德水平。

4.1 确立人工智能研发的伦理原则

4.1.1 以人为本的普遍立法原则

康德的道德规范是围绕“绝对命令”的概念而组织的，这是一项普遍的道德原则，指出一个人应始终尊重他人的人性，并且仅应按照适用于所有人的规则行事。“要这样行动，使得你的意志的准则任何时候都能同时被看作一个普遍立法的原则”^①。普遍立法是康德道德伦理的核心，康德道德伦理是以人为中心的道德框架，最终目的是实践哲学，它与实现道德行为相关且适用，它强调人类尊严和人类本身就是目的，该哲学指导人类对道德行为的理解。解决行动问题的一项突出传统表明，当我们的行动以适当的方式“属于”我们时，即当那些行为属于我们时，我们就可以合理地将自己视为行动者动作是真实的或自主的。从康德的角度来看，这是因为理性的行动特别容易受到自我反省意识的影响，因此可以成为在理性基础上进行慎重选择或认可的产物。换句话说，当我们采取某种行动时，我们可以意识到我们内心的动机。然后，我们可以考虑采取该行动或反对该行动的原因，并最终选择我们执行或避免采取该行动的依据。

人工智能和机器人技术将如何实施康德对绝对必要性？人工智能和机器人技术不具备人类的理性思维能力，也不具有能够理解构成什么规则的自由意志，该规则固地被人们所期望，可行和有价值，从而使其能够被普遍化。但是在这种技术的设计，开发，测试和部署中存在人为因素，因此实施绝对必要的责任在于人。人类确定将哪些规则编程到技术中，以确保道德使用和道德行为。为了使这些规则具有普遍性，它

^①康德著，邓晓芒译. 实践理性批判[M]. 人民出版社, 2016:36.

们必须是“公开且可共享的”。例如，在民用领域，在军事领域，在《联合国某些常规武器公约》的主持下，关于致命性自主武器的讨论代表了使可能管制或禁止此类武器的规则普遍化的过程。实际上，在一些州中已经出现了关于预防性禁止规则的法律意见，大多数州都认识到，任何规范致命性自动武器的规则都必须考虑到道德，法律和人道主义方面的考虑。

如何生成规则来规范技术的道德使用和操作？这取决于该技术是要完全替代人类功能和理性思维，还是要补充这种人类特征。完全自主技术是指人工智能和机器人技术取代了人类的理性思维能力和自由意志，因此规则从技术本身而非人类中浮现出来。另一方面，人机集成技术是指在某些情况下支持和协助人类的技术，以便通过人机交互和干预的结合来创建，影响，控制和定制规则。两种规则生成方法都具有伦理意义。完全自主技术是现代机器学习的终极目标，机器通过依靠自己的数据库和经验不断的学习，完善，来生成未来的规则和行为，最终能实现自主，从道德伦理层面考虑即无需人为干预便可以进行道德决策。这种方法面临的风险是完全自主武器系统将产生超出其设计意图的规则，因此存在不确定性和不可预测性，因此它将不符合国际人道主义法或康德伦理。在民用领域，完全自主的技术可能会产生规则，从而导致人的裁员，失业，收入不稳定和不平等，从而对人的自我价值和进步产生不利影响。对人类的自我价值和进步的不利影响，以及在规则制定过程中的不确定性和不可预测性，与从根本上对人类有利的事物相反。目前在民用和军事领域都存在一种人机规则生成方法。例如，IBM 更喜欢“增强智能”而不是人工智能，因为这更好地反映了他们构建旨在增强和扩展人类专业知识和技能的系统的目标，而不是取代它们。该技术专注于帮助人们执行定义明确的任务的实际应用（例如，清理房屋的机器人；在生产链中与人合作的机器人；负责整个仓库任务的仓库机器人；用于娱乐，交谈的伴侣机器人帮助老年人与朋友，亲戚和医生保持联系）。在军事领域，遥控和半自主武器将人类行动与武器技术结合在一起。人工干预对于确定何时执行攻击命令或激活中止机制是必要的。这种规则生成方法使人始终处于决策制定的中心。但是，如果人机之间存在接口问题（例如错误，性能故障，通信中断，操作失败），会发生什么情况？通讯链接丢失，错误协调？这可能在依赖通信和协调的人武器综合系统中被证明是致命的，因此需要一个备用系统来中止或中止行动。如果该技术被黑客破解以产生替代规则或随机规则，从而导致故障、性能不佳或有害影响，将会发生什么？同样的问题也适用于完全自主的技术，这似乎是限制使用 and 性能设置以设置任务，受控方案或环境的可能原因，其中可能包含任何潜在危害。

康德以人为中心的人是目的的方法将非人类动物和无生命的物体潜在地排除在绝对命令之外的可能性，可能直接适用于在人工智能和机器人中制定道德行为。如果担心机器在生成自己的规则时具有不可预测性和不确定性，则人类干预可以设定绝对必

要，因为“技术必须始终将人类生命置于对财产或非人类动物生命的损害之上”。因此，可以建议在人工智能设计和使用的过程中，通过设定一些理性的指标以弥补偏见的产生，比如在该论文的实验中我们根据大部分实验参与者的选择结果设置了一个理性的平均参考范围，在此范围之外的点击我们将其视为无效点击，以减少由于实验人员对个别照片的特殊喜好而影响普遍的审美标准。这种通过人工干预的以人为本的方法已经在自动驾驶汽车中试用，德国政府最近批准了自动驾驶汽车的道德准则，该准则要求：

在平衡受法律保护的利益时，保护人类生命是头等大事。因此，在技术上允许的限制范围之内，如果必须以损害冲突中的动物或财产为代价以防止人类的人身伤害，则该人工智能系统必须编程接受。

康德伦理学提供了以人为本的方法来制定道德规则。康德伦理学的核心要素导致人们关注规则制定和遵守规则的人类自决能力。这些要素说明了人类的属性和能力，例如实践推理，行使判断力，自我反思和思考，这些基本方法允许形成能够普遍化的道德规则。这样的人类属性和能力在人工智能和机器人技术中是不存在的，因此人类机构必须在设计和承担对其最终行为和行动承担责任的最前沿。可以在机器中设定有限的理性思维能力，这是根据康德理性存在概念发展而来的。在民用领域中，在封闭技术将技术用于确定的任务的情况下，这种有限的理性思考能力可能是适当的，因为不必行使自由裁量权。因此可以得出结论，以康德的普遍原则作为人工智能设计的指导原则，可以给人工智能赋予有限的理性思考能力，设计通用规则，但实施绝对命令的关键还是以人为本。

4.1.2 在道德情绪主义中设定理性主义指标

近年来，道德心理学领域经历了复兴，这在很大程度上归因于 Haidt 的社会直觉主义道德判断模型。根据这个模型，道德判断不是慢和刻意推理的产物，正如早期道德认知模型所强调的那样，而是快速和自动直觉的产物。显式推理（如果发生的话）采取事后合理化的形式，口头上对道德判断的辩护构成判断本身的结果而不是原因。对这种模型的支持来自越来越多的研究，这些研究证明了情感和直觉的重要性。

人类道德在理性与情感的交互中难以找到最佳的平衡状态是由人类特殊的脑部结构与心理状态决定的，这种不平衡的权衡结果导致了各种偏见的产生，由人类设计和训练的人工智能也无法避免其带有偏见的结果，但由于人工智能可设计的优势，可以为其设定一些理性标准来更好的避免此类的“不平衡”，而这一操作方法实际上比对人类进行长期的去偏干预训练和自我报告等一系列干预手段更有效率。基于此，许多学者提出了“人工智能道德提升”的概念，即通过技术（例如通过生物技术）提高人类道德的想法，这些干预措施包括使用催产素和 5-羟色胺等各种物质，以及经颅磁刺

激和提供神经反馈等各种技术，这些干预措施的目的是增进对他人的信任，并培养合作的愿望，但是生物技术对人体的伤害一直令人担忧。我们中的许多人在生物学上倾向于具有有限的认知和有限的利他主义水平每个人都有内隐的偏见，尽管这并非完全是由生物学原因引起的。偏见的存在将导致机器学习中的偏见问题，这一点已在该论文的实验中得到证明。与生物技术相比，人工智能在改善人类生活质量的同时，在帮助人类提高道德方面更值得信赖。尤其是现有的隐性偏见干预措施往往会效果有限。为了避免非道德人工智能的道德困境，例如军用杀人机器人，在上一小节已讨论，在这一节不再赘述，本节仅讨论道德提升类的人工智能，即能对民用日常生活提供便利并有所帮助的人工智能，例如，道路上安装的空气质量检测系统可以提醒我们是否应该限制私家车旅行次数并减少气体排放。智能病毒跟踪 APP 提醒您可能会接触到高危人群，因此有必要考虑隔离措施。一些研究人员对人类的道德本质是如此悲观，很多 Dietrich 对 AI 的可能性如此乐观，以至于他相信机器人将实现“哥白尼式转向”，而大多数人类由于其生物学条件而无法进入。AI 可以监控影响道德决策的物理和环境因素，可以识别并让行为人意识到他们的偏见，并可以根据行为人的道德价值观为他们提供正确的行动建议。然而人工智能的这一道德提升也是建立在相对完美的道德标准之上，人工智能自由度越大，就越需要道德理性标准。

4.2 完善人工智能道德算法的建设

4.2.1 提升算法的透明性

一种算法是一组计算机程序如下，以作出有关行动的特定决策步骤。算法透明性是关于用于搜索，处理和传递信息时结构和基本操作的开放性。“算法透明性”是透明性法律，互联网法和隐私法发展的下一阶段，该原则将影响个人的数据处理过程公开化。当前的互联网生态系统缺乏算法透明性，这对在线捍卫基本人权（从隐私，言论自由到安全）提出了严峻的挑战。“当算法影响人权，公共价值或公共决策时，我们需要监督和透明。”“法治和普遍人权”必须纳入大型技术公司的体系。这甚至在最高层上都引起人们的关注，德国总理安格拉·默克尔（Angela Merkel）一直是要求降低算法保密性。

是否应该使影响公众的算法透明化的问题是有争议的。以用于确定信用评分的程序为例。如果某人的信用等级低于其应有的水平，则他们有权对该分数提出上诉，但无权要求公开用于确定该不良分数的算法。这是因为确定个人信用评分的公司也具有权利，在这种情况下，是保护其知识产权（IP）的权利。

由于技术和社会原因，算法做出的决定可能是不透明的，此外，为了保护知识产权也特意使其变得不透明。但是算法以不明显的方式渗透到了日常生活的各个方面。算法决定信用评分和保险费，评估简历，在市场上进行交易，甚至预测患者患癌症的

可能性。而且，他们在做出这些相应的决定时会剥夺人类的代理权。必须有一种解释程序工作方式的文化，以确保开发安全和公平的算法，透明度将提高人们对现代社会广泛使用算法的认识。因此，需要透明性以确保算法按预期工作，而又不会给人的决策带来负担的偏见和歧视性做法，同时又保护了算法提供者的知识产权。于是第三方审核不失为一种实际可行的措施。这种方法称为合格透明性。例如，在向联邦贸易委员会（FTC）投诉搜索巨头 Google 之后，FTC 工作人员创建的监视算法发现 Google 的搜索算法通常会导致其自身的服务在搜索结果中领先于其他服务。为了提高透明度，公开发布并解释评估中使用的标准以及结果非常必要。尽管联邦贸易委员会（FTC）认为 Google 的行为本质上不是反竞争的行为，但该调查造成的负面宣传促使 Google 做出了改变。之后，Google 开发了 TensorFlow，一个广泛使用的开源机器学习库，以促进 AI 的透明性，Google（及其他技术巨头）还拥有特定的 AI 博客，使他们能够将其 AI 知识传播到世界各地。

4.2.2 完善算法的可解释性

机器学习（ML）模型惊人地擅长做出预测，但通常无法以人类容易理解的方式为它们的预测提供解释。他们得出结论的特征是如此之多，其计算也是如此复杂，以至于研究人员发现无法确切确定算法为何能产生答案。但是，有可能确定机器学习算法如何得出其结论，这种能力，也称为“可解释性”（explainable AI (XAI)），这个词最早是 2004 年由 Van Lent 等人创造的。^①用来描述其系统解释模拟游戏应用程序中 AI 控制实体的行为的能力。

尽管该术语相对较新，但自 1970 年代中期研究人员研究专家系统的解释以来，就一直存在可解释性的问题^②。传统上，AI 涉及一种“黑匣子”方法，即用户输入一些原始数据，然后接收机器生成的输出/结果-无需任何有关导致此结果的原因或过程的信息。

可解释性至关重要，要使 AI 有效，用户必须了解系统如何处理数据。例如，如果研究人员不了解模型的工作原理，他们可能难以将学习成果转移到更广泛的知识库中。同样，可解释性对于防止嵌入式偏差或调试算法至关重要。它还可以帮助研究人员衡量模型中权衡的影响。更广泛地讲，随着算法在社会中扮演着越来越重要的角色，准确地理解它们如何提出答案只会变得越来越关键。在医疗保健中，错误的结果可能会损害患者的健康，在最坏的情况下可能会致命^③。AI 和 ML 在敏感领域（例如医学领域）的实际应用的现实情况表明，深度学习系统无法与用户进行有效通信。因此，迫切需要使结果和机器决策透明，可理解和可解释，这将提高接受度和信任度，这在安全关键

① Entezari R. PhD Forum Abstract: Understanding Deep Model Compression for IoT Devices. Information Processing in Sensor Networks (IPSN) [J]. 19th ACM/IEEE International Conference 2020: 385-386.

② Minovski D, Åhlund C, Mitra K. Modeling Quality of IoT Experience in Autonomous Vehicles[J]. Internet of Things Journal IEEE, 2020;7: 3833-3849.

③ Szolovitz P. AI for the M.D. [J]. Science, 2019: 1402.

型系统中是必不可少的，并且在许多应用（例如，医疗机器人，环境辅助生活，企业决策，ETC）通过提供文字和视觉说明，已采取了使这些系统对用户易于理解的第一步。^①

如果我们向用户提供一个解释其工作原理的 AI 系统，我们如何知道该解释是否有效并且用户已经对 AI 达成了务实的理解？可解释性如何评估？霍夫曼等人在其研究中将此归纳为以下几点：（1）解释的良好性；（2）用户对解释是否满意；（3）用户对 AI 系统的理解程度如何；（4）好奇心如何促使人们寻求解释；（5）用户对 AI 的信任和依赖是否适当，（6）人工 XAI 工作系统的性能如何。^②

总之，深度神经网络由于是建立在经验知识之上，因此在理论上有所滞后。一些研究人员正在通过可视化方法研究深度学习中的特征提取和信息处理过程以了解深度学习的决定，但是仍然很难解释其做出的每个决定^③，但这也是人工智能领域必须要面对和解决的棘手难题。

4.2.3 提高样本及数据集的多样性

算法固然重要，但好的数据也很重要，并且在某种程度好的数据优于好的算法，假如你有一个无偏见多样性超大数据集，那么无论你使用哪种算法可能对分类性能影响不大。Wang 等研究发现多样性与讨论的绩效指标之间存在很强的相关性^④。由于 Beauty.AI 的数据集中没有足够的少数族裔，这导致人工智能对少数族裔的学习能力不够，认识不足，没有将少数族裔的审美特征纳入标准，所以选美的结果显示黑皮肤的候选者不受欢迎^⑤。但本论文研究实验通过改善数据集弥补了其缺陷，详见第三部分。

经过不断的尝试，也有些积极的例子证明如何使用数据来消除任何形式的性别或种族偏见。例如，美国的研究人员开发了一种 AI 工具，可以准确预测女性未来患乳腺癌的风险，对非裔美国女性特别有效。研究人员使用了大约 40,000 名不同种族妇女的近 90,000 幅乳腺 X 线照片的代表性数据集来训练，验证和测试深度学习模型。^⑥麻省理工学院的研究员 Joy Buolamwini 发现，支持三种市售面部识别软件系统的算法无法识别肤色较深的肤色。通常，大多数面部识别训练数据集估计超过 75% 的男性和 80% 的白人。当照片中的人是白人时，该软件在将人识别为男性的准确率高达 99%。根据 Buolamwini 的研究，这三种产品的产品错误率总体上不到 1%，但在将深色皮肤的女性识别为女性时，一种产品的错误率提高到 20% 以上，其他两种产品的错误率提高到

① Goebel R, Ajay C, Katharina H, et al. Explainable AI: The New 42?[A]. Cham: Springer International Publishing, 2018: 295-303.

② Hoffman R. R, Mueller S. T. Metrics for Explainable AI: Challenges and Prospects[A]. arXiv.org, 2019(2).

③ 莫宏伟. 强人工智能与弱人工智能的伦理问题思考[J]. 科学与社会, 2018, 8(01): 14-24.

④ Wang S., Yao X. Relationships between Diversity of Classification Ensembles and Single-Class Performance Measures[J]. IEEE Transactions on Knowledge and Data Engineering, 2013 (1) 25: 206-219.

⑤ The Guardian. A beauty contest was judged by AI and the robots didn't like dark skin[EB]. The Guardian, 2016(8).

⑥ McKinney S.M., Sieniek M., Godbole V. et al. International evaluation of an AI system for breast cancer screening[J]. Nature, 2020; 577: 89-94.

34%。^①为了回应 Buolamwini 的面部分析发现，IBM 和 Microsoft 都致力于提高其识别软件的准确性，以解决肤色较深的面部，并取得了一定的成就。

许多现实生活中的人工智能偏见问题可以描述为数据不平衡，比如其中属于其中一个类别的实例数量远大于其他类别的实例数量。那些专门为解决不平衡问题而设计的最常用也最重要的方法是：主动获取更多的少量样本数据针对少量样本数据，那么我们可以尽最大努力在各大网站中搜集更多的样本数量。其他的技术方法包括但不限于：生成合成数据、数据增强、改变权重、上采样、下采样、设定惩罚因子等，或者我们可以考虑选择对数据样本不平衡相对不怎么敏感的算法，如树模型等。

针对数据不平衡问题，目前也有多重解决方式，但是得具体问题具体分析，可以从以上提到的技术方法算法去解决，如本案例中我们就使用了改变小样本权重的方法，引入 R 值来解决数据不平衡问题，以及利用 GAN 生成合成数据来扩充数据库的方法（详见第三部分），在未来的研究中，我们会引入 loss function 的设计等等多种角度来选择解决数据不平衡的方法。例如，Wang 等研究开发了集成算法 AdaBoost 在不使用任何类分解的情况下，该算法在识别少数类示例和平衡数据方面表现出更好的表现^②，这也是值得学习的。

总之，在数据缺乏多样化的情况下，虽然通过一些技术手段可以达到数据平衡的效果，但如果能一开始就在采样过程中实现样本多样化则会使问题变得更简单，且更能真实反应实际情况。

4.3 加强对研发主体的道德培育

4.3.1 提倡研发企业的多元文化建设

汉娜·阿伦特在 1964 年与君特·高斯的访谈录中提到：“我在我这一生当中从没有爱过任何民族或群体，不论是德国人、法国人、美国人，还是工人阶级或之类的都没有。事实上我只爱我的朋友，而且就再也无法去爱别人了，如果因为我是犹太人，就说我特别爱犹太人，这是需要商榷的。”^③如此不带任何政治立场和民族身份的大爱源自于对人类自由平等这一信念的尊重。然而，人工智能发展到至今，其中裹挟了不可避免的政治标签，民族偏见，文化偏见，要解决这一问题，研发企业必须承担起多元化研发团队的责任。由来自不同背景和经验丰富的人组成的团队不仅可以站在不同立场上来思考问题，并且更具创造性和解决问题的能力。虽然招聘和公司具有相同文化底蕴的员工也许在团队合作上比较容易，但却不利于提高产品的创造性。

① Hardesty L. Study Finds Gender and Skin-Type Bias in Commercial Artificial-Intelligence Systems[N]. MIT News, 2018(2).

② Wang S, Yao X. Multiclass Imbalance Problems: Analysis and Potential Solutions[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2012(8) 42: 1119-1130.

③ 君特·高斯对汉娜·阿伦特的采访[Z]. <https://www.bilibili.com/video/av62097269/>, 1964.

显而易见，一个多元化的团队将拥有更广泛的知识组合，这将有助于他们准确地做出明智的决定。从统计抽样的角度考虑这一点，例如，我们想对一部分人口进行抽样，以使其完全代表其中的所有类型的数据点。同样，团队中更多的多样性将有助于构建适合更多消费者的产品以适应多元化的市场需求。当工作场所中有来自不同背景和经验的不同人群时，您的公司可以更有效地向各种种族的消费者进行营销，这些人群包括不同种族和种族背景，男女，老年人和年轻人以及标识为同性恋者。建立多元化的工作场所可以帮助您增加公司的市场份额。多元化的工作环境对招聘人才更具有吸引力，四大国际审计公司之一德勤 Deloitte 在 2013 年的研究表明，当员工认为自己的组织高度致力于并支持多元化，并且感到自己被高度包容时，则他们认为自己在一个高效组织中工作的可能性要比他们认为对多样性和低包容性的支持和承诺偏低的公司高 80%^①。根据 Catalyst 调查报告显示提供多元化和包容性的公司也因此得到了更多的溢价，当公司建立包容性的企业文化和政策时，公司的创造力，创新和开放度增加 59.1%，评估消费者兴趣和需求的比例提高了 37.9%。具有包容性企业文化和实践的组织提高声誉的可能性要高 57.8%^②。

对于 AI 系统中，确保偏见最小的最好的方法是考虑多元化团队的意见以产生包容性产出。如果在训练 AI 模型中使用的数据仅将某些组作为异常值，或者将那些偏离所谓“规范”的数据包括在内，那么这些数据就不会被考虑或丢弃，我们是否可以相信他们所做的决定？AI 的“镜像”能力反映了我们对人类智能的当前理解。这种理解也不可避免地照搬了由于我们的知识和经验上的限制而产生的偏见。关于这个话题，奥巴马政府 2016 年发表了名为《为人工智能的未来做准备》的白皮书，里面强调了 AI 工作者对 AI 公平性的影响。在组建开发 AI 的团队时，至关重要的一点是，在构建系统时要考虑是否忽略了人类，文化或系统多样性中的任何要素。比如来自亚洲国家的人的世界观可能会与来自德国的人大相径庭，他们都会提出不同但重要的问题，如果研发团队过于单一化，这就导致了在研发时遗忘事物的危险，这会导致 AI 偏见。

4.3.2 增加研发主体女性的从业比例

女性研发主体的缺席无疑加重了人工智能行业的性别歧视，并造成 AI 产品的性别代表性不足。Google 的 2020 年年度多样性报告中显示员工的性别多样性与其他跨国技术公司相似，女性只占不到总劳动力的三分之一，而担任领导职务的员工比例甚至更低^③。

① Deloitte. Waiter, is that inclusion in my soup? A new recipe to improve business performance[R]. 2013.

② Catalyst. Why Diversity and Inclusion Matter: Quick Take[R]. 2020.

③ Google. Google Diversity Annual Report 2020[R]. 2020.

根据联合国教科文组织部门发布的《如果可以，我会脸红》报告，女性比例在机器学习研究领域仅占12%^①。该报告还指出：如今男女相比，女性懂得如何将数字技能应用于基本生活目的（如点餐、出行等）的可能性要低25%，懂得如何对计算机进行编程的可能性要低4倍，而申请技术专利则更少，几乎要低13倍。在每个部门都成为技术部门的时刻，这些差距应该使执政者，教育者和日常公民“脸红”。人工智能行业女性比例严重不足很大程度上源于社会对女性的刻板印象，从小女孩受到的教育和舆论是数学和理工科思维不如男孩，导致潜移默化之下女孩逐渐丧失对自然科学和计算机学科的兴趣及自信。并且由于长期受刻板印象的影响，女性对自己数学类的学习能力的自我认同明显没有男性高。




图 4.1 国际经合组织调查显示女生（紫色）对数学的自信普遍不如男生

Joanne M. Cohoon 等人在其研究中指出女工程师和计算机科学家必须找到方法来解构她们作为女性和作为技术创造者的身份之间的冲突。由于性别歧视传达了一种观点，即女性不适合计算机文化，因此增加了将女性性别认同与技术认同相结合的难度。许多女性试图通过最大限度地减少女性气质或像男人一样扮演女性的角色来应对这一挑战^②。

就业性别的不平衡导致人工智能的性别偏见，Buolamwini 将来自主要技术公司的三个商业面部分析系统应用于她新构建的数据集。在所有这三个方面，女性的性别分类错误率始终高于男性，肤色较黑的人比肤色较浅的人更高。对于肤色较黑的女性（在 Fitzpatrick 量表上分配 IV, V 或 VI 评分的女性），错误率在百分之二十到百分之三十五左右，但是，在其中两个系统中，数据集中皮肤最黑的女性（被赋予 VI 分的女性）的错误率仍然更差，超过百分之四十六。对于那些皮肤最黑的女性，该系统猜测性别的方式还只是随机的^③。

① 联合国教科文组织部门. 如果可以，我会脸红：通过教育消除数字技能中的性别差异[M].2019(3).

② Cohoon J. M., Nable M., Boucher. P. Conflicted identities and sexism in computing graduate programs[J]. 2011 Frontiers in Education Conference (FIE), 2011, S1H-1-S1H-5.

③ Hardesty L. Study Finds Gender and Skin-Type Bias in Commercial Artificial-Intelligence Systems[N]. MIT News, 2018(2).

针对在人工智能和其他科学与工程领域女性比例的严重失调，艾伦·图灵研究所 2005 年为致力于促进和促进女性在高等教育和研究领域中的科学，工程，技术，数学和医学方面的职业发展而设立雅典娜天鹅宪章，该宪章提出了十项原则以消除学术界的性别不平等和保证女性在学术界的可持续发展。

增加人工智能女性就业比例不仅能减少人工智能的性别歧视问题，而且对于公司的财务效应也有积极作用，如麦肯锡在 2015 年的调查报告表明，性别多样性排在前四分之一的公司获得高于其各自国家行业中位数的财务回报的可能性要高 15%^①。Catalyst 在 2020 年研究显示，在高层管理团队中女性代表人数最多的公司的股本回报率和股东总回报率要好于女性代表人数最少的公司^②。这对于人工智能公司改善该行业就业不平等具有积极动力。

4.3.3 加强研发主体的伦理道德教育

为了增强研发主体的伦理道德，很多知名高校也开始开设人工智能伦理课程，这些课程包括人工智能伦理、数据科学伦理、技术伦理、算法伦理、机器人道德、机器人伦理等。如哈佛、康奈尔、麻省理工学院、斯坦福大学等诸多美国名校都开设了类似课程。这些课程都是为重点培养未来科技公司员工的伦理意识而服务，培养从业组织及人员自律意识，知其有所为而有所不为。很多课程都是从本科生就开始开设，例如斯坦福大学的以人为本的人工智能项目，让其学生在大学入学刚开始学习算法的时候，就培养应该站在社会大背景的角度下考察 AI 的思维方式。英国人工智能专责委员会指出对儿童的 AI 道德教育十分重要，在早期的教育阶段，需要为儿童做好使用 AI 的充分准备，AI 的道德设计和使用应成为课程的组成部分^③。

为了避免招聘人员的内隐偏见，旨在消除内隐偏见的培训在市场上如火如荼，Google People Operations 团队为员工开设一个工作坊-“无意识偏见@工作”，以介绍无意识偏见的概念及其影响。研讨会主要依靠外部研究和内部实例。成千上万的 Google 员工参加了 60-90 分钟的研讨会，这使其成为 Google 规模最大的自愿学习计划之一。^④Facebook 相信了解和管理无意识的偏见可以帮助他们建立更强大，更多样化和更具包容性的组织从而减少他们在工作场所中的负面影响。星巴克在面对陷入种族歧视丑闻的信任危机中也开始自救，它执行了一项员工志愿服务计划，该计划具有一些具有前瞻性的功能，变革性的志愿活动为参与者创造了超越自身及其社区的直接环境和环境的空间。志愿者不仅要花费时间或资源来做出改变，还要引导他们考虑自己的潜力，使他们变得越来越亲近社会，具有更大的同情心。变革性志愿服务的主要重点

① McKinsey. Why diversity matters[R]. McKinsey, 2015.

② Catalyst. Why Diversity and Inclusion Matter: Quick Take[R]. Catalyst, 2020.

③ 英国上议院人工智能专责委员会. AI in the UK: ready, willing and able? [R]. 英国上议院人工智能专责委员会. 2018(4)

④ Google. Watch Unconscious Bias @ Work [EB]. <https://rework.withgoogle.com/guides/unbiasing-raise-awareness/steps/watch-unconscious-bias-at-work/>

是志愿者自身发生的变化。志愿服务计划和活动旨在邀请参与者发现他们的内隐偏见，“对他们的经历进行批判性反思，从而导致观点转变。”^①从个人的角度来看，这种转变对于实现心理、信念和行为层面的改变是必要的。

这些教育和再培训无非是为内隐偏见建立一种科学的干预手段，事实证明它形成了一定的效果，除了这些打破习惯的技术外，另一种策略看起来很有希望：用于消除偏见的习惯形成技术被称为实施意图。如果满足以下条件，则明确制定实施意向：然后补充目标意向的计划；例如，通过形成实施意图（不要对女性领导有偏见），我们可以在特定的机会（遇见一个女人）和一个响应（像对待领导一样对待她）之间建立联系，从而快速识别机会发起新的和“想要的”响应，以取代陈规定型的响应。因此，在形成实施意图时，我们摆脱了隐式关联的影响，以便我们可以“重新控制”自我控制。换句话说，这种实施意图类似于自省式的自我教育^②。

4.3.4 提高行业伦理协会的监管效果

英国国会将对 AI 偏见错误而进行巨额罚款或者合法性调查这一想法进行了探讨，相信不久的便会付诸实践。^③这要求所有数学家和机器学习工程师都应在一定程度上考虑偏见，通常一个资源有限的小公司的偶然偏见可能被容忍，但一家可能拥有确保公正算法的资源的《财富》500强公司将严格执行标准。美国众议院和参议院提出了《2019年算法责任法案》，该法案将要求大公司对其算法进行审计。具体来说，公司必须报告算法中发现的任何“对准确性，公平性，偏见，歧视，隐私和安全性的影响”。该立法还将要求美国联邦通信委员会进行监督，以监控报告，并确保公司在出现任何错误的情况下纠正其算法。如果公司不遵守，委员会将可以诉诸处罚。^④分析医学图像的人工智能（AI）软件正变得越来越普遍，同时也应对相关的道德和法律挑战，来自加拿大放射医师协会的白皮书提供了一个框架，用于研究与医学成像中 AI 相关的法律和道德问题。奥巴马政府 2016 年发表了名为《为人工智能的未来做准备》的白皮书，同年，源于 2016 年由奥巴马政府白宫主办，由微软研究员 Kate Crawford 和 Google 研究员 Meredith Whittaker 主持的 AI Now 专题讨论会召开，该活动重点关注 AI 在社会领域的近期影响：不平等，劳工，道德和医疗保健，偏见和多样性研究。2018 年 4 月，AI Now 发布了算法影响评估框架（AIA 报告），作为政府评估公共机构中 AI 使用情况的一种方式。根据 AI Now 的说法，AIA 类似于环境影响评估，以评估 AI 系统的效果以及任何意想不到的后果。这将允许系统审查诸如偏差的结果或偏斜的培训

① Starbucks. Will Implicit Bias Training Solve the Starbucks Problem? [EB].

<https://www.realizedworth.com/2018/04/23/implicit-bias-training-starbucks-problem/>

② Webb T., Sheeran P., Pepper, J. Gaining control over responses to implicit attitude tests: Implementation intentions engender fast responses on attitude-incongruent trials[J]. The British journal of social psychology, 2012, 51: 13-32.

③ parliament.uk. Mitigating the risks of artificial intelligence [S].

<https://publications.parliament.uk/pa/ld201719/ldselect/ldai/100/10012.htm>. 2018

④ Khawaja H. What is algorithmic transparency and why do we need it? [EB]. <https://policyinterns.com/2019/07/31/what-is-algorithmic-transparency-and-why-do-we-need-it/>. 2019.

数据之类的问题，研究人员已经在全国各地部署的算法系统中确定了这些问题。^①英国下议院科学与技术委员会在 2016 年 10 月颁布的机器人与人工智能报告中指责英国政府将“机器人与自主系统（RAS）”作为实现英国领导全球的“八大技术”之一，却没有实现 2015 年的承诺成立 RAS 委员会，在 RAS 的领导与管理上缺乏效率，由人工智能引发的一系列道德和法律问题急需成立专家联盟以求解决^②。于是于 2017 年 6 月英国上议院“人工智能专责委员会”应声成立，该专责委员会由各行业专家组成，其职责是确定指导人工智能开发和应用的的原则，向政府提供建议，并促进公众对话。2017 年 11 月，英国政府在颁布的工业战略白皮书中指出：我们将以安全和合乎道德的方式使用数据和人工智能，引领世界，使公民和企业充满信心和明晰化。英国的数据伦理与创新中心作为“世界第一”的咨询机构将审查现有的人工智能治理环境，并就如何启用和确保包括人工智能在内的数据以道德，安全和创新的方式向政府提供建议^③。

除了外部规章制度式的行业性伦理监管，企业自身的内省式监管也非常重要，如同上市公司财务除了外部审计，公司内部也需要审计部门。各大人工智能企业大多建立了自己的道德团队以监督其 AI 产品是否符合伦理规范，如 Google 的建立了自己的 AI 道德团队，Facebook 和慕尼黑工业大学合作建立了独立的 AI 伦理研究中心，外部道德研究可以帮助 Facebook 保持其 AI 公平并防止原本无法预料的事件。微软的研究组织建立了公平问责制透明度和道德规范小组，推出了负责任 AI，通过负责任的 AI 办公室（ORA），AI，道德和工程与研究效果（Aether）委员会以及负责任的 AI 工程战略（RAISE）将负责任的 AI 原则付诸实践。USC 和亚马逊建立安全可靠的机器学习中心，该中心支持以信任为中心的机器学习和 AI 创新的新颖方法。自省式的监管效果很大程度上源于公司领导人及科研人员的道德伦理境界和对人类责任的担当，2015 年 1 月，世界著名的物理学家斯蒂芬·霍金（Stephen Hawking），特斯拉等多家人工智能公司的创始人埃隆·马斯克（Elon Musk），以及数十名人工智能专家共同签署了一封关于人工智能的公开信，呼吁全社会对 AI 的社会影响进行研究。这封信肯定了人工智能将给人类社会带来的巨大的潜在收益，但某些潜在的“陷阱”也必须进行具体研究：人工智能具有消除疾病和贫困的能力和潜力，但研究人员禁止创造出无法控制的东西。

总之，人工智能的伦理监管需从外部和内部同时着手，外部提供政策性和指导性监管办法和规章制度，内部建立或者联合建立公司伦理中心，通过自我审计和监督的方式以实现人工智能的发展符合人类伦理道德的要求。

① Reisman D., Schultz J., Crawford K., et al. Algorithmic Impact Assessments: A Practical Framework For Public Agency Accountability[S]. AI Now,2018.

② 英国下议院科学技术委员会. Robotics and artificial intelligence [R]. 英国下议院科学技术委员会, 2016（10）.

③ 英国总理办公室. Industrial Strategy White Paper. [M]. 英国总理办公室. 2017.

第5章 结语

内隐偏见一直是 21 世纪心理学领域研究的热点，随着学科的交叉，由它产生的一系列道德伦理问题也引起了哲学领域的关注，内隐偏见普遍存在并且正在以一种无声的方式影响着我们生活的方方面面，甚至是在 21 世纪同样热门的人工智能领域，消除人工智能的内隐偏见对人类未来的发展意义重大。要想减少偏见，我们则需要了解偏见，只有当我们全面透彻地了解了内隐偏见，我们才能更好的在生活和工作中避免它，本文对隐偏见的形成原因以及它存在的方式及特点做了全面的阐述和分析，并探讨了它为什么要在道德伦理界引起重视。了解了人的部分，我们则需要对人和机器的交互关系进行研究，人的偏见是否会被机器所复制？本文提出了两个假设，通过证明两个假设的成立验证了内隐偏见存在的普遍性以及人工智能将复制人类的偏见，该实验系统的示范了人类的内隐偏见如何影响人工智能。通过对人工智能各种内隐偏见表现的分析，本实验得出了人工智能内隐偏见的可能性原因，并且寻找到了一个如何消除人工智能内隐偏见的方法，在这一实际解决案例中，两个主要贡献是首先用 GAN 图像扩充了各样本数据库和一种无偏见机器学习工具的新方法，我们将来可以在其他区域的较大数据集上扩展此方法。其次，本学习实验改善了算法的公平性，从机器学习的角度出发，对有偏数据进行无偏模型的训练是一个重要的目标，通过学习如何应对这种偏见，无偏见网络是迈向未来的重要一步。未来人工智能将做出更多决策，因此更多生命将受到人工智能的影响，无偏见人工智能决策是道德基础。如何从伦理的角度设计无偏见的人工智能？本文以康德的普遍立法原则作为人工智能的伦理指导原则，试探了绝对命令在人工智能伦理设计中的可行性，同时提出了在人工智能中设定道德情感指标的设想。在文章的第四部分我探讨了如何消除人工智能内隐偏见的方法，从道德算法建设、对研发主体的道德培育、多元化企业文化、提高女性就业比例以及增强行业伦理协会的监管等方面进行对策研究。无偏决策是机器学习任务中一个具有挑战性的问题但是，它具有成为 AI 最重要的优势之一的巨大潜力。公平和公正的 AI 系统的进一步开发和部署对于 AI 对人类的未来至关重要，前路漫漫，这项工作未来还有很长的路要走，但不管走到哪一步，科研人员要始终保持一颗对自然和道德的敬畏之心，只有这样，才能保证这项科研是走向善的。最后，用康德的一句经典名言来作为本文结语：有两样东西，人们越是经常持久地对之凝神思索，它们就越是使内心充满常新而日增的惊奇和敬畏：我头上的星空和我心中的道德律^①。

^① 康德著，邓晓芒译. 实践理性批判[M]. 人民出版社, 2016:186

参考文献

- [1]Moule J. Understanding unconscious bias and unintentional racism: Acknowledging our possible biases and working together openly is essential for developing community in our schools [J]. Phi Delta Kappan, 2009(1):321-326.
- [2]Ahuja G. What a Doll Tells Us about Race[EB].abc News, 2009(3).
- [3]Spencer M . Study: White and black children biased toward lighter skin [EB].CNN world, 2010(5).
- [4]Dastin J. Amazon scraps secret AI recruiting tool that showed bias against women. [EB].Reuters, 2018(10).
- [5]CBS NEWS . Minneapolis mayor says George Floyd would "be alive today if he were white"[EB].CBS NEWS,2020(5).
- [6]Shankar S, Halpern Y, Breck E,et al J. No Classification without Representation:Assessing Geodiversity Issues in Open Data Sets for the Developing World [DB]. arXiv, 2017(11).
- [7]Angwin J, LarsonJ. Bias in criminal risk scores is mathematically inevitable researchers say [EB]. Propublica, 2016(12).
- [8]Crawford K. Artificial Intelligence's White Guy Problem[EB].The New York Times, 2016(6).
- [9]The Guardian. A beauty contest was judged by AI and the robots didn't like dark skin[EB]. The Guardian,2016(8).
- [10]科技战略咨询研究院. 2017 人工智能:技术、伦理与法律”研讨会在京召开[EB].中国科学院,2017 (4) .
- [11]徐锐.论我国人工智能的伦理规范建设[J]. 岭南学刊, 2019(1): 111-117
- [12]英国下议院科学技术委员会. Robotics and artificial intelligence [R]. 英国下议院科学技术委员会, 2016 (10) .
- [13]英国上议院人工智能专责委员会. AI in the UK: ready, willing and able? [R]. 英国上议院人工智能专责委员会. 2017(4).
- [14]ACM U.S. Public Policy Council, ACM Europe Policy Committee . Statement on Algorithmic Transparency and Accountability[J]. 2017(5).
- [15]第 40 届数据保护与隐私专员国际大会.人工智能伦理与数据保护 [M].2018(10).
- [16]世界经济论坛.2018 年全球性别差距报告 [M].2018(12).
- [17]联合国教科文组织部门. 如果可以，我会脸红：通过教育消除数字技能中的性别差异[M].2019(3).
- [18]Cath C, Wachter S, Mittelstadt B. et al. Artificial Intelligence and the ‘Good Society’: the US, EU, and UK approach[J]. Sci Eng Ethics, 2018(24): 505–528.
- [19]Greenwald A, Krieger L. Implicit Bias: Scientific Foundations[J]. California Law Review, 2006(4), 945-967.
- [20]戈登.奥尔波特著, 杜伟华译. 偏见的本质[M].北京师范大学出版社, 2017.
- [21]Howard A., Borenstein J. The Ugly Truth About Ourselves and Our Robot Creations: The Problem of Bias and Social Inequity[J]. Sci Eng Ethics, 2018(24), 1521–1536
- [22]Tarrant M., Hargreaves D. J., North, A. C. Social categorization, self-esteem, and the estimated musical preferences of male adolescents. Journal of Social Psychology,2001, 141(5), 565–581.
- [23]Robinson B. A.“Personal Preference” as the New Racism: Gay Desire and Racial Cleansing in Cyberspace[J]. Sociology of Race and Ethnicity, 2015,1 (2) 317–330.
- [24]Greenwald AG, Banaji, MR. Implicit social cognition: Attitudes, self-esteem, and stereotypes[J]. Psychological Review,1995 (102): 4–27
- [25]Fazio R& Olson M. Implicit Measures in Social Cognition Research: Their Meaning and Use[J]. Annual review of psychology2003 (54): 297-327.
- [26]Greenwald A G, McGhee. D E , Schwartz J L K. Measuring individual differences in implicit cognition: The implicit association test[J]. Journal of Personality and Social Psychology, 1998 (74): 1464–1480.
- [27]Hahn A, Judd C M, Hirsh H K, . et al. Awareness of implicit attitudes[J]. Journal of Experimental Psychology: General, 2014 (143): 1369–1392.
- [28]United Nations. International Convention on the Elimination of All Forms of Racial Discrimination[S]. United Nations. 1969.
- [29]Devos T. "Attitudes and attitude change". Implicit attitudes 101: Theoretical and empirical Insights[J]. New York: Psychology Press, 2008: 61–84.
- [30]Gawronski B, Payne B K. Handbook of Implicit Social Cognition: Measurement[M]. Theory and Application, 2010.
- [31]Eberhardt J L, Purdie. V J, Goff P A, et al. Seeing Black: Race, Crime, and Visual Processing[J]. Journal of Personality and Social Psychology, 2004 (6): 876–93.
- [32]Belenko S, Cassia S . Drugs, Crime, and Justice[M]. Sage, 2014.
- [33]Angwin J, LarsonJ. Bias in criminal risk scores is mathematically inevitable researchers say [EB]. Propublica, 2016(12).

- [34]Crawford K. Artificial Intelligence's White Guy Problem[EB].The New York Times, 2016(6).
- [35]Costa-jussà MR. An analysis of gender bias studies in natural language processing[J]. Nat Mach Intell, 2019(1): 495–496.
- [36]Johns M, Schmader T, Martens A. Knowing Is Half the Battle: Teaching Stereotype Threat as a Means of Improving Women's Math Performance[J]. Psychological Science, 2005(16):175-179.
- [37]Moss-Racusin C A, Dovidio J F, Brescoll V L, et al. Faculty's subtle gender biases favor male students[J]. Proceedings of the National Academy of Sciences, 2012; 109 (41): 16474-16479.
- [38]Nosek B. A, Banaji M. R, Greenwald A. G. Math = male, me = female, therefore math $\neq$ me[J]. Journal of Personality and Social Psychology. 2002; 83 (1): 44–59.
- [39]Steffens M. C, Jelenec P, Noack P. On the leaky math pipeline: Comparing implicit math-gender stereotypes and math withdrawal in female and male children and adolescents[J]. Journal of Educational Psychology, 2010; 102 (4): 947–963.
- [40]Banaji M. R., Greenwald, A. G. Implicit gender stereotyping in judgments of fame [J]. Journal of Personality and Social Psychology, 1995, 68 (2): 181–198.
- [41]Handelsman J, Ward W . Increasing Diversity in the STEM Workforce by Reducing the Impact of Bias [EB]. The White House, 2016.
- [42]Aronson E., Wilson T. D., Akert R. Social psychology[M]. Upper Saddle River: Prentice Hall, 2010.
- [43]Schwartz M. B., Vartanian L. R., Nosek B. A., et al. The Influence of One's Own Body Weight on Implicit and Explicit Anti-fat Bias[J]. Obesity 2006;14 (3): 440–447.
- [44]Carlsson R, Björklund F . Implicit stereotype content: mixed stereotypes can be measured with the implicit association test[J]. Social Psychology, 2010;41 (4): 213–222.
- [45]Amodio D.M, Harmon-Jones E, Devine P.G, Curtin J.J, et al. Neural Signals for the Detection of Unintentional Race Bias[J]. Psychological Science. 2004;15(2):88-93.
- [46]马扎林. 贝基, 安东尼. 格林沃尔德. 葛樱楠译. 盲点. [M]. 中信出版社, 2014:188.
- [47]Jules Holroyd. Implicit bias, awareness and imperfect cognitions[J]. Consciousness and Cognition, 2015: 511-523,
- [48]Ortner T. M.; Van D.V., Fons J.R. Behavior-based assessment in psychology : going beyond self-report in the personality, affective, motivation, and social domains[M]. Hogrefe Publishing, 2015.
- [49]Nosek B. A, Greenwald A. G., Banaji M. R. Understanding and using the Implicit Association Test: II. Method variables and construct validity[J]. Personality and Social Psychology Bulletin, 2005; 31 (2): 166–180.
- [50]丹尼尔·卡尼曼著, 胡晓姣, 李爱民等译. 思考, 快与慢[M]. 中信出版社, 2012:1-13.
- [51]Elizabeth A. P., Kevin J. O'C., William A. C., et al. Performance on Indirect Measures of Race Evaluation Predicts Amygdala Activation[J]. J Cogn Neurosci, 2000; 12 (5): 729–738.
- [52]Bucciarelli M., Khemlani S., Johnson-Laird, P.N..The psychology of moral reasoning. Judgment and Decision Making[J]. 2008: 121–139.
- [53]Baron A., Dunham Y., Banaji M., Carey S. Constraints on the Acquisition of Social Category Concepts[J]. Journal of Cognition and Development, 2014;15: 238-268.
- [54]Fu F., Tarnita, C. E., Christakis N A, et al. Evolution of in-group favoritism. Scientific Reports, 2012. 2: 460.
- [55]Billig M., Tajfel H. Social categorization and similarity in intergroup behaviour[J]. European Journal of Social Psychology, 1973; 3 (1): 27–52.
- [56]Tajfel H., Turner J.C. An integrative theory of intergroup conflict[J]. The Social Psychology of Intergroup Relations. Brooks-Cole, 1979: 33–47.
- [57]Rudman L.A. Sources of Implicit Attitudes[J]. Current Directions in Psychological Science. 2004;13(2):79-82.
- [58]Rudman L. A., Heppen J. B. Implicit romantic fantasies and women's interest in personal power: A glass slipper effect?[J]. Personality and Social Psychology Bulletin, 2003; 29:1357-1370.
- [59]Jonas E., Ernst H.W. K., Nazanin D.. The combined cognitive bias hypothesis in depression[J]. Clinical Psychology Review, 2012: 413-424.
- [60]Keith Payne B., Vuletich H. A., Brown-Iannuzzi J. L. Historical roots of implicit bias in slavery [J]. Proceedings of the National Academy of Sciences, 2019; 116 (24) 11693-11698,
- [61]Richard G., Psychology: The Science of Mind and Behaviour[M]. Hodder Education, 2010.
- [62]Evelyn H. , Peer S., Mérove G. Education and Ethnic Prejudice in Europe: Explanations for cross-national variances in the educational effect on ethnic prejudice [J].Scandinavian Journal of Educational Research, 2002; 46: 5-24
- [63]Piotr Ż. Nation, national remembrance, and education – Polish schools as factories of nationalism and prejudice[J]. Nationalities Papers, 2017; 46:6: 1046-1062

- [64]Matharu K., Shapiro J., Hammer R., et al. Reducing obesity prejudice in medical education[J]. Education for health (Abingdon, England), 2014: 27(3), 231-237.
- [65]Greene J., Haidt J. How (and where) does moral judgment work? [J]. Trends in Cognitive Sciences, 2002(6) 517-523.
- [66]Bucciarelli M., Khemlani S., Johnson-Laird, P.N. The psychology of moral reasoning[J]. Judgment and Decision Making, 2008.
- [67]Haidt J. The emotional dog and its rational tail: A social intuitionist approach to moral judgment[J]. Psychological Review, 2001; 108 (4): 814-834.
- [68]Bargh J.A., Chartrand T.L. The unbearable automaticity of being [J]Am. Psychol., 1999;54: 462-479.
- [69]Galotti K.M. Approaches to studying formal and everyday reasoning[J]. Psychol. Bull., 1989;105:331-351
- [70]Shaver K.G. The attribution of blame: Causality, responsibility, and blameworthiness[M]. Springer Verlag, New York, 1985.
- [71]Weiner B. Judgments of responsibility: A foundation for a theory of social conduct[M]. Guilford Press, New York (1995)
- [72]Kelly D., Roedder E. Racial Cognition and the Ethics of Implicit Bias[J]. Philosophy Compass, 2008; 3: 522-540.
- [73]Washington N., Kelly D. Implicit bias and philosophy. Moral responsibility, structural injustice, and ethics by [M]. Oxford University Press, 2016: 11-26.
- [74]Fischer J.M., Ravizza M. Précis of Responsibility and Control: A Theory of Moral Responsibility[J]. Philosophy and Phenomenological Research, 2000; 61: 441-445.
- [75]Suhler C. L., Churchland P. S. Control: conscious and otherwise[J]. Trends in Cognitive Sciences, 2009; 13: 341-347.
- [76]Levy N., Bayne T. Doing without deliberation: Automatism, automaticity, and moral accountability[J]. International Review of Psychiatry, 2004; 16: 209-215.
- [77]Holroyd J. Responsibility for Implicit Bias[J]. Journal of Social Philosophy, 2012; 43: 274-306.
- [78]Zheng R. Implicit bias and philosophy. Moral responsibility, structural injustice, and ethics [M]. Oxford University Press, 2016: 65-66.
- [79]Bellamy R. K. E., Dey K., Hind M., et al. AI Fairness 360: An Extensible Toolkit for Detecting, Understanding, and Mitigating Unwanted Algorithmic Bias[DB]. arXiv 2018.
- [80]Goodfellow I., Bengio Y., Courville A. Deep learning [J]. Cambridge: MIT press, 2016: 326-366
- [81]Iversen T.N., Larsen L., Solem P.E. A conceptual analysis of ageism[J]. Nordic Psychology, 2009, 61 (3): 4-22.
- [82]Nelson T.D., ed. Ageism: Stereotyping and Prejudice against Older Persons [M]. MIT Press. 2012
- [83]Levy B. R. Eradication of Ageism requires addressing the enemy within[J]. The Gerontologist, 2001, 41 (5): 578-579.
- [84]Terry R. L., Kroger D. L. Effects of eye correctives on ratings of attractiveness[J]. Perceptual and Motor Skills, 1976: 562.
- [85]Aydin R. Women in Japan Are Being Told Not to Wear Glasses in the Workplace — Here Are 5 Sexist Dress Codes From Around the World[EB]. Thrive Global, 2019, 11.
- [86]Sahay S., Piran N. Skin-color preferences and body satisfaction among South Asian-Canadian and European-Canadian female university students[J]. The Journal of Social Psychology, 1997; 137(2): 161-172.
- [87]Xie Q., Zhang M. White or tan? A cross-cultural analysis of skin beauty advertisements between China and the United States[J]. Asian Journal of Communication, 2013; 23: 538-554.
- [88]Thakore B.K. Must-See TV: South Asian Characterizations in American Popular Media[J]. Sociology Compass, 2014, 8: 149-156.
- [89]Zou J., Schiebinger L. AI can be sexist and racist — it's time to make it fair[EB]. Nature comment, 2018.
- [90]Mitchell W. J. T. Picture Theory: Essays on Verbal and Visual Representation[M]. The University of Chicago press, 2007.
- [91]Crawford K., Paglen T. The Politics of Images in Machine Learning Training Sets[Z]. Excavating AI, 2019.
- [92]Kaplan R.M., Chambers D.A., Glasgow R.E. Big Data and Large Sample Size: A Cautionary Note on the Potential for Bias[J]. Clinical And Translational Science, 2014; 7: 342-346.
- [93]Žliobaitė I. Measuring discrimination in algorithmic decision making[J]. Data Min Knowl, 2017; 31: 1060-1089.
- [94]Howard A., Borenstein J. The Ugly Truth About Ourselves and Our Robot Creations: The Problem of Bias and Social Inequity[J]. Science and Engineering Ethics, 2018, 24: 1521-1536.
- [95]Garcia M. Racist in the Machine: The Disturbing Implications of Algorithmic Bias[J]. World Policy Journal Duke University Press 2016/2017: 111-117.
- [96]Dastin J. Amazon scraps secret AI recruiting tool that showed bias against women. [EB]. Reuters, 2018(10).
- [97]Kirkpatrick K. Battling algorithmic bias how do we ensure algorithms treat us fairly? [J]. Communications of the ACM, 2016, 59: 16-17.

- [98]Licklider J. C. R. Man-Computer Symbiosis[J]. IRE Transactions on Human Factors in Electronics, 1960, 3: 4-11.
- [99]范向民,范俊君,田丰等. 人机交互与人工智能:从交替浮沉到协同共进[J]. 中国科学:信息科学,2019,49(03):361-368.
- [100]Entezari R. PhD Forum Abstract: Understanding Deep Model Compression for IoT Devices. Information Processing in Sensor Networks (IPSN) [J]. 19th ACM/IEEE International Conference 2020: 385-386.
- [101]Minovski D, Åhlund C, Mitra K. Modeling Quality of IoT Experience in Autonomous Vehicles[J]. Internet of Things Journal IEEE, 2020;7: 3833-3849.
- [102]Szolovitz P. AI for the M.D. [J]. Science, 2019: 1402.
- [103]Goebel R, Ajay C, Katharina H, et al. Explainable AI: The New 42?[A]. Cham: Springer International Publishing, 2018: 295-303.
- [104]Hoffman R. R, Mueller S. T. Metrics for Explainable AI: Challenges and Prospects[A]. arXiv.org , 2019(2).
- [105]莫宏伟.强人工智能与弱人工智能的伦理问题思考[J].科学与社会,2018,8(01):14-24.
- [106]Wang S., Yao X. Relationships between Diversity of Classification Ensembles and Single-Class Performance Measures[J]. IEEE Transactions on Knowledge and Data Engineering, 2013 (1) 25: 206-219.
- [107]McKinney S.M., Sieniek M., Godbole V. et al. International evaluation of an AI system for breast cancer screening[J]. Nature, 2020; 577: 89-94.
- [108]Hardesty L. Study Finds Gender and Skin-Type Bias in Commercial Artificial-Intelligence Systems[N] .MIT News, 2018(2).
- [109]君特·高斯对汉娜·阿伦特的采访[Z]. <https://www.bilibili.com/video/av62097269/>,1964.
- [110]Deloitte. Waiter, is that inclusion in my soup? A new recipe to improve business performance[R]. 2013.
- [111]Catalyst. Why Diversity and Inclusion Matter: Quick Take[R]. 2020.
- [112]Google. Google Diversity Annual Report 2020[R]. 2020.
- [113]Cohoon J. M., Nable M., Boucher. P. Conflicted identities and sexism in computing graduate programs[J] . 2011 Frontiers in Education Conference (FIE), 2011, S1H-1-S1H-5.
- [114]Hardesty L. Study Finds Gender and Skin-Type Bias in Commercial Artificial-Intelligence Systems[N] .MIT News, 2018(2).
- [115]Mckinsey. Why diversity matters[R] . Mckinsey,2015.
- [116]Google. Watch Unconscious Bias @ Work [EB]. <https://rework.withgoogle.com/guides/unbiasing-raise-awareness/steps/watch-unconscious-bias-at-work/>
- [117]Starbucks. Will Implicit Bias Training Solve the Starbucks Problem? [EB]. <https://www.realizedworth.com/2018/04/23/implicit-bias-training-starbucks-problem/>
- [118]Webb T., Sheeran P., Pepper, J. Gaining control over responses to implicit attitude tests: Implementation intentions engender fast responses on attitude-incongruent trials[J].The British journal of social psychology, 2012, 51: 13-32.
- [119]parliament.uk. Mitigating the risks of artificial intelligence [S]. <https://publications.parliament.uk/pa/ld201719/ldselect/ldai/100/10012.htm>. 2018
- [120]Khawaja H. What is algorithmic transparency and why do we need it? [EB]. <https://policyinterns.com/2019/07/31/what-is-algorithmic-transparency-and-why-do-we-need-it/> . 2019.
- [121]Reisman D., Schultz J., Crawford K., et al. Algorithmic Impact Assessments: A Practical Framework For Public Agency Accountability[S]. AI Now,2018.
- [122]英国总理办公室. Industrial Strategy White Paper. [M]. 英国总理办公室. 2017.
- [123]康德著, 邓晓芒译. 实践理性批判[M].人民出版社, 2016.

附录 A 攻读学位期间发表的论文与科研成果清单

发表的论文

- [1] Gerlach, Tobias , Danner, Michael , Le Ping Peng. Who Loves Virtue as much as He Loves Beauty?: Deep Learning based Estimator for Aesthetics of Portraits. [J]. VISIGRAPP 2020, 2020: 521-528.
- [2] Leping Peng, Micheal Danner. Ethically aligned Deep Learning: Unbiased Facial Aesthetic Prediction [J]. CEPE/IACAP Joint Conference 2021 （已录用稿件）
- [3] 彭乐平.女性主义伦理视域下德国育儿政策解读[J].侨园,2021,3: 165-166.

致 谢

首先要感谢我的导师杨盛军副教授，论文的选题他充分尊重了我自己的兴趣和研究方向，如果没有他来回多次替我修改提纲、逐字逐句对我的论文进行精炼，甚至耐心细致到格式的调整，没有他的这些工作这篇论文很难完结。还记得他在我开题之前深夜 10 点照顾完孩子后急急忙忙赶回办公室替我修改提纲的情景，他对我拖拖拉拉不求上进少有怨言，回复我信息的速度永远比我回复他信息的速度快，如果没有他时常对我论文的进展表示亲切问候，我的惰性不会让我这么奋力的去奔跑以赶上这趟毕业的班车。也许我没有成为他的得意门生，但我感觉很荣幸能成为他的开山弟子。

其次，要感谢哲学系的导师们对我论文提出的一次又一次的宝贵意见，让我有了明确的写作方向及目标。还要感谢哲学系的各位老师，由于我的研究项目在国外，期间他们对我带来的诸多不便予以了充分的理解和帮助，让我有了一个充分自由的学术空间，以使我在这个研究项目的基础上产生了这篇毕业论文以及另外三篇期刊论文，成果虽小，但如果没有老师们的理解和鼓励，恐怕再小的果子也难以结成。

我还要特别感谢我的工作搭档 Michael Danner 以及德国 Reutlingen 大学的 ViSiR 研究团队，Michael Danner 是计算机视觉的在读博士，没有他在机器视觉方面专业的知识，我的毕业设计则很难实现，他对我设计想法总是积极回应，通过这个项目也激发了他对于自己研究方向的些许变化，希望以后能将他的专业知识与哲学、伦理相结合，对此我十分高兴，因为人工智能伦理领域确实太需要这样跨学科的专业人才了。

我要感谢我的家人，先生的工作任务非常大，除了正常的上下班，还总是不得不加班加点，活得跟全世界努力生活的人一个样子，大部分时间我都是一个人照顾孩子，有时候真的几近崩溃，但即便很忙，难得有周末休息时间他也还是每个周末都认真执行着爸爸的职责，让我有了更多零零碎碎的工作时间。也要感谢我的孩子，才 10 个月就表现出十分独立的研究精神，常常一个人能坐上半个小时专心研究他的小世界，这也让我得以在一地鸡毛的日常生活里找到些许思考和呼吸的空间。

我还要感谢我的同窗们，他们对我的帮助几乎从来都是有求必应，他们总是热心的跑前跑后替我解决我制造的麻烦，还总是跟我说“别客气，举手之劳”，但谁的时间不宝贵呢？在这个忙碌的世界愿意为你停留上片刻的人又有多少。我很珍惜和感恩这段同窗之缘，借此机会，我真心的祝福他们都有美好的前程！

最后，再次，感恩各位老师帮我打开哲学的大门，虽然我自认为自己还只是一直在门外晃荡，但至少，我看到了那道光，并心有向往！

彭乐平
2021 年 6 月