

演化博弈视角下的算法偏见与伦理规制

向安玲 沈 阳

摘 要 推荐算法已成为社交媒体时代信息分发的驱动要素，受政治、资本、流量等因素影响，算法在信息分发过程中往往会出现结构性偏见、选择性偏见和趋利性偏见。本文基于人机演化博弈视角，对冷启动、协同过滤、收敛稳定和交互博弈四大阶段算法偏见的生成与纠偏机制进行分析，并基于反向工程实验，面向今日头条新闻客户端进行动态数据追踪和多阶段对比分析。发现算法推荐主题内容存在从发散到收敛的动态演变，使用早期旨在拓展用户兴趣边界，后期推荐主题趋于集中；在各个阶段正面内容均占据推荐主导地位；随着用户使用频次增加，中央媒体内容和广告内容被推荐占比趋于上升；面向不同群体推荐主题内容和情感倾向存在一定结构性差异。适度约束算法权力，有效保障用户权利，才能在合乎伦理的前提下最大化发挥人工智能的信息红利。

关键词 算法偏见 演化博弈 伦理规制 人机交互 智能推荐

Algorithmic Bias and Ethical Regulation under the Perspective of Evolutionary Game

Xiang Anling Shen Yang

Abstract Recommendation algorithm has become the driving factor of information distribution in the era of social media. Influenced by political, capital, flow and other factors, the algorithm often presents structural bias, selective bias and profit bias in the process of information distribution. Based on the perspective of human-computer evolutionary game, this paper analyzes the generation and

correction mechanism of algorithm bias in four stages: cold-start, collaborative filtering, convergence stability and interactive game. Based on reverse engineering experiment, dynamic data tracking and multi-stage comparative analysis are carried out for the news app TouTiao. It is found that there is a dynamic evolution from divergence to convergence in the topic of the algorithm recommendation. In the early stage, it aims to expand the user's interest boundary, and in the later stage, the recommended topics tend to be concentrated; in each stage, the positive content occupies a dominant position in recommendation; with the increase of use frequency, the proportion of central media content and advertising content being recommended tends to rise; besides, there are some structural differences in propensity of topic and emotional tendency recommended for different groups. Only when the algorithm power is moderately constrained and the user rights are effectively protected can the information dividend of artificial intelligence be maximized under the premise of ethics.

Keywords Algorithmic Bias; Evolutionary Game; Ethical Regulation; Man-Machine Interactive; Intelligent Recommendation

— 引言

人工智能和大数据技术驱动信息传播生态加速变革，智能推荐算法已逐渐取代编辑分发和订阅分发，成为新媒体时代信息分发的核心要素。算法作为连接信息与用户的中介，其运作逻辑、连接规则、价值取向直接决定了用户获取信息的类别和质量。在这个过程中，算法的信息分发权力和用户的信息获取权利往往会出现冲突。受政治、资本、流量偏好等因素影响，算法在信息分发过程中往往会出现结构性偏见、选择性偏见和趋利性偏见，不利于用户信息获取的公正性、客观性和开放性；而用户可在一定程度上通过交互行为和自发性选择来反向驯化算法，基于主体能动性实现算法纠偏。这种人机博弈过程中，偏见是如何生成又是如何被强化抑或被弱化？权力和权利是如何对抗又是如何演化？都有待进一步探讨。

二 偏见溯源：人机博弈与权力失衡

算法偏见（algorithmic bias）主要是指算法程序在信息生产和分发过程中丧失客观中立立场，从而影响受众对信息的全面客观的认知。^[1]算法偏见既包括基于性别、种族、职业身份等社会结构性因素的信息偏见，又包括基于个体偏好、资本利益、政治宣传等因素的信息选择性偏见。受限于程序设计者主观偏见、输入数据中隐蔽性偏见、利益操纵下的刻意偏见以及算法本身的局限，^[2]算法很难真正保障所谓的技术中立性和信息公正性。而用户作为算法偏见作用的对象，同时也通过其交互行为反作用于算法本身的迭代与优化。在这种人机博弈的过程中，偏见伴随着信息权力的失衡与平衡不断演化，从冷启动阶段的结构性偏见、数据收集阶段的失真性偏见、兴趣收敛阶段的选择性偏见到反向驯化阶段的纠偏，算法和用户之前的博弈不断演化，最终会形成一种循环性的动态平衡状态。

根据演化博弈理论（Evolutionary Game Theory），博弈双方并不掌握完全信息，也非完全理性的行为主体，而是会通过不断试错的方法达到动态均衡状态，历史因素、系统性因素和偶发性因素都会对博弈选择产生影响。^[2]在算法和用户的博弈过程中，算法会根据最优设定目标、既有训练语料、用户行为反馈等因素不断调整其推荐信息，而用户也会根据自身偏好、价值感知、预期收益等因素不断调整自身行为反馈。选择（Selection）和突变（Mutation）是演化博弈的两个核心因素。人机双方在不断试探和交互过程中，一方面会通过规律性选择逐步收敛达到平衡状态，另一方面也会通过一些偶发性突变破坏平衡，又进入新一轮的博弈。包括算法运行逻辑、用户自身偏好、平台信息生态等在内的多种因素的改变都会促使博弈的动态循环，而人机博弈过程也伴随着算法偏见的演化和信息权力的重构（图1）。本文针对算法迭代不同阶段的偏见成因进行溯源，从演化博弈视角探讨人机交互与偏见的交织影响。




图1 人机博弈阶段与算法偏见演化

（一）冷启动阶段：社会结构性归因与连带性偏见

冷启动（cold-start）是指在算法未获取用户行为数据和交互关系数据的前提下，其信息分发行为的试探性启动。在此阶段受限于个体用户行为轨迹和兴趣标签的缺失，算法通常会基于群体特征关联和社会结构性偏见针对特定用户推荐信息。国外大量研究已经证实推荐算法会基于现实社会的刻板印象针对特定群体推送差异化信息，并且这些在现实社会中既存的结构性偏见会被推荐算法的自生循环（self-perpetuating loop）进一步放大。^[3]性别、种族、职业等结构性因素成了影响智能信息分发的关键特征，而降低这些敏感特征干扰是保障信息中立性和公平性的前提。^[4]而这种中立和公平往往很难实现，尤其是在缺乏个体细颗粒度画像的冷启动阶段，在算法无法精准定位个体属性偏好时，往往会采用“连带歧视”策略，也即根据人群通用特征来进行群体信息推送，这些“通用特征”变量往往衍生于现实社会中的结构性偏见。如认为女性群体和低收入群体更关注娱乐八卦等低价值密度信息，男性群体和高收入群体更关注财经时政等高价值密度信息。看似中立的群体划分标准中实则暗含了对群体品味、价值取向、消费能力的偏见和歧视。

尤其是在演化博弈早期，用户的参与程度相对较低，处于被动接收信息状态，对于部分主观能动性较弱的用户群体而言，很容易受算法诱导而局限于偏见循环，进一步强化算法的结构性偏见，损害用户获取全面、中

立、客观信息的权利。社会结构性归因偏见是现实世界权力失衡在信息世界的复制与放大，破除这种连带性偏见就需要在冷启动阶段给用户更多信息自主选择权，通过自定义用户标签替代算法层面的群体刻板标签，只有解构固有“结构”才能保障算法中立性。

（二）协同过滤阶段：自生循环与偏见强化

协同过滤（Collaborative filtering）是指根据其他相似用户的偏好给目标用户推荐信息的算法模型，在各大推荐系统中被广泛采用。^[5]相比于基于性别、年龄、种族等结构性因素的聚类，协同过滤更多基于用户历史行为习惯、信息偏好和社交网络关联来确定相似用户。这种行为偏好驱动的推荐虽然在一定程度上弱化了社会结构性因素和算法设计者主观因素带来的归因偏见，但由于协同过滤对用户行为数据的高度依赖，以及其自生循环验证的运作机制，使得部分潜藏在行为数据中的偏见不断被强化。

一方面，算法在学习人类行为偏好和语言能力的过程中，会无意识习得人类在行为和言语中所暗含的固有偏见，在缺乏道德指令限制的情况下算法会将这些习得偏见进一步体现在其功能应用中。目前所谓的人工道德智能体（Artificial Moral Agents）还处于摸索构建阶段，现有算法体系无法做到对偏见的屏蔽与抵制。^[6]微软设计的 Twitter 机器人 Tay 在短短 24 小时内就从一个乐观的健谈者被训练成了一个满嘴脏话、仇视女权主义、否认大屠杀的种族主义者。这种习得性偏见并非算法预先设定，但扭曲、偏激、不可控的用户行为数据会无意识渗透到算法运作过程中。^[7]另一方面，这种被算法吸收的偏见则会进一步通过信息推荐分发影响到更多受众，从而使得偏见性内容在“相似用户”群中不断得到正向行为反馈，进一步强化了偏见本身。研究发现，算法推荐会强化社会的两极分化，通过对邻近用户的同质性信息推荐，会使得群体内部连接度增强，极化趋势增加，而群体间则会加剧分化程度。^[8]群体偏见和算法偏见在人机交互过程中彼此呼应，并通过偏见习得—信息推荐—正向反馈—偏见强化的循环，使得偏见伴随着信息流传递。此外，用户偶发性错误点击行为、社交机器人虚假操作行为等都会导致算法在信息分发过程中出现偏差。尤其是在流量造假、社交水军大量存在的环境下，算法被资本操纵的可能性也进一步扩大。如何通过技术自动识别、追踪、过滤有意识的偏见性操作，成为算法

伦理规制必须要解决的一个问题。

（三）收敛稳定阶段：过滤气泡与选择性偏见

随着人机交互过程演化，受众的兴趣偏好和使用习惯会逐渐收敛，算法的推荐逻辑也会进入相对稳定阶段，也即人机双方在反复试探、选择、反馈后进入到演化博弈的动态平衡阶段。在算法收敛阶段，受众的信息偏食倾向逐渐凸显，容易出现信息茧房现象。算法出于流量最大化原则，倾向于基于用户偏好进行信息过滤和选择性推荐；而用户出于认知协调和自我确认需要，倾向于接触与自己预设立场更加接近的信息，而排斥与自己既有观点相悖或兴趣范围外的信息。^[2]在这种交互反馈过程中，用户接触到的信息会愈发同质化和窄化，算法的倾向性和用户自身倾向性相叠加，干扰了多元、客观、中立的信息生态。

另外，算法本身的纠错机制、关联发现机制、自我迭代能力对于破除个体信息茧房是有正向促进作用的。长期沉浸在同质化信息中会削减用户的感知愉悦性和使用活跃度。算法出于增强用户黏性、追求流量红利最大化的目的，会不断探索用户新的兴趣领域，通过多元化偏好挖掘在更长的时间线上与用户保持强绑定。研究发现，信息茧房是个体、社会、场景与技术等因素共同作用的结果，算法既不是其形成的必要条件，也不是加速条件，甚至通过人机交互和深度迭代，可以消解信息茧房的存在。^{[9][10]}

选择性偏见是算法和用户在数据对话中的衍生产物，既折射出了用户本身的信息偏食和认知协调需求，又体现了算法迎合用户偏好和追求流量效应的本质运作逻辑。重复性、规律性、偏向性的选择是演化博弈达到动态平衡的必要条件，而用户偏好、行为和算法规则的突变则是推动博弈进入新一轮循环的驱动力。这种动态演化过程伴随着旧偏见的消解和新偏见的萌生，也伴随着信息权力的解构和重构。

（四）交互博弈阶段：驯化与反向驯化

算法和用户的交互博弈在连接之初便已存在，但在早期，信息权力更多集中在算法方，用户获取信息的主题类别、情感倾向、价值取向主要由算法决定。算法作为用户信息议程设置的决定性因素，虽然不能改变用户怎么想，但往往能影响用户想什么。随着交互频次的深入，用户的信息范

畴、内容偏好、使用频度或多或少都会受到算法影响，甚至是被算法在一定程度上驯化。驯化（domestication）主要是指新媒介技术在被使用过程中对人们日常生活的形塑功能，涉及媒介技术对用户思想、态度、行为等多方面的显性或隐性影响。^[11]这种驯化过程既受限于算法设计者的程序化目标设定，也来源于用户自身的行为反馈。

当然，用户在被驯化的过程中也在对算法进行反向驯化。一方面，内容创作者通过行为试探试图诠释算法推荐的逻辑和意义，并在理解算法的基础上应用算法去实现信息精准触达，算法已成为其攫取流量红利的一种技术工具。^[12]另一方面，普通用户可通过标签设定、搜索、屏蔽、点击、分享等交互行为来训练算法模型，让算法服务于其既定信息需求，在有意识的训练下算法既可以成为魔鬼，也可以成为高价值信息的智能筛选器。驯化和反向驯化过程中，推荐平台内部形成的“职责共识网络”和自媒体创作群体内形成的“规律共识网络”相互连接形成权力博弈网络。^[13]用户在交互博弈过程中主观能动性越强，其掌握信息的自主权就越强，进一步可通过反向驯化实现算法偏见的修正和价值的提升，当然这对于用户自身的媒介素养也提出了更高的要求。

此外，在驯化和反向驯化过程中，政治、资本等外部因素也在很大程度上影响着算法偏见的强化和纠偏过程。在信息生态管控逐步趋强的新媒体环境中，信息的政治倾向和舆论导向是否正确决定了算法推荐的价值底线。而广告转化、流量溢价等资本逻辑则成了算法推荐的高权重因子。投入产出比是广告信息分发考虑的关键因素，具有不同“潜在转化价值”的用户在信息接收上会存在明显差异，部分弱势群体在信息接收上遭受了算法歧视。^[14]另外，实证研究发现流量效应驱动下往往会使得高质量的内容被“泡沫化”，尤其是算法在流行度计算上倾向于量而非质，由此导致的计算偏差也会影响内容生态的整体质量。^[9]

三 偏见演化：主题、情感与价值导向

从冷启动到数据收集、收敛稳定再到反向驯化，算法外生性和内生性偏见随着人机交互的博弈过程不断演化。这个过程中，算法推荐内容和用户阅读内容在主题类别、情感倾向、价值导向上相互影响。一方面，算法

根据用户阅读行为数据不断调整其推荐信息的相关属性；另一方面，用户针对推荐内容进行选择性接收，并通过点击交互行为向算法传达反馈自身偏好。从试探、迎合、偏离到再度契合，算法推荐在多大程度上影响用户的信息选择？用户的行为反馈又在多大程度上反作用于算法推荐？不同群体的被推荐信息是否存在结构性差异？高频度人机交互是否会带来茧房效应？政治和资本又在多大程度上影响信息分发？为了进一步探索相关问题，笔者采用反向工程试验，通过构建虚拟 ID 针对今日头条资讯客户端进行周期性访问和模拟行为交互，并对虚拟 ID 行为数据和平台推荐信息进行机器学习和属性标注，进一步探讨算法偏见的多阶段演化特征。

具体操作上，笔者通过计算机模拟设定虚拟用户群体相关属性，包括性别、年龄、所在地域、手机型号、使用频度等基础行为信息，在设定好虚拟 ID 基础属性后基于代理 IP 技术、多属性模拟技术、数据跟踪运维技术实现相关交互行为的触发和数据记录。本次实验先后共构建 105 个虚拟 ID，交互行为发生及数据监测区间为 2020 年 1 月 1 日至 2020 年 8 月 28 日，根据样本账号行为数据的收敛程度，笔者将数据划分为三个阶段进行跨时期的对比分析，包括使用早期（冷启动期）也即 2020 年 1 月 1 日至 2020 年 1 月 31 日，人机交互期（兴趣探索期）也即 2020 年 2 月 1 日至 2020 年 3 月 31 日，稳定收敛期（兴趣偏好基本稳定）也即 2020 年 4 月 1 日至 2020 年 8 月 28 日。采集字段包括平台推荐信息标题及内容、推荐信息发布账号、推荐信息标签、推荐时间、文章热度，以及虚拟 ID 主动搜索关键词、阅读文章标题及内容、阅读文章标签、阅读时间、交互行为等。在采集数据基础上通过深度学习模型对信息内容的主题类别和情感倾向进行抽取，其中主题类别划分为体育、健康养生、军事、动漫、历史、国际、娱乐等 26 类，情感倾向根据内容属性划分为正面、中性、负面三类。在此基础上，分别针对平台推荐信息和虚拟 ID 阅读信息进行多阶段属性聚类，并按照性别和所在区域（一线城市和四五线城市）进行群体交叉对比（样本账号分布见表 1），以探讨算法偏见的群体差异性和动态演化特征。

表 1 样本账号类型分布

虚拟 ID 类型	ID 数量
城市男性群体	27
城市女性群体	25
小镇男性群体	22
小镇女性群体	27

（一）主题收敛：“选择”强化与“突变”产生

“选择”和“突变”是演化博弈从平衡、失衡到再平衡的两个关键变量。算法通过习得用户的倾向性选择不断收敛其推荐主题，用户在接收推荐信息的同时，也会自发性探索兴趣信息，并通过兴趣突变推动算法迭代。笔者根据算法推荐内容和用户阅读内容的重合度计算推荐偏差，通过实验数据分析发现（图 2），随着人机交互的频度深入，算法推荐信息的主题分布不断动态变化，用户阅读信息的主题分布也不断演化，且算法推荐和用户阅读的主题相似度在早期差异较大；在兴趣探索期，算法逐渐适应用户的阅读偏好，差异度显著降低；进入收敛稳定阶段后，随着突变的产生和兴趣的改变，推荐和阅读主题差异度略有回升，进入演化博弈再平衡




图 2 不同群体算法推荐内容及阅读内容偏离度分析

周期。对于不同群体而言，算法推荐的主题收敛速度和突变产生的周期出现差异分化，笔者研究发现，样本中的城市男性和小镇男性的差异度波动幅度十分接近，而城市和小镇女性群体之间的差异度波动幅度则差别明显，其中算法对城市女性的阅读主题推荐准确度最高，对小镇女性的推荐准确度最低，这当中也折射出现实社会中结构性因素所导致的媒介素养差异。

整体而言，算法推荐的偏差度在四类群体中都表现为中期下降、稳定期略有回升的趋势，其中城市女性群体的变化波动幅度最大。这也印证了笔者所假定的算法和用户之间动态演化博弈的过程，用户选择的强化使得算法推荐偏离度逐渐下降，算法推荐逐步适应用户偏好，但兴趣行为的突变及算法的探索性尝试会进一步使得偏离度出现新的波动，在新一轮人机博弈中算法偏见又会出现新的演化趋势。






图3 不同阶段算法推荐偏离度趋势

在算法推荐不同阶段，用户阅读内容兴趣主题也会动态演化。笔者根据用户阅读文章的关键词进行共现网络分析，以城市女性用户为例（图4），发现随着算法推荐主题和用户自身兴趣偏好的演化，样本用户对娱乐、体育、星座运势等议题的阅读占比显著降低，时事类议题的阅读占比明显增加。这一方面受到疫情等时事热点事件的影响，另一方面也和算法推荐导向相关。进一步对不同阶段用户兴趣主题网络密度进行分析，发现在用户使用早期议题网络密度较大，也即用户阅读文章议题类型相对集中；随着使用频次和阅读内容的增加，议题呈现多元化趋势，网络密度变小，在稳定期略有回升。值得注意的是，议题共现网络并不能完全反映茧房程度，多元化议题所对应的内容、价值判断、政治倾向等可能同质化，用户涉猎议题





除了推荐议题层面的选择性偏见,算法在推荐内容的情感倾向上也存在一定偏向。笔者采用自然语言处理技术对文本内容的情感倾向进行识别,认为正面新闻、正能量事件、积极向上、幽默搞笑等信息为正面情感内容,而社会负面新闻、负面舆情事件、悲观仇恨等内容为负面情感内容。实验数据发现(图5),算法推荐内容中正面导向内容约七成,负面内容一般不到三成。面向不同用户群体,算法推荐内容的情感偏向性也存在一定差异,早期对于样本中的女性用户群体,算法推荐负面内容占比相对较高(25.61%),从区域来看推荐给城市样本用户的负面内容(25.53%)占比略高于小镇用户(25.03%)。此外,随着推荐算法的自我学习和迭代,负面内容占比普遍存在先降低后升高的过程,稳定期负面内容占比(25.95%)普遍更甚于早期(25.28%),而小镇男性群体接收的负面推荐内容占比整体上却呈现下降趋势(从24.63%下降到21.98%)。值得注意的是,城市样本用户在各个时期接触的负面信息占比(均值25.24%)均高于小镇用户(均值23.54%)。这一方面受到群体差异化阅读偏好性影响,另一

方面也反映了用户群体进行信息甄别和选择性接触的结构性差异。




图5 不同阶段算法推荐内容情感倾向

就具体议题来看，负面内容主要集中在社会时事、国际事件、娱乐和财经等领域，尤其是疫情背景下社会时事议题负面性明显高于其他议题。而正面内容除了社会正能量，娱乐新闻、体育、文化、旅游、美食等民生相关内容也成为算法推荐主流内容。总体而言，各个用户群体之间正负面内容的议题分布相似，严肃类内容成为负面信息高发地，娱乐类内容则成为正面信息聚合地（表2、表3）。

表2 算法推荐负面内容主题占比

城市男性		城市女性		小镇男性		小镇女性	
主题	占比	主题	占比	主题	占比	主题	占比
社会	30.52%	社会	31.38%	社会	31.90%	社会	28.54%
综合	8.10%	综合	8.48%	国际	8.21%	娱乐	8.41%
国际	8.07%	娱乐	7.96%	综合	8.15%	综合	8.24%
娱乐	7.48%	国际	7.83%	娱乐	7.12%	国际	7.18%
财经	6.49%	财经	6.66%	财经	5.93%	财经	6.30%
时事	4.69%	时事	4.14%	时事	4.87%	时事	4.72%
体育	4.17%	情感	3.70%	体育	4.70%	体育	3.91%
情感	3.36%	体育	3.47%	健康养生	3.35%	情感	3.66%
科技	3.13%	健康养生	3.10%	母婴育儿	3.29%	母婴育儿	3.52%
母婴育儿	3.05%	教育	2.94%	情感	3.25%	教育	3.29%

表 3 算法推荐正面内容主题占比

城市男性		城市女性		小镇男性		小镇女性	
主题	占比	主题	占比	主题	占比	主题	占比
社会	19.87%	社会	20.29%	社会	20.50%	社会	19.78%
娱乐	11.18%	娱乐	11.91%	娱乐	10.22%	娱乐	11.55%
时事	7.16%	时事	7.17%	时事	8.38%	时事	7.42%
综合	6.83%	综合	7.05%	综合	7.04%	综合	7.16%
体育	4.79%	文化	5.25%	体育	5.09%	文化	4.79%
文化	4.79%	财经	4.61%	文化	4.84%	财经	4.72%
财经	4.64%	教育	4.35%	财经	4.66%	旅游	4.37%
旅游	4.35%	体育	4.18%	教育	4.52%	体育	4.34%
教育	4.30%	旅游	3.91%	旅游	4.06%	教育	4.28%
美食	4.03%	美食	3.69%	国际	3.77%	美食	3.89%

（三）信息偏食：茧房的结构性差异

笔者基于用户阅读内容的主题类别分布来判断用户的信息偏食程度，认为用户阅读主题越单一、集中度越高，其信息偏食程度越强，也即信息茧房存在概率越大；相反，用户阅读主题越分散、离散系数越高，其信息偏好越多元，茧房存在概率相应较低。实验数据分析发现，不同用户群体阅读主题均存在从集中到离散再到集中的动态变化过程。在使用早期，用户阅读主题相对集中，存在较为明显的信息偏食；随着算法推荐主题和用户接触信息的多元化，阅读主题分布离散度变高，即在主题偏好层面存在一个“破茧”过程，人机演化博弈过程也成了用户不断探索兴趣边界的过程，这在一定程度上也否定了算法强化茧房的论调；而随着用户使用的深入，算法推荐和用户兴趣偏好逐步趋于稳定，阅读主题分布会进一步趋向集中，也即“茧房”有一定回归趋势，但整体上主题集中度会低于使用早期，即对于多数样本用户而言，算法拓展了其阅读主题偏好，在一定程度上有助于用户接触多元化信息。诚然，笔者所研究的信息茧房仅限于主题类别，并未对信息本身的价值取向进行更深入的挖掘，多元化的主题接触是否会影响受众的价值判断，破除价值茧房仍有待进一步探索。




图6 不同阶段不同群体阅读主题分布离散度

就不同群体的阅读主题分布来看，早期小镇女性群体主题集中度较高，也即信息偏食程度相对最高，城市用户信息偏食程度相对较弱；稳定期小镇女性群体阅读主题趋于多元化，主题偏好离散程度与城市女性用户基本无差（1.39），相比之下小镇男性用户则成为信息偏食相对最重的群体（1.37），而城市男性用户的主题偏好相对多元化（1.40）（图6）。总体而言，从三个不同时期的主题分布离散度变化程度（波动幅度）来看，算法对四五线城市用户群体的影响更大，尤其是在用户信息主题偏好的引导上具备明显效果。相比之下，一二线城市用户兴趣偏好更为稳定，在人机交互博弈过程中主观能动性更强，受算法影响相对较小，这也进一步印证了算法偏见的结构性差异。

（四）权力操纵：政治内嵌与资本干预

算法作为社交媒体时代信息分发的驱动因素之一，也是舆论生态建构和受众心智塑造的关键因子。算法在舆论引导和用户行为培养中的重要作用决定了其政治属性和经济属性，政治和资本因素也成为算法偏见形成的隐性作用力。受限于政治和资本操作的隐蔽性，笔者基于算法推荐内容的显性属性来观察政经要素对信息分发的影响，具体包括中央媒体发布内容占比和广告内容占比。央媒作为政府官方的主要发声窗口，其发布内容的被推荐频次在一定程度上反映了算法的主流价值倾向和政治内嵌程度；而算法推荐的广告内容占比则直接反映了资本对信息分发的介入程度。实验数据发现，早期算法推荐给样本用户内容中，央媒发布内容占比为7%左

右，广告内容占比约9%；随着交互深入，央媒和广告内容占比均出现大幅增加，在算法收敛稳定期，央媒推荐内容占比达到15%左右，包括环球网、中国经济网、新华网、央视网、中国青年网、人民日报等央媒，在实验周期内平均被推荐给每个用户的频次均超过200余次；而广告内容占比更是达到约22%，平均每个用户可接触到10次以上汽车、房产、美食类广告内容。其中小镇女性群体接收央媒内容的比例上升最为明显，城市用户接收广告内容的比例上升相对较大，这在一定程度上反映了主流媒体舆论引导所辐射的重点对象和资本对用户的商业价值考量。总体而言，算法推荐过程中政治和资本的影响作用在逐渐强化，但群体差异并不显著，外部利益因素对信息分发的干预普遍存在，这对相关平台话语空间的公共性和开放性也造成了一定影响（图7、图8）。




图7 算法推荐的中央媒体内容占比




图8 算法推荐的广告内容占比

四 伦理规制：权力与权利的平衡

笔者研究发现，算法偏见是一种复合型、连带性、动态演化式的信息权利消减，既包含社会结构性归因偏差带来的群体性信息歧视，又包含用户个体行为反馈带来的选择性信息过滤，同时也受到政治和资本的控制和干扰。算法偏见直击信息公平性、客观性、真实性、全面性等媒介伦理问题核心。只有对算法权力进行适度约束控制，增强用户在人机演化博弈过程中的主动性和能动性，在保障用户知情权、选择权、纠偏权、被遗忘权的基础上，才能真正让算法的正向价值最大化发挥，在合法、合规、合理的前提下充分激活人工智能发展所带来的信息红利。

（一）推荐算法权力约束

1. 强化算法透明

算法透明主要包括指标因子和指标权重的公开性。指标因子即算法收集了哪些用户信息，生成了哪些数据标签，基于哪些字段属性来进行信息推荐；指标权重则是相关标签因子的重要性排序，也即算法更倾向于依据哪些标准，哪些因素在信息推荐中起到决定性作用。算法设计过程中的指标因子选取和权重设计决定了算法推荐的核心导向和价值目标，选择的指标因子是否含敏感特征、是否对特殊群体带有歧视性质、是否有政治或商业利益考量，包括不同因子的优先级排序是否符合媒介伦理和公共利益，这些都会直接影响算法偏见的生成。此外，增强算法透明还需要公开关联设置的阈值，让用户知道兴趣和关联度达到多大的阈值时才会影响信息推荐，从而让用户对交互行为进行有意识频度限制。^[15] 算法透明性的提升对于增强用户的主观能动性、强化社会舆论监督、降低利益操纵可能性都有很大帮助。但受限于平台间的商业竞争、模型本身的复杂性、技术操纵的风险性等因素，全面公开算法运作逻辑机制并不现实，但对于公众而言知晓算法推荐的重要指标及其优先序列仍属必要。

2. 规避资本操纵

随着算法被大量应用到广告投放和商业经营中，具有技术和资本优势的经营者往往更容易通过算法设置贸易壁垒，实现精准投放，刺激消费转

化。^[16]资本对高价值人群的偏好使得部分弱势群体被排挤在有效信息之外，在就业、招聘等信息分发中的性别和学历歧视也进一步强化了社会结构性偏见，^[17]“大数据杀熟”更是彰显了精准营销背后的社会伦理失范和监管缺失。^[18]降低资本对算法的操纵一方面需要从法律规范层面进行约束，强化对用户合法权益的保障，同时通过集体诉讼制度引入，强化用户维权意识，包括对消费权、信息权、隐私权等多方面权益保护；另一方面也可通过设立专门的审查机构针对算法黑箱操作的正当性、资本介入深度和维度进行审计，包括采用反向工程技术手段进行风险评估。此外，算法和数据的透明性、用户反馈渠道的通畅性、信息筛选机制的可控性都会在一定程度上约束资本的干预。资本的适度介入是提升信息传达效率和精度之必要，但如何平衡资本介入过程中社会效益与经济效益仍需做进一步探讨。

3. 警惕数据霸权

数据作为算法运作的核心资源，数据规模越大、颗粒度越细、价值密度越高，算法运作效能越高、洞察能力越强。在某种意义上，算法权力背后是数据权力在做支撑，而数据权力则又由政治和资本权力做保障。互联网科技的垄断性背后往往伴随着数据霸权，尤其是当不同渠道、不同维度的数据关联到一起后，通过匹配、拼接、推理、消歧等技术手段可以完整勾勒出从个体到群体再到社会的行为逻辑，其所能发挥的数据聚合效应很可能助推算法独裁和数据霸权。这种数据聚合效应带来的上帝视角，不仅会形成对于个体合法权益的风险，对于社会稳定和国家主权也具备一定挑战。随着全球数据的打通和智能算法的迭代，甚至会演化成人工智能对整个人类的霸权。^[19]当然，适当的数据联通和共享是很有必要的，当下数据割裂、数据孤岛现象在政务系统和多个行业领域仍普遍存在，极大地影响了数据智能效益，增加了技术运作成本。但在数据聚合的过程中需警惕部分企业通过灰色手段进行数据关联分析，一方面需要从源头上保障数据来源的合法合规性，另一方面要从应用层面保障关联应用的合情合理性。尤其是相关重点领域需要防范数据帝国的形成和算法独裁的风险，避免对数据和算法的过度依赖，基于使用场景对数据的收集、储存、分析和算法的设计、迭代和应用进行分级管理，在保障公共性和安全性的基础上充分激活算法价值。

4. 推进技术问责

算法偏见潜藏在数据收集、标签抽取、运算逻辑等各个方面，具备较强的隐蔽性和不可控性，随着人机博弈的演化，算法本身也会不断衍生出新的偏见，很难从源头上规避偏见的产生。因此，强化对算法的监督和追责成为必要。包括欧盟《通用数据保护条例》（GDPR）、美国《消费者在线隐私权利法》等在内的法律对数据收集和算法应用都进行了规制，强调数据主体在全过程中的自主性和可控性。国内虽然在《数据安全法》《网络安全法》《电子商务法》等法律规章中对数据获取与应用进行了约束，但并未对算法的透明性和关联应用深度进行强制要求。此外，受限于法律问责的滞后性，从宣传和观念变革层面来看，需将伦理责任内化于算法设计和应用的全流程中，强化媒介伦理观和技术社会责任的重要性，在明确技术伦理责任归属的基础上，通过行业自律和社会监督手段去约束算法权力，多层面推进算法伦理问责的规范性和可行性。^[20]

（二）用户信息权利保障

1. 知情权：突破过滤气泡

知情权（right to know）是公众获取与自身相关的信息的一种民事权利、政治权利，也是涉及信息公正和自由的一项基本人权。^[21]在不涉及保密性和安全性的前提下，公众有权利获取真实、客观、全面的信息，这要求平台和算法在信息筛选和分发机制上保证公正性和中立性。除了政治内嵌和资本操纵等外部因素施压，包括信息偏食、舆论极化、文化内卷化等媒介生态内生性问题也会导致算法偏见，强化过滤气泡和信息倾向性，禁锢公众视野，损害公众知情权。过滤气泡不仅让受众接触信息窄化，同时也压缩了部分内容创作者的话语权，让小众的声音难以大范围传播，更有可能加剧群体间分化和舆论撕裂。要保障公众的知情权和舆论生态的公共性，需要在算法设计环节引入“机会平等”理念，避免因算法指标、权重的区分形成结构性歧视，造成用户群体获取信息的先天性不平等；尤其针对与公众切身利益相关的议题，需要尽可能提供客观真实信息以供公众做出有效行为决策^[22]，在保障知情权的基础上保障公众的议政参政权和自主决策权。

2. 选择权：主体决策优先

信息选择权是指在合法合规的范畴内，用户能够根据个体偏好和既定目的自由选择接触信息的权利，既包括用户对信息类别、倾向、主题等属性的直接选择，也包括从冷启动、协同过滤到交互博弈阶段，用户对算法的反向驯化机制，也即用户通过既定选择行为来优化算法推荐信息。一方面，平台需要给用户提供更多的自主选择功能，包括主题偏好和价值取向等筛选过滤机制，避免偶发性操作带来的算法误判和内生性偏见；另一方面，当用户个体偏好和价值取向与资本导向发生冲突时，算法需尊重个体自主性，以用户选择优先，避免资本对多元价值观和用户自主性的剥夺，保障信息生态的公共性和开放性。

3. 纠偏权：算法设计重构

受设计者价值取向和社会结构性问题影响，算法在设计之初就带有偏见的原罪。相比于千人千面的信息推荐，算法核心逻辑框架、抽取标签、优先级序列一般具备同一性。而这种同质化的规则便成了算法偏见生成的内生因素，只不过受用户个体媒介素养、使用习惯、应用场景等因素影响，偏见的程度和算法的正负外部效应呈现差异分化趋势。要在本质层面避免个体性或群体性信息歧视，需要保障算法设计层面的开放性和多元性。理想情况下，用户可以根据自我需求选择屏蔽或开启算法推荐；基于特定场景选择在多大程度上让算法介入自动化推荐；也可以对算法所考量的标签因子、权重系数、优先序列进行自定义设置，如以保障信息属性的多元性、平衡性为最优目的进行算法调整，或对特定属性内容进行自动屏蔽……让用户介入算法设计、实现算法的千人千面是从根源上进行纠偏的必要路径，但出于操作成本、技术可控性、商业性、安全性等多方面因素考虑，全面放开算法纠偏机制并不现实。应基于使用场景有选择性地开放部分算法参数、让用户部分介入算法修正，在实现算法分权的基础上提升用户的纠偏权、选择权和知情权。

4. 被遗忘权：数据边界控制

被遗忘权（right to be forgotten）是2012年欧盟在个人数据保护立法草案中正式提出的概念，主张在合法合规的前提下，民众有权要求相关机构删除与个人相关的数据信息。^[23]如果说知情权和选择权是关于“信息可见性”的权利，那么被遗忘权则是用户选择“不被看到”的自由。个人数据

是算法运作的底层资源，数据的可获取与否直接决定了算法的可用与否。在不影响公共利益和用户权益的情况下，用户有权删除或隐藏个体历史数据，即拒绝算法的个性化推荐服务。被遗忘权重新界定了用户个体数据的使用边界，让用户在人机博弈中的话语权大幅提升，从数据源头上断绝了算法偏见，但也在一定程度上阻碍了智能技术的发展和运作效率。诚然，被遗忘权的落地应用还需要从多层面进行细化设计，如何把握技术发展、社会福利和个体权益之间的平衡点，仍然需要学界和业界做进一步探讨。

（作者：向安玲，清华大学新闻与传播学院博士研究生；
沈阳，清华大学新闻与传播学院教授、博士生导师）

〔基金项目：国家社会科学基金重大项目“基于机器博弈的网络信息传播安全多准则动态管控策略研究”（项目编号：19ZDA329）〕

注释

- [1] 张力，郑丽云．算法推荐的歧视与偏见 [J]．中国报业，2020（13）：48-49.
- [2] 张超．作为中介的算法：新闻生产中的算法偏见与应对 [J]．中国出版，2018（1）：29-33.
- [3] 黄凯南．演化博弈与演化经济学 [J]．新华文摘，2009（10）：154-158.
- [4] Hajian, S., Bonchi, F., Castillo, C. Algorithmic bias: From discrimination discovery to fairness-aware data mining [C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 2125-2126.
- [5] Edizel, B., Bonchi, F., Hajian, S., et al. FaiRecSys: mitigating algorithmic bias in recommender systems [J]. *International Journal of Data Science and Analytics*, 2020, 9（2）：197-213.
- [6] 冷亚军，陆青，梁昌勇．协同过滤推荐技术综述 [J]．模式识别与人工智能，2014（8）：720-734.
- [7] 〔美〕温德尔·瓦拉赫，科林·艾伦．道德机器：如何让机器人明辨是非 [M]．王小红译．北京：北京大学出版社，2017．
- [8] Garcia, M. Racist in the Machine: The Disturbing Implications of Algorithmic Bias [J]. *World Policy Journal*, 2016, 33（4）：111-117.

- [9] Lambrecht A, Tucker C. Algorithmic bias? an empirical study of apparent gender-based discrimination in the display of stem career ads [J]. *Management Science*, 2019, 65 (7): 2966 – 2981.
- [10] Berelson, B. , Steiner, G. A. *Human Behavior: An Inventory of Scientific Findings* [M]. New York: Harcourt , Brace & World, 1964: 529 – 530.
- [11] 喻国明, 方可人. 算法推荐必然导致“信息茧房”效应吗——兼论算法的媒介本质与技术伦理 [J]. 新闻论坛, 2019 (6): 14 – 18.
- [12] 师文, 陈昌凤. 驯化、人机传播与算法善用: 2019 年智能媒体研究 [J]. 新闻界, 2020 (1): 19 – 24 + 45.
- [13] Wu, E. Y. , Pedersen, E. , Salehi, N. Agent, Gatekeeper, Drug Dealer: How Content Creators Craft Algorithmic Personas [J]. *Proceedings of the ACM on Human-Computer Interaction*, 2019, 3 (CSCW): 1 – 27.
- [14] 黄淼, 黄佩. 算法驯化: 个性化推荐平台的自媒体内容生产网络及其运作 [J]. 新闻大学, 2020 (1): 15 – 28.
- [15] Ciampaglia G L, Nematzadeh A, Menczer F, et al. How algorithmic popularity bias hinders or promotes quality [J]. *Scientific Reports*, 2018, 8 (1): 1 – 7.
- [16] 郭小平, 秦艺轩. 解构智能传播的数据神话: 算法偏见的成因与风险治理路径 [J]. 现代传播, 2019 (9): 19 – 24.
- [17] 刘友华. 算法偏见及其规制路径研究 [J]. 法学杂志, 2019 (6): 55 – 66.
- [18] 胡萌萌. “大数据杀熟”背后精准营销的社会伦理失范问题探析 [J]. 北京经济管理职业学院学报, 2019 (1): 23 – 27 + 46.
- [19] 陈鹏. 算法的权力: 应用与规制 [J]. 浙江社会科学, 2019 (4): 52 – 58.
- [20] 蒋晓丽, 杨珊. 大数据时代媒介技术的伦理问责 [J]. 西南民族大学学报 (人文社科版), 2016 (7): 145 – 149.
- [21] 郭道晖. 知情权与信息公开制度 [J]. 江海学刊, 2003 (1): 127 – 133.
- [22] 林爱珺, 刘运红. 智能新闻信息分发中的算法偏见与伦理规制 [J]. 新闻大学, 2020 (1): 29 – 39.
- [23] 王茜茹, 马海群. 开放数据视域下的国外被遗忘权法律规制发展动向研究 [J]. 图书情报知识, 2015 (5): 121 – 128.